

PSYCHOMÉTRIE

Informations relatives à l'examen

- 40 questions V/F (+1 ; 0 ; -1)
- 5 exercices (+2 ; 0 ; 0)

TABLE DES MATIERES

Introduction	4
Mesure et évaluation	4
Sciences exactes et sciences humaines	4
Test WAIS 4 d'intelligence	4
Signification des échelles.....	5
Modèles de mesure	6
Effets délétères des erreurs de mesure.....	9
Prérequis statistiques	10
1. Les indices de tendance centrale	10
1.1 La moyenne	10
1.2 La médiane.....	10
1.3 Le mode	10
2. Indices de dispersion.....	11
2.1 Amplitude.....	11
2.2 L'écart moyen absolu	11
2.3 L'écart interquartile.....	11
2.4 La variance	11
2.5 L'écart-type	11
2.6 Coefficient de variation	12
3. Les indices d'association entre deux variables	12
3.1 Covariance	12
3.2 Corrélation	12
4. Les niveaux de mesure.....	13
4.1 Les échelles nominales	14
4.2 Les échelles ordinales.....	14
4.3 Les échelles d'intervalles égaux.....	15
4.4 Les échelles de rapport	15
5. Les distributions théoriques	15
5.1 La fonction de densité	16
5.2 La fonction de répartition.....	16
Chapitre 1 : Problématique de la mesure	18
1. Introduction	18
2. Psychométrie vs édumétrie.....	19
3. Ignorer les erreurs de mesure	21

Chapitre 2 : Le processus de la mesure	22
1. Etape 1 : le concept à mesurer	22
2. La collecte des informations	23
3. Transformation des observations en données.....	23
4. L'application du modèle de mesure.....	23
5. Transformations complémentaires éventuelles.....	24
6. Synthétiser les résultats d'une batterie de test	25
Chapitre 3 : La rédaction des items d'un instrument de mesure	27
1. Représentativité du cadre d'évaluation	27
2. Elaboration des items d'une épreuve de performance.....	27
2.1 Le choix du format des questions.....	27
2.2 Modalités de présentation	28
2.3 Rédaction des items.....	29
2.4 Interaction entre les items et les sujets	32
3. Les items dans un questionnaire contextuel	33
3.1 Le format des questions	33
3.2 Mise en forme des items.....	35
Chapitre 4 : L'assemblage du test et le dispositif de collecte de données	38
1. L'assemblage du test.....	38
1.1 Introduction	38
1.2 Développement des Tests Designs incomplets.....	38
1.3 Écueils à éviter.....	41
2. Le dispositif de collecte de données.....	44
Chapitre 5 (<3) : La théorie classique du score vrai	45
1. Définition du score observé	45
2. Définition du score vrai	47
3. Postulats de base de la théorie classique du score vrai	47
Postulat n°1.....	47
Postulat n°2.....	48
.....	48
Postulat n°3.....	48
.....	48
4. Développements autorisés par les postulats : la fidélité	48
Distribution des scores vrais et des scores observés	48
5. Fidélité d'un test et longueur.....	50
6. Opérationnalisation du calcul de la fidélité.....	50
1) Les méthodes test-retest	51
2) Les méthodes de consistance interne.....	51

3) Les méthodes mixtes ou méthodes de formes parallèles	57
4) Variances vraie et variance d'erreur	57
7. L'analyse d'items	57
7.1 L'indice de difficulté	57
7.2 L'indice de discrimination.....	59
7.3 Le fonctionnement différentiel de l'item (DIF)	59
8. Conclusion	60
Chapitre 6 : Les modèles de réponse à l'item	61
1. Introduction	61
2. Le modèle Rasch pour les items dichotomiques	61
2.1 Introduction	61
2.2 Description du modèle de Rasch	61
2.3 Calibration.....	62
2.4 Calcul des scores : méthode de maximum de vraisemblance (MLE)	64
2.5 Calcul des scores des élèves : cas de plans de test incomplet	65
2.6 Conditions optimales pour les items d'ancrage	66
2.7 Erreur de mesure	67
2.8 Une illustration	67
3. Extension du modèle de rasch.....	67
3.1 Modèle de réponse à crédit partiel	67
3.2 Autres modèles utilisant la théorie de réponse à l'item	67
4. Conclusion.....	67
Chapitre 7 : La validité	68
1. Relation entre fidélité et validité	68
2. La validité prédictive.....	69
Les caractéristiques de la mesure critère.....	69
Méthodes pour déterminer la validité prédictive	69
3. La validité de contenu	70
4. La validité théorique	70

INTRODUCTION

MESURE ET ÉVALUATION


Pour **Laurencelle**, la distinction entre mesure et évaluation prend généralement peu d'importance en sciences et dans le monde des laboratoires scientifiques.

Mesure	Évaluation
Mesurer = opération quasi machinale Mesures physiques, purement matérielles, ne laissent pas beaucoup de place à l'interprétation subjective	Évaluer = plus que mesurer. On devrait parler de 'jugement évaluatif' plutôt que d''évaluation', à considérer comme un acte responsable, une décision

SCIENCES EXACTES ET SCIENCES HUMAINES

Sciences exactes	Sciences humaines et psychologiques
mesures conventionnelles à l'aide d'outils et d'unité de mesure, mesures physiques, exactes et quantifiables. Une seule mesure suffit. Laisse peu de champ à l'interprétation subjective	il n'existe pas de mesure conventionnelle ni d'outils de mesure, on parle d'observations multiples, on évalue, « jugement évaluatif », poser un grand nombre de questions, développer des « épreuves » qui vont mobiliser la variable à étudier. Tout cela dépend du chercheur, du sujet, de l'environnement, ... qui font varier le résultat. Laisse plus de place à la subjectivité

TEST WAIS 4 D'INTELLIGENCE



Pour le test de QI, la distribution normale est la résultante de la façon dont le test a été conçu (courbe de Gauss)

⚠ Le **QI** se distribue normalement (moyenne = 100, écart type = 15), mais cela ne veut pas dire que **l'intelligence** se distribue normalement aussi !

Il existe également d'autres types de tests :

- Tests de performance (ex. PISA)
- Inventaire de dépression de Beck (21 items variant de 0 à 3) :
 - o 0-9 (dépression mineure)
 - o 10-18 (légère dépression)
 - o 19-29 (dépression modérée)
 - o 30-63 (sévère dépression)
- Mesure du stress psychologique : perspective normative où on interprète le score en comparaison au score des autres individus, situe l'individu dans la population (aucune signification intrinsèque)

SIGNIFICATION DES ÉCHELLES

Chaque réponse à chaque item correspond à une observation

Avec l'ensemble des réponses aux items, on peut assigner une valeur à chacune des réponses, pour pouvoir ensuite en dégager une somme (total des scores) et une moyenne, ceci dans le but de créer un **continuum**

Exemple :

- Mesure de la taille *de petit* $\longleftrightarrow$ *à grand*

À quelle fréquence vous arrive-t-il ce qui suit ?

(Ne cochez qu'une seule case par ligne.)

		Toujours ou presque toujours	Régulière- ment	Parfois	Jamais ou presque jamais	
ITEMS INVERSES → 5 - x pour items inverses	A1) Dans les magasins, je dois demander de l'aide pour attraper les articles en hauteur. = <i>petit</i>	☐	☐	☒	☐	
	A2) On me demande si je joue au basket. = <i>grand</i>	☐	☒	☐	☐	5 - 2 = 3
	A3) Quand je descends dans une cave, je dois courber le dos pour ne pas me cogner la tête. = <i>grand</i>	☒	☐	☐	☐	5 - 1 = 4
	A4) Je dois raccourcir les pantalons que j'achète. = <i>petit</i>	☐	☐	☐	☒	
	A5) Quand je saute, je parviens à toucher un anneau de panier de basket. = <i>grand</i>	☐	☒	☐	☐	5 - 2 = 3
	A6) Au cinéma, une personne assise devant moi réduit mon champ de vision.	☐	☐	☒	☐	
	A7) J'éprouve des difficultés à m'asseoir sur la banquette arrière d'une voiture.	☐	☒	☐	☐	5 - 2 = 3
	A8) Je dois me mettre sur la pointe des pieds pour embrasser une personne.	☐	☐	☐	☒	
	A9) Lorsque je m'assieds dans un canapé, mes pieds ne touchent pas le sol.	☐	☐	☐	☒	

Pour **interpréter les résultats**, il faut se référer aux paramètres de la population : moyenne, écart-type, percentile, etc.

Le **percentile** est une mesure statistique qui indique la position relative d'un score par rapport à une population de référence. Il exprime le pourcentage de personnes ayant obtenu un score inférieur ou égal à celui de l'individu évalué.

Par exemple : un percentile 75 signifie que 75% de la population a un score inférieur ou égal à celui de la personne évaluée

Il est nécessaire de **vérifier la qualité de la mesure** : certaines propriétés ne sont pas mesurables objectivement, elles peuvent parfois tendre + vers le subjectif

Exemple :

- corrélations entre des estimations de la taille et taille réelle
- corrélations entre des estimations du poids et poids réel

	Taille	Poids
Échelle Likert	0,85	0,48
Oui / Non	0,78	0,38
Total	0,86	0,49
Corrélations	Élevées	Faibles

Effet plancher / plafond = l'outil ne parvient plus à différencier les individus car trop simple / compliqué

Pour **améliorer la qualité de la mesure**, il faut s'assurer que le test mesure bien ce qu'il prétend mesurer = **validité**.

Effet de recouvrement = biais statistique, fausse l'estimation de la cohérence interne d'un test

- Lorsqu'on calcule la corrélation item-score total, le score total inclut forcément l'item
→ surestimation de la corrélation, car l'item contribue mécaniquement au score total
- Plus le nombre d'items est faible, plus cet effet est fort, car chaque item représente une plus grande proportion du score total
- À l'inverse, plus il y a d'items, plus l'effet de recouvrement diminue, car l'influence d'un seul item sur l'ensemble du score total devient négligeable
- Solution : Spearman-Brown

Stabilité test-retest : degré de corrélation entre les scores obtenus par un même groupe de participants lors de deux passations du même test à des moments distincts

Indice de consistance interne = fidélité

L'indice de consistance interne évalue à quel point les items d'un test sont cohérents entre eux
Importance de l'unidimensionnalité d'un test : le test mesure bien une seule et même caractéristique

Par exemple : *L'alpha de Cronbach* (varie entre 0 et 1)

Attention aux compromis entre fidélité et validité

Améliorer la consistance interne implique parfois de supprimer des items hétérogènes. mais, retirer trop d'items risque de compromettre **la validité** du test !

MODÈLES DE MESURE

- La théorie classique du score vrai (CTT)
- Les modèles de réponse à l'item (IRT)
- L'analyse factorielle confirmatoire
- La généralisabilité

La théorie classique du score vrai

Repose sur l'idée que le score observé d'un individu (score total) est composé de :

$$\text{Score observé} = \text{score vrai} + \text{erreur de mesure}$$

Principes



- **Score total** = indicateur principal
- **Analyse de la fidélité et de la validité** d'un test psychométrique
- **Analyse des items**
 - Difficulté d'un item : représentée par le % de réussite à cet item
 - Corrélation item-total : mesure si un item est bien relié au score total
 - Fonctionnement différentiel des items (DIF) : s'assurer que les items ne favorisent pas un groupe en particulier indépendamment des compétences $\Rightarrow$ pour un score total donné, le % devrait être identique pour les deux sous-populations

Limites

- **Gestion des données manquantes** : si un individu ne répond pas à certaines questions, son score n'est pas directement comparable aux autres
- **Comparabilité des scores entre tests différents** : si deux versions d'un test ont des niveaux de difficulté différents, les scores ne peuvent pas être directement comparés
- **Problème de l'échelle ordinale** : un score de 4/5 ne signifie pas que la personne est 2x plus compétente qu'une autre ayant obtenu 2/5 – il manque une unité de mesure objective
- **Difficulté des items non pris en compte dans le score total** : Tous les items sont comptabilisés de la même manière, alors qu'un individu ayant répondu correctement à des questions très difficiles devrait être distingué de quelqu'un ayant réussi uniquement les plus faciles

Les modèles de réponse à l'item

Permet d'estimer la probabilité qu'un individu réussisse un item en fonction de sa compétence et de la difficulté de l'item



Composants :

- Axe des abscisses (-5 à +5) : compétence des sujets / difficulté de l'item
- Axe des ordonnées (0 à 1) : probabilité de réussite à un item

Variable latente : variable inobservable (construct) qui influence la performance des individus sur les items d'un test

La compétence peut être considérée comme une variable latente, influençant les réponses aux items


Analyse des items

Difficulté d'un item ; corrélation item-total ; fonctionnement différentiel des items (DIF)

Fonction logistique : permet d'étudier sous forme de probabilité le lien entre la compétence des sujets et la difficulté des items

- θ (thêta) = compétence de l'individu
- δ (delta) = difficulté de l'item

- Modèles de mesure réflexifs : mesure de l'intelligence, de la compétence en mathématique, du racisme, du stress
- Modèles de mesure formatifs : indice des prix à la consommation



Avantages

- Difficulté des questions et performance des sujets sur un même continuum
- Possibilité de calculer la probabilité de réussite d'un sujet à un item en fonction de sa performance et de la difficulté des questions
- Prise en compte de la difficulté des questions pour le calcul du score des sujets
- Possibilité de ramener sur une seule et même échelle la performance de deux individus ayant passé des scores partiellement différents

Analyse factorielle confirmatoire

Permet de vérifier si un modèle théorique de structure factorielle est cohérent avec les données observées ; tester un modèle préétabli et vérifier s'il correspond aux données

⇒ Situer l'individu sur une variable latente (construct, inobservable)

Indices d'ajustement : quantifient l'adéquation de données à un modèle théorique

Résidus : différence entre ce que l'on a prédit et ce que l'on observe

Modèle unidimensionnel	Modèle multidimensionnel	Modèle de second ordre	Modèle bifactoriel
Un seul facteur latent (facteur g), une seule dimension qui sous-tend toutes les variables	Plusieurs facteurs latents distincts <u>corrélés</u> entre eux ; chaque variable est liée à un seul facteurs, mais les facteurs partagent des liens entre eux	Facteurs de premier ordre (variables latentes spécifiques) qui influencent directement les variables observées ; ces facteurs sont eux-mêmes influencés par un facteur de second ordre (facteur g)	Un facteur général qui influence toutes les variables observées ; plusieurs facteurs spécifiques qui influencent certaines variables de manière indépendante
Indimensional model Correlated factors model Higher-order model Bifactor model			

EFFETS DÉLÉTÈRES DES ERREURS DE MESURE

Les erreurs de mesure ont un impact sur les estimations des paramètres de population

Ex. plus les erreurs de mesure sont importantes, plus les relations (corrélations) entre les phénomènes mesurés seront sous-estimés

PRÉREQUIS STATISTIQUES

1. LES INDICES DE TENDANCE CENTRALE

1.1 LA MOYENNE

Ou « *moyenne arithmétique* » = somme des valeurs observée / nombre d'observations

$$\mu_X = \frac{1}{n} \sum_{i=1}^n x_i$$

La moyenne est symbolisée par...

m $\bar{x}$	moyenne des valeurs de l'échantillon observé
μ_X	moyenne de la population
$\hat{\mu}_X$	estimation de la moyenne de la population à pd échantillon

Moyenne = centre de gravité

→ La somme des différences par rapport à la moyenne est toujours égale à 0

Propriétés de la moyenne

1. La moyenne d'une somme est égale à la somme des moyennes

Si x et y sont deux variables, alors $\mu_{(X+Y)} = \mu_X + \mu_Y$

2. La moyenne d'une variables multipliée par une constante est égale à la moyenne de cette variable multipliée par cette constante

Si x est une variable et a est une constante, alors $\mu_{(a.X)} = a.\mu_X$

1.2 LA MÉDIANE

La moitié des observations lui sont inférieures (ou égales), l'autre moitié supérieures (ou égales)

Si n est un nombre impair	Si n est un nombre pair
$\tilde{x} = x_{(n+1)/2}$	$\tilde{x} = \frac{x_{\left[\frac{n}{2}\right]} + x_{\left[\frac{n}{2}+1\right]}}{2}$

1.3 LE MODE

⇒ valeur la plus souvent observée

Dans une variable discontinue (nombre de valeurs possibles limité)	Dans une variable continue (infinité de valeurs possibles)
« mode » Valeur qui apparait le plus souvent	« classe modale » Regroupe les valeurs en classes (intervalles) → la classe la plus fréquente *le choix des intervalles influence la classe modale

2. INDICES DE DISPERSION

2.1 AMPLITUDE

Distance qui sépare la valeur maximale de la valeur minimale dans une distribution

NB. Rarement utilisée car non pertinente (la valeur minimale de l'échantillon sera soit égale soit supérieure à celle de la population, et la valeur maximale de l'échantillon sera soit égale soit inférieure à celle de la population → estimation des valeurs de la population sont biaisées)


2.2 L'ÉCART MOYEN ABSOLU

Moyenne des valeurs absolues des écarts par rapport à la moyenne

$$e_m = \frac{1}{n} \sum_{i=1}^n |x_i - \mu_x|$$

2.3 L'ÉCART INTERQUARTILE

Distance qui sépare le 1^{er} quartile (percentile 25) du 3^{ème} quartile (percentile 75)



2.4 LA VARIANCE

Moyenne arithmétique des carrés des différences à la moyenne

$$\sigma_x^2 = \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - m_x)^2$$

Quelques propriétés importantes de la variance

1. Si X est une variable et a une constante, alors $\sigma_{(X+a)}^2 = \sigma_{(X)}^2$
2. Si X est une variable et a une constante non nulle, alors $\sigma_{(aX)}^2 = a^2 \sigma_{(X)}^2$
3. Si X et Y sont deux variables, alors $\sigma_{(X+Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 + 2 \text{cov}(X, Y)$
4. Si X et Y sont deux variables, alors $\sigma_{(X-Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 - 2 \text{cov}(X, Y)$

2.5 L'ÉCART-TYPE

Racine carrée de la variance

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - m_x)^2}$$

Varie de 0 à $+\infty$

Si l'ensemble des valeurs sont toutes égales (égale à une constante), alors la moyenne sera égale à cette constante et l'écart-type sera égal à 0

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - m_x)^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (m_x - m_x)^2} = \sqrt{\frac{0}{n}} = 0$$

La valeur maximale d'un écart-type est toujours égale ou inférieure à la moitié de l'amplitude de la distribution. Elle sera égale à la moitié de l'amplitude si la moitié des sujets obtiennent la valeur maximale et l'autre moitié, la valeur minimale

Les deux premières propriétés de la variance peuvent se décliner pour l'écart-type

1. Si X est une variable et a une constante, alors $\sigma_{(X+a)} = \sigma_{(X)}$
2. Si X est une variable et a une constante non nulle, alors $\sigma_{(aX)} = |a|\sigma_{(X)}$

2.6 COEFFICIENT DE VARIATION

Variabilité pondérale : indice relatif de dispersion, permet de comparer la variabilité de deux distributions, même si elles sont exprimées sur des échelles différentes

S'obtient en divisant l'écart-type par la moyenne

$$cv = \frac{\sigma}{\bar{x}}$$

3. LES INDICES D'ASSOCIATION ENTRE DEUX VARIABLES

3.1 COVARIANCE

Moyenne du produit des écart à la moyenne

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - m_X)(y_i - m_Y)$$

La covariance varie de $-\infty$ à $+\infty$

- Une covariance égale à 0 traduit l'absence de lien entre les deux variables
- Une covariance positive indique que lorsque le phénomène X augmente, le phénomène Y augmente
- Une covariance négative indique que lorsque le phénomène X augmente, le phénomène Y diminue, et inversement

Première propriété importante :

$$\text{cov}(aX, Y) = a \cdot \text{cov}(X, Y)$$

(!) La covariance dépend directement de l'échelle utilisée

→ Pour remédier à cela et faciliter l'interprétation, on recourt plus souvent à la corrélation

3.2 CORRÉLATION

'Covariance standardisée'

Covariance divisée par le produit des écarts-types

$$\rho_{(X,Y)} = \text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_{(X)}\sigma_{(Y)}} = \frac{\text{cov}(X, Y)}{\sqrt{\sigma_{(X)}^2 \sigma_{(Y)}^2}}$$

La corrélation varie de -1 à +1

- Une corrélation égale à 0 signifie l'absence de lien entre les variables X et Y ; en connaissant X (ou Y), on ne peut rien dire à propos de Y (ou X)
- Une corrélation de +1 signifie un lien parfait et positif entre la variable X et la variable Y ; en connaissant X (ou Y), on peut prédire sans risque d'erreur la valeur de Y (ou X)
- Une corrélation de -1 signifie un lien parfait et négatif entre la variable X et la variable Y ; en connaissant X (ou Y), on peut prédire sans risque d'erreur la valeur de Y (ou X)

Si en calculant la covariance, on standardise les variables X et Y (càd de diviser chaque valeur par son écart-type respectif), alors la covariance sera égale à la corrélation

Lorsque la corrélation entre deux variables est égale à 0

- la variance de la somme ou de la différence est simplement la somme des variances des deux variables

$$\sigma^2_{(X+Y)} = \sigma^2_X + \sigma^2_Y = \sigma^2_{(X-Y)}$$

- la covariance entre ces deux variables est égale à 0

$$\sigma^2_{(X-Y)} = \sigma^2_{(X)} + \sigma^2_{(Y)}$$

4. LES NIVEAUX DE MESURE

Ces indices ne peuvent pas s'appliquer sur tous les types de variables

Guilford définit 9 axiomes qui permettent de définir le niveau de la mesure :

Axiomes d'identité	1. Les éléments sont identiques ou différents Soit $a = b$; soit $a \neq b$
	2. La relation d'identité est symétrique Si $a = b$; alors $b = a$
	3. La relation d'identité est transitive Si $a = b$; et $b = c$; alors $a = c$
Axiomes d'ordre	4. La relation d'ordre est asymétrique Si $a > b$; alors b n'est pas plus grand que a
	5. La relation d'ordre est transitive Si $a > b$; et $b > c$; alors $a > c$
Axiomes d'additivité	6. Les éléments peuvent s'additionner (l'addition d'un 0 laisse l'élément invariant) Si $a = p$; et $b > 0$; alors $a + b > p$
	7. L'addition est commutative $a + b = b + a$
	8. Des éléments identiques peuvent être substitués l'un à l'autre dans l'addition Si $a = p$ et $b = q$; alors $a + b = p + q$
	9. L'addition est associative $(a + b) + c = a + (b + c)$

4.1 LES ÉCHELLES NOMINALES

Représentent le niveau le plus bas de mesure

Utilisent des **numéros comme étiquettes** pour distinguer des classes, des catégories

- ➔ Deux individus dans la même catégorie sont considérés identiques pour la caractéristique mesurée (et inversement)
- ➔ Principe d'exclusivité : un individu appartient à une seule catégorie

Seuls les **3 axiomes d'identité** sont d'application

Exemples : typologies psychologiques de la personnalité, professions, sexe, statut matrimonial

Les traitements statistiques que l'on peut effectuer sur ce type d'échelles sont :

1. Avec une seule échelle nominale :
 - a. La fréquence absolue
 - b. La fréquence relative
 - c. La classe modale
2. Avec deux échelles nominales (c'est-à-dire que les mêmes individus ont été classés selon deux critères distincts) :
 - a. Le test d'indépendance
 - b. Le coefficient d'association (coefficient Phi, coefficient Phi de Cramer, rapports des chances)
 - c. L'analyse des correspondances

Condition d'invariance : On peut transformer les valeurs des **échelles nominales** avec une fonction $X'=f(x)$ **tant que** les distinctions entre catégories sont conservées ($x \neq y$ et donc $f(x) \neq f(y)$) ; seules les transformations qui ne modifient pas la distinction des catégories OK

*Exemple : $f(x)=x^2$ transforme **1 (garçon)** → **1** et **2 (fille)** → **4**, tout en maintenant la distinction*

4.2 LES ÉCHELLES ORDINALES

Consistent à classer des sujets dans des **catégories ordonnées** selon un critère déterminé

Les **3 axiomes d'identité** ainsi que les **2 axiomes d'ordre** sont d'application

Exemples : le prestige social, les classes d'âges, les niveaux scolaires

En + des traitement statistiques qu'on peut appliquer aux échelles nominales, on peut calculer :

1. Avec une seule échelle ordinale :
 - a. La fréquence cumulée, absolue ou relative (nombre d'individus ou % d'individus plus petits ou égaux à une catégorie donnée)
 - b. La médiane, les quartiles, déciles, centiles...
2. Avec deux échelles ordinales:
 - a. Le coefficient de corrélation de rangs

Conditions d'invariance : se limitent aux transformations qui laissent l'ordre invariant

$X'=f(x)$ pour autant que si $x > y$, alors $f(x) > f(y)$

Exemple : $f(x)=x^2$ peut s'appliquer puisque $1 < 2$ et $1 < 4$

4.3 LES ÉCHELLES D'INTERVALLES ÉGAUX

Ajoutent à la relation d'ordre la signification des distances

La **distance qui sépare les catégories 1 et 2** est **égale** à celle qui sépare les catégories 2 et 3

Elles se caractérisent par un **zéro arbitraire** (point de départ)

On peut additionner les intervalles, mais on ne peut pas réellement parler de propriétés d'additivité au sens absolu (la somme de quantité sur l'échelle n'a pas beaucoup de sens)

Les **9 axiomes** de Guilford sont d'application

Exemples : échelle des températures (Celsius et Fahrenheit), altitude, calendrier

En + des traitement statistiques qu'on peut appliquer aux échelles ordinales, on peut calculer :

1. Avec une seule échelle d'intervalles égaux :
 - a. La moyenne
 - b. Les indices de dispersion (variance, écart-type, amplitude, etc)
 - c. La classe modale
2. Avec deux échelles d'intervalles égaux :
 - a. Le coefficient de covariance ou tout autre paramètre dérivé, la corrélation, le coefficient de régression

Conditions d'invariance : limitent les transformations aux fonctions linéaires du type $X' = ax + b$ avec $a > 0$.

4.4 LES ÉCHELLES DE RAPPORT

Ajoutent aux échelles d'intervalles égaux un **zéro absolu**, où le zéro représente l'absence de propriété mesurée par l'échelle

Postulat : si $\frac{a}{p} = \frac{b}{q}$; alors $a \cdot q = b \cdot p$

→ On peut donc établir des rapports

Exemples : la plupart des échelles physiques (longueur, temps, masse, etc) + mesures de dénombrement (comptage)

En + des traitement statistiques qu'on peut appliquer aux échelles ordinales, on peut calculer
le calcul du coefficient de variation


Conditions d'invariance : limitent les transformations aux fonctions linéaires du type $X' = ax$ avec $a > 0$

5. LES DISTRIBUTIONS THÉORIQUES

La distribution normale est la distribution théorique la plus utilisée en statistiques ; elle varie de $-\infty$ à $+\infty$

Elle possède deux asymptotes (droite et gauche) ; entre ces deux asymptotes, toutes les valeurs peuvent être rencontrées

'Variable continue'



La distribution normale est parfaitement symétrique = le pourcentage d'individus en dessous de -1 est égal au pourcentage d'individus au-dessus de 1.

La plupart des phénomènes ne peuvent pas réellement se distribuer de $-\infty$ à $+\infty$; mais une distribution observée peut s'apparenter à une distribution normale

⇒ Le test de **Kolmogorov-Smirnov** permet de tester l'adéquation d'une distribution observée à la distribution théorique normale

L'importance de la distribution normale en stats est applicable à deux raisons :

1. Un certain nombre de phénomènes ont tendance à se distribuer normalement
2. Le théorème de **Laplace-Liapounov** (théorème de limite centrale) démontre que 'toute somme de variables aléatoires indépendantes (même de distributions différentes) est une variable asymptotiquement normale (distribution normale)
 - a. « asymptotiquement » : tend vers (la normalité) lorsque le nombre (de variables) devient de plus en plus grand
 - b. « indépendantes » l'espérance mathématique de la corrélation entre deux variables est égale à 0

Ce théorème de *limite centrale* est intéressant en psychométrie...

Toute mesure est entachée d'un certain nombre d'erreurs. Si l'on suppose que ces différentes erreurs sont indépendantes, on peut affirmer que l'erreur de mesure se distribue normalement.

La distribution normale (et toute autre distribution théorique) peut être décrite par 2 fonctions :

5.1 LA FONCTION DE DENSITÉ

En présence d'une variable discontinue, on peut calculer la probabilité d'apparition d'une des valeurs possibles (ex. probabilité d'obtenir 1 à un lancer de dé)

Cependant, en présence d'une **variable continue**, on ne parle plus de probabilité mais de **densité de probabilité**.

La fonction de densité décrit mathématiquement la valeur attendue de cette densité de probabilité en fonction de la valeur de la mesure

$$f(x) = \phi(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

5.2 LA FONCTION DE RÉPARTITION

Elle permet de calculer le pourcentage d'individus qui se situent en dessous d'une borne, ou entre deux bornes. Ce pourcentage dépend des paramètres qui caractérisent la distribution normale (la moyenne et l'écart-type)

Il existe une infinité de moyennes et d'écart-type → nécessaire de réaliser un passage d'une distribution normale quelconque à une **distribution normale réduite (moyenne = 0 ; écart-type = 1)**, en appliquant la transformation linéaire à l'ensemble des valeurs de la distribution :

$$z_i = \frac{(x_i - m_x)}{\sigma}$$


Parmi les autres distributions théoriques...

- Distribution X^2 , qui se définit par son degré de liberté
- Distribution Fisher Snédecor, qui se définit par 2 degrés de liberté
- Distribution t de Student, qui se définit par un degré de liberté
- Distribution uniforme, qui se définit par une borne inférieure et une borne supérieure
- Distribution binomiale

Table de répartition pour une distribution normale réduite

Figure 8.9. Fonction de répartition de la distribution normale réduite

Fournit la probabilité $P(X \leq x)$
pour $X \sim N(0,1)$



x	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0,0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0,1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0,2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0,3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0,4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0,5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0,6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0,7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0,8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0,9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1,0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1,1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1,2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1,3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1,4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1,5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1,6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1,7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1,8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1,9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2,0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2,1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2,2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2,3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2,4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2,5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2,6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2,7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2,8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2,9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3,0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3,1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3,2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3,3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3,4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

CHAPITRE 1 : PROBLÉMATIQUE DE LA MESURE

1. INTRODUCTION

Selon **Dickes** : ‘La psychométrie concerne l’ensemble des théories et des méthodes de la mesure en psychologie. Elle trouve son application chaque fois que le psychologue attribue des nombres à ses objets d’étude.’

Au sein des sciences exactes, **7 grandeurs fondamentales** :

<i>Grandeurs fondamentales</i>	<i>Unité</i>	<i>Symbole</i>
Longueur	Mètre	m
Masse	Kilogramme	kg
Temps	Seconde	s
Courant électrique	Ampère	A
Température thermodynamique	Kelvin	K
Quantité de matière	Mole	mol
Intensité lumineuse	Candela	cd

Il existe, au départ de ces grandeurs fondamentales, des **grandeurs dérivées** :

- L’aire et le volume sont des grandeurs dérivées de la longueur, $[L].[L]$ et $[L].[L].[L]$
- La vitesse exprime une longueur parcourue en un laps de temps déterminé, $[L].[T]^{-1}$ et l’accélération, un taux de variation de vitesse, $[L].[T]^{-1}].[T]^{-1}$
- Une force (exprimée en Newton) est définie comme une masse multipliée par une accélération, $[M].[V].[T]^{-1}$

La mesure physique, avec un instrument de mesure adéquat, peut atteindre un très haut niveau de précision, et donc laisser peu de place à l’erreur de mesure. Cependant, en sciences humaines, il n’existe pas d’unités de mesure conventionnelles comme en sciences physiques.

Différents éléments engendrent des difficultés pour atteindre une grande qualité de mesure :

1. Complexité du concept

Les concepts d’intelligence, de stress, de compétence (constructs) recouvrent une réalité bien plus complexe que celle des mesures physiques (le poids, la taille, etc)

+ Absence de consensus entre scientifique : d’un auteur à l’autre, les définitions peuvent varier dans des proportions non négligeables

2. Variabilité du sujet

La performance d’un individu est susceptible de varier selon fatigue / alcoolémie, etc

3. Interaction entre le sujet et l’instrument de mesure

- **Effet de testing** : impact de la mesure avant expé sur mesure après expé – familiarité avec le contenu du test et/ou avec les modalités de questionnement
- **Formulation de la question** : QO / QCM / échelle de Likert / forme affirmative ou négative

4. Interaction entre le sujet et le contexte

- Administrateur de l’épreuve, ...

Il convient également de distinguer la **psychométrie** et l'**analyse de données** (statistique)

Psychométrie	Analyse de données
Étude des relations qui existent entre variables manifestes (observables) et variables latentes (constructs)	Étude des relations qui existent entre variables dépendantes (critères) et variables indépendantes (variables explicatives)

2. PSYCHOMÉTRIE VS ÉDUMÉTRIE

Selon **V. de Lansheere**, *‘Édumétrie, mot créé par Carver, sur le modèle de psychométrie, pour désigner l’étude quantitative des variables relatives aux apprentissages suscités par l’éducation : influence d’une action pédagogique, performance effective par rapport à une performance attendue, épreuves centrées sur les objectifs...’*

Carver argumente cette distinction entre la mesure des différences individuelles et la mesure des résultats de l’apprentissage

Dimension psychométrique	Dimension édumétrique
Un test peut être évalué en fonction de ses qualités psychométriques, càd la mesure dans laquelle il reflète correctement des différences inter-individuelles	Un test peut être évalué en fonction de ses qualités édumétriques, càd la mesure dans laquelle il reflète des différences intra-individuelles liées aux développements des individus eux-mêmes
Intérêt premier du psychologue	Intérêt premier des tests dans le domaine de l’éducation

Suite à la publication de Carver distinguant psychométrie et édumétrie, plusieurs réactions ont émergé dans la communauté scientifique, dont certaines critiques :

- **E. Witt** estime que la psychométrie couvre déjà la mesure de tout attribut psychologique ou comportemental, y compris en milieu éducatif (représente un sous-domaine, sauf si elle mesure aussi des éléments non psychologiques liés à l’éducation)
- **S.K. Rock** rejette l’idée même d’édumétrie = distinction inutile ; créer une nouvelle terminologie ne fait que générer de la confusion sans valeur ajoutée
- **P.R. Swank** critique en comparant cela à distinguer des statistiques « éducatives » ou « biologiques » : les outils restent les mêmes, quel que soit le domaine d’application

Carver distingue également les **tests normatifs** (inter-individuels) des **tests critériés** (intra-individuels), et justifie que ces deux types de tests ne diffèrent pas uniquement par les finalités poursuivies, mais également par rapport aux théories et modèles auxquels ils recourent

- Une question réussie à 0% ou à 100% n’apportera aucune information inter-individuelle, donc aucune utilité dans un test normatif ; par contre, importance dans un test critérié
- Les résultats d’un test normatif ne présentent aucune signification seuls, ils n’ont de valeur que par rapport à la distribution des résultats de la pop° ; par contre, les résultats d’un test critérié informent de la distance qui le sépare de la maîtrise de ses objectifs

Les arguments de Carver sont jugés **trop limités**

1. La psychométrie ne se réduit pas aux tests : elle peut exister sans eux et concerne tous types de mesures
2. Il est inapproprié de circonscrire l'étude des différences inter-individuelles aux sciences psychologiques et les différences intra-individuelles aux sciences de l'éducation. Tous deux recourent aux tests normatifs, et s'intéressent à des phénomènes similaires comme l'apprentissage

Il semble donc **+ approprié** de distinguer les théories et les méthodes de la mesure en fonction des finalités poursuivies (en non pas selon le champ disciplinaire // Carver)

Deux dimensions déterminent les problèmes de mesure auxquels le chercheur sera confronté :

1. Mesure-t-on un individu ou une population ?
2. Mesure-t-on une caractéristique ou une évolution (mesures prétest et posttest) ?

	<i>Une seule mesure</i>	<i>Plusieurs mesures</i>	<i>Finalités de la mesure et nature des erreurs</i>
<i>Individu</i>	• Examen d'entrée, test pronostic • Certification • Test diagnostic	• Mesure d'un apprentissage • Effet d'un traitement thérapeutique	Minimiser l'erreur de mesure au niveau individuel
<i>Population</i>	• Anciennes enquêtes de l'IEA pour l'évaluation de la performance de populations scolaires • Etalonnage d'un test d'intelligence	• Nouvelles enquêtes de l'IEA ou de l'OCDE.	Minimiser l'erreur de mesure au niveau de la population <i>Erreur d'échantillonnage : dans quelle mesure le changement observé est-il imputable à l'échantillon sélectionné ?</i>
		<i>Erreur d'ancrage : dans quelle mesure le changement observé est-il imputable aux items communs sélectionnés ?</i>	

Trois types d'erreurs sont identifiés :

- **Erreur d'échantillonnage** : variabilité de l'estimation du paramètre de population d'un échantillon à l'autre
- **Erreur de mesure** : variabilité de la performance d'un individu en fonction du test, des questions qui le composent ; plus une épreuve contient de questions, plus elle sera précise et plus l'erreur de mesure sera faible
- **Erreur d'ancrage** : variabilité du changement due à la sélection des items communs = cas particulier de l'erreur de mesure

3. IGNORER LES ERREURS DE MESURE

Les erreurs de mesure n'affectent pas seulement la qualité de la mesure, mais aussi certaines estimations des paramètres de population.

3 caractéristiques fondamentales des erreurs de mesure

1. Se distribuent normalement
2. Ont une moyenne égale à 0
3. Sont indépendantes de toute autre mesure

→ L'erreur de mesure n'affecte pas l'estimation de la moyenne

$$\mu_{(Y+E)} = \mu_{(Y)} + \mu_{(E)}$$

→ L'erreur de mesure affecte la variance, et par conséquent l'écart-type

$$\sigma_{(Y+E)}^2 = \sigma_{(Y)}^2 + \sigma_{(E)}^2 + 2\text{cov}(Y, E)^4$$

Comme les erreurs de mesure sont indépendantes des autres mesures, la covariance est = 0
Plus l'erreur de mesure est grande, plus la surestimation de la variance sera importante

→ L'erreur de mesure engendre une sous-estimation de la corrélation (d'autant plus importante que l'erreur de mesure est grande)

$$\rho_{(X,Y)} = \text{corr}(Y + E, X) = \frac{\text{cov}(Y, X) + \text{cov}(E, X)}{\sigma_{(Y+E)} \sigma_{(X)}} = \frac{\text{cov}(Y, X)}{\sqrt{\sigma_{(Y+E)}^2 \sigma_{(X)}^2}} = \frac{\text{cov}(Y, X)}{\sqrt{(\sigma_{(Y)}^2 + \sigma_{(E)}^2) \sigma_{(X)}^2}}$$

Avec $\text{cov}(E, X) = 0$

Plus l'erreur de mesure est grande, plus le dénominateur augmente, plus la corrélation sera sous-estimée


→ L'erreur de mesure affecte les analyses de régression

L'erreur de mesure au niveau de la variable dépendante n'affecte pas le coefficient de régression

$$\beta = \frac{\text{cov}(Y, X)}{\sigma_X^2} \quad \beta = \frac{\text{cov}(Y + E, X)}{\sigma_{(X)}^2} = \frac{\text{cov}(Y, X) + \text{cov}(E, X)}{\sigma_{(X)}^2} = \frac{\text{cov}(Y, X)}{\sigma_{(X)}^2}$$

→ L'erreur type sur le coefficient de régression est surestimée et par conséquent, la valeur du T test est sous-estimée

CHAPITRE 2 : LE PROCESSUS DE LA MESURE



1. ETAPE 1 : LE CONCEPT À MESURER

En sciences de l'éducation tout comme en sciences psychologiques, il est important de définir et de circonscrire le concept à mesurer. Cette description théorique conditionne la construction de l'instrument de mesure, ainsi que les résultats de la mesure.

Depuis la fin des années 90, il existe deux grands organismes internationaux qui évaluent les performances des populations scolaires dans les disciplines fondamentales : l'OCDE et l'IEA

Exemple dans le domaine de la culture scientifique

OCDE

Identifie 3 facteurs majeurs susceptibles d'influencer la difficulté des tâches

- Les processus / savoir-faire scientifiques
- Les concepts scientifiques
- Les contextes

Définition plutôt basée sur une organisation thématique des contenus

IEA

Identifie 2 dimensions

- Les contenus
- Les domaines cognitifs

Définition basée sur une décomposition classique des sciences // organisation des contenus scolaires

⇒ **Ces deux définitions concrétisent les limites de l'évaluation**, elles garantissent une certaine diversité dans les tâches soumises aux élèves. En effet, l'épreuve construite devra porter sur les différents contenus et solliciter divers processus cognitifs.

Cependant, la **définition d'un cadre de référence** dans le cadre des enquêtes internationales en sciences de l'éducation ne se limite pas à la mesure de compétences scolaires → influence du contexte

TIMMS Assessment Framework : structure l'évaluation en indiquant quoi mesurer (contenu), comment (cognitivement), et dans quel contexte (facteurs environnementaux)

Depuis la 2^{de} étude internationale de l'IEA, il est d'usage de structurer les infos contextuelles selon 2 catégories : le composant et le niveau concerné →

À ces différents niveaux correspondent différents outils de mesure

Tableau 2.1. Cadre d'évaluation des informations contextuelles pour les études de l'IEA.⁶

	Antécédents	Contextes	Curricula
Système éducatif	Caractéristiques du pays (structure fédérale, scission ou non entre l'état et l'église)	Structure des systèmes éducatifs (filières, redoublement...)	Curriculum officiel
Ecole	Caractéristiques du milieu (rural/urbain) de l'école (taille,...), du type d'école (public, privée)	Politiques d'admission, d'évaluation des élèves, y compris le redoublement, d'activités extra-scolaires, gestion de l'hétérogénéité...	Curriculum implanté
Classe	Caractéristiques des maîtres (sexe, formations initiale et continue...)	Processus d'enseignement	
Elève	Caractéristiques familiales (origine sociale, culturelle) de l'élève, sexe, âge, aspirations professionnelles	Comportement scolaire de l'élève (motivation, travail en classe et à domicile...)	Curriculum atteint

Le cadre de référence peut aussi concerner des comportements verbaux, non verbaux, etc.

Exemple : étude de Landsheere et Bayer « Comment les maîtres enseignent » avec pour cadre de référence l'unité comportementale verbale en fonction de sa direction et de son rôle.

Nombreuses théories pédagogiques ont influencé la classification.

2. LA COLLECTE DES INFORMATIONS

Une mesure passe impérativement par des observations. Ces observations peuvent prendre la forme de réponses à un test de connaissances, de réponses à un questionnaire d'opinion, de l'émission d'un comportement verbal donné, d'un comportement non-verbal, etc.

Ces observations sont réalisées selon un **dispositif de collecte de données**. Différents dispositifs doivent être envisagés et leur influence sur la qualité des données doit être réfléchi → utilisation du dispositif susceptible d'engendrer le plus petit nombre de biais.

L'observation fait intervenir deux ensembles différents

- Les sujets = individus qui font l'objet d'une mesure
- Les items = réponses des sujets

Dickes : « *la collecte des observations consiste à rassembler l'information (en provenance des sujets) relative à des items (en rapport avec l'objet à mesurer), mettant éventuellement en œuvre une technique de collecte bien définie* »

En sciences physiques : instruments de mesure conventionnels – une observation suffisante

En sciences humaines : recourt à des observations multiples, grand nombre d'items pour permettre à l'expérimentateur de se forger une idée à propos du concept mesuré.

3. TRANSFORMATION DES OBSERVATIONS EN DONNÉES

Les observations collectées doivent être transformées en données pour qu'un modèle d'analyse (modèle de mesure) puisse leur être appliqué ⇒ **changement de terminologie** : on n'analyse pas des observations, mais bien leur interprétation (recodage)

Les transformations dépendent essentiellement du cadre de référence (concept mesuré)

Dans le cas de QCM ou QO courte, aucune place n'est laissée à **l'interprétation de l'expérimentateur**. Par contre, le codage d'une question ouverte à réponse longue nécessitera une interprétation de l'expérimentateur, et cette interprétation est source de biais potentiels ! L'interprétation de l'expérimentateur sera plus grande si les comportements sont définis en termes de '**conséquences**' du comportement (l'observateur doit attribuer une intention, une finalité à l'action : + interprétatif).

4. L'APPLICATION DU MODÈLE DE MESURE

Les modèles de mesure permettent de transformer des données en mesure

Deux grands types de modèles que nous verrons dans le cadre de ce cours :

- (1) Le théorie classique du score vrai (CTT)
- (2) Les modèles de réponses à l'item

Chaque modèle repose sur un certain nombre de postulats = présupposés théoriques

Dans le cadre de l'évaluation des compétences mathématiques d'une population scolaire, via un test de 50 questions dichotomiques → attribution d'un score qui contribue au nombre réponses correctes. Cette mesure résultante suppose que :

- La compétence mathématique est une caractéristique unidimensionnelle
- Les 50 items ont été correctement choisis // représentatifs de la caractéristique mesurée
- L'évaluation d'une personne est équivalente à celle d'une autre personne (pas d'interaction entre le sujet et la mesure)
- Les différences individuelles entre les évaluations d'une même personne sont des erreurs

Il est possible que tous ces postulats soient vrais, mais il est aussi probable qu'ils ne le soient pas tous. Ce modèle de mesure (score vrai) ne requiert aucun présupposé sur la distribution de la variable latente dans la population (d'autres modèles imposent des postulats // population)

Durant cette étape (4), il est nécessaire de vérifier la fidélité et la validité de la mesure

Fidélité	Validité
Précision avec laquelle une mesure représente la caractéristique mesurée du sujet	Degré selon lequel des mesures résultantes prédisent / rendent compte d'un ou de plusieurs critères externes

5. TRANSFORMATIONS COMPLÉMENTAIRES ÉVENTUELLES

Certaines mesures, après application d'un modèle de mesure, peuvent subir une transformation dans le but de faciliter l'interprétation. En effet, dans le cadre d'une épreuve normative, on a besoin de connaître la moyenne et l'écart-type pour pouvoir interpréter un score et le situer adéquatement dans la population.

Après évaluation d'un sujet à l'échelle d'Intelligence de Wechsler, l'expérimentateur doit calculer les résultats partiels à tous les sous-tests (somme / table de conversion) pour transformer ces scores en quotients intellectuels → nouvelle mesure résultante (moyenne = 100 ; écart-type = 15) permettant à l'individu de se situer dans la population

Tableau 2.2. Différents scores possibles

	Echelle	Moyenne	Ecart type
Note z ou note standard	Continue	0	1
Score T	Continue	50	10
Stens	10 échelons	5,5	2
Stanines	9 échelons	5	2


Ces scores poursuivent essentiellement le même but : faciliter l'interprétation des scores individuels

Les scores T s'obtiennent en

- Transformant les données en score $z = \frac{x - \mu}{\sigma}$
- Multiplier la note z par l'écart-type T et ajouter la moyenne

L'échelle des stens et l'échelle des stanines sont des échelles discontinues qui comportent respectivement 10 et 9 niveaux
Pour calculer les scores via ces échelles : même méthode que ci-dessus, ou utilisation des tables de conversion

Figure 2.2. Représentation graphique des différents scores



Les évaluations internationales en sciences de l'éducation utilisent les modèles de réponse à l'item pour étalonner les données sur une échelle commune (**standardiser**).

6. SYNTHÉTISER LES RÉSULTATS D'UNE BATTERIE DE TEST

Dans le cadre d'une batterie de test, les résultats à différentes épreuves peuvent être synthétisés pour ne fournir qu'un seul score aux candidats / sujets.

Ce score total peut notamment s'obtenir par sommation des résultats aux différentes épreuves (4 méthodes) :

- Addition des résultats aux différentes épreuves
- Addition pondérée des résultats aux différentes épreuves
- Addition des résultats aux différentes épreuves après standardisation
- Addition pondérée des résultats aux différentes épreuves après standardisation

Test 1 Brut	Test 2 Brut	Total Brut	Rang Brut	Test 1 Note Z	Test 2 Note Z	Total Note Z	Rang Note Z	Différence de rang
1	15	16	20	-1,67	-1,36	-3,03	20	0
2	16	18	19	-1,49	-0,60	-2,09	17	2
3	16	19	17	-1,31	-0,60	-1,92	16	1
4	15	19	17	-1,14	-1,36	-2,49	19	-2
5	15	20	16	-0,96	-1,36	-2,32	18	-2
6	16	22	15	-0,78	-0,60	-1,38	15	0
7	16	23	14	-0,60	-0,60	-1,21	14	0
8	17	25	13	-0,43	0,15	-0,28	11	2
9	17	26	11	-0,25	0,15	-0,10	10	1
10	16	26	11	-0,07	-0,60	-0,67	13	-2
11	16	27	10	0,11	-0,60	-0,50	12	-2
12	17	29	9	0,28	0,15	0,43	9	0
13	18	31	8	0,46	0,90	1,37	7	1
14	18	32	7	0,64	0,90	1,54	6	1
15	20	35	3	0,82	2,41	3,23	1	2
16	18	34	5	0,99	0,90	1,90	4	1
17	19	36	2	1,17	1,66	2,83	2	0
18	16	34	5	1,35	-0,60	0,75	8	-3
17	18	35	3	1,17	0,90	2,08	3	0
20	17	37	1	1,70	0,15	1,85	5	-4

Comme on peut le constater via la dernière colonne (différence de rang), les deux méthodes aboutissent à des classements distincts

Le passage par une forme de standardisation (ici score z) garantit que les deux tests contribueront de façon presque identique à la composition du score global

Par contre, dans la méthode des scores bruts, la contribution des tests au score total sera proportionnelle à la variance des différentes épreuves

- Variance élevée // contribution élevée
- Variance faible // contribution faible (ex. tout le monde réussi / rate)

Comme la standardisation transforme les scores bruts des différentes épreuves en des scores présentant des indices de dispersion identiques, la contribution de chaque épreuve au score global sera équivalente.

Toutefois, la standardisation est insuffisante si le score global se compose de + de 2 tests...

En sachant que la variance du score total est égal à la somme de variances de chacun des tests + le double produit de l'ensemble des covariances :

$$\sigma_{(Total)}^2 = \sum_{i=1}^k \sigma_{(k)}^2 + \sum_{i=1}^{k-1} \sum_{j=i+1}^k 2\text{cov}(i, j)$$

Lorsque le score global se compose de 3 tests (A, B, C), la variance totale sera égale à :

$$\sigma_{(Total)}^2 = \sigma_{(A+B+C)}^2 = \sigma_{(A)}^2 + \sigma_{(B)}^2 + \sigma_{(C)}^2 + 2\text{cov}(A, B) + 2\text{cov}(A, C) + 2\text{cov}(B, C)$$

La contribution du test A au score global peut se définir par :

$$C_A = \frac{\sigma_{(A)}^2 + \text{cov}(A, B) + \text{cov}(A, C)}{\sigma_{(Total)}^2}$$

⇒ La contribution d'un test sera proportionnelle à sa variance et aux covariances avec les autres tests

La somme des contributions sera égale à 1

$$C_A + C_B + C_C = \frac{\sigma_{(A)}^2 + \text{cov}(A, B) + \text{cov}(A, C)}{\sigma_{(Total)}^2} + \frac{\sigma_{(B)}^2 + \text{cov}(A, B) + \text{cov}(B, C)}{\sigma_{(Total)}^2} + \frac{\sigma_{(C)}^2 + \text{cov}(A, C) + \text{cov}(B, C)}{\sigma_{(Total)}^2}$$

$$C_A + C_B + C_C = \frac{\sigma_{(A)}^2 + \sigma_{(B)}^2 + \sigma_{(C)}^2 + 2\text{cov}(A, B) + 2\text{cov}(A, C) + 2\text{cov}(B, C)}{\sigma_{(Total)}^2} = 1$$

Si les différentes variables ont été préalablement standardisées en notes Z, la contribution d'un test peut se calculer comme ceci :

$$C_A = \frac{1 + \rho_{(A,B)} + \rho_{(A,C)}}{\sigma_{(Total)}^2}$$

⇒ Après standardisation, la contribution d'un test sera proportionnelle aux corrélations que ce test présente avec les autres tests


- Si les tests sont corrélés de façon similaire entre eux, c'est-à-dire qu'ils mesurent à peu près la même chose, avec la même intensité → leur contribution au score globale sera équilibrée (± égale)
- Si les corrélations entre les tests sont assez différentes (particulièrement élevées ou particulièrement faibles) les contributions respectives de chacun des tests varieront davantage

NB : la moyenne ne détermine pas le rang final – c'est la variabilité des scores entre individus

Exemple : si un test est réussi de la même façon par l'entièreté des sujets, il n'y a aucune différence entre les individus → donc aucune information pour classer les sujets !

En conclusion, la démarche recommandée pour le score global passe donc par une standardisation des notes brutes. Si un sous-test s'avère plus important que les autres (par exemple grammaire > orthographe), alors on peut appliquer une pondération sur la note standardisée.

CHAPITRE 3 : LA RÉDACTION DES ITEMS D'UN INSTRUMENT DE MESURE



Dans le but d'obtenir des observations, le chercheur va construire...

- Un instrument de mesure
- Un dispositif de collecte des observations

⇒ Élaboration et rédaction des items de l'instrument de mesure

1. REPRÉSENTATIVITÉ DU CADRE D'ÉVALUATION

Les observations sont généralement extraites d'un **ensemble infini d'observations potentielles** – Explication : les items sélectionnés pour créer un test (de performance) ne peuvent représenter qu'une partie infime de l'ensemble des questions que l'on pourrait poser

Généralisabilité : on veut également s'assurer que les items repris dans l'instrument de mesure couvrent bien le domaine évalué dans ses différentes dimensions

Pour assurer cette représentativité, différentes techniques d'échantillonnage des items :

Le processus de sélection des items concerne le **contenu abordé**, les **processus mentaux** mis en œuvre, mais aussi la **forme des questions** et les **modalités de réponse** (l'importance relative des questions selon ces dimensions devrait être précisée dans le cadre d'évaluation)

La taxonomie de Bloom :

Bloom a recueilli et analysé un grand nombre de questions posées par des profs à leurs élèves. Ces travaux ont abouti à l'élaboration d'une **taxonomie des processus cognitifs à 6 niveaux**, qui peut servir à l'élaboration de nouvelles épreuves, afin d'éviter qu'elles ne portent que sur des processus de connaissance ou d'application

1. Connaissance	= mémoriser, reconnaître, réciter
2. Compréhension	= expliquer, illustrer, résumer
3. Application	= utiliser, résoudre, démontrer
4. Analyse	= comparer, catégoriser, distinguer
5. Synthèse	= créer, élaborer
6. Évaluation	= justifier, critiquer

2. ELABORATION DES ITEMS D'UNE ÉPREUVE DE PERFORMANCE

On distingue les items en fonction

- Des formats de questions (VF / QCM / QOC / QOL)
- Des modalités de présentation (une seule question / plusieurs questions)

2.1 LE CHOIX DU FORMAT DES QUESTIONS

La majorité des premières études de l'IEA comportaient exclusivement des QCM ; pourquoi ?

- La standardisation de la correction, d'où l'absence (ou quasi-absence) de toute subjectivité du correcteur
- La réduction des coûts : pas nécessaire de recourir à un codage (correction) des réponses des élèves, codage qui nécessite
 - La rédaction de consignes de corrections
 - La formation des codeurs
 - Le codage en lui-même
 - Des études de qualité du codage

Critique principale vis-à-vis des QCM : ils réduisent les savoirs et les savoir-faire à un processus de reconnaissance uniquement ; or, savoir distinguer la bonne réponse parmi les mauvaises ≠ produire une réponse correcte.

Donc, en réponse aux critiques → introduction aux **questions ouvertes**

Au fil du temps, la répartition entre QCM et QO tend à s'équilibrer ; cet **équilibre** permet de

- Varier les processus cognitifs sollicités
- Minimiser les comportements différentiels des items en fonction de certaines caractéristiques personnelles et/ou culturelles des sujets
- Garantir une faisabilité pratique nécessaire à la conduite d'une étude à large échelle

L'élément primordial à considérer dans le **choix d'une répartition** relève des finalités poursuivies définies dans le cadre d'évaluation

Pourquoi ne pas privilégier un type de question au détriment des autres ? Car chaque type de question présente des avantages et des inconvénients, et il n'est dès lors pas possible de trancher en faveur d'un type de question ou d'un autre

2.2 MODALITÉS DE PRÉSENTATION

⇒ Différencier les questions en fonction du dispositif de présentation de la question

Une question se compose souvent d'un stimulus, puis de la question proprement dite = « item »

Indépendance (études IEA)	Dépendance relative au stimulus (études PISA)	Dépendance au sens strict
Un stimulus correspond à 1 seul item = les items qui composent le test sont indépendants	Un stimulus est proposé, plusieurs items y sont liés (= 1 unité) = les items dépendent du même stimulus	Les items sont liés au même stimulus, et liés entre eux
La probabilité de réussir un item ne dépend nullement de la probabilité de réussir l'item précédent	La réponse à un item ne dépend nullement de la réponse à un autre item	La réussite à une question dépend notamment de la question précédente (une erreur en (1) conduira à une erreur en (2))

La dépendance entre items est, en règle générale, déconseillée, voire proscrite dans le cadre des modèles de réponse à l'item → risque de biaiser certaines indices stats / psychométriques : surestimation corrélation entre items, surestimation fidélité, sous-estimation de la performance des + faibles, variabilité des résultats surestimée)

2.3 RÉDACTION DES ITEMS

La rédaction des questions fermées

Distinction entre questions de type vrai – faux et questions à choix multiples (QCM)

Questions de type Vrai / Faux (et variantes « oui-non », etc)

- Facilité de rédaction ; automatisation de la correction (comme les QCM)
- MAIS possibilité d'obtenir une réponse correcte en choisissant au hasard

Règles de rédaction des questions fermées de type « vrai – faux »

1. S'assurer que la proposition est réellement vraie / fausse, sans devoir ajouter d'autres conditions
 - a. Utiliser des propositions aussi courtes que possibles
 - b. Utiliser un langage précis
 - c. Utiliser des propositions à la forme affirmative et éviter les doubles négations
2. La longueur des propositions vraies doit être identique à la longueur des propositions fausses
3. Éviter de présenter les items selon un pattern donné (VVFVV etc)
4. L'item doit éviter de donner des informations qui pourraient conduire à la réponse (termes à éviter : toujours, jamais)
5. Si l'item présente une opinion, s'assurer que la source est indiquée
6. Si la proposition n'évalue pas la connaissance d'une relation entre deux idées, elle doit au moins présenter une idée

Questions à choix multiples (QCM)

- Réduction de la probabilité d'une bonne réponse choisie au hasard

Règles de rédaction

1. N'utiliser la QCM que si ce type de question est approprié à ce qu'on veut évaluer
2. La QCM doit correspondre à l'objectif visé, au comportement à évaluer
3. La QCM ne doit pas perturber les apprentissages
4. La QCM doit renseigner l'évaluateur sur le processus mental utilisé par l'élève
5. Les distracteurs doivent indiquer le type d'erreur commise / le cheminement incorrect suivi par l'élève
6. On doit préciser sur quelle partie de l'énoncé porte la question
7. La question doit être cohérente, compatible avec la consigne
8. Proposer des phrases avec une syntaxe correcte

9. Pas d'éléments ambigus, de termes vagues dans l'énoncé
10. Éviter les propositions à forme négative, éviter les doubles négations
11. Séparer informations et questions
12. Regrouper dans l'amorce (l'énoncé) les éléments communs aux solutions proposées
13. Assurer l'indépendance syntaxique
14. Les solutions proposées doivent être « conceptuellement » indépendantes les unes des autres
15. Éviter de donner des éléments de réponse dans les questions
16. Produire des distracteurs de même vraisemblance
17. Produire des distracteurs de même complexité : la solution correcte ne doit pas être systématiquement plus longue que les autres
18. Produire des distracteurs de même complexité
19. Produire des distracteurs de même niveau de généralité dans les indicateurs (temps, modificateurs, etc)
20. Produire des distracteurs de même degré de technicité du vocabulaire dans toutes les solutions proposées

⇒ La rédaction de QCM est plus complexe qu'il n'y paraît, il est parfois conseillé aux rédacteurs de recourir dans un premier temps à des questions ouvertes, pour recueillir un ensemble de réponses qui pourront servir de base pour la rédaction des distracteurs QCM ultérieurement

La rédaction de questions ouvertes

Questions ouvertes à réponse courte

Elles exigent comme réponse un / quelques mots, une phrase courte, un nombre, un symbole

Il existe essentiellement 3 types de questions ouvertes à réponse courte

- **La phrase interrogative** : on pose une question directement à l'élève
- **La phrase lacunaire** : on présente une phrase incomplète à compléter
- **L'association** : on présente une liste de termes / d'images pour lesquels l'élève doit fournir des nombres, des noms, des symboles, etc.

Les questions ouvertes à réponse courte peuvent évaluer la performance des étudiants à un éventail de compétences de niveau inférieur (taxonomie de Bloom : connaissance, compréhension, application)

Les QOC neutralisent les choix au hasard (production) ; elles ont l'avantage de ne présenter aucune difficulté majeure dans leur conception, leur rédaction et leur correction.

Cependant, il ne faut pas aller jusqu'à considérer que la subjectivité du correcteur n'intervient nullement : pas toujours possible d'envisager toutes les réponses possibles, problèmes d'écriture, d'orthographe, etc → les consignes de correction doivent donc préciser comment agir dans ces cas-là ; ces consignes peuvent varier d'une question à l'autre, selon l'objectif visé

Règles de rédaction

1. Pour autant que cela soit possible, l'item doit être écrit sous forme de question
2. L'item doit être écrit de façon claire, de sorte que la réponse correcte puisse être fournie par un mot, un symbole, un nombre ou une phrase courte
3. L'espace prévu pour la réponse est à la fin de la phrase
4. Si l'item relève de la catégorie texte lacunaire, le mot manquant doit être un mot important
5. L'espace réservé à la réponse a la même longueur que l'espace réservé dans les autres questions
6. Si nécessaire, l'item doit informer l'élève sur le degré de précision / de détails requis pour la réponse
7. L'item doit éviter des informations de type grammatical par exemple qui pourrait aider l'élève (un / une → un(e))

Questions ouvertes à réponse longue

Elles ont pour objectif d'évaluer des processus cognitifs plus élevés du type analyse, synthèse, et évaluation (cf. Bloom)

Il importe de préciser dans la question ce qu'on attend de l'élève – utilisation de verbe précis sur le type de raisonnement demandé : « comparer », « définir », « contraster »

Il convient également de ne pas inclure des informations inutiles qui pourraient altérer la perception de l'étudiant relativement à la tâche demandée

Difficulté majeure : concevoir les consignes de correction qui laissent peu de place à la subjectivité du correcteur – risque de réduction de la fidélité de la mesure

⇒ Il importe donc que les consignes de correction envisagent les différentes réponses correctes et précisent les limites tolérées par rapport à la réponse prototype

L'essai sur le terrain (prétest) fournit une base pour la révision des consignes de correction, pour qu'elles puissent être aménagées en fonction des difficultés rencontrées en premier lieu
→ Inciter les correcteurs à lister les difficultés rencontrées et les transmettre aux rédacteurs

Dans certains cas, il est possible de donner différents types de crédits selon les réponses

- Un crédit complet : réponses considérées comme complètement correctes
- Un crédit partiel : réponses partiellement correctes

À l'intérieur de ces catégories, il est possible de classer encore les réponses selon la nature du processus cognitif en jeu **mais attention** que la multiplication des codes de correction peut rendre le travail des correcteurs plus ardu, plus lent et donc moins fiable et plus coûteux

2.4 INTERACTION ENTRE LES ITEMS ET LES SUJETS

Il arrive que des items présentent des **interactions avec certaines caractéristiques des sujets** interrogés → cela se produit lorsque deux individus de compétences égales n'ont pas la même probabilité de réussir un item. Il est important de distinguer deux concepts différents :

Le biais d'item	Le comportement différentiel de l'item
Un groupe de sujets à moins de chance de réussir à un item qu'un autre groupe en raison de certaines caractéristiques de l'item ou des conditions de testing non reprises dans le cadre de l'évaluation	À niveau de compétence égale, des sujets appartenant à différents groupes (basés sur l'âge, le sexe, l'origine, etc) ont des probabilités différentes de réussir l'item.
Il résulte d'un défaut au niveau de la conception du test ou de ses modalités d'administration dans la mesure où il s'agit d'une différence non-souhaitée / non-expliquée dans les résultats	Le fait d'observer des DIF ne signifie pas nécessairement que l'item présente un biais (par ex. différence filles/garçons pour tel type d'item signifie simplement une plus grande aisance des filles/garçons dans ce type d'item)
	Certains DIF peuvent être cohérents avec la littérature / souhaités dans la recherche

Le type de stimulus

Selon le type de question, le type de test

La différence entre les filles et les garçons en compréhension de lecture diffère selon que le type de question porte sur des textes non continus (tableaux, etc) que sur des textes continus
 ⇒ Les questions posées à pd un texte non continu sont relativement + faciles pour les garçons, alors que les questions posées à pd un texte continu sont relativement + faciles pour les filles

La modalité de réponse à l'item

Les sujets se comportent différemment selon leur sexe aux QCM et aux QO

⇒ À niveau de compétence égale, les filles obtiennent en général de meilleurs résultats aux QO et les garçons de meilleurs résultats aux QCM

Différentes hypothèses ont été émises pour expliquer cette différence :

1. Les garçons sont plus enclins à recourir au choix au hasard
2. La QO nécessite l'évaluation de la qualité de la réponse par un codeur – les filles ont généralement une meilleure écriture, orthographe, etc → se voient attribuer de meilleures notes (effet de Halo)

Le contenu de l'item

Certains contenus peuvent paraître plus familiers à certains qu'à d'autres – engendrer des modifications au niveau de la probabilité de réussite d'un item

⇒ On observe des interactions entre sous-domaines de la discipline évaluée et le sexe

- Performance nettement plus élevée chez les garçons pour les concepts géométriques, alors que performance à peine plus élevée pour les concepts liés aux quantités

Processus cognitifs évalués par l'item

La différence entre les filles et les garçons présente des variations importantes selon le processus cognitif

En conclusion...

Le contenu des tests peut influencer substantiellement certains indicateurs statistiques tels que les différences entre filles et garçons, entre élèves de différents milieux sociaux, etc. La cadre d'évaluation doit donc prévoir et envisager l'influence de ces différentes composantes et préciser la place respective à leur accorder (+ prendre en compte les DIF logiques par rapport aux connaissances actuelles)

3. LES ITEMS DANS UN QUESTIONNAIRE CONTEXTUEL

Les questionnaires contextuels sont les instruments de mesure via lesquels on recueille des données **contextuelles**, par exemple des données sociodémographiques sur les élèves

→ Tout aussi important de disposer de mesures fiables car bon nombre d'indicateurs sur l'efficacité / l'équité d'un système éducatif reposent sur ces variables

3.1 LE FORMAT DES QUESTIONS

Les différents types de questions définies dans le cadre du test de performance sont également d'application dans le cadre des questionnaires contextuels

Cependant, à l'inverse des tests de performance, il n'y a pas de bonnes / mauvaises réponses

Question dichotomique de type vrai / faux

Propose deux alternatives parmi lesquelles l'individu doit choisir

Ex.1. Êtes-vous une fille ou un garçon ?

- ☐ Fille
- ☐ Garçon

Ex.2. À la maison, disposez-vous de... (cochez les cases qui conviennent)

- ☐ Un bureau pour travailler
- ☐ Un chambre à vous seul
- ☐ Etc.

Dans ce cas de figure, la question s'apparente à une question du type « oui/non », si ce n'est que l'élève n'a pas la possibilité de répondre par la négative ; l'absence de réponse est donc assimilée à « non » ⇒ risque de confusion entre [un élève qui ne dispose pas des biens matériels] et [un élève qui refuse de répondre à la question]

Pour résoudre ce problème : offrir la possibilité de répondre par la négative ou ajouter un item du type « je ne possède aucun de ces biens »

Question dichotomique filtrante

Do you ever use a computer?
(Do not include Nintendo®, GameBoy®, or other TV/ video game computers.)

Yes -- ☐ No -- ☐ (If No, go to #12)

If Yes...

11a. How often do you use a computer in each of these places?

Fill **one** circle for each line.

	Every day or almost every day	Once or twice a week	Once or twice a month	Never or almost never
a) I use a computer at home	☐	☐	☐	☐
b) I use a computer at school	☐	☐	☐	☐

Sans la question filtrante, les étudiants devraient répondre non pour chacune des propositions – risque d'abandon au bout de quelques propositions → accroître le taux de non réponse

Question à choix multiple

Quelle activité exerce actuellement votre mère (ne cochez qu'une seule case)

- ☐ Travail rémunéré à temps plein
- ☐ Travail rémunéré à temps partiel
- ☐ Ne travaille pas mais cherche un emploi
- ☐ Autre (femme au foyer, retraitée,...)

Ces catégories doivent être mutuellement **exclusives** et **exhaustives**

Pour assurer l'exhaustivité sans toutefois allonger indéfiniment la liste des modalités, il est d'usage de terminer la question en proposant la modalité « autre »

QCM à plusieurs choix possibles

La question s'apparente à une QCM, mais est en réalité un ensemble d'items dichotomiques – nécessaire de mentionner qu'il est possible de sélectionner plusieurs propositions

Votre mère a-t-elle terminé les niveaux d'études suivants ?

- ☐ Niveau CITE 3A
- ☐ Niveau CITE 3B, 3C
- ☐ Niveau CITE 2
- ☐ Niveau CITE 1
- ☐ Aucun de ces niveaux d'étude

Classement à choix forcé

Demander au sujet de classer des éléments / de choisir un nombre donné d'élément parmi un ensemble plus grand (si liste > 5 éléments → ne classer que 5 des éléments)

Classer les cours suivants par ordre de préférence

(1 = le cours le plus apprécié 4 = le cours le moins apprécié)

Français ____ ; Mathématiques ____ ; EDM ____ ; gym ____

Échelles d'évaluation

Les modalités de réponse se situent sur une échelle ordinale, le répondant doit en choisir une pour chaque proposition. La plus populaire : Likert

Dans quelle mesure êtes-vous d'accord avec les affirmations suivantes ?

(« Cochez » une seule case par ligne).

	Tout à fait d'accord	D'accord	Pas d'accord	Pas du tout d'accord
a) L'école n'a pas fait grand chose pour me préparer à la vie d'adulte.....	☐ ₁	☐ ₂	☐ ₃	☐ ₄

D'autres échelles ordinales peuvent être utilisées, à titre d'exemples :

- Degré d'importance
- Degré de fréquence
- Degré d'assurance
- Etc

Le *différenciateur sémantique d'Osgood* est une variante d'échelle d'évaluation où l'on place deux adjectifs de sens contraire aux deux pôles de l'échelle

Vous trouvez l'utilisation de manuels scolaires en classe:

inutile 1 2 3 4 5 6 7 utile

→ Évite l'interprétation variable d'un sujet à l'autre d'expressions telles que « tout à fait d'accord » ou « souvent » **mais** il n'échappe pas à des variations de significations d'un répondant à l'autre, voire à des changements de réponse pour un individu donné selon l'échelle numérique adoptée

Les informations recueillies par échelle de Likert ou Osgood sont souvent synthétisées sous la forme d'un indice, soit en recourant à la théorie du score vrai, soit en utilisant un modèle de réponse à l'item ⇒ l'item a la valeur d'un indicateur d'un phénomène + complexe que l'on ne peut mesurer directement (→ relation entre phénomène + complexe et performance)

Questions ouvertes

Parfois utilisées mais souvent évitées car

- Nécessité de codage – augmente les coûts
- Source supplémentaire d'erreurs liée au codeurs
- Risque d'accroître le pourcentage de données manquantes
- Délai supplémentaire nécessaire pour le codage

Quel grade fréquentez-vous ?

Quel est l'emploi principal de votre mère ?

Que fait votre mère dans le cadre de son emploi ?

3.2 MISE EN FORME DES ITEMS

Les caractéristiques des items constituent une source d'erreurs de mesure qui affectent les qualités psychométriques des mesures, mais aussi la distribution des réponses, et par voie de conséquence, la distribution des mesures résultantes

Les dispositifs de présentation

- Caractéristiques sémantiques
- Caractéristiques formelles des items (longueur, complexité, forme)
- Contexte

De très légers changements dans le choix des termes utilisés peuvent modifier le sens de l'item et, par conséquent, les réponses des sujets

- L'asymétrie autorisation / interdiction démontre la sensibilité des caractéristiques sémantiques des items sur les résultats
- Les sujets ont tendance à répondre en choisissant des catégories plutôt centrales lorsque les items sont formulés négativement (+ indices de fidélité plus faibles)
- Concernant l'influence de la longueur des items : les résultats sont contradictoires

Les dispositifs de réponse

Différents aspects doivent être pris en compte pour les questions fermées contextuelles ou dans un test qui recourt aux échelles de Likert

- *Combien d'échelons à retenir ?* → le nombre optimum se trouve entre 5 et 9 ; en deçà ou au-delà, la fidélité diminue
- *Quel étiquetage adopter ?*
 - Les étiquettes numériques : selon l'échelle adoptée (de 0 [pas du tout] à 10 [tout à fait] ou de -5 à +5), les résultats varient considérablement
 - Les étiquettes verbales : ambiguïté dans certains termes (par ex. « souvent »)

Le problème de la présence ou l'absence d'une réponse médiane (nombre pair / impair de modalités de réponse) a suscité beaucoup de recherches

- ➔ L'absence de réponse médiane accroît le pourcentage de non-réponses : les personnes qui n'ont pas d'avis préfèrent s'abstenir
- ➔ La présence d'une réponse médiane n'altère pas / peu la distribution des autres réponses
- ➔ Lorsque cela se justifie, insérer une modalité de réponse « je ne sais pas »

Recommandations générales

Éviter :

1. Les questions orientées, qui permettent d'anticiper la réponse attendue (désirabilité sociale)
2. Les questions trop complexes (contenu, syntaxe, lexique)
3. Les questions trop irritantes, trop intrusives
4. De donner des ordres dans les consignes
5. Les questions négatives (et les doubles négations)
6. Le recours à trop de questions ouvertes
7. Les questions ambiguës – éviter d'utiliser des termes comme « régulièrement », « parfois », « souvent », etc
8. Les doubles questions

Il est conseillé de commencer le questionnaire des questions anodines et simples, mais qui présentent un certain intérêt, pour encourager la participation, ou pour éviter que le répondant ne développent une attitude négative. Les questions sensibles seront placées ultérieurement.

On conseille souvent de structurer le questionnaire comme ceci :

1. Commencer par le recueil d'informations factuelles
2. Passer aux questions fermées
3. Terminer par les questions ouvertes et personnalisées

La **mise en page** a également une importance capitale

- Utiliser une taille de caractère raisonnable et espacer les questions
- Fournir, en début et en fin de questionnaire, des consignes générales et précises (avec des exemples de questions)
- Indiquer, dans les consignes, que l'anonymat est respecté
- Répéter ces consignes aussi souvent que nécessaire, avec police de caractère différente, en gras, en italique
- Numérotter les questions et les items au sein des questions
- Remercier le répondant pour sa participation en fin de questionnaire

Être vigilant lors de la conception et l'interprétation des résultats à certains phénomènes :**Tendance à l'indécision**

difficulté à choisir une réponse, souvent en optant pour des réponses neutres

Tendance à privilégier la vitesse sur l'exactitude

répondre vite au détriment de la précision pour finir plus rapidement

Tendance à répondre au hasard

donner des réponses sans réflexion, surtout en cas de difficulté ou de fatigue

Tendance à l'acquiescement

tendance à dire "oui" ou à être d'accord indépendamment du contenu de la question

Tendance à la falsification (désirabilité sociale)

modifier ses réponses pour paraître meilleur ou plus acceptable socialement

Enfin, les réponses au questionnaire seront traitées par des **logiciels d'analyse**. Il importe d'automatiser autant que possible ce travail et de limiter le recours à la mémoire ou à l'interprétation auprès des personnes en charge de l'encodage.

→ Il est conseillé que les codes attribués aux modalités des différentes questions respectent l'ordre de lecture (de droite à gauche, de haut en bas)

CHAPITRE 4 : L'ASSEMBLAGE DU TEST ET LE DISPOSITIF DE COLLECTE DE DONNÉES

1. L'ASSEMBLAGE DU TEST

1.1 INTRODUCTION

Les tests psychométriques sont généralement conçus de telle sorte que l'ensemble des items sont administrés à tous les sujets. Cela permet à toute personne qui administre le test de calculer aisément le score de l'individu et de pouvoir l'interpréter en référence aux résultats de l'ensemble des sujets ayant passé le même test ou par rapport à une norme.

L'Inventaire de Dépression de Beck (IDB), dont l'objet est de quantifier l'intensité des sentiments dépressifs de personnes âgées de 13 -80 ans, comporte dans sa version initiale 21 items à 4 énoncés (5 version Fr) gradués de 0 à 3. Les scores totaux peuvent varier de 0 à 63, à calculer par simple sommation, et à interpréter comme tel :

1. Score de 0 – 11 : absence de dépression
2. Score de 12 à 19 : dépression légère
3. Score de 20 à 27 : dépression modérée
4. Score supérieur à 27 : dépression sévère

NB : l'IDB n'est pas un test diagnostique, mais bien un test de sévérité

Aucune norme de population n'est fournie – l'interprétation se base sur des seuils, indépendamment de la distribution des scores d'une population

Le **test de Mesure du Stress Psychologique (MSP)**, dont l'objectif est d'évaluer l'intensité de l'expérience subjective de se sentir stressé, comporte 49 items gradués selon une échelle de Likert à 8 modalités (pas du tout → énormément), et répartis en 3 types d'indicateurs :

- i. Cognitivo-affectifs
- ii. Somatiques
- iii. Comportementaux

Les scores totaux peuvent varier de 49 à 392, à calculer par simple sommation, et à interpréter par rapport à la distribution des scores de la population (test normatif) (cf. Table des normes de la MSP – compare le score MSP avec score T et centile)

1.2 DÉVELOPPEMENT DES TESTS DESIGNS INCOMPLETS

Les études internationales telles que PISA sont conçues pour estimer NON PAS la performance d'un élève donnée MAIS la **performance d'une population** d'élèves d'un âge donné, fréquentant une année scolaire spécifique dans des domaines tels que les mathématiques, les sciences, la compréhension en lecture.

Pour qu'une étude puisse être considérée comme valide, il faut développer de **nombreux items** et les inclure dans les tests définitifs → de nombreux items sont nécessaires pour pouvoir évaluer des **concepts aussi larges**.

Pourtant, il ne serait pas raisonnable de faire passer à chaque élève échantillonné la batterie de test entière pour les raisons suivantes :

- Après un certain temps consacré à répondre à un test, les élèves commencent à ressentir les **effets de la fatigue et leurs résultats en souffrent** → risque de biais dans les résultats de l'étude

- Les directeurs d'écoles auraient tendance à **refuser la participation** de leurs élèves à un **test d'une très longue durée** → risque de réduire le taux de participation des écoles et donc risque de biais dans les résultats

⇒ Afin de pouvoir répondre à la fois à la demande d'un temps réduit et une couverture suffisamment large, différentes formes parallèles du test sont développées de sorte que les personnes interrogées ne répondent qu'à un sous-ensemble de la batterie d'items = *chaque item n'est passé que par un sous-ensemble d'élèves*

Lors de la première étude internationale en mathématique de l'IEA, tous les élèves d'une population-cible donnée (année scolaire) devaient répondre à toutes les questions (chaque élève passait l'ensemble des questions prévues pour son groupe). Cependant, les questions développées pour l'ensemble des niveaux (pour les différentes populations-cibles = différentes années scolaires) ont été réparties en **blocs de questions** ; certains blocs étaient communs à plusieurs niveaux, autorisant des comparaisons entre les différentes années concernées.

		Test design
Population 1a	Elèves de 13 ans	1,2,3
Population 1b	Année d'étude qui comporte la majorité des élèves de 13 ans	3,4,5
Population 3a	Fin secondaire – spécialiste du domaine évalué	5,7,8,9
Population 3b	Fin secondaire – non spécialiste du domaine évalué	3,5,6

La première, mais aussi la seconde étude en sciences (SISS) ont accentué le recours aux **items** dits **d'ancrage**. Quatre formes parallèles ont été développées (niveau de la population cible de l'enseignement primaire ; niveau de la population cible de l'enseignement secondaire).

	Forme A	Forme B	Forme C	Forme F
Enseignement primaire	Core test : questions 1 à 24			
	25 à 32	32 à 40	41 à 48	49 à 56
Enseignement secondaire	Core test : questions 1 à 30			
	31 à 40	41 à 50	51 à 60	61 à 70

Les épreuves de rendement pour la population de l'enseignement primaire comportent au total 56 questions, dont 24 **administrées à l'ensemble des élèves** interrogés (core test) . Les 32 autres questions se répartissent dans les 4 formes parallèles (8 questions / groupe).

Ce test design permet de **mieux couvrir le domaine évalué** tout en **limitant le nombre de questions posées à chaque élève** (30 questions au total / élève).

Balanced Incomplete Bloc design (BIB)

Les études internationales en sciences de l'éducation privilégient depuis environ une décennie les **Balanced Incomplete Bloc design**

Balanced (1) chaque **bloc** de questions (ensemble de questions) doit apparaître le même nombre de fois dans chaque position (annuler biais de fatigue)
(2) chaque **paire** de blocs doit apparaître le même nombre de fois
→ assure que les blocs soient bien réparti

Incomplete : aucun élève ne répond à toutes les questions. Chaque livret ne contient qu'une partie des blocs, donc les données de chaque élève sont incomplètes par rapport à l'entièreté de la batterie d'items

Exemple : BIB à 7 livrets, 3 blocs de questions

→ 3 paires (AB – AD – BD) possibles par livret ⇔ 21 paires possibles au total

	Position 1	Position 2	Position 3
Livret 1	A	B	D
Livret 2	B	C	E
Livret 3	C	D	F
Livret 4	D	E	G
Livret 5	E	F	A
Livret 6	F	G	B
Livret 7	G	A	C

Grâce à ces tests designs, les domaines évalués sont relativement bien couverts, puisque l'ensemble du matériel peut facilement correspondre à plus de 300 minutes de testing, tout en maintenant un temps d'évaluation par sujet interrogé dans des normes acceptables, qui limitent les effets de la fatigue et ne mettent pas en péril la participation des écoles.

- Il est préférable de limiter le temps d'administration de l'épreuve afin d'éviter un effet de fatigue auprès des sujets interrogés.
- Attention également que l'accroissement du nombre de livrets peut accentuer les problèmes logistiques et générer des erreurs qui pourraient s'avérer irréversibles pour la qualité des données

Partial Balanced Incomplete Bloc design (pBIB)

Ces design n'exigent plus que toutes les paires de blocs soient représentées

	Position 1	Position 2		Position 1	Position 2
Livret 1	A	C	Livret 9	F	G
Livret 2	B	A	Livret 10	G	H
Livret 3	C	D	Livret 11	G	E
Livret 4	D	B	Livret 12	H	F
Livret 5	A	D	Livret 13	C	G
Livret 6	B	C	Livret 14	D	H
Livret 7	H	E	Livret 15	E	B
Livret 8	E	F	Livret 16	F	A

Les livrets étant composés d'une seule paire de bloc, et les blocs de questions allant jusqu'à la lettre H (8 blocs différents) → il faudrait 28 livrets si on exigeait que toutes les paires soient présentes. Ici, chacun des 8 blocs apparaît 2x dans chacune des positions (4x en tout)

Le schéma suivant est particulièrement adapté lorsque deux sous-dimensions d'un domaine sont évaluées et que l'on souhaite calculer des scores par sous-dimension

Items	A	B	C	D	E	F	G	H
A								
B	1							
C	1	1						
D	1	1	1					
E	0	1	0	0				
F	1	0	0	0	1			
G	0	0	1	0	1	1		
H	0	0	0	1	1	1	1	

Il est par ailleurs possible de concevoir des tests design avec *mesures répétées*. Dans ce design, on suit les mêmes groupes (expérimental et contrôle) plusieurs fois dans l'année pour voir comment leurs performances évoluent ; les exigences imposées au design de l'étude sont :

- On veut comparer les résultats du groupe expérimental au groupe contrôle
- Toutes les évaluations doivent être comparables entre elles $\Rightarrow$ on utilise des items d'ancrage (questions communes) pour créer une seule échelle de mesure
- Un élève ne doit jamais voir 2x la même question (éviter des effets de mémoire)
- Tous les élèves d'une même classe passent la même version du test (consignes identiques)

Voici un test design qui permet de répondre à ces exigences :

	Test 1	Test 2	Test 3	Test 4	Test 5
Groupe expérimental	AB	DC	EF	HG	IJ
Groupe contrôle	AC	EB	DG	IF	HJ

Lors du premier test, tous les élèves (expé + contrôle) répondent au bloc de questions A = constitue une base commune pour pouvoir comparer les groupes sur la même échelle

En plus, chaque groupe reçoit aussi un bloc différent (expé – B ; contrôle – C)

Au deuxième test, on inverse ces seconds blocs dans les groupes (expé – C ; contrôle – B) et on leur assigne à chacun 1 autre bloc (toujours 2 différents), et ainsi de suite

Ce système relie les résultats des deux groupes entre les test, il évite que les mêmes élèves voient les mêmes questions plusieurs fois, et assure que toutes les évaluations restent comparables sur la même échelles

1.3 ÉCUEILS À ÉVITER

Longueur des formes parallèles

Pour garantir que les différents livrets d'un test design puissent être rapportés sur une seule et même échelle, il est préférable que chaque bloc de questions soit +/- de même difficulté moyenne, mais aussi qu'il nécessite un temps de passation identique.

L'étude PISA 2000 a été confrontée à un '*booklet effect*' (= les performances des élèves peuvent varier en fonction du livret de question qu'ils reçoivent, indépendamment de leur niveau)

Chaque élève disposait de deux heures pour répondre à l'ensemble des question, avec une pause après 1h. Après la pause, l'élève n'était pas autorisé à revenir sur les questions de la première partie du test.

- Un item sans réponse suivi d'un item avec réponse témoigne l'impossibilité pour l'élève d'y répondre et sera considéré comme réponse incorrecte (omission = réponse fausse)
- Les items sans réponse à la fin du test reflètent que l'élève n'a pas eu le temps d'y répondre $\Rightarrow$ *non-reached items* ; ils ne sont pas pris en considération pour le calcul de la difficulté des items, mais sont considérés comme réponse incorrecte lors du calcul du score total de l'élève

Nombre d'items non atteints	Livret 1	Livret 2	Livret 3	Livret 4	Livret 5	Livret 6	Livret 7	Livret 8	Livret 9
Session 1									
0	86.7	95.1	87.4	70.9	79.5	85.9	83.7	81.9	84.1
1	2.7	0.3	0.7	3.0	1.2	1.0	2.7	3.9	3.4
2	2.3	0.9	1.6	4.8	1.6	0.8	3.9	1.3	1.0
3	2.2	0.3	3.9	3.3	4.4	1.7	2.5	0.9	1.8
4	1.1	0.7	0.2	2.7	1.0	4.7	0.4	1.8	1.4
5	2.2	0.4	0.9	3.8	0.5	1.6	0.5	0.7	2.3
6	0.2	1.8	0.4	1.5	1.0	0.6	0.4	0.8	1.5
>6	2.6	0.5	4.9	10.0	10.8	3.7	5.9	8.7	4.5
Session 2									
0	76.2	78.7	89.6	85.4	87.3	95.1	91.8	86.9	79.6
1	3.9	12.3	3.1	1.6	3.0	1.4	2.2	1.0	4.2
2	2.9	0.9	2.0	1.9	0.9	0.4	1.1	1.1	2.4
3	6.9	0.6	1.3	2.3	1.5	0.2	0.6	1.0	1.4
4	1.5	1.4	0.5	1.2	1.0	0.5	1.1	1.5	2.8
5	0.7	0.5	0.3	0.7	1.9	0.2	1.0	0.6	3.1
6	3.7	0.4	0.3	0.5	1.3	0.3	0.5	1.4	1.2
>6	4.2	5.2	2.9	6.4	3.1	1.9	1.7	6.5	5.3

- ➔ Les livrets 2 (session 1) et 6 (session 2) sont ceux que les élèves terminent le plus
- ➔ Les livrets 4, 5 (session 1) et 1, 2, et 9 (session 2) ont des taux d'achèvement plus faibles
- ⇒ Ces différences indiquent que les différents livrets étaient de longueur variable

Afin d'étudier l'impact de ces taux variables d'élèves avec des items non-atteints, les résultats des élèves ont été standardisés par pays. On constate en effet que les élèves qui ont reçu le livret 2 obtiennent des résultats sensiblement meilleurs que les autres élèves. Inversement, les élèves qui ont reçu le livret 8 (+ 6 non-reached items) semblent désavantagés – perf moy. <10

Certains pourraient accuser le test design non balancé utilisé lors de PISA 2000. Cependant, même après l'adoption d'un test design équilibré pour PISA 2003 et PISA 2006, des booklet effects ont continué d'être constatés...

Effet de fatigue

Après une heure de test, la performance d'un élève régresse en raison d'un effet de la fatigue et/ou d'une réduction de son attention.

On constate, ci-dessous, que pour un même bloc de question, plus il se situe loin dans un test, plus la moyenne des bonnes réponses diminue et l'écart-type augmente


	Position 1	Position 2	Position 3	Position 4
Livret	Livret 5	Livret 4	Livret 2	Livret 9
Moyenne	8.65	8.70	8.30	7.29
Ecart type	3.27	3.45	3.56	4.10

Cet effet de fatigue peut avoir des effets cumulatifs si le test design n'est pas bien conçu

Pour démontrer cet effet, des données ont été simulées selon un test design

Chaque bloc de questions a été conçu pour avoir une difficulté initiale en moyenne égale.

MAIS la probabilité de réussite à une question donnée se voit réduite de 5% lorsque la question appartient au second bloc du test



Le lien entre le livret 1 et le livret 2 est assuré par le bloc de questions B. Puisque le taux moyen de réussite a été diminué de 5% pour le bloc B du livret 1, les élèves qui ont répondu à ce livret apparaissent moins performants sur ce bloc que les élèves qui ont répondu au livret 2, car leur bloc commun a été affecté par la fatigue

Ce phénomène se poursuit avec les livrets suivants et les effets se cumulent

L'existence du livret 7 permet d'obtenir un design équilibré et de neutraliser cet effet cumulatif (leur réussite du bloc A est inférieure à celle du livret 1)

⇒ Importance d'un test design équilibré pour neutraliser les effets de fatigue

Cet effet de fatigue peut également générer un biais dans les études à mesures répétées

→ Un bloc repris dans plus d'un test est toujours situé soit en première position, soit en deuxième position

Prenons l'exemple de la comparaison interpellante des tests design de PISA 2000 (accent mis sur la lecture) et PISA 2003 (accent mis sur la culture mathématique)

- En 2000, le matériel d'ancrage en lecture se situait en position 1 à 3, alors que ce même matériel occupe les positions 1 à 4 en 2003 ⇒ les données en 2003 devraient être affectées davantage par l'effet de fatigue qu'en 2000 = déclin en lecture
- Inversement, le matériel de mathématiques et de sciences se situe principalement en position 4 en 2000, mais occupe toutes les positions en 2003 ⇒ les données en 2003 devraient subir moins l'effet de fatigue qu'en 2000 = amélioration maths et sciences

Voici les résultats, résultats qui confirment les prédictions :

Domaine	Amélioration significative	Déclin significatif
Mathématiques: Changements et relations	14	1
Mathématiques: Espace et forme	11	3
Sciences	13	5
Compréhension de l'écrit	5	9

2. LE DISPOSITIF DE COLLECTE DE DONNÉES

« Un test, c'est une situation standardisée servant de stimulus à un comportement. Ce comportement est évalué par comparaison avec celui d'individus placés dans la même situation, afin de classer le sujet, soit quantitativement, soit typologiquement. »

On dit d'un test qu'il **standardisé** lorsque les conditions d'administration et de correction sont uniformisées. Une modification des conditions de passation risque d'invalidier les résultats. Les tests psychométriques doivent donc en principe toujours contenir une section qui décrit les conditions d'administration de l'épreuve.

Un test peut s'administrer de manière individuelle ou de manière collective

L'administrateur doit :

- S'assurer que les participants comprennent les consignes
- Distribuer le matériel
- Respecter les limites de temps
- Recueillir les réponses des participants

Il existe un **manuel de l'administrateur de test** (PISA)

Ce manuel décrit dans les moindres détails les différentes activités que l'administrateur doit entreprendre (+ script à lire). Ces activités sont regroupées en 3 grandes catégories

- Préparer la séance
- Conduire la séance
- Terminer les activités relatives à la séance

Des consignes très strictes sont également fournies aux pays en ce qui concerne les personnes qui peuvent assurer cette fonction : l'administrateur peut soit être membre du personnel de l'école (préférable que non quand même), soit un membre extérieur.

Ces différentes consignes d'administration ont pour seul objectif d'assurer la comparabilité des résultats et maintenir la validité des normes (un test normatif n'a aucune signification sans rapport à la population de référence ; changer les conditions d'administration n'autorise plus à situer la performance d'un individu par rapport à cette distribution)

CHAPITRE 5 (<3) : LA THÉORIE CLASSIQUE DU SCORE VRAI

La théorie classique du score vrai propose un modèle qui sert à estimer la fidélité.

Dickes : « On considère qu'un instrument de mesure est fidèle si le résultat qu'il produit est reproductible = si on applique le même instrument (ou versions comparables) à une personne plusieurs fois de suite, cette personne doit être caractérisée par le même score. On s'intéresse donc à la précision avec laquelle une caractéristique psychologique est mesurée. »

1. DÉFINITION DU SCORE OBSERVÉ

Dans le modèle de la théorie classique du score vrai, un score attribué à un sujet correspond à la somme des scores obtenus à chacun des items qui composent le test

La matrice des données ci-dessous présente les résultats de 11 sujets à un tests de 10 items.

- Le score total d'un sujet (dernière colonne) correspond à la somme des scores de ce sujet à chacun des items. Ce score, dénommé **score observé X_i** correspond au nombre de réponses correctes fournies par chacun des sujets.
- L'avant dernière ligne correspond, par item, au nombre de réponses correctes données
- La dernière ligne correspond au pourcentage de réussite par item (nombre de réponses correctes fournies / nombre de sujets)

	It_1	It_2	It_3	It_4	It_5	It_6	It_7	It_8	It_9	It_10	Total
Sujet 1	0	0	0	0	0	0	0	0	0	0	0
Sujet 2	1	0	0	0	0	0	0	0	0	0	1
Sujet 3	1	1	0	0	0	0	0	0	0	0	2
Sujet 4	1	1	1	0	0	0	0	0	0	0	3
Sujet 5	1	1	1	0	1	0	0	0	0	0	4
Sujet 6	1	1	1	1	1	0	0	0	0	0	5
Sujet 7	1	1	1	1	1	0	1	0	0	0	6
Sujet 8	1	1	1	1	1	1	1	0	0	0	7
Sujet 9	1	1	1	1	1	1	1	0	1	0	8
Sujet 10	1	1	1	1	1	1	1	1	1	0	9
Sujet 11	1	1	1	1	1	1	1	1	1	1	10
Nombre de bonnes réponses	10	9	8	6	7	4	5	2	3	1	55
Moyenne	0.91	0.82	0.73	0.55	0.64	0.36	0.45	0.18	0.27	0.09	5

Étant donné que le **score observé** correspond à la somme des scores à chacun des items, on peut déduire que :

- 1) La **moyenne des scores** observés est égale à
 - La moyenne du nombre de bonnes réponses par item (soit 55/11)
 - La somme des moyennes d'items (0,91 + ... + 0,09)
- 2) La variance des scores observés est égale à la variance de la somme des scores à chacun des items :

$$\sigma^2_{(X_i)} = \sigma^2_{(item_1 + item_2 + \dots + item_k)} = \sigma^2_{(\sum_{i=1}^k item_i)}$$

À partir de :

- 1) La généralisation de la formule présentée dans les prérequis statistiques :

$$\sigma_{(X+Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 + 2\text{cov}(X, Y)$$

- 2) Et la définition de la corrélation :

$$\rho_{(X,Y)} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} \rightarrow \text{cov}(X,Y) = \rho_{(X,Y)} \sigma_X \sigma_Y$$

On peut écrire que la variance observée :

$$\sigma_{(X_t)}^2 = \sum_{i=1}^k \sigma_{(item_i)}^2 + 2 \sum_{i=1}^{k-1} \sum_{j=i+1}^k \rho_{(item_i, item_j)} \sigma_{(item_i)} \sigma_{(item_j)}$$

Les **caractéristiques des items déterminent en partie les valeurs de la moyenne et de la variance** des scores observés → En fonction de la difficulté des questions et/ou la compétence des individus interrogés, la moyenne des scores observés peut augmenter / diminuer.

Comment la difficulté des items peut-elle modifier la variance totale ?

La variance observée sera maximale si chacune des variances d'items est maximale

- si chacune des variances d'items est maximale
- si les corrélations inter-items sont toutes égales à 1

La variance d'un item dichotomique sera maximale si et seulement si le % de réponses correctes est égale à 0,50. En effet, si **p_i représente le % de réussite** et si **$q_i = 1 - p_i$ représente le % d'échec**, alors on peut affirmer que la variance d'un item dichotomique est égale à $p_i \times q_i$.

La variance d'un item dichotomique est égale à $p_i q_i$

$$\begin{aligned} \sigma_{(X_i)}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - p)^2 \\ \sigma_{(X_i)}^2 &= \frac{n_0(0-p)^2 + n_1(1-p)^2}{n} = \frac{n_0(0-p)^2}{n} + \frac{n_1(1-p)^2}{n} \\ \sigma_{(X_i)}^2 &= q(0-p)^2 + p(1-p)^2 = q(-p)^2 + p(q)^2 = p^2 q + p q^2 \\ \sigma_{(X_i)}^2 &= p[q^2 + p q] = p q [p + q] = p q [1] = p q \end{aligned}$$

p_i	q_i	$p_i q_i$ (variance d'items)	Écart-type
0,0	1,0	0,00	0,00
0,1	0,9	0,09	0,30
0,2	0,8	0,16	0,40
0,3	0,7	0,21	0,46
0,4	0,6	0,24	0,49
0,5	0,5	0,25	0,50
0,6	0,4	0,24	0,49
0,7	0,3	0,21	0,46
0,8	0,2	0,16	0,40
0,9	0,1	0,09	0,30
1,0	0,0	0,00	0,00

→ La variance observée d'un test sera maximale si et seulement si :

- 1) Les items ont tous un % de réussite égale à 0,50 ;
- 2) Les corrélations inter-items sont toutes égales à 1

Au fur et à mesure que la difficulté des items s'écarte de 0,50 et que les corrélations entre items s'éloignent de 1, la variance diminuera ⇒ La difficulté des items influence la valeur de la variance et, par conséquent, la forme de la distribution des scores observés.

Ainsi :

- Si le test ne comprend que des questions difficiles, on observera une distribution des scores totaux en i. Un grand nombre d'individus obtiendront des résultats très faibles, et seulement les individus les plus compétents se détacheront du reste de la distribution
⇒ permet de distinguer les individus très compétents des autres individus, mais ne permet pas de différencier les individus faibles ou moyens des individus les plus faibles.
- Si le test comporte à la fois des questions faciles, moyennes et difficiles, la distribution des scores observés, pour autant que les corrélations entre items en moyenne avoisinent les 0,30, s'apparentera à une distribution normale ⇒ permet d'offrir une discrimination acceptable tout au long du continuum.
- Si le test ne comporte que des questions faciles, alors la majorité des individus obtiendront un score très élevé ⇒ permet de différencier les individus

⚠ **Une distribution normale des scores observés ne peut, en aucun cas, être considérée comme une preuve de la normalité du trait latent.**

2. DÉFINITION DU SCORE VRAI

X_t = score observé

X_∞ = score vrai

X_e = score d'erreur (variable aléatoire qui résulte de différentes sources (conditions expé, etc))

→ On peut écrire : $X_t = X_\infty + X_e$

Le score observé, le score vrai et le score d'erreur se situent sur la même échelle. Il peut s'agir des points obtenus à un test, du nombre d'erreurs enregistrées à une épreuve, ...

On peut définir le score vrai X_∞ de trois manières :

1. X_∞ est le score qu'un individu obtiendrait dans des conditions idéales avec un instrument parfait. Cependant, un tel instrument de mesure n'existe pas.
2. X_∞ est la moyenne des scores obtenus par un sujet au départ d'un grand nombre d'administrations indépendantes du même instrument. Plus le nombre de mesures augmente, plus la moyenne converge vers le score vrai.
3. Le score vrai est assimilé à la valeur attendue du score observé.

3. POSTULATS DE BASE DE LA THÉORIE CLASSIQUE DU SCORE VRAI

Postulat : principe premier, indémontrable et non démontré ; règle que l'on accepte sans pour autant être en mesure de vérifier sa véracité.

L'utilité des postulats réside dans les développements théoriques qu'ils autorisent.

POSTULAT N°1

La moyenne des erreurs commises est égale à 0

$$\mu_{X_e} = 0$$

En d'autres termes, les erreurs de mesure s'annulent : aucun sujet n'est systématiquement avantagé / désavantagé. « Il n'existe pas de biais systématiques qui conduiraient à surestimer ou sous-estimer les différents sujets qui font l'objet d'une mesure » ⇒ la mesure est dite 'non-biaisée'


POSTULAT N°2	
La corrélation (et la covariance) entre les scores vrais et les scores d'erreur est égale à 0 $\rho_{(X_{\infty}, X_e)} = 0$	Il n'existe pas de mécanismes qui conduiraient : • À surestimer, par exemple, les sujets compétents et sous-estimer les sujets peu compétents (dans ce cas, la corrélation serait positive) ; • À surestimer, par exemple, les sujets peu compétents et sous-estimer les sujets compétents (dans ce cas, la corrélation serait négative) ⇒ Les erreurs de mesure ne dépendent pas du niveau réel de compétence d'un individu
POSTULAT N°3	
Les différents types d'erreurs sont indépendants $\rho_{(X_{ei}, X_{ej})} = 0$	Les corrélations (et la covariance) entre erreurs sont toutes nulles : les erreurs commises lors d'une mesure ne corréleront pas avec les erreurs commises lors d'une autre administration ⇒ La mesure en tant que telle n'affecte pas la caractéristique mesurée du sujet

4. DÉVELOPPEMENTS AUTORISÉS PAR LES POSTULATS : LA FIDÉLITÉ

$\sigma_{(X_t)}^2 = \sigma_{(X_{\infty} + X_e)}^2$ $\sigma_{(X_t)}^2 = \sigma_{(X_{\infty})}^2 + \sigma_{(X_e)}^2 + 2\text{cov}(X_{\infty}, X_e)$ $\sigma_{(X_t)}^2 = \sigma_{(X_{\infty})}^2 + \sigma_{(X_e)}^2$	En effet, la corrélation (et la covariance) entre le score vrai et le score d'erreur est égale à 0 La variance totale est égale à la somme de la variance vraie et la variance erreur
---	---

Comme toute variance, la variance d'erreur est positive ou nulle. Cependant, une variance d'erreur nulle signifierait aussi que tous les scores d'erreurs soient nuls = instrument parfait. Comme un tel instrument n'existe pas, **la variance d'erreur sera toujours plus grande que 0.**

DISTRIBUTION DES SCORES VRAIS ET DES SCORES OBSERVÉS



Comme une erreur entache chaque mesure, certains des étudiants peu performants voient leur score surestimé tandis que d'autres tout aussi peu performants voient leur score sous-estimé (de même pour les élèves très performants)

L'amplitude des scores observés est plus élevée que l'amplitude des scores vrais donc...

⇒ **La variance observée sera plus élevée que la variance vraie**

Plus l'instrument de mesure sera imprécis, plus la variance d'erreur sera importante et plus la distribution des scores observés s'écartera aux extrémités de la distribution des scores vrais.

Fidélité d'un test ρ_{tt} = corrélation d'un test avec lui-même

Plus un test est fidèle, plus les corrélations entre les scores d'un individu lors de différentes administrations seront élevées (corrélation de 1 = fidélité parfaite)

$$\begin{aligned}
 \text{Corr}(T_1, T_2) &= \frac{\text{COV}(T_1, T_2)}{\sqrt{\sigma_{T_1}^2 \sigma_{T_2}^2}} = \frac{\text{COV}(X_{\infty} + X_{e1}, X_{\infty} + X_{e2})}{\sqrt{(\sigma_{X_{\infty}}^2 + \sigma_{X_{e1}}^2)(\sigma_{X_{\infty}}^2 + \sigma_{X_{e2}}^2)}} \\
 &\quad \text{Les corrélations qui font intervenir au moins 1 erreur = 0} \\
 &= \frac{\text{COV}(X_{\infty}, X_{\infty}) + \text{COV}(X_{\infty}, X_{e2}) + \text{COV}(X_{e1}, X_{\infty}) + \text{COV}(X_{e1}, X_{e2})}{\sqrt{(\sigma_{X_{\infty}}^2 + \sigma_{X_{e1}}^2)(\sigma_{X_{\infty}}^2 + \sigma_{X_{e2}}^2)}} \\
 &= \frac{\sigma_{X_{\infty}}^2}{\sigma_{X_{\infty}}^2 + \sigma_{X_{e1}}^2} = \frac{\sigma_{X_{\infty}}^2}{\sigma_{X_i}^2} \\
 &\Rightarrow \text{Corr}(X_{\infty}, X_i) = \frac{\sigma_{X_{\infty}}^2}{\sqrt{\sigma_{X_{\infty}}^2 \sigma_{X_i}^2}} \\
 &\Rightarrow \text{Corr}(X_{\infty}, X_i) = \frac{\sigma_{X_{\infty}}^2}{\sigma_{X_i}^2} = \frac{\sigma_{X_{\infty}}^2}{\sigma_{X_i}^2} \\
 &\quad \text{corrélation avec lui-même}
 \end{aligned}$$

→ Proportion de variance des scores vrais par rapport à la variance des scores observés

= pourcentage de vrai dans ce qui est observé

$$\rho_{tt} = \frac{\sigma_{(X_{\infty})}^2}{\sigma_{(X_i)}^2} \Leftrightarrow \rho_{tt} = \frac{\sigma_{(X_{\infty})}^2}{\sigma_{(X_i)}^2} = \frac{\sigma_{(X_i)}^2 - \sigma_{(X_e)}^2}{\sigma_{(X_i)}^2} = \frac{\sigma_{(X_i)}^2}{\sigma_{(X_i)}^2} - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_i)}^2} = 1 - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_i)}^2}$$

On peut donc estimer la **variance et l'écart-type des scores vrais**


$$\begin{aligned}
 \sigma_{(X_{\infty})}^2 &= \rho_{tt} \sigma_{(X_i)}^2 \\
 \sigma_{(X_{\infty})} &= \sqrt{\rho_{tt} \sigma_{(X_i)}^2}
 \end{aligned}$$

Et celles des **scores erreurs**

$$\begin{aligned}
 \sigma_{(X_e)}^2 &= \sigma_{(X_i)}^2 (1 - \rho_{tt}) \\
 \sigma_{(X_e)} &= \sigma_{(X_i)} \sqrt{1 - \rho_{tt}}
 \end{aligned}$$

L'écart-type des scores d'erreurs, « *erreur standard de mesure* », traduit l'incertitude associée à l'estimation du trait latent mesuré. La distribution du score d'erreur // distribution normale.

Il est possible d'utiliser les propriétés mathématiques de cette distribution théorique pour construire un intervalle de confiance autour d'une estimation individuelle.



Cette distribution des scores d'erreurs autour d'une estimation individuelle traduit la variabilité des différents scores observés possibles pour un individu

5. FIDÉLITÉ D'UN TEST ET LONGUEUR

Un test qui comporte 100 questions devrait être plus précis qu'un test qui comporte seulement 10 questions. Ainsi, plus un test sera long (pour autant qu'il mesure une seule et même compétence), plus il sera fidèle.

La **formule de Spearman-Brown** permet **d'estimer la fidélité d'un test dont la longueur serait multipliée (ou divisée) par un coefficient n**. Cette formule suppose l'homogénéité du test, c-à-d que tous les items mesurent une seule et même compétence.

La fidélité d'un test dont la longueur est multipliée par un coefficient n sera égale à :

$$\rho_{nt} = \frac{n\rho_{tt}}{1 + (n-1)\rho_{tt}}$$

⇒ permet d'exprimer la fidélité attendue d'un test n fois plus long que le test original à partir de la fidélité de celui-ci

- * La valeur n ne doit pas nécessairement être un nombre entier et peut être comprise entre 0 et 1
- * Cette formule permet également de calculer la fidélité d'un test dont on supprime une partie des items

Cette formule, par transformation, permet également de déterminer le nombre d'items nécessaire pour atteindre une fidélité donnée. Le coefficient d'allongement est égal à :

$$n = \frac{\rho_{nt}(1 - \rho_{tt})}{\rho_{tt}(1 - \rho_{nt})}$$

ρ_{nt} = fidélité que je veux atteindre

ρ_{tt} = fidélité actuelle

n = coefficient (utilisé pour multiplier / diviser le nombre d'items actuels)

6. OPÉRATIONNALISATION DU CALCUL DE LA FIDÉLITÉ

Il existe 3 grandes méthodes de calcul de la fidélité

- 1) Les méthodes test-retest
- 2) Les méthodes de consistance interne
 - a. Rulon
 - b. Pairs-impairs
 - c. KR
 - d. Alpha de Cronbach
 - e. Scores composites
- 3) Les formes mixtes ou formes parallèles

1) LES MÉTHODES TEST-RETEST

Le concept clé de ces méthodes est la **stabilité dans le temps** (corrélation 1^{ère} – 2^{ème} admin°)

- Une corrélation élevée signifie que le classement des individus demeure stable à travers le temps
- Si la moyenne et l'écart-type observés lors de la 1^{ère} et de la 2^{ème} administration restent stables, on peut déduire que les scores des individus restent inchangés à travers le temps (à l'exception d'une erreur de mesure)

Cette méthode présuppose que le trait latent mesuré

- n'est pas susceptible d'évoluer à travers le temps
- ou du moins que les individus n'ont pas fait l'objet d'un enseignement
- ou qu'ils n'ont pas eu l'occasion de s'exercer afin d'améliorer leur performance

Pour **estimer la fidélité** selon la méthode Test-retest, un même échantillon d'individus doit répondre au même test à 2 reprises. La fidélité sera dès lors estimée par le **coefficient de corrélation de Bravais-Pearson**

2) LES MÉTHODES DE CONSISTANCE INTERNE

Les méthodes basées sur le postulat de consistance interne ont comme présupposés de base :

1. Soit les items du test mesurent tous le même trait latent ;
2. Soit les différents sous-tests qui composent la batterie du test mesurent le même trait latent

Avantage de ces méthodes : elles ne requiert qu'une seule administration

a) La méthode de Rulon

La méthode consiste à :

- Diviser le test en 2 parties (sous-tests) qui comportent le même nombre d'items
- Calculer le score obtenu par chaque individu aux deux sous-tests
- Calculer la différence entre ces 2 scores (scores de différence)
- Calculer la variance des différences, notée σ^2_d et considérée comme variance d'erreur
- Calculer la fidélité selon la formule de Rulon

$$\rho_{tt} = 1 - \frac{\sigma^2_{(X_{diff})}}{\sigma^2_{(X_t)}}$$

Retour sur cette matrice de données...

Ici, on a choisi comme sous-tests de séparer les items pairs des items impairs (on aurait pu faire autrement)

	It_1	It_2	It_3	It_4	It_5	It_6	It_7	It_8	It_9	It_10	Total	Items Impairs	Items Pairs	dif
Sujet 1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Sujet 2	1	0	0	0	0	0	0	0	0	0	1	1	0	1
Sujet 3	1	1	0	0	0	0	0	0	0	0	2	1	1	0
Sujet 4	1	1	1	0	0	0	0	0	0	0	3	2	1	1
Sujet 5	1	1	1	0	1	0	0	0	0	0	4	3	1	2
Sujet 6	1	1	1	1	1	0	0	0	0	0	5	3	2	1
Sujet 7	1	1	1	1	1	0	1	0	0	0	6	4	2	2
Sujet 8	1	1	1	1	1	1	1	0	0	0	7	4	3	1
Sujet 9	1	1	1	1	1	1	1	0	1	0	8	5	3	2
Sujet 10	1	1	1	1	1	1	1	1	1	0	9	5	4	1
Sujet 11	1	1	1	1	1	1	1	1	1	1	10	5	5	0
Nombre de bonnes réponses	10	9	8	6	7	4	5	2	3	1	55	33	22	11

Pour calculer l'indice de fidélité selon la méthode de Rulon, il faut :

1. Calculer la moyenne du score total ;

$$\mu_{(X_t)} = \frac{1}{n} \sum_{i=1}^n X_t = \frac{55}{11} = 5$$

2. Calculer la variance du score total ;

$$\sigma_{(X_t)}^2 = \frac{1}{n} \sum_{i=1}^n (X_t - \mu_{(X_t)})^2 = \frac{[(0-5)^2 + \dots + (10-5)^2]}{n} = \frac{110}{11} = 10$$

3. Calculer la moyenne des différences ;

$$\mu_{(X_{dif})} = \frac{1}{n} \sum_{i=1}^n X_{dif} = \frac{11}{11} = 1$$

4. Calculer la variance des différences ;

$$\sigma_{(X_{dif})}^2 = \frac{1}{n} \sum_{i=1}^n (X_{dif} - \mu_{(X_{dif})})^2 = \frac{[(0-1)^2 + \dots + (0-1)^2]}{n} = \frac{6}{11} = 0.545$$

5. Calculer l'indice de fidélité ;

$$\rho_{tt} = 1 - \frac{\sigma_{(X_{dif})}^2}{\sigma_{(X_t)}^2} = 1 - \frac{0.545}{10} = 0.945$$

Remarques :

- Selon le regroupement des items opéré pour constituer les 2 sous-tests, l'estimation de la fidélité peut varier
- Constituer 2 sous-tests qui ne comportent pas le même nombre d'items va également amplifier la variance des différences et diminuer l'indice de fidélité

b) La méthode pairs – impairs

La méthode consiste à :

- Regrouper les items en 2 sous-tests en **imposant** que le regroupement soit opéré sur la base des items pairs et des items impairs
- Calculer la corrélation entre les 2 sous-tests
- Corriger la corrélation en utilisant la formule de Spearman-Brown.

Pour calculer l'indice de fidélité selon la méthode pairs-impairs, il faut :

1. Calculer la moyenne des scores aux items pairs ;
2. Calculer la variance aux items pairs ;
3. Calculer la moyenne des scores aux items impairs ;
4. Calculer la variance aux items impairs ;
5. Calculer la covariance entre les scores aux items pairs et aux items impairs :

$$Cov(X_{pairs}, X_{impairs}) = \frac{1}{n} \sum_{i=1}^n [(X_{pairs} - \mu_{(X_{pairs})})(X_{impairs} - \mu_{(X_{impairs})})]$$

$$Cov(X_{pairs}, X_{impairs}) = 2.36$$

6. Calculer la corrélation entre les scores aux items pairs et aux items impairs

$$\rho_{(X_{pairs}, X_{impairs})} = \frac{Cov(X_{pairs}, X_{impairs})}{\sqrt{\sigma_{(X_{pairs})}^2 \sigma_{(X_{impairs})}^2}} = \frac{2.36}{\sqrt{2.91 * 2.36}} = 0.90$$

7. Corriger la corrélation par la formule de Spearman-Brown

$$\rho_{nt} = \frac{n\rho_{tt}}{1 + (n-1)\rho_{tt}} = \frac{2(0.90)}{1 + (2-1)(0.90)} = \frac{1.8}{1.9} = 0.95$$

Remarque :

- Si les variances des scores aux items pairs et aux items impairs sont identiques, alors la fidélité obtenue via la formule de Rulon ou par l'intermédiaire de la formule de Spearman-Brown sont identiques.

c) Les méthodes de Kuder-Richardson

Ces deux méthodes consistent à :

- Découper le test en 'k' parties de 1 item
- Postulat : tous les items mesurent le même trait latent (1 seule même dimension)
- Elles s'appliquent aux **items dichotomiques**

KR 20

Pour calculer l'indice de fidélité selon la méthode du KR20, il faut

1. Calculer la variance du score total
2. Calculer la variance des k items qui composent le test ($p_i q_i$)
3. Calculer l'indice de fidélité

$$\rho_{tt} = kr20 = \frac{k}{k-1} \frac{\left(\sigma_t^2 - \sum_{i=1}^k p_i q_i \right)}{\sigma_t^2}$$

KR21

Pour calculer l'indice de fidélité selon la méthode du KR21, il faut

1. Calculer le pourcentage moyen de réussite et le pourcentage moyen d'échec

$$p_m = \frac{\sum_{i=1}^k p_i}{k}$$

$$q_m = 1 - p_m$$

2. Calculer l'indice de fidélité

$$\rho_{tt} = kr21 = \frac{k}{k-1} \frac{(\sigma_{(X_t)}^2 - k p_m q_m)}{\sigma_{(X_t)}^2}$$

d) Alpha de Cronbach

Cette méthode...

- ne se limite pas aux items dichotomiques → peut également s'appliquer aux items à crédit partiel (0, 1, 2, ...) et aux échelles de Likert
- s'utilise si et seulement si cette batterie évalue une seule variable latente
- La formule correspond à celle de KR, excepté que les $p_i q_i$ ont été remplacés par σ_i^2 (variance totale)

Utilisation dans deux types de situation

- Calculer la fidélité d'une batterie composée de k sous-tests

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2} \quad k = \text{nombre de sous-tests}$$

NB : cette formule est sensible à la variance respective des différents sous-tests : plus la variance d'un test est élevée, plus la contribution de ce sous-test sera importante. Pour neutraliser l'effet des variances de chacun des sous-tests dans le calcul de la fidélité, Cronbach a développé un coefficient standardisé qui attribue à chaque sous-test le même poids (*formule à utiliser en cas d'hétérogénéité des variances*)

$$\alpha = \frac{k\bar{\rho}}{1 + ((k-1)\bar{\rho})} \quad \text{Avec } \bar{\rho} = \text{moyenne des corrélations entre k sous-tests}$$

- Un seul test, mais les items qui composent le test ne sont pas dichotomiques (échelles de Likert). Le score total d'un sujet correspond à la somme des scores obtenus à chacun des items. La formule est la même :

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2}$$

e) La fidélité des scores composites

Moiser a développé une formule qui permet d'estimer la fidélité d'un score composite au départ des fidélités de chacun des sous-tests

$$\rho_{cc} = 1 - \frac{\sum p_j^2 \sigma_j^2 - \sum p_j^2 \sigma_j^2 \rho_{jj}}{\sum p_j^2 \sigma_j^2 + 2 \sum \sum p_j p_k \sigma_j \sigma_k \rho_{jk}} \quad \rho = 1 - \frac{\text{variance d'erreur}}{\text{variance totale}}$$

Cette formule permet de calculer la fidélité du score composite obtenu en combinant deux / plusieurs tests

Les indices j et k font référence à deux tests particuliers (valeur de k > valeur de j)

Éléments composant la formule

- σ_t^2 : variance du score total à chacun des sous-tests j
- ρ_{jj} : fidélité de chacun des sous-tests j
- p_j : poids attribué à chaque sous-test j dans le calcul du score global

Cette formule, de prime abord rébarbative, peut se comprendre aisément. Premièrement, l'ensemble de la formule s'apparente à la définition générale de la fidélité, à savoir

$$\rho_{tt} = 1 - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2}$$

Le dénominateur de la fraction n'est rien d'autre que la variance du score global à la batterie de tests et est obtenu par la formule généralisée de :

$$\sigma_{(A+B)}^2 = \sigma_{(A)}^2 + \sigma_{(B)}^2 + 2\rho_{(A,B)} \sigma_{(A)} \sigma_{(B)}$$

Enfin, le numérateur de la fraction peut également s'écrire :

$$\sum p_j^2 \sigma_j^2 (1 - \rho_{jj})$$

En d'autres termes, il s'agit de la somme pondérée des variances d'erreurs de chacun des sous-tests j.

3) LES MÉTHODES MIXTES OU MÉTHODES DE FORMES PARALLÈLES

Mesure de l'équivalence du contenu psychologique mesuré aux moyens de deux formes de tests parallèles, censés mesurer le même trait latent

⇒ Présenter ces deux formes parallèles à une certaine distance temporelle = mesurer à la fois la consistance interne et la stabilité dans le temps

4) VARIANCES VRAIE ET VARIANCE D'ERREUR

Méthodes	Variance vraie	Variance d'erreur
Consistance interne	Covariance entre items ou groupes interne d'items à l'intérieur d'un même test	Les items (ou groupes d'items) ne mesurent pas la même chose
Test-retest	Covariance entre les résultats du test présenté à deux occasions (test et retest)	A deux occasions, des résultats supposés identiques diffèrent en raison de conditions extérieures (fatigue différente = aléatoire car variable d'un sujet à l'autre / effet de testing = systématique, la mémorisation jouant plus ou moins fortement selon la nature du test)
Formes parallèles	Covariance entre les deux formes à deux moments différents	A deux occasions, les résultats diffèrent (cf. test-retest) Les résultats aux deux formes diffèrent (cf. différences à l'intérieur d'un même test, comme dans l'étude de la consistance interne)

7. L'ANALYSE D'ITEMS

Le calcul du coefficient de fidélité par des méthodes de consistance interne peut révéler un manque d'unidimensionnalité du test. Si un / plusieurs items présentent des corrélations faibles avec les autres items, la fidélité du test diminuera. Il importe donc pour assurer l'unidimensionnalité de la mesure de vérifier si les items mesurent bien tous le même trait latent ⇒ étudier les propriétés psychométriques des items.

Trois indices sont pris en considération :

1. L'indice de difficulté
2. L'indice de discrimination
3. Fonctionnement différentiel de l'item

7.1 L'INDICE DE DIFFICULTÉ

Si l'item est corrigé de manière dichotomique (0, 1), l'indice le + élémentaire est le pourcentage de réponses correctes (p_i) ⇒ constitue un indice de difficulté moyenne pour l'ensemble des individus testés = probabilité de réussite de l'item pour les différents individus testés

Dans le cadre d'un item avec +2 modalités de réponses (0, 1 et 2 par ex), l'indice de difficulté moyen peut s'obtenir en multipliant les pourcentages par leurs scores respectifs, puis en faisant la somme de ces produits, et en divisant le tout par le score maximum

Par exemple, si 20% des élèves obtiennent un score nul, 50% un score de 1 et 30% un score de 2, l'indice moyen de difficulté p_i sera égal à

$$p_i = \frac{(0.20 \cdot 0) + (0.50 \cdot 1) + (0.30 \cdot 2)}{2} = 0,55$$

En règle générale, les tests ont pour objectif de différencier les individus → on va privilégier les items dont les indices de difficulté varient de 0,15 à 0,85

Dans le cadre des QCM, il est possible d'obtenir une réponse correcte en choisissant au hasard. Ces réponses au hasard constituent une erreur de mesure et réduisent la fidélité du test.

Il existe plusieurs méthodes pour réduire / contrôler ces phénomènes de réponses au hasard :

- Augmentation du nombre de solutions proposées
- Ajout de solutions « toutes » ; « aucune »
- **Pénalisation des réponses fausses**
- Utilisation de degrés de certitude (créditent les réponses en fonction de la confiance que les sujets déclarent accorder à leur réponse)

Pénalisation des réponses fausses

Hypothèse : toutes les réponses incorrectes résultent d'un choix au hasard

Un individu qui répond uniquement au hasard à n QCM comportant k solutions proposées

Pour chaque question répondue au hasard, l'individu a $\frac{1}{k}$ chance de trouver la bonne réponse

Au total, l'individu obtiendra $n \cdot \frac{1}{k}$ réponses correctes

→ On se connaît pas n (nombre de réponses au hasard)

→ Par contre, on connaît le nombre de réponses incorrectes x

$$\Leftrightarrow x = n - \left(n \cdot \frac{1}{k}\right)$$

Pour que le score d'un individu traduise uniquement le nombre de réponses correctes obtenues en ne choisissant pas au hasard, il faut appliquer une pénalité de $-\frac{1}{k-1}$ par réponse incorrecte

Faiblesses :

- si un étudiant répond incorrectement sans choisir au hasard, il se verra indûment pénalisé
- cette correction ne prend pas en considération la chance variable d'un individu à l'autre
- pose l'hypothèse que les différentes solutions proposées ont le même pouvoir d'attraction ; si ce n'est pas le cas (solutions absurdes, etc) la correction sera trop peu sévère

Au niveau de l'item, le pourcentage moyen de réussite corrigé pour choix au hasard :

$$p_c = p_r - \frac{p_e}{k-1}$$

7.2 L'INDICE DE DISCRIMINATION

Pour accroître la fidélité d'un test, il importe de maximaliser la corrélation entre items

Une procédure (+ économique que de réaliser chaque corrélation entre tous les items) consiste à vérifier que l'item mesure bien la même chose que le test dans sa globalité

→ Corrélation Pearson entre l'item et le score total

En présence d'un item dichotomique, la corrélation Pearson se simplifie

Dans ce cas, on parle de corrélation bisériale de point

$$r_{pbis} = \frac{M_r - M_e}{\sigma_{(X_t)}} \sqrt{p_i q_i}$$

M_r : moyenne des scores totaux pour les seuls sujets qui ont réussi l'item i

M_e : moyenne des scores totaux pour les seuls sujets qui ont échoué à l'item i ;

$\sigma_{(X_t)}$: écart type du score total

$\sqrt{p_i q_i}$: écart type de l'item

En règle générale, on retiendra dans un test tous les items qui ont une corrélation bisériale de point supérieure à 0,25

7.3 LE FONCTIONNEMENT DIFFÉRENTIEL DE L'ITEM (DIF)

On observe un DIF lorsque, à niveau équivalent de compétence, des sujets appartenant à différents groupes (sexe, âge, pays) ont des probabilités différentes de réussir l'item.

Statistiquement, dans le cadre de la théorie classique du score vrai, la détection de DIF peut être réalisée au départ d'un tableau, par l'intermédiaire d'un test khi carré d'indépendance (attention que ce test exige au minimum 5 observations par cellule – peut être une contrainte)

La régression logistique offre une alternative intéressante ; elle s'apparente à la régression linéaire classique, si ce n'est que la VD est une variable dichotomique (codes 0 et 1)

Par exemple, la variable dépendante peut indiquer si l'individu a ou n'a pas eu de crise cardiaque (0 ou 1), et les variables indépendantes constitueront les différents facteurs de risque (poids, âge, régime alimentaire, consommation tabac / alcool, etc)

La modélisation se réalise sur un échantillon et ultérieurement, on peut, grâce aux valeurs des différents VI, calculer la probabilité pour un individu donné, de présenter un arrêt cardiaque


Dans le cadre du DIF, la réponse à un item, codée 0 ou 1, constitue la variable dépendante
 Comme première variable indépendante on retrouve le score total des individus
 Comme deuxième variable indépendante, la caractéristique pour laquelle on souhaite déterminer l'impact sur l'item

Pour modéliser l'interaction entre les deux VI (score et caractéristique individuelle), on teste si la discrimination varie entre les deux groupes

Plus la compétence d'un sujet augmente, plus sa probabilité de réussir augmente aussi

L'inclinaison des courbes est proportionnelle à la discrimination de l'item
(plus un item discrimine les élèves, plus la pente de la courbe sera élevée et inversement)

DIF uniforme	DIF non-uniforme
Les deux courbes sont parallèles, indiquant une discrimination identique entre les deux groupes À compétences égales, la probabilité de réussite à l'item pour un groupe est toujours supérieure à la probabilité de l'autre	Les deux courbes ne sont pas parallèles La pente de l'une est + élevée que l'autre Avant le croisement des deux courbes, à compétences égales, le premier groupe a une probabilité + élevée de réussir l'item, et inversement après le croisement



8. CONCLUSION

La théorie classique du score vrai est mise en œuvre dans un grand nombre de situations. Ce modèle permet d'estimer la fidélité de la mesure, mais aussi d'identifier aisément les items qui semblent ne pas convenir au construit

Les limites essentielles sont celles-ci :

- Elle ne permet pas de modéliser la probabilité de réussite d'un individu en particulier (rôle des modèles de réponse à l'item, ch.6)
- Elle ne propose pas de solutions satisfaisantes dans le cadre d'un plan d'évaluation incomplet

CHAPITRE 6 : LES MODÈLES DE RÉPONSE À L'ITEM

1. INTRODUCTION

La théorie classique du score vrai ne prend en compte les caractéristiques des items pour estimer la performance du sujet. En revanche, avec les **modèles de réponse à l'item**, l'estimation de la performance des sujets dépend à la fois de leurs réponses ET des **propriétés psychométriques des items** qui leur ont été administrés

→ Il est dès lors possible de rapporter la performance des sujets à des tests partiellement différents sur un seul et même continuum et ainsi, de les comparer.

Il existe de nombreux modèles de réponse à l'item, que l'on peut différencier selon...

- Le nombre de paramètres utilisés pour caractériser les items
- Le nombre de dimensions latentes
- Le nombre de catégories par réponse
- La fonction mathématique utilisée

Ce chapitre se concentrera sur le **modèle de Rasch**, modèle logistique à 1 paramètre

2. LE MODÈLE RASCH POUR LES ITEMS DICHOTOMIQUES


2.1 INTRODUCTION

Mise en situation (voir pp110,111)

2.2 DESCRIPTION DU MODÈLE DE RASCH

Le modèle de Rasch (ainsi que les autres modèles de réponse à l'item), crée un continuum sur lequel seront localisées à la fois la performance des élèves et la difficulté de l'item, liées entre elles par une fonction probabilistique.

Cette figure présente la **probabilité de réussir (courbe grise)** et la **probabilité d'échec (courbe noire)** pour un item de difficulté de 0 :



- Un élève avec une aptitude de 0 a une probabilité de réussite et d'échec de 0,5
- Un élève avec une aptitude de -2 a une probabilité de réussir de 0,10 et une probabilité d'échec de 0,90
- Ce même élève (aptitude -2), pour un item d'une difficulté -2 (on décale les courbes de 2 unités vers la gauche) aura une probabilité de réussite et d'échec de 0,5

D'un point de vue mathématique, la **probabilité de réussite** pour élève i , avec une aptitude β_i , à un item j de difficulté δ_j est égale à :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = \frac{\exp(\beta_i - \delta_j)}{1 + \exp(\beta_i - \delta_j)}$$

La **probabilité d'échec** est égale à :

$$P(X_{ij} = 0 | \beta_i, \delta_j) = \frac{1}{1 + \exp(\beta_i - \delta_j)}$$

On peut démontrer que la somme de la probabilité de réussite et de la probabilité d'échec est toujours égale à 1

$$P(X_{ij} = 1 | \beta_i, \delta_j) + P(X_{ij} = 0 | \beta_i, \delta_j) = 1$$

À partir de ces formules, on peut déduire que, quel que soit l'endroit où se situent l'aptitude de l'élève et la difficulté de l'item sur le continuum... (*NB : une unité de Rasch = un 'logit')

Lorsque l'aptitude de l'élève est égale à la difficulté de l'item $\Leftrightarrow p = 0,5$

Aptitude élève = 0	Difficulté item = 0	Probabilité réussite = 0,5
--------------------	---------------------	----------------------------

Lorsque l'aptitude de l'élève est inférieure d'1 logit* à la difficulté de l'item $\Leftrightarrow p = 0,27$

Aptitude élève = -1	Difficulté item = 0	Probabilité réussite = 0,27
---------------------	---------------------	-----------------------------

Lorsque l'aptitude de l'élève est supérieure d'1 logit à la difficulté de l'item $\Leftrightarrow p = 0,73$

Aptitude élève = 1	Difficulté item = 0	Probabilité réussite = 0,73
--------------------	---------------------	-----------------------------

Lorsque l'aptitude de l'élève est inférieure de 2 logit à la difficulté de l'item $\Leftrightarrow p = 0,12$

Aptitude élève = -2	Difficulté item = 0	Probabilité réussite = 0,12
---------------------	---------------------	-----------------------------

Lorsque l'aptitude de l'élève est supérieure de 2 logit à la difficulté de l'item $\Leftrightarrow p = 0,88$

Aptitude élève = 2	Difficulté item = 0	Probabilité réussite = 0,88
--------------------	---------------------	-----------------------------

On peut conclure que **le seul facteur influençant la probabilité de réussite est la différence entre l'aptitude de l'élève et la difficulté de l'item** sur le continuum de Rasch

On remarque une certaine **symétrie** de l'échelle

-2 unités	-1 unité	égalité	+1 unité	+2 unités
0,12	0,27	0,5	0,73	0,88

2.3 CALIBRATION

Dans un contexte réel, la réponse est soit exacte, soit erronée ; quelle est la signification de cette 'probabilité de réussite de 0,5' en termes de réponses correctes ou non ?

- Si 100 élèves d'aptitude 0 doivent répondre à un item de difficulté 0, le modèle prévoit 50 réponses exactes et 50 réponses erronées
- Si 1 élève d'aptitude 0 doit répondre à 100 item de difficulté 0, le modèle prévoit 50 réponses exactes et 50 réponses erronées

Le modèle de Rasch permet, via une fonction probabilistique, de situer l'aptitude des sujets et la difficulté des items sur un même continuum → il faut construire ce continuum, sur lequel la difficulté d'un item sera située

Dans le cadre de ce chapitre, une méthode approchée d'estimation telle que décrite par Rasch sera décrite à travers un *exemple* ; cette méthode donne des résultats satisfaisants dans le cadre d'un plan de test complet (pour les plans de test incomplets, des méthodes d'estimation des paramètres d'items doivent être utilisées – pas décrites dans ce cours)

Ce tableau présente le pourcentage de réponses correctes d'un échantillon de 818 sujets à un test de 10 items, en fonction des scores obtenus

	Scores possibles au test de 10 items								
	1 (18)	2 (40)	3 (96)	4 (101)	5 (132)	6 (133)	7 (111)	8 (88)	9 (68)
Item 1	0.39	0.40	0.69	0.81	0.89	0.86	0.94	0.98	1.00
Item 2	0.22	0.57	0.63	0.75	0.85	0.91	0.91	0.97	0.96
Item 3	0.11	0.18	0.28	0.46	0.62	0.79	0.86	0.90	0.99
Item 4	0.00	0.13	0.38	0.52	0.61	0.74	0.87	0.93	0.97
Item 5	0.00	0.15	0.34	0.39	0.52	0.69	0.82	0.85	0.93
Item 6	0.11	0.18	0.14	0.30	0.34	0.54	0.60	0.80	0.91
Item 7	0.01	0.15	0.19	0.21	0.32	0.56	0.64	0.67	0.87
Item 8	0.01	0.01	0.16	0.25	0.39	0.32	0.54	0.61	0.87
Item 9	0.00	0.01	0.15	0.23	0.27	0.34	0.49	0.73	0.85
Item 10	0.00	0.10	0.01	0.01	0.19	0.24	0.32	0.57	0.66

- ➔ Seuls les scores 1 à 9 sont repris car les scores nuls / parfaits ne peuvent pas intervenir dans le calcul de la difficulté des items (ils n'apportent aucune information utile sur les différences entre items)
- ➔ La probabilité de réussite augmente plus le score des individus augmente (difficulté croissante : les items sont de + en + compliqués)
- ➔ Parmi les sujets ayant obtenu le score de 1 au test de 10 items, 39% ont réussi l'item 1 ; alors que parmi les sujets ayant obtenu un score de 7, 94% ont réussi l'item 1

Dans un premier temps, les pourcentages de réussite doivent être transformés en *logit*

$$\text{Logit}(p) = \ln\left(\frac{p}{1-p}\right)$$

Ce tableau présente la conversion des pourcentage de réussite *logit*, par item et par score

	Score 1	Score 2	Score 3	Score 4	Score 5	Score 6	Score 7	Score 8	Score 9	Moyenne	Difficulté Rasch
Item 1	-0,45	-0,41	0,80	1,45	2,09	1,82	2,75	3,89	4,84	1,87	-1,92
Item 2	-1,27	0,28	0,53	1,10	1,73	2,31	2,31	3,48	3,18	1,52	-1,57
Item 3	-2,09	-1,52	-0,94	-0,16	0,49	1,32	1,82	2,20	4,60	0,63	-0,68
Item 4	-3,48	-1,90	-0,49	0,08	0,45	1,05	1,90	2,59	3,48	0,41	-0,46
Item 5	-3,48	-1,73	-0,66	-0,45	0,08	0,80	1,52	1,73	2,59	0,04	-0,10
Item 6	-2,09	-1,52	-1,82	-0,85	-0,66	0,16	0,41	1,39	2,31	-0,30	0,25
Item 7	-3,48	-1,73	-1,45	-1,32	-0,75	0,24	0,58	0,71	1,90	-0,59	0,54
Item 8	-3,48	-4,60	-1,66	-1,10	-0,45	-0,75	0,16	0,45	1,90	-1,06	1,01
Item 9	-3,48	-4,60	-1,73	-1,21	-0,99	-0,66	-0,04	0,99	1,73	-1,11	1,06
Item 10	-3,48	-2,20	-4,60	-4,60	-1,45	-1,15	-0,75	0,28	0,66	-1,92	1,87
Moyenne	-2,68	-1,99	-1,20	-0,71	0,05	0,51	1,06	1,77	2,72	-0,05	
Compétence Rasch	-2,73	-2,04	-1,25	-0,76	0,00	0,46	1,01	1,72	2,67		

Les **moyennes des logit** sont ensuite calculées par item et par score (le calcul des moyennes ne prend pas en compte le nombre de sujets par colonne)

La **moyenne générale** est aussi calculée, au départ de la moyenne des items (0,05)

La **moyenne ajustée par item (difficulté Rasch)** est calculée : [moyenne générale] – [moyenne des logit d'un item]

L'**estimation de la compétence des sujets (compétence Rasch)** est calculée : [moyenne générale] + [moyenne des logit d'un score donné]

⇒ **Tous les sujets qui obtiennent un même score se voient attribuer la même compétence Rasch, indépendamment de quels items ont été réussis**

Exemple : un sujet qui obtient un score de 1 se verra attribuer le score Rasch de -2,73, qu'il ait réussi l'item le plus facile ou l'item le plus difficile

2.4 CALCUL DES SCORES : MÉTHODE DE MAXIMUM DE VRAISEMBLANCE (MLE)

Le modèle de Rasch fait l'hypothèse que les **items sont indépendants** (*indépendance locale des items*) = la probabilité de donner une réponse exacte à un item ne dépend pas des réponses données aux autres items

⇒ La probabilité d'observer un pattern de réponses donné est égale au produit des probabilités de chaque item

Considérons un test composé de 4 items de difficultés δ_j : -1 ; -0,5 ; 0,5 et 1

→ 16 patterns différents de réponses peuvent être obtenus

Score brut	Combinaisons de réponse
0	(0,0,0,0)
1	(1,0,0,0), (0,1,0,0), (0,0,1,0), (0,0,0,1)
2	(1,1,0,0), (1,0,1,0), (1,0,0,1), (0,1,1,0), (0,1,0,1), (0,0,1,1)
3	(1,1,1,0), (1,1,0,1), (1,0,1,1), (0,1,1,1)
4	(1,1,1,1)

Pour tout élève d'aptitude β_i , il est possible de calculer la probabilité de tous les patterns de réponses ; prenons l'exemple du pattern (1, 1, 0, 0) pour 3 élèves d'aptitudes -1, 0, 1

			$\beta_i = -1$	$\beta_i = 0$	$\beta_i = 1$
Item 1	$\delta_1 = -1$	Réponse=1	0,50	0,73	0,88
Item 2	$\delta_2 = -0,5$	Réponse=1	0,38	0,62	0,82
Item 3	$\delta_3 = 0,5$	Réponse=0	0,82	0,62	0,38
Item 4	$\delta_4 = 1$	Réponse=0	0,88	0,73	0,50
Probabilité d'obtenir la combinaison de réponses.			0,14	0,21	0,14

On calcule les probabilités de réussite des items 1 et 2 et d'échec des items 3 et 4 (formules ↑)

Exemple :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = P(X_{1,1} = 1 | -1, -1) \frac{\exp(-1 - (-1))}{1 + \exp(-1 - (-1))} = 0,5$$

Étant donné que ces 4 items sont considérés comme indépendants, la probabilité du pattern de réponses (1, 1, 0, 0) pour un élève d'aptitude -1 est égale à $0,50 \times 0,38 \times 0,82 \times 0,88 = 0,14$


→ un élève avec une aptitude de -1 a 14 chances sur 100 d'obtenir ce pattern de réponses

Ce procédé peut s'appliquer à un large éventail d'aptitudes d'élèves et à toutes les combinaisons de réponses possibles.

Sur base des mêmes items, la figure ci-contre représente la probabilité d'observer le pattern de réponses (1,1,0,0) pour toutes les aptitudes comprises entre -6 et +6


→ La valeur la plus probable est celle qui correspond à une aptitude de 0

→ Le modèle de Rasch estime donc l'aptitude de tous les élèves ayant obtenu cette combinaison de réponses à 0



La figure ci-contre présente la distribution des probabilités de toutes les combinaisons pour 1 seul item correct → 4 combinaisons possibles (1,0,0,0) ; (0,1,0,0) ; (0,0,1,0) ; (0,0,0,1)

- Pour tous les élèves qui n'ont réussi qu'un seul item, la combinaison la plus probable est (1,0,0,0 = item 1 étant le plus facile) et la moins probable est (0,0,0,1)
- L'estimation de la valeur de l'aptitude est la même, peu importe la combinaison de réponses
- Le modèle de Rasch donnera donc une valeur de -1,25 pour tout élève avec un score brut de 1, peu importe l'item auquel il a répondu




Ce type d'estimation des aptitudes selon le modèle de Rasch est habituellement appelé **estimation par maximum de vraisemblance** : à chaque score brut correspond 1 seul maximum de vraisemblance

La figure ci-contre présente la probabilité d'observer les 5 combinaisons de réponses les plus probables (0,0,0,0) ; (1,0,0,0) ; (1,1,0,0) ; (1,1,1,0) ; (1,1,1,1) en fonction des compétences des sujets

On observe que le modèle de Rasch ne peut pas estimer correctement l'aptitude des élèves qui obtiennent un score nul (0/4) ou un score parfait (4/4)

- Les maxima de vraisemblance (estimation des aptitudes) se situent à $-\infty$ et à $+\infty$
- Le test est trop difficile / trop facile pour estimer avec précision l'aptitude de l'élève




2.5 CALCUL DES SCORES DES ÉLÈVES : CAS DE PLANS DE TEST INCOMPLET

Plan incomplet : plan de test où différents sous-ensembles d'items sont attribués aux élèves

Les principes énoncés dans la section précédente pour calculer l'estimation de l'aptitude individuelle de chaque élève restent applicable dans le cas de plans incomplets

Supposons que deux élèves d'aptitude -1 et 1 doivent répondre à 2 des 4 items du tableau de la p63 ; l'élève avec l'aptitude de -1 doit répondre aux 2 premiers items, et l'élève avec l'aptitude de +1 doit répondre aux deux derniers items. Les deux élèves réussissent le premier des deux items, mais ratent le second

			$\beta_i = -1$	$\beta_i = 1$
Item 1	$\delta_1 = -1$	Réponse=1	0.50	
Item 2	$\delta_2 = -0.5$	Réponse=0	0.62	
Item 3	$\delta_3 = 0.5$	Réponse=1		0.62
Item 4	$\delta_4 = 1$	Réponse=0		0.50
Pattern de réponses			0.31	0.31



- ➔ Les deux combinaisons ont une probabilité de 0,31, que ce soit pour l'aptitude de -1 ou de +1
- ➔ Pour chaque élève qui a réussi un item du test facile, le modèle estimera son aptitude à -0,75, et pour chaque élève ayant réussi un item du test difficile, le modèle estimera son aptitude à +0,75

Si les scores bruts avaient été utilisés en tant qu'estimations de l'aptitude de l'élève, nous aurions obtenu 1 sur 2 (0,5) dans les deux cas, car ils ne tiennent pas compte de la difficulté de l'item → rend leur interprétation dépendante de la difficulté des items

⇒ Le modèle Rasch utilise le nombre de réponses exactes ainsi que les difficultés des items administrés à un élève donné pour estimer son aptitude ⇒ le score peut donc être interprété indépendamment des difficultés des items

Tant que tous les items peuvent être situés sur le même continuum, le modèle de Rasch peut générer des estimations des aptitudes des élèves totalement comparables, même dans le cas où les élèves sont testés à partir de différents sous-ensembles d'items

NB : la validité des scores des élèves obtenus selon la méthode de Rasch dépend de la connaissance précise des difficultés des items

Cette possibilité des modèles de réponse à l'item de rapporter des scores sur un seul continuum pour des plans de tests incomplets permet de résoudre le problème des données manquantes dans le cadre des échelles de Likert (ex. un individu qui n'aurait pas répondu à tous les items)

2.6 CONDITIONS OPTIMALES POUR LES ITEMS D'ANCRAGE

Les données recueillies lors des différents tests doivent pouvoir être ancrées pour être mises sur une même échelle. L'ancrage est généralement effectué par l'attribution d'items communs aux divers tests à différents élèves ou par l'attribution des différents tests à un même élève. En suivant ce processus d'ancrage, les difficultés des items seront localisées sur un seul et même continuum (s'assurer que la position des items d'ancrage est semblable dans les deux tests et ce, pour éviter que l'effet de fatigue puisse influencer la performance)

2.7 ERREUR DE MESURE

L'erreur de mesure dans le cadre des modèles de réponses à l'item est fonction de la compétence des sujets, de la difficulté des items et du nombre d'items

$$ESM = \frac{1}{\sqrt{\sum_{i=1}^j p_i q_i}}$$

2.8 UNE ILLUSTRATION

Voir pp128-131

Il est également possible, avec ces modèles de réponses à l'item, d'étudier le fonctionnement différentiel des items (DIF). Il suffit d'estimer, de manière indépendante ou conjointe, la difficulté des items pour les deux groupes et ensuite de comparer, item par item, la difficulté estimée pour le groupe 1 et la difficulté estimée pour le groupe 2. On peut également comparer la difficulté générale de l'item avec la difficulté spécifique à un groupe

3. EXTENSION DU MODÈLE DE RASCH

3.1 MODÈLE DE RÉPONSE À CRÉDIT PARTIEL

Wright et Masters ont étendu le modèle d'origine de Rasch aux items polytomiques

→ PCM : Partial Credit Model

Ce modèle permet de corriger les items en considérant que la réponse peut être correcte, partiellement correcte ou incorrecte

Il peut également être appliqué aux données obtenues par des échelles de Likert ; dans ce cas, il n'y aura pas de bonne ou de mauvaise réponse

Les principes de base restent les mêmes : les réponses possibles peuvent être classées selon un certain ordre

3.2 AUTRES MODÈLES UTILISANT LA THÉORIE DE RÉPONSE À L'ITEM

Les divers modèles se servant de la théorie de réponse à l'item se distinguent notamment par le nombre de paramètres utilisés pour décrire les items. Dans le modèle logistique à 3 paramètres, les courbes des caractéristiques des items dépendent de

- i) Le paramètre de difficulté des items
- ii) Le paramètre de discrimination des items
- iii) Un paramètre lié à la probabilité de « deviner » la bonne réponse (guessing)

4. CONCLUSION

Le modèle de Rasch a été conçu pour construire un continuum symétrique sur lequel la difficulté des items et les aptitudes des élèves sont localisées et reliées par une fonction logistique.

Grâce à cela, il est possible de calculer la probabilité de répondre correctement à un item. De plus, il n'est pas nécessaire d'administrer l'entièreté de la batterie d'item à chaque élève.

Dans le cas où des items d'ancrage sont garantis, le modèle de Rasch pourra créer une échelle sur laquelle chaque élève et chaque item seront situés

Le modèle de Rasch est devenu la référence dans les *surveys* internationaux en éducation

CHAPITRE 7 : LA VALIDITÉ

Legendre : « *La validité est la capacité d'un instrument à mesurer réellement ce qu'il doit mesurer, selon l'utilisation que l'on veut en faire* »

La validité peut donc être définie comme étant

- Le degré auquel un test mesure un trait latent
→ validité de contenu (7.3) et validité théorique (7.4)
- La relation entre les scores obtenus à un test et une mesure à un critère externe
→ validité prédictive (7.2)

Le concept de validité essaie de répondre aux questions suivantes :

1. Le type de test utilisé convient-il vraiment à l'usage auquel il est destiné ?
2. Quels sont les traits mesurés par le test ?
3. Le test mesure-t-il ce qu'il est censé mesurer ?
4. Les informations fournies par le test sont-elles utiles pour prendre des décisions ?
5. Quelles interprétations peut-on faire des scores obtenus au test ?
6. Quelles prédictions peut-on tirer des scores obtenus au test ?
7. Quel degré de variance découle de la variable mesurée par le test ?

La validité d'un test doit toujours être contextualisée : un test peut être valide pour prédire des résultats scolaire d'étudiants universitaires, mais non valide pour prédire la réussite professionnelle des étudiants universitaires diplômés

1. RELATION ENTRE FIDÉLITÉ ET VALIDITÉ

La relation qu'un test peut avoir avec une variable externe (ex. réussite universitaire) permet de décomposer la variance vraie en deux composantes : la composante vraie commune (avec la variable externe), et la composante vraie unique

La mesure de cette variable externe ('critère') est entachée d'erreur : ces erreurs de mesure, au niveau du test X et du critère externe Y, conduisent à une **sous-estimation de la corrélation** entre ces deux variables latentes. Si E1 et E2 représentent les erreurs sur les variables X et Y :

$$\text{cov}(X + E1, Y + E2) = \text{cov}(X, Y) + \text{cov}(X, E2) + \text{cov}(E1, Y) + \text{cov}(E1, E2)$$

Comme les covariances qui incluent un terme d'erreurs sont égales à 0, il ne reste que :

$$\text{cov}(X + E1, Y + E2) = \text{cov}(X, Y) \rightarrow \text{covariance intacte}$$

Par contre, les variances et les écart-type sont surestimés par les erreurs de mesure :

$$\rho_{(X+E1, Y+E2)} = \frac{\text{cov}(X, Y)}{\sqrt{(\sigma_{(X)}^2 + \sigma_{(E1)}^2)(\sigma_{(Y)}^2 + \sigma_{(E2)}^2)}}$$

→ le dénominateur augmente en raison des erreurs de mesure E1 et E2

Par conséquent, les corrélations entre les variables observées (avec erreur de mesure) sera plus petite que la corrélation entre les variables latentes ⇒ **sous-estimation de la corrélation des variables latentes**

La corrélation entre les deux variables latentes s'obtient comme ceci : si ω représente la variable latente mesurée par le test X et ω représente la variable latente du critère externe, alors

$$\rho_{(\omega, \omega)} = \frac{\rho_{(X, Y)}}{\sqrt{\rho_{(X, X)} \rho_{(Y, Y)}}}$$

La validité ne peut qu'être égale ou inférieure à la fidélité : $\rho_{(X, Y)} \leq \rho_{(X, X)}$

2. LA VALIDITÉ PRÉDICTIVE

⇒ **La capacité d'un test à prédire un critère** : on cherche à savoir si les scores obtenus à un test X permettent de prédire le rendement à un critère externe Y. Dans ce type de validité, l'élément le plus important est **le critère externe**, car le test X est développé essentiellement dans le but de prédire le critère externe Y, le contenu du test en lui-même est secondaire

La détermination de la validité prédictive exige toujours la collecte de **données empiriques** pour établir la relation entre les scores obtenus au test et les scores obtenus au critère externe

Les données du critère externe Y sont recueillies bien après les données relatives au test X

→ *Un test qui a pour objet de prédire la réussite universitaire doit atteindre 4 ou 5 ans avant de pouvoir disposer des données relatives au critère externe Y*

LES CARACTÉRISTIQUES DE LA MESURE CRITÈRE

Critère conceptuel	Mesure-critère
critère que l'on cherche à mesurer	façon dont on va opérationnaliser ce critère pour le mesurer, peut prendre plusieurs formes pour un même critère conceptuel

Par exemple : la réussite à l'université constitue un critère conceptuel qui peut être mesuré par une mesure-critère comme la moyenne cumulée des notes obtenues lors des études, etc

La mesure-critère doit posséder un certain nombre de **propriétés**

- Elle doit être pertinente, c'est-à-dire qu'elle doit prendre en considération tous les différents aspects fondamentaux du critère conceptuel (et pas 1 seulement)
- Elle doit être fidèle
- Elle ne peut pas être contaminée (biais de l'évaluation de l'examineur, etc)

Il existe **4 grands types** de mesure-critères :

1. Mesure directe du rendement (ex. niveau salarial)
2. Rendement à un test
3. Appartenance à un groupe (classification des individus)
4. Indices statistiques, de type coefficient de saturation (analyses factorielles)

MÉTHODES POUR DÉTERMINER LA VALIDITÉ PRÉDICTIVE

Le coefficient de corrélation

Simplement calculer la **corrélation de Bravais – Pearson** entre les scores au test X et les scores au critère externe Y. Si la relation n'est pas linéaire, les données sont transformées, ou on utilise une autre méthode corrélationnelle

L'indice d'efficacité

Un test conçu dans une perspective prédictive aboutit généralement à une décision

→ **Analyser la proportion de bonnes décisions** prises à partir du test

Plus cette proportion est grande, plus le test est efficace / valide

Pour calculer l'indice d'efficacité :

- Classer les décisions suggérées par le test prédicteur en 2 catégories mutuellement exclusives, puis faire de même avec la mesure critère
- Analyser les données du tableau construit à partir de ces deux catégories

		Mesure-critère	
		<i>Echec</i>	<i>Réussite</i>
Test prédicteur	<i>Réussite</i>	A (+) (-) Inexacte	B (+) (+) Exacte
	<i>Echec</i>	C (-)(-) Exacte	D (-)(+) Inexacte

→ Proportion de bonnes décisions $P = \frac{B+C}{A+B+C+D}$

→ Proportion de bonnes décisions qui donnent des résultats positifs $P = \frac{B}{A+B+}$

L'indice de séparation des groupes

Comparer au moins deux groupes définis selon la mesure-critère et vérifier si le score prédicteur moyen permet de distinguer les groupes

Ensuite, réaliser un test de Student pour déterminer si la différence est significative

3. LA VALIDITÉ DE CONTENU

⇒ **Mesure du degré de représentativité de l'échantillon des questions** : on cherche à savoir si le test reprend bien les différents aspects du domaine qui est censé être évalué

Ce type de validité est étudié au moyen d'une analyse rationnelle du contenu du test et déterminée par un jugement de valeur

Validité apparente	Validité logique (d'échantillonnage)
déterminée par le jugement d'un expert qui examine le test et conclut que celui-ci mesure vraiment le trait qu'il est censé mesurer	établie de façon plus concrète, se présente sous la forme d'un tableau de spécifications qui peut, par exemple, croiser les savoirs et les savoir-faire

Lors de la définition du concept à mesurer ⇒ vérifier la validité de contenu !

4. LA VALIDITÉ THÉORIQUE

⇒ « **validité de construit** » ou « **validité hypothético-déductive** » : on cherche à évaluer la validité d'une mesure d'une mesure en l'absence de critère, et en l'absence d'univers d'items déterminé ; elle vise à assurer l'existence de la variable latente mesurée et à en éclairer la signification

Dans la validité théorique, on distingue la validité convergente et validité divergente

Dans la **validité convergente**, on cherche à démontrer que les scores attribués aux sujets ne sont pas affectés par le processus de la mesure ; on s'attend à ce que 2 mesures différentes du même concept aboutissent au même résultat. Ce type de validité s'inscrit dans une problématique + générale, visant à éliminer tous les facteurs non-pertinents

On peut recourir aux **matrices multitraits-multiméthodes**, qui reprennent les corrélations entre la mesure de différentes variables latentes, recueillies selon différentes méthodes

Imaginons 3 concepts (traits) à mesurer...

A. Estime de soi

B. Sociabilité

C. Contrôle de soi

...et 3 méthodes de mesures de ces traits

Méthode 1 : test sur papier complété par l'élève

Méthode 2 : évaluation de l'enseignant

Méthode 3 : évaluation des parents

		Méthode 1			Méthode 2			Méthode 3		
		A1	B1	C1	A2	B2	C2	A3	B3	C3
Méthode 1	A1	0,89								
	B1	0,51	0,89							
	C1	0,38	0,37	0,76						
Méthode 2	A2	0,57	0,22	0,09	0,93					
	B2	0,22	0,57	0,10	0,68	0,94				
	C2	0,11	0,11	0,46	0,59	0,58	0,84			
Méthode 3	A3	0,56	0,22	0,11	0,67	0,42	0,33	0,94		
	B3	0,23	0,58	0,12	0,43	0,66	0,34	0,67	0,92	
	C3	0,11	0,11	0,45	0,34	0,32	0,58	0,58	0,60	0,85

Il existe 4 types de corrélations dans cette matrice

Même trait, même méthode (cellules rouges)

Ces corrélations, situées sur une diagonale, auraient dû être égales à 1, mais elles ont été remplacées par une estimation de la fidélité de chacune de ces mesures ; ces corrélations doivent être les + élevées, car un trait devrait corrélér + avec lui-même qu'avec npt quel autre

Même trait, différentes méthodes (cellules jaunes)

On s'attend à observer des corrélations élevées, puisqu'un seul trait est mesuré et que l'on cherche à minimiser l'influence de la procédure de collecte de données ; ces corrélations se situent sur des diagonales

Différents traits, même méthode (cellules vertes)

Des corrélations élevées indiquent la présence d'une influence de la méthode sur les mesures (pas ouf, parce qu'on cherche justement à éviter cette influence !) ; ces corrélations forment des triangles dans la matrice des données

Différents traits, différentes méthodes (cellules blanches)

Ces corrélations devraient être les plus faibles dans la matrice

Pour que la validité convergente des mesures soit prouvée, il faut :

- Que les corrélations entre les mêmes traits mais selon différentes méthodes (cellules jaunes) soient élevées, on les appellera les 'indices de validité'
- Que ces indices de validité soient supérieurs aux corrélations de la même ligne ou de la même colonne pour les méthodes différentes
- Que ces indices soient supérieurs aux corrélations dans les triangles monométhodes

Dans la **validité convergente**, on regarde si le construit n'est pas déjà recouvert par d'autres construits ou traits déjà existants. S'il est bien distinct, on devrait observer des corrélations faibles entre ce construit et les autres, quelle que soit la méthode de mesure