Synthèse de Statistiques III:

Quelques bases :

→ Il faut **toujours** finir la phrase par ";". L'ordre à respecter est :

1. DATA UN/DEUX/… : ça va nous permettre la création d'une table.
2. INPUT : détermine le nombre de variables à lire et leur type :
   a. Des variables numériques.
   b. Des variables alpha numériques (préciser un signe $ à côté de celles ci).
3. DATALINES : on le situe avant les données à lire.
4. PROC PRINT DATA = UN/DEUX/… : éxecuter un nombre de programmes.
5. RUN : démarrer la programmation.

➔ Cela représente la démarche de **base**.

```
data un ;
input identification $ x1 x2 x3 ;
datalines;
S1 3 4 2
S2 4 5 1
S3 2 . 3
S4 . 2 4
S5 3 5 1
S6 1 2 3
S7 . 1 .
S8 5 4 5
S9 1 . 1
proc print data = un ;
run ;
```

!! Lorsqu'on prend une source externe et qu'on ne doit pas écrire les données manuellement.

= infile '/home/uX/sasuser.v94/nom du doc' firstobs = X

→ Il faudra, en plus, ajouter lorsque le fichier sera un ".csv": dlm = ';' dsd

Liste de programmation :

- TOTAL = x1+…+xX (si pas de données manquantes!) (à mettre après l'input), on peut également écrire TOTAL = sum (of x1-xX) (celle ci peut être utilisée s'il y a des données manquantes).
- Moyenne = mean (of x1-xX), utilisable s'il y a des données manquantes (calcul de la moyenne par lignes).
- SET X : création d'un sous tableau.

```
proc print data = coucou ;
run ;
data aurevoir ;
  set coucou ;
    total = x1+x2+x3;
proc print data=aurevoir ;
run;
```

nom du nouveau tableau

Proc Means :

Mot-clé	Signification
N	Nombre d'observations
NMISS	Nombre de valeurs manquantes
MEAN	Moyenne
STD	Ecart-type
MIN	Minimum
MAX	Maximum
VAR	Variance
MEDIAN	Médiane
MODE	Mode
CV	Coefficient de variation
ALPHA=	Niveau d'incertitude (0.05 défaut)

Mot-clé	Signification
CLM	Intervalle de confiance sur la moyenne
RANGE	Etendue
Q1	Premier quartile
Q3	Troisième quartile
QRANGE	Intervalle interquartile
SKEW	Indice d'asymétrie
KURT	Indice d'aplatissement
MAXDEC=	Nombre de décimales souhaitées = souvent 4
T	Test t de la nullité de la moyenne
PRT	Probabilité de dépassement du test t

Proc Sort :

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau;
proc sort data=un;
by mes1;
proc print data=un;
run;
```

- By = la variable qu'on veut trier.
- Descending (qu'on met juste après le By) = on veut organiser par ordre décroissant. Faire attention s'il y a plus d'une variable à organiser de cette façon.

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau;
proc sort data=un;
by descending groupe descending genre;
proc print data=un;
run;
```

Proc Standard :

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps;
proc standard mean=0 std=1 out=sortie;
var mes1 temps;
proc print data=sortie;
run;
```

→ Nous permet de standardiser, de mettre un score Z.
→ S'il y a des variables manquantes dans les données qu'on veut standardiser on rajoutera 'replace' à la suite de 'std'.

Proc Rank :

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau;
proc print data=un;
run;
proc rank data=un out=sortie ties=mean;
var mes1-mes3 temps;
proc print data=sortie;
title 'rangs croissants';
run;
```

→ Transformer des données numériques en rangs.
→ Ajouter descending après 'out = sortie' s'il faut le faire en ordre décroissant.
→ Ties peuvent être : Mean, High, Low. Lorsque le logiciel rencontre des valeurs identiques, il doit leur attribuer un rang qui correspond à la moyenne/valeur plus grande/valeur plus basse des rangs de chaque valeur.

Proc Format :

```
data un ;
infile '/home/u64031678/sasuser.v94/initial0.txt'firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau ;
proc format ;
 value sx 1 = 'femme' 2 ='homme'; → pas oublier les '...'
proc print data = un ;
format genre sx. ;
run ;
```

→ Des variables nominales alphanumériques vont devenir numériques. On peut faire le même processus afin de changer le noms d'une variable nominale.

Proc Freq :

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau;
proc print data=un;
run;
proc freq data=un;
tables mes1;
run;
```

- Colonne mes1 : les différentes valeurs de la variable.
- Fréquence : nombre de sujets qui ont obtenu le même score.
- Pourcentage : nombre de fois que la valeur est survenue.

mes1	Fréquence	Pourcentage	Fréquence cumulée	Pourcentage cumulé
26	1	4.00	1	4.00
29	1	4.00	2	8.00
35	1	4.00	3	12.00
37	1	4.00	4	16.00
42	1	4.00	5	20.00

Lorsque les données sont des données regroupées :

On ajoutera 'weight' où l'on mettra la variable contenant les fréquences.

```
data un ;
infile '/home/u64031678/sasuser.v94/data42.t
input cote effectif ;
data deux ;
set un ;
if cote > 0 ;
proc freq data = deux ;
tables cote ;
weight effectif ;
run ;
```

Proc Univariate :

```
data un;
infile '/home/u59521151/sasuser.v94/initial0.txt' firstobs=2;
input nom $ genre groupe $ mes1-mes3 temps niveau;
proc print data=un;
run;
proc univariate data=un;
var mes1;
run;
```

→ On va se retrouver avec plein de données intéressantes. Il est important de spécifier la variable qu'on veut calculer pour ne pas se retrouver avec plein de tableaux différents.

Opérateurs arithmétiques, logiques et de comparaison:

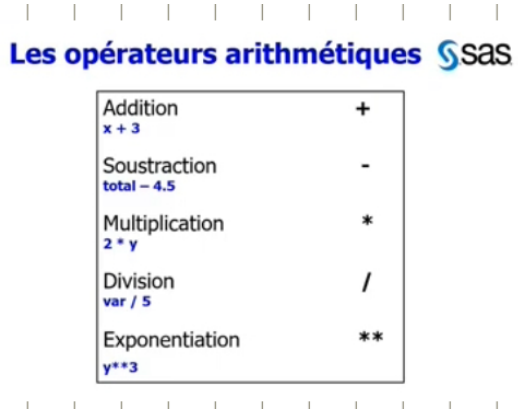

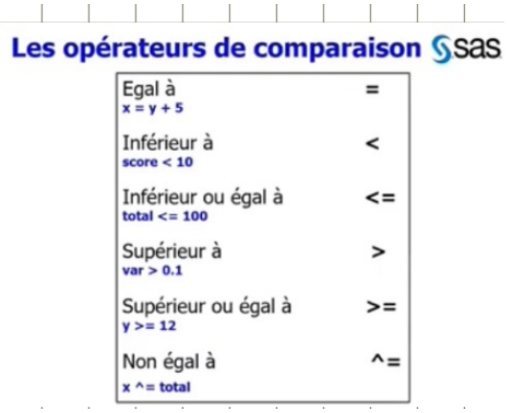

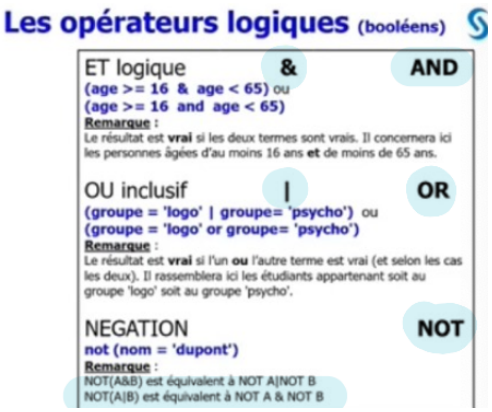


```
1 data un ;
2 infile '/home/u64031678/sasuser.v94/initial3.txt' firstobs=2;
3 input genre $ test1 test2 temps score ;
4 if score < 20 then niveau = 'faible';
5 if score >= 20 and score < 26 then niveau = 'moyen';
6 if score >= 26 then niveau ='bon';
7 proc print data = un;
8 run ;
```

→ Si … alors …
→ Il faut tenir en compte que si on utilise OR : il faut que les deux conditions qu'on citera fassent partie de la même variable.

Données groupées :

```
infile 'c:\etudiant\initial5.csv' firstobs=2 dlm=';' dsd ;
input cote effectif ;
proc print data=un ;
run ;
data deux ;
  set un ;
  if cote > 0 ;
proc means data=deux n mean median mode var ;
  var cote ;
  freq effectif ;
```

→ tenir en compte de

Il faut noter qu'on prend à partir des côtes supérieures à 0.

Données en intervalles :

On va considèrer que les sujets ont eu la moitié de l'intervalle dans laquelles ils sont. Pour cela, il va falloir calculer la valeur de tous les milieux.
On va par la suite utiliser la variable 'milieu' pour calculer des moyennes, …

1	0	20	28
2	20	30	12
3	30	35	19
4	35	40	31

```
data un ;
infile 'c:\etudiant\initial6.txt' firstobs=2 ;
input binf bsup effectif ;
  milieu = (binf+bsup) /2 ;
proc print data=un ;
run ;
```

Comparaison avec un standard:

a) On va comparer une moyenne avec une autre moyenne qui elle, est calculée de façon standard.

```
data un;
infile '/home/u59521151/sasuser.v94/initial4.txt' firstobs=2;
input x1-x5;
proc print data=un;
run;
data deux;
set un;
diff = x4 - 16;
proc means data=deux n mean clm;
var diff;
title 'exercice 1 méthode 1';
run;
```

b) Voir la nullité de la moyenne dans la population.

```
data un;
infile '/home/u59521151/sasuser.v94/initial4.txt' firstobs=2;
input x1-x5;
proc print data=un;
run;
proc means data=un n mean clm;
var x4;
title 'exercice 1 méthode 2' ;
run;
```

Corrélation :

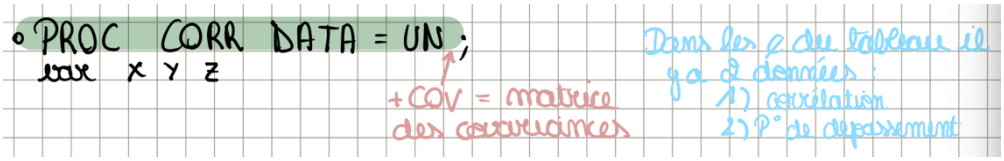

→ Corrélation bisériale : une variable métrique et une variable dichotonique (il faudra lui donner des valeurs numériques).
→ Corrélation partielle : influence d'une troisième variable qui influence la relation entre les deux autres variables.

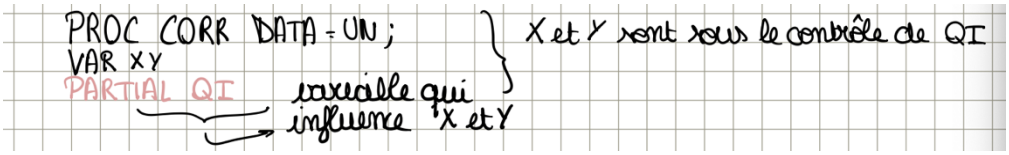

Tester la normalité :

Il faudra utiliser : 'PROC UNIVARIATE = UN NORMAL' (avec précision d'une variable). On pourra ainsi avoir, par exemple : l'indice d'asymétrie ou celui d'applatissement (kurt/curtosis ou skew).

Asymétrie/Skew

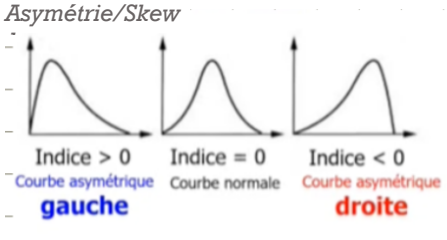

Kurt/Applatissement

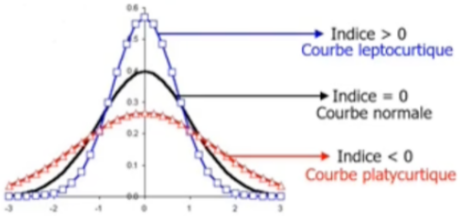

Test T de Student (échantillons indépendants):

→ Comparer les moyennes de deux groupes. Il faudra tenir en compte de la **normalité** et de **l'homogénéité des variances**.

```
data un;
infile '/home/u59521151/sasuser.v
input psychose $ qi age temps sco
proc print data=un;
run;
ods graphics off;
proc ttest data=un;
class genre;
var qi;
run;
```

→ Hypothèse : égalité des variances = si la probabilité de dépassement est > que 0,05 alors on tolère l'homogénéité des variances.

1- La première chose à faire sera de regarder le tableau contenant les informations sur l'égalité des variances :

• Si on tolère l'hypothèse x > 0,05 : on doit utiliser la ligne « pooled ».
• Si on rejette l'hypohtèse x < 0,05 : on doit utiliser la ligne « satterthwaite ».

Egalité des variances				
Méthode	DDL num.	DDL den.	Valeur F	Pr > F
Folded F	17	29	1.84	0.1457

2- Ensuite, on regardera dans le bon tableau les données qu'on doit retrouver dans la ligne correcte.

Test T de Student (échantillons appariés) :

```
data un;
infile '/home/u59521151/sasuser.v94/Documents/data57.txt' firstobs=2;
input sujet $ score1 score2;
proc print data=un;
run;
ods graphics off;
proc ttest data=un;
paired score1*score2;
run;
```

→ on ne met pas "CLASS" mais "PAIRED" avec les 2V pairées

Tableau de contingence :

Elle consiste à croiser les modalités de deux variables catégorielles en dénombrant l'effectif figurant dans chaque croisement de ces modalités.

	Niveau 1	Niveau 2	Niveau 3	Total
Femme	4	22	3	29
Homme	5	2	14	21
Total	9	24	17	50

On obtiendra un tableau où chaque cas contient :

1) L'effectif de chaque cellule
2) Pourcentage du contenu de la cellule par rapport à l'effectif total
3) Pourcentage du contenu de la cellule par rapport à la ligne
4) Pourcentage du contenu de la cellule par rapport à la colonne

```
data un;
infile '/home/u59521151/sasuser.v94/Doc
input genre $ niveau $;
proc print data=un;
run;
proc freq data=un;
tables genre*niveau;
run;
```

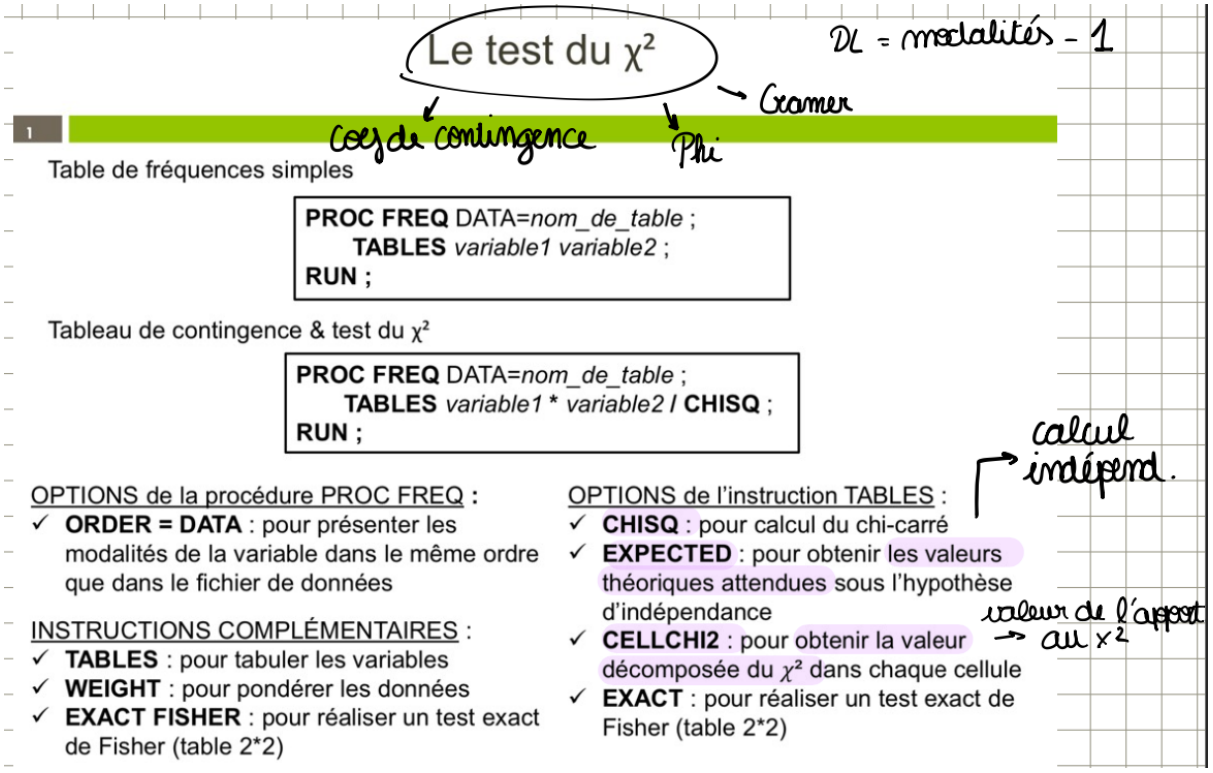

En effectuant 'chisq' nous pouvons obtenir la probabilité de dépassement qui nous permettra de tolérer ou pas l'hypothèse d'indépendance. Mais il peut y avoir d'autres informations comme le coéfficient de contingence, Phi et Cramer.

Statistique	DDL	Valeur	Prob
Khi-2	2	23.2096	<.0001
Test du rapport de vraisemblance	2	26.0518	<.0001
Khi-2 de Mantel-Haenszel	1	5.1768	0.0229
Coefficient Phi		0.6813	
Coefficient de contingence		0.5631	
V de Cramer		0.6813	

Dans le tableau en haut, la valeur présente pour le khi-2 permettra de rejetter l'hypothèse d'indépendance.

Il se pourrait que les données soient groupées, alors il faudra faire un fichier comme ceci (on trouvera les noms des colonnes par nous mêmes):

```
data un ;
input statut $ lieu $ effectif ;
datalines ;
belgique inferieur 26
belgique moyen 35
belgique superieur 12
europe inferieur 43
europe moyen 54
europe superieur 28
monde inferieur 17
monde moyen 21
monde superieur 42
proc print data = un ;
run ;
```

```
data un;
infile '/home/u59521151/sasuser.v94/
input statut $ depress $ nombre;
proc print data=un;
run;
proc freq data=un order=data;
tables statut*depress / chisq;
weight nombre;
run;
```

Le test du chi-carré n'est pas fiable pour l'analyse d'un tableau de 2x2 à cause de la distribution du chi-carré lorsqu'il n'a qu'un seul degré de liberté. Il faudra utiliser le **test de Fischer**.

```
data un;
infile '/home/u59521151/sasuser.v94/Documen
input attitude $ sexe $ effectif;
proc print data=un;
run;
proc freq data=un;
tables attitude*sexe / chisq;
weight effectif;
run;
```

Test exact de Fisher	
Cellule (1,1) Fréquence (F)	30
Pr <= F unilatérale à gauche	0.1885
Pr >= F unilatérale à droite	0.8783
Probabilité de la table (P)	0.0668
Pr <= P bilatéral	0.3252

→ Ici, on tolère l'hypothèse de l'indépendance des variables dans la population.

Test du khi-carré:

→ Nous permet de calculer l'indépendance.
Dans le tableau on regardera 'De dos caras Pr<=P' si c'est plus grand que 0,05 : on tolère lindépendance.

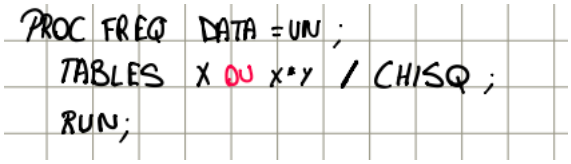

Modèle linéaire normal :

On va faire une régression : PROC GLM. **On explique une VD par une VI**.
→ Faire une droite de régression : **Y = a + bX**

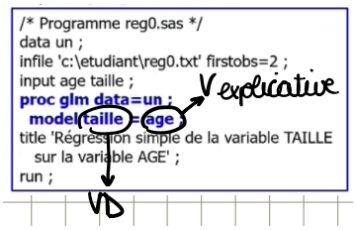


```
infile 'c:\etudiant\reg0.txt' firstobs=
input age taille ;
proc print data=un ;
run ;
proc glm data=un ;
  model taille = age / P ;
title 'Régression de  variable taille
```

Ici, on peut ajouter :

- CLPARM : donne les intervalles de confiance pour les différents paramètres.
- P : demander ce que la régression prédit pour un sujet particulier (elle prédit : le résidu, la prédiction et la valeur observée).
- CLM : intervalle de confiance sur la valeur prédite (basé sur la moyenne de tous les sujets) = l'intervalle de confiance moyen.
- CLI : intervalle de confiance individuel.

→ CLI et CLM ne peuvent pas être mis en même temps.

Mettre en relation deux variables métriques = régression.

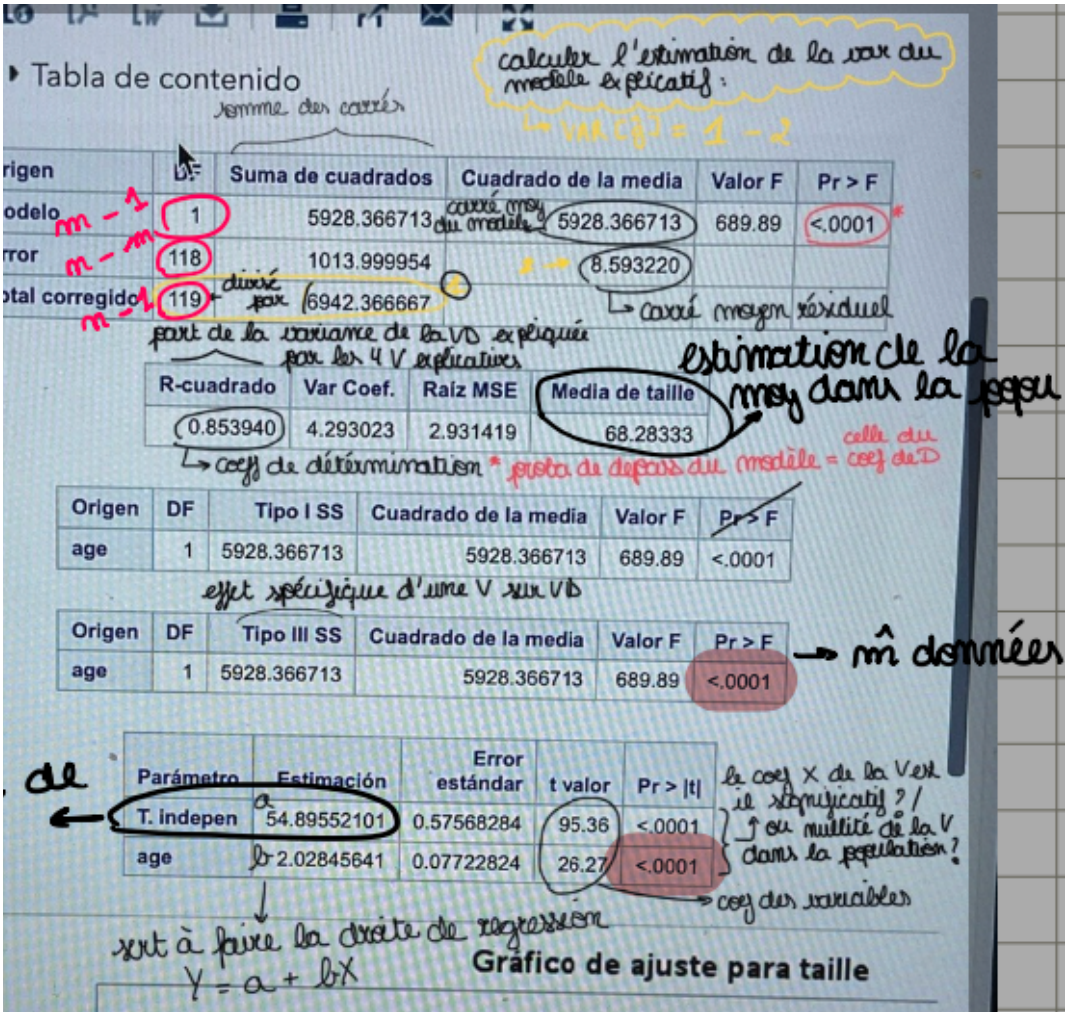

Hypothèses fondamentales :

Le résidu est de moyenne nulle, non corrélé avec les explications.
→ Loi de la décomposition de la variance : var (g) = var (^g) + var (E)
Les variances sont toujours positives.

- Pour l'échantillon ?

Au lieu d'utiliser las variances on utilise les sommes des carrés (SS).
Sy = S^y + S(E)

Dependent Variable: taille

Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	1342.459185	1342.459185	108.53	<.0001
Error	28	346.340815	12.369315		
Corrected Total	29	1688.800000			

← Tableau de PROC GLM

Hypothèse dans la régression:
Les variables explicatives n'expliquent rien du comportement de la VD / le modèle explicatif n'est pas pertinent.

- Le coefficient de détérmination est nul dans la population et il est égal à var^g/var g.

SYNTHÈSE : Le coefficient de détermination

- Le coefficient de détermination ρ^2 est **toujours compris entre 0 et 1**.
- Sa racine carrée ρ est la **corrélation multiple** de la régression.
- Dans la régression est **simple** (un seul explicateur) ρ est égale à la **corrélation de Pearson** entre la variable dépendante et la variable explicative.
- La valeur ρ^2 fournie par SAS a été calculée avec les **variances** de l'**échantillon** !!!
- Cette valeur du coefficient de détermination dans l'échantillon **surestime** toujours la valeur du coefficient de détermination dans la population !

  ➡ Nécessité d'une valeur calculée $\hat{\rho}^2$ d'**estimation** du coefficient de détermination dans la **population**.

$Y = a + bX + \varepsilon$

↳ modèle

La statistique F :

Dependent Variable: taille

Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	$S_{\hat{y}}$ 1342.459185	1342.459185	108.53	<.0001
Error	28	S_ε 346.340815	12.369315		
Corrected Total	29	1688.800000			

num de F

dénom de F

$\equiv F = \dfrac{S_{\hat{y}} / v}{S_\varepsilon / n - V - 1}$

Régression multiple :

On explique une VD par plusieurs VI.
Hypothèse : si je rejette l'hypothèse nulle = au moins une VI explique VD.
si je tolère l'hypothèse nulle = je tolère que simultanément tous les coefficients de regréssion puissent être nuls.

Sommes des carrés :
Type I = régressions hiérarchiques, où l'utilisateur introduit volontairement les variables dans un certain ordre.
Type III = l'effet spécifique d'une variable explicative sur la VD, ce que chaque variable apporte **seule**.

Les estimations :

modèle VD résidu

$VAR(\hat{g}) = VAR(g) - VAR(\varepsilon)$

$VAR_g - VAR\varepsilon$

PROC MEANS de la VD

PROC GLM le carré moyen résiduel

Variance de la VD ?

```
run ;
proc means data=un n mean var ;
  var qi ;
run ;
```

→ L'estimation du rho carré dans la population = PROC REG, et dans les tableaux on prend les données du 'R-Sq Adjust'.

Le problème de la multi colinéarité dans les regréssions multiples :

Exemple : des corrélations trop corrélées entre elles.

```
data un ;
infile '/home/u64031678/sasuser.v94/reg2.txt
input sujet y x1-x4 ;
proc reg data = un ;
  modele y = x1-x4 / tol vif ;
run ;
```

problématique en dessous de 0,10

problématique en dessous de 10

```
data deux ;
   set un ;
x24 = (x2+x4)/2 ;
proc reg data = deux ;
  model y = x1 x24 x3 / tol vif ;
run ;
```

1) On trouve les corr qui sont très élevées
2) On crée une V avec ces dernières avec leur moy ou somme

→ On peut aussi effectuer un PROC CORR et voir quelles correlations sont élevées, mais il vaut mieux faire 'tol/vif'.

Les anova simple :

```
data un ;
infile 'c:\etudiant\fbasic1.txt' firstobs=2 ;
input psychose $ qi age temps score genre $ nivsoc $ ;
proc glm data=un ;
  class nivsoc ;
  model qi = nivsoc ;
  means nivsoc ;
title 'Analyse de variance simple' ;
```

VE

c'est ici qu'on mettra "/p ..."

VD

Means permet d'avoir le tableau pour avoir la moyenne / écart type / ...

Le coefficient de détermination représente la part de la VD qui est expliquée par la VE. Pour savoir la part de la VD qui est expliquée par d'autres choses :
➔ **100% - (Rcarré mis en %)**

On utilise PROC MEANS avec 't' et 'prt' pour tester la significativité du coefficient pour chacun des sous groupes. Le modèle **prédira à un élève** d'un groupe **la moyenne de son groupe**.

Exemple d'hypothèse : les moyenes au sein des **groupes** de la variable **qi** doit être tolérée comme pouvant être égale dans la population ou pas ?

Tester les hypothèses fondamentales :

Normalité de la variable dépendante dans chaque modalité

Elle se testera via la procédure **proc univariate** avec l'option **normal**

Exemple : **proc** univariate data= un normal ;
class groupe ;
var score;

Valeur prédite par la variable dépendante dans chaque modalité

Elle se testera via la procédure **proc means** avec l'instruction **class**

Exemple : **proc** means data= un ;
class groupe ;
var score ;

Homogénéité des variances de la variable dépendante dans les modalités

Elle se testera par un des tests suivants en utilisant l'option **HOVTEST** de l'instruction **means** dans la procédure **proc glm** :

Hovtest = levene (c'est le plus couramment utilisé)
Hovtest = bf (test de Brown-Forsythe)
Hovtest = bartlett (test de Bartlett – Rapport des variances)
Hovtest = obrien

↗ 0,05 tolère ↘ 0,05 ↳ rejet HOMOG

→ Ça se met après → MEANS

SI HOMOGÉNÉITÉ = REJETÉE
↳ WELCH

Pour voir si le modèle est significatif

Il faudra tenir en compte de l'homogénéité, la normalité, … cette anova peut nous aider à predire la valeur prédite par la variable dépendante dans chaque modalité.

```
data un ;
infile 'c:\etudiant\anova11.txt' firstobs=2 ;
input groupe $ score ;
proc glm data=un ;
  class groupe ;
  model score = groupe ;
  means groupe / tukey cldiff ;
run ;
```

pour avoir les étoiles

VE

↳ INT de conf entre les moy

Comparer des moyennes 2 à 2 :
Si on a que 2 modalités = T de Student.
Si on a plus de 6 modalités = HSD de Tukey.
Si on a entre 3 et 5 modalités = Neumans-Keuls/Rukey/BF/Scheffé/…

Un tableau apparaîtra = les différences significatives dans le tableau auront trois petits points sur la ligne OU la valeur 0 se retrouvera dans l'intervalle, on pourra dire qu'elles ne sont pas significatives.

Les contrastes :
→ On veut comparer des groupes avec d'autres groupes.
! Lorsque les modalités sont des mots il faut faire attention à leur ordre alphabétique !
→ Au niveau des variables qu'on n'utilisera pas ppour les contrastes, il faudra indiquer un 0.

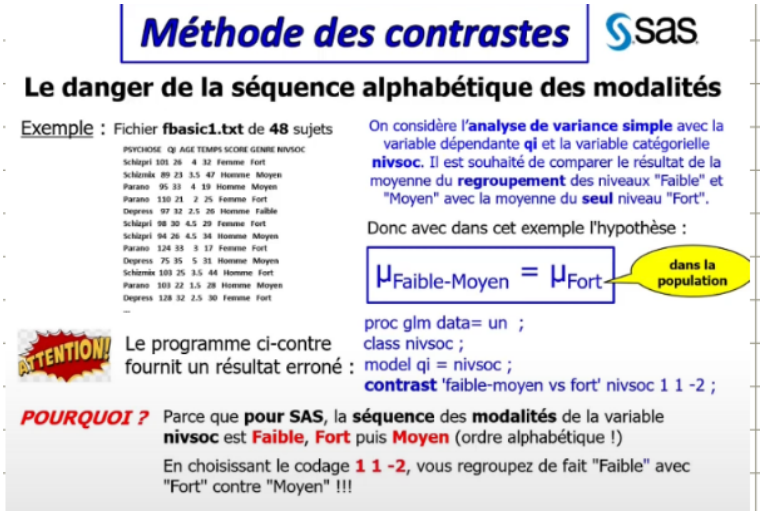

Définitions / synonimes :

- Corrélation multiple = Racine carrée du coéfficient de détermination
- Coefficient de détermination dans la population :

$$1 - \left(\frac{SS_{erreur} / DL_{erreur}}{SS_{TOTAL} / DL_{TOTAL}} \right)$$

Procedimiento GLM

Variance dans l'ech.

carré moy du modèle ou carré moy entre les groupes

Origen	DF	Suma de cuadrados	Cuadrado de la media	Valor F	Pr > F
Modelo	3	6921.608974	2307.202991	54.30	<.0001
Error	56	2379.241026	42.486447		
Total corregido	59	9300.850000			

Var E ech

carré moyen résiduel
variance résiduelle dans la pop

valeur statistique pour tester la significativité du modèle
OU valeur statistique F associée au modèle

R-cuadrado	Var Coef.	Raiz MSE	Media de M2
0.744191	10.35451	6.518163	62.95000

coef de détermination

Origen	DF	Tipo I SS	Cuadrado de la media	Valor F	Pr > F
NIVEAU	3	6921.608974	2307.202991	54.30	<.0001

Origen	DF	Tipo III SS	Cuadrado de la media	Valor F	Pr > F
NIVEAU	3	6921.608974	2307.202991	54.30	<.0001

valeur statistique associée à l'effet spécifique

- Quelle est la valeur prédite par la régression pour un individu où VE = X ?
  → Remplacer les valeurs dans l'équation de regréssion.
- Une proportion n'est pas égal à un pourcentage.
- Valeur que le modèle explicatif va prédire à un groupe OU valeur de l'estimation de la moyenne d'un groupe.
- Si on nous donne une valeur observée X et qu'on nous dit de calculer le résidu : on cherchera la valeur observée (ce qu'on nous dit dans l'ennoncé) – la valeur prédite (proc means) = résidu.
- Calculer les moyennes d'une cellule →

Procedimiento GLM

Nivel de NIVEAU	N	M2 Media	M2 Desv. est.
bon	15	64.9333333	7.85099326
faible	15	51.0000000	6.12955370
satis	13	54.7692308	5.38754499
tbon	17	78.0000000	6.33442973

```
PROC MEANS DATA=UN;
CLASS  VE
VAR    VD
```

Anova double croisée :

Le programme SAS s'écrira :

```
/* Programme anova21.sas */
data un ;
infile 'c:\etudiant\fbasic1.txt' firstobs=2 ;
input psychose $ qi age temps score genre $ nivsoc $ ;
proc glm data=un ;
  class psychose nivsoc ;
  model qi = psychose nivsoc psychose*nivsoc ;
title 'anova double croisée' ;
run ;
```

Prg : anova21.sas – Fich : fbasic1.txt

La droite de regression :

$qi = 88.5 \times h_{parano}h_{faible} + 93.0 \times h_{parano}h_{moyen} + 106.0 \times h_{parano}h_{fort}$
$+ 81.0 \times h_{depress}h_{faible} + 99.2 \times h_{depress}h_{moyen} + 116.8 \times h_{depress}h_{fort}$
$+ 63.0 \times h_{schizmix}h_{faible} + 97.3 \times h_{schizmix}h_{moyen} + 109.0 \times h_{schizmix}h_{fort}$
$+ 81.7 \times h_{schizpri}h_{faible} + 99.6 \times h_{schizpri}h_{moyen} + 105.5 \times h_{schizpri}h_{fort}$

Après obtention de **toutes** les moyennes des sous-groupes

→ par PROC MEANS, vu plus haut !

Décomposition de la somme de carrés du modèle complet :

plet $S_g = S_{\hat{g}} + S_\varepsilon$

n-1 d-1 n-d degrés de liberté

La décomposition de $S_{\hat{g}}$ fournit

$S_g = S_{\hat{g}_l} + S_{\hat{g}_c} + S_{int} + S_\varepsilon$

1e facteur — 2e facteur — interaction

Somme des carrés ligne — Somme des carrés colonnes

ddl = n-1 | l-1 | c-1 | (l-1)(c-1) 4.3 = 12 | n-l.c = (n-d)

n de ε = 12

⚠ pas de cellules vides !!

Anova double hiérarchique :

On souhaite expliquer Y1 par des variables catégorielles Test et Groupe.

```
PROC GLM DATA = UN;
CLASS GROUPE TEST;
MODEL Y1 = GROUPE TEST(GROUPE);
RUN;
```

→ chaque TEST est propre à un groupe

TEST(GROUPE) : appartient à

! On va utiliser QUE les sommes de type I !

L'équation de regréssion riche est la suivante :

Dans notre exemple, elle devrait s'écrire :

$$\text{Score} = 10.0 \times h_{test1forme1} + 14.0 \times h_{test2forme1} + 10.0 \times h_{test2forme2} + 14.5 \times h_{test2forme3} + 10.5 \times h_{test3forme1} + 12.0 \times h_{test3forme2}$$

C'est l'**équation** de la régression hiérarchique

Analyse de covariance :

Quand on va faire ce programme, celui ci va supposer le parallelisme! Il va falloir le vérifier par après.

C'est ici qu'on va utiliser les LSMEANS.

```
ods graphics off ;
/* Programme ancova1.sas */
/* Analyse de covariance */
data un ;
infile 'c:\etudiant\fcova1.txt' firstobs=2 ;
input groupe $ 20. resultat competence ;
proc glm data=un ;
  class groupe ;
  model resultat = groupe competence ;
title 'Analyse de variance simple' ;
run ;
```

- **L'analyse de covariance** est une **RÉGRESSION** linéaire d'une variable **métrique** sur une (ou des) variable(s) **catégorielle(s)** **ET** une (ou des) variable(s) **métrique(s)**.
- Dans l'**analyse de variance**, ce qui est testé c'est l'**égalité des moyennes** de la variable dépendante dans les différentes **modalités** de la(ou des) variable(s) **catégorielle(s)**.
- **L'analyse de covariance** ne **modifie en rien** les valeurs des moyennes **observées** de la variable dépendante dans les différentes **modalités** de la(ou des) variable(s) **catégorielle(s)**.
- Ce que fait l'**analyse de covariance**, c'est tester l'**égalité des moyennes ajustées** (= telles qu'elles ***apparaissent*** **modifiées**) par la **présence** de la(ou des) **covariable(s)**.

Obtention des moyennes ajustées : **Lsmeans** groupe ;

Obtention des intervalles de confiance sur les moyennes ajustées : **Lsmeans** groupe **/ cl** ;

si > 0,05 alors la diff est significative

Comparaison multiple des moyennes ajustées : **Lsmeans** groupe **/ adjust=tukey** ;
(ou) **= scheffe** ;
(ou) **= bon** ;
etc...

Le parallélisme :

⚠ Pour faire un test de covariance, il faut d'abord savoir s'il y a du parallélisme :

```
/* Programme ancova6_2.sas – Test du parallélisme */
data un ;
infile 'c:\etudiant\fcova2.txt' firstobs=2 ;
input classe $ score test ;
proc glm data=un ;
  class classe ;
  model score = classe test classe*test ;
title 'Test du parallélisme' ;
run ;
```

→ on va dans les sommes de type III
- ↳ si > 0,05 on tolère le parallelisme
- ↳ si < 0,05 on rejette le parallelisme = on rejette la nullité de l'interaction

↳ quand le test // est significatif

H1 : la covariable se comporte de façon diff avec les diff modalités de V catégorielle.

Quand < 0,05, alors : on utilise le programme de pentes séparées.

```
/* Programme ancova7_1.sas – Programme en pentes séparées */
data un ;
infile 'c:\etudiant\fcova3.txt' firstobs=2 ;
input groupe $ score pretest ;
proc glm data=un ;
  class groupe ;
  model score = groupe pretest(groupe) ;
title 'Analyse de covariance – Pentes séparées' ;
run ;
```

la covariable se comporte ≠ en fonction de la variable catégorielle

⚠ dans ce cas ci on va utiliser les sommes de carré de type I !

↳ lorsqu'on rejette le parallélisme

Anova en mesures répetées avec structure répétitive :

↳ on va intégrer la structuration en deux niveaux de la variable répétitive ainsi que la présence de la variable catégorielle (la VI ?)

⚠ ne pas introduire des "variables nouvelles" relatives à la structuration répétitive

```
/* Programme analyse de variance en
mesures répétées */
/* Programme mesrep5.sas */
data un ;
infile 'c:\etudiant\fmrep5.txt' firstobs=2 ;
input sujet $ genre $ mes1-mes6 ;
proc glm data=un ;
class genre ;
model mes1-mes6 = genre / nouni ;
repeated test 2, mesure 3 / nom ;
title 'Analyse de variance structurée en
mesures répétées' ;
run ;
```

si pas de V cat, on laisse un espace vide

→ le produit des niveaux exprimés dans la structuration doit être égal au total des variables répétitives → 2 × 3 = 6

les 2 termes de la structuration doivent être séparés par une virgule

! ATTENTION !

Il faut prendre garde à l'**ordre** des variables qui seront « définies » dans la programmation de la **structuration** des valeurs répétitives.

Dans le présent exemple, la variable principale est **TEST** et la variable secondaire est **MESURE**.

On écrira donc ici

TEST 2, MESURE 3

Anova répétées :

Lorsque pas de VI :

Fichier **fmrep1.txt**

SUJET	ITEM1	ITEM2	ITEM3	ITEM4
S1	31	42	14	80
S2	42	26	25	106
S3	84	21	19	83
S4	26	60	36	69
S5	14	35	44	48
S6	16	80	28	76
S7	29	49	80	39
S8	32	38	76	84
S9	45	65	15	91
S10	30	71	82	39

Le programme SAS s'écrira :

```
/* Programme analyse de variance en mesures répétées */
/* Programme mesrep1.sas */
data un ;                                   Vcat indep
infile 'c:\etudiant\fmrep1.txt' firstobs=2 ;
input sujet $ item1-item4 ;
proc glm data=un ;                          non univariate → annule l'analyse de variance simple
model item1-item4 = / nouni ;
repeated item / nom ;                       no multivariate
title 'Analyse de variance simple en mesures répétées' ;
run ;
```

Ce sont les V qui interviennent dans la répétition → VI

les mesures dans l'ech sont "item" → on met nom

Lorsqu'il y a une VI :

SUJET	GENRE	ITEM1	ITEM2	ITEM3	ITEM4
S1	F	31	42	14	80
S2	G	42	26	25	106
S3	F	84	21	19	83
S4	F	26	60	36	69
S5	G	14	35	44	48
S6	G	16	80	28	76
S7	G	29	49	80	39
S8	F	32	38	76	84
S9	G	45	65	15	91
S10	F	30	71	82	39

Le programme SAS s'écrira :

```
/* Programme analyse de variance en mesures répétées */
/* Programme mesrep2.sas */
data un ;
infile 'c:\etudiant\fmrep2.txt' firstobs=2 ;
input sujet $ genre $ item1-item4 ;
proc glm data=un ;
class genre ;                               VD
                                            VI → variable catégorielle
model item1-item4 = genre / nouni ;
repeated item / nom ;
title 'Analyse de variance simple en mesures répétées' ;
run ;
```

Tester la sphéricité :

SOIT on utilise un autre test (ex: le test non-paramétrique de Friedman)

SOIT on utilise pour la décision un correctif ε classique

Comment réaliser le test de Mauchly

Programme mesrep1.sas

Fichier **fmrep1.txt**

SUJET	ITEM1	ITEM2	ITEM3	ITEM4
S1	31	42	14	80
S2	42	26	25	106
S3	84	21	19	83
S4	26	60	36	69
S5	14	35	44	48
S6	16	80	28	76
S7	29	49	80	39
S8	32	38	76	84
S9	45	65	15	91
S10	30	71	82	39

➡ Il suffit d'ajouter au programme l'option **printe** (instruction **repeated**)

```
/* Programme analyse de variance en mesures répétées */
/* Programme mesrep1.sas */
data un ;
infile 'c:\etudiant\fmrep1.txt' firstobs=2 ;
input sujet $ item1-item4 ;
proc glm data=un ;
model item1-item4 =  / nouni ;
repeated item / nom printe ;
title 'Obtention du test de Mauchly' ;
run ;
```

➡ On obtient la ligne Orthogonal Components :

on utilise pour les correctifs

Sphericity Tests

Variables	DF	Mauchly's Criterion	Chi-Square	Pr > ChiSq
Transformed Variates	5	0.2044649	12.25794	0.0314
Orthogonal Components	5	0.4358515	6.4129476	0.2681

$\chi^2 = 6.4129$
$p = 0.2681$

$p > 0,05$ la sphéricité est bien respectée on utilise donc χ^2

↳ la valeur du test de Mauchly

Lorsque des variables ont un caractère subordonné :

RESEAU	CLASSE	S1	S2	S3	S4	S5	S6
officiel	1	4.0	4.0	4.1	3.6	3.6	3.8
officiel	1	4.2	4.3	3.7	3.7	4.8	5.0
officiel	1	4.3	4.2	4.3	4.3	4.5	5.8
...							
officiel	2	3.3	3.3	3.3	3.4	3.6	3.1
officiel	2	4.2	4.0	4.2	4.1	4.2	4.0
officiel	2	4.1	4.2	4.3	4.3	4.2	4.0
libre	1	4.5	4.4	4.3	4.5	5.3	4.4
libre	1	3.2	3.3	3.8	3.8	4.4	4.2
libre	1	3.3	3.4	3.4	3.7	3.7	3.6
...							
libre	2	4.2	3.9	4.5	4.7	3.9	3.8
libre	2	4.1	4.1	3.7	4.0	4.1	4.6
libre	2	3.5	3.6	3.6	4.2	4.8	4.9

➡ Le programme SAS s'écrira dès lors :

```
/* Programme analyse de variance en mesures répétées */
/* Programme mesrep4.sas */
data un ;
infile 'c:\etudiant\fmrep4.txt' firstobs=2 ;
input reseau $ classe $ s1-s6 ;
proc glm data=un ;
class reseau classe ;
model s1-s6 = reseau classe(reseau) / nouni ;
repeated item / nom ;
title 'Analyse de variance simple en mesures répétées' ;
title2 'Variables indépendantes subordonnées' ;
run ;
```

(le nouveau) (la classe appartient au réseau)

Lorsque réseau est "officiel" on est précément 1
Lorsque réseau est "libre" on est précément 2

Lorsque es variables sont croisées :

Fichier **fmrep3.txt**

SUJET	ECOLE	GENRE	ITEM1	ITEM2	ITEM3	ITEM4
S1	A	F	31	42	14	80
S2	A	G	42	26	25	106
S3	A	F	84	21	19	83
S4	A	F	26	60	36	69
S5	A	G	14	35	44	48
S6	A	G	16	80	28	76
S7	A	G	29	49	80	39
S8	A	F	32	38	76	84
S9	A	G	45	65	15	91
S10	A	F	30	71	82	39
S11	B	F	33	56	17	90
S12	B	F	18	64	22	102
S13	B	G	22	51	35	87
S14	B	F	31	48	66	66
S15	B	G	27	15	34	50
S16	B	G	12	74	18	41
S17	B	G	19	63	22	75
S18	B	F	35	55	17	88
S19	B	G	38	47	39	90
S20	B	F	17	33	43	47

❗ Il convient ici de tenir compte du caractère **CROISÉ** des deux variables indépendantes ❗

➡ Le programme SAS s'écrira dès lors :

```
/* Programme analyse de variance en mesures répétées */
/* Programme mesrep3.sas */
data un ;
infile 'c:\etudiant\fmrep3.txt' firstobs=2 ;
input sujet $ ecole $ genre $ item1-item4 ;
proc glm data=un ;
class ecole genre ;
model item1-item4 =  genre ecole genre*ecole / nouni ;
repeated item / nom ;
title 'Analyse de variance simple en mesures répétées' ;
title2 'Variables indépendantes croisées' ;
run ;
```

Il y a G et F dans toutes les écoles A et B

Régression stepwise :

→ Il y a des variables en trop ? Trouver les meilleures VE.

La régression classique :

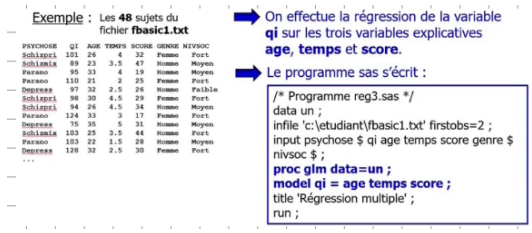

Forward :

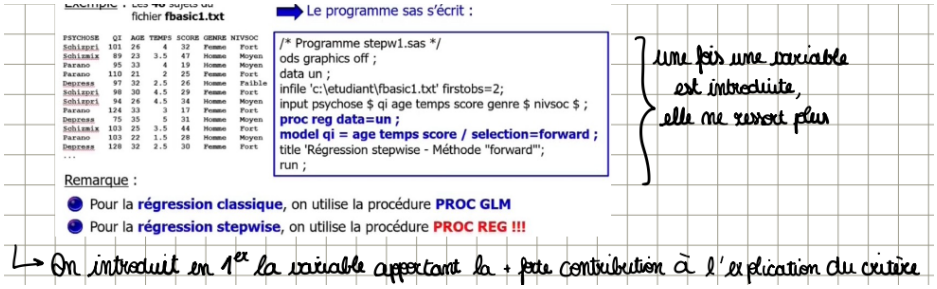

Backward :
On retire les variables jusqu'à qu'elles remplissent toutes les critères d'inclusion: une fois une variable exclue elle ne revient plus.

Stepwise :
À chaque fois qu'on introduit une variable on réévalue les autres pour voir si elles sont toujours pertinentes : ici, des variables peuvent être supprimées ultérieurement.

Maxr :
On détermine d'abord un modèle à une variable présentant la plus grande valeur de rho carré et ainsi de suite.

Rsquare :
Elle fournit toutes les régressions possibles en les rangeant par ordre décroissant du rho carré dans l'échantillon.

Adjrsq :
Elle fournit toutes les régressions possibles en les rangeant par ordre décroissant du rho carré dans la population.

Cp et Aic :

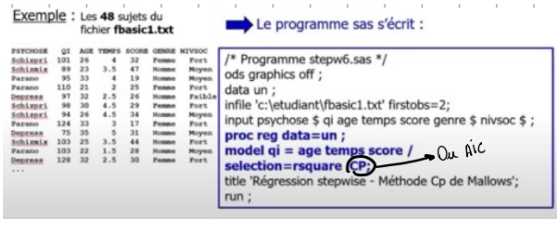

Compléments :

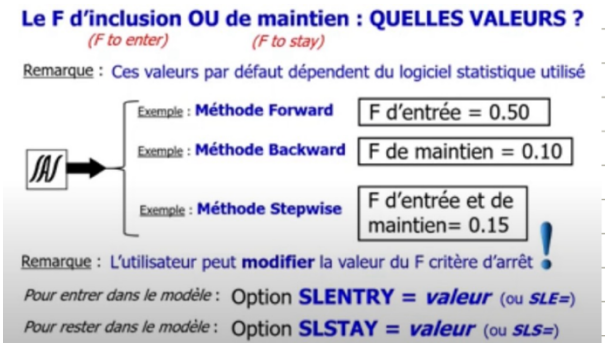

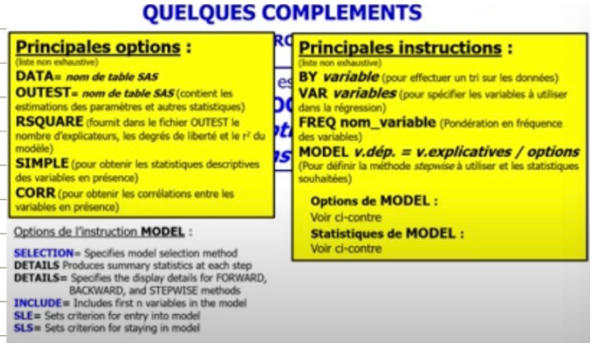

SLENTRY : que devient le résultat de la régression si on porte le niveau de la significativité à 1,5?

```
ods graphics off;
data un ;
infile '/home/u59521151/sasuser.v94/Documents/data144.txt' firstobs=2;
input age y1-y4;
proc print data=un;
run;
proc reg data=un;
model age = y1-y4 / selection = forward slentry=1.5;
run;
```

Question 2 : Si on effectue cette même régression selon la méthode backward, quelles sont les variables explicatives conservées dans le modèle final ? Quel est alors le coefficient de détermination de ce modèle dans l'échantillon ?

→ Les variables explicatives conservées sont **y1 et y4**.

→ R^2 dans l'échantillon = **0.1418**

```
ods graphics off;
data un ;
infile '/home/u59521151/sasuser.v94/Documents/data144.txt' firstobs=2;
input age y1-y4;
proc print data=un;
run;
proc reg data=un;
model age = y1-y4 / selection = backward;
run;
```

on va dans la dernière étape effectuée par la régression et on regarde le R carré pour avoir le coef de dét

Elimination descendante : Etape 2

Variable y3 supprimée : r-carré = 0.1418 et C(p) = 3.4395

Analyse de variance

Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	2	1019.24519	509.62260	4.96	0.0102
Erreur	60	6167.35798	102.78930		
Total sommes corrigées	62	7186.60317			

Variable	Valeur estimée des paramètres	Erreur type	SC Type II	Valeur F	Pr > F
Intercept	68.05853	2.79155	61097	594.39	<.0001
y1	0.00318	0.00168	366.59245	3.57	0.0638
y4	-0.16170	0.06763	587.52043	5.72	0.0200

Quelle est la valeur du coef de la V → Y1 dans le modèle final

Quelle est la part de variance spécifiquement apportée par la variable X dans le modèle final ?

↳ on prend le R^2 avant l'ajout de cette variable et le R^2 lors de l'ajout de cette variable et on soustrait

La régression logistique :

Lorsque la VD est dichotomique.

death	black	whitic	serious	culp	serious2
0	1	0	7.1	2	3.4
1	0	1	11.5	5	4.66666666
0	0	0	6	2	3
0	0	1	8.4	4	3.2
1	1	0	12.2	5	4.2
0	0	0	7.7	1	3.2
1	1	0	3.6666667	2	2.83333333
1	0	1	12.8	5	4.8
0	1	0	7	1	3.2
0	1	0	7.875	5	2.75
0	1	1	3.7	1	2.4
0	1	1	7.3	1	3.4
0	0	1	9.2	1	3.2
0	1	0	8.6	1	3.8
1	1	0	8	5	3.8
0	1	0	3.5833333	1	2.83333333
.	.	.			

```
/* Programme logist2.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\flogit2.txt' firstobs=2 ;
input death blackd withvic serious culp serious2 ;
proc logistic data=un descending ;
 model death = blackd withvic serious ;
/* DESCENDING privilégie ici le codage 1 (peine de mort) */
TITLE 'Régression logistique' ;
RUN ;
```

→ on privilégie le codage 1, sinon il privilégie le codage 0

L'exécution du programme SAS **logit2.sas** a aussi donné les importants résultats suivants (***qui seront explicités dans la suite***) :

Les **critères** relatifs à la **comparaison** entre **deux modèles envisagés**.

Les **statistiques** et **probabilités de dépassement** relatives au **test d'hypothèse**.

Model Fit Statistics

Criterion	Intercept Only	Intercept and Covariates
AIC	190.491	184.285
SC	193.481	196.247
-2 Log L	188.491	176.285

qualité du modèle de régression logistique

Testing Global Null Hypothesis: BETA=0

Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	12.2060	3	0.0067
Score	11.6560	3	0.0087
Wald	10.8211	3	0.0127

on rejette l'H0 de la nullité conjointe de tous les coef de la population

⚠ le coef de déter. généralisé = formule de Cox-Snell
↳ option RSQ

⚠ ODDS RATIO = ESTIMADORES DE RATIO...

Le coefficient de détermination → on ajoute '/RSQ' au niveau de 'model'

Équation de la régression : $\ln\left(\frac{p}{1-p}\right) = \text{Intercept} + X.V_1 + \ldots + X.V_t$

Determiner une intervalle de confiance sur l'estimation des paramètres
→ CLPARM = WALD ou CLMPARM = PL/BOTH (suite à model)

On peut aussi obtenir des valeurs prédites (=probabilités) par le modèle pour chaque sujet de l'échantillon.

death	black	whitic	serious	culp	serious2
0	1	0	7.1	2	3.4
1	0	1	11.5	5	4.66666666
0	0	0	6	2	3
0	0	1	8.4	4	3.2
1	1	0	12.2	5	4.2
0	0	0	7.7	1	3.2
1	1	0	3.6666667	2	2.83333333
1	0	1	12.8	5	4.8
0	1	0	7	1	3.2
0	1	0	7.875	5	2.75
0	1	1	3.7	1	2.4
0	1	1	7.3	1	3.4
0	0	1	9.2	1	3.2
0	1	0	8.6	1	3.8
1	1	0	8	5	3.8
0	1	0	3.5833333	1	2.83333333
.	.	.			

```
/* Programme logist2_2.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\flogit2.txt' firstobs=2 ;
input death blackd withvic serious culp serious2 ;
proc logistic data=un descending ;
 model death = blackd withvic serious / RSQ ;
OUTPUT out=sortie PREDPROBS=individual ;
PROC PRINT data=sortie ;
title 'Probabilités individuelles' ;
run ;
```

Quelle ocndition le modèle prédit au X sujet ? On regarde la colonne INTO + le chiffre et à quoi ça correspond.

```sas
data un;
infile '/home/u59521151/sasuser.v94/Documents/data153.txt' firstobs=2;
input ID LOW AGE LWT RACE SMOKE PTL HT UI FTV BWT;
proc print data=un;
run;
proc logistic data=un descending;
model LOW = AGE LWT RACE SMOKE PTL HT / rsq;
output out=sortie predprobs = individual;
proc freq data=sortie;
tables _FROM_ * _INTO_ ;
run;
```

↳ pour avoir les effectifs pour chaque catégorie

Les personnes qui sont dans les rgroupes corrects sont les 1/1 et 0/0.
Lorsque les données sont regroupées on utilise :

```sas
data un;
infile '/home/u59521151/sasuser.v94/Documents/data154.txt' firstobs=2;
input sexe traitement amelioration total;
proc print data=un;
run;
proc logistic data=un descending;
model amelioration = sexe traitement;
freq total;
run;
```

Question : Comment déterminer, à partir du modèle de régression, la probabilité qu'un **sujet extérieur à l'échantillon** soit condamné (ou non) à la peine de mort ?

Exemple : Un sujet portant les valeurs : BLACKD = 0 WHITVIC = 1 et SERIOUS = 9.2

➡ Le plus simple est d'utiliser la **forme exponentielle** de la probabilité !

Les coefficients du modèle sont :

Parameter	DF	Estimate
Intercept	1	-2.6516
blackd	1	0.5952
withvic	1	0.2565
serious	1	0.1871

$$p = \frac{e^{(\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k)}}$$

$$e^{(-2.6516 + 0.5952\times\mathbf{0} + 0.2565\times\mathbf{1} + 0.1871\times\mathbf{9.2})} = e^{(-0.67378)} = 0.509778$$

Les données du sujet sont :

BLACKD = 0
WHITVIC = 1
SERIOUS = 9.2

$$p = \frac{0.509778}{1 + 0.509778} = 0.3376$$

Que prédira le modèle à une personne externe ?

- On calcule la probabilité.
- Si < 0,5 → 1 et si 0,5 → 0 (par exemple, ça peut varier).

Frequency
Percent
Row Pct
Col Pct

Table of _FROM_ by _INTO_

FROM(Formatted Value of the Observed Response)	_INTO_(Formatted Value of the Predicted Response) 0	1	Total
0	91 61.90 93.81 71.09	6 4.08 6.19 31.58	97 65.99
1	37 25.17 74.00 28.91	13 8.84 26.00 68.42	50 34.01
Total	128 87.07	19 12.93	147 100.00

Règle :
Toutes les observations qui ont une **valeur prévue** (= probabilité) **inférieure ou égale à 0.5** sont classées en ECHEC (= 0). Toutes celles avec une **valeur prévue supérieure à 0.5** sont classées en SUCCES (= 1).

Sont également fournis les **pourcentages de classification correcte** dans chaque catégorie.

Le **pourcentage global** (brut) **de classification correcte** peut être déterminé.
Ici (91+13)/147 = **0.7075**

Tests non paramétriques :

Quand utiliser ces tests ?

- Lorsque les H préalables à l'application des procédures paramétriques classiques ne sont pas satisfaites.
- Lorsque l'échantillon est trop petit.
- Lorsque les données sont ordinales ou déjà mesurées sous forme de rangs.

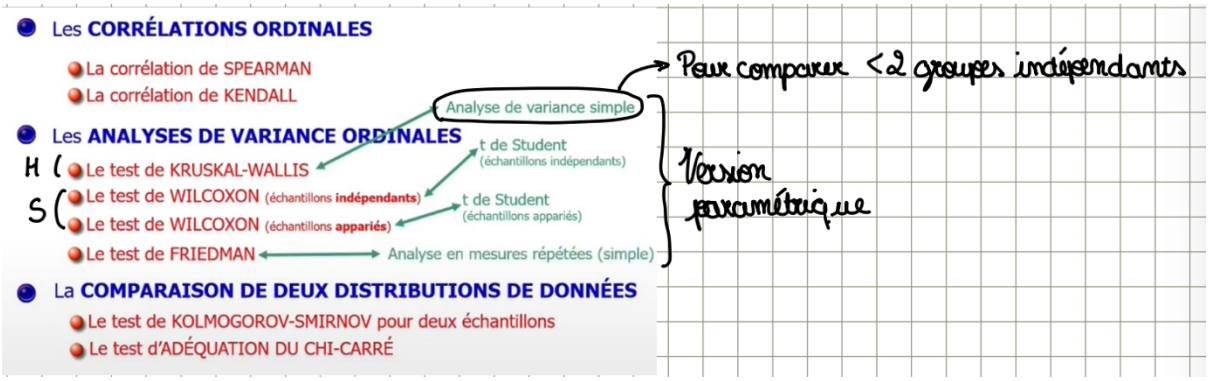

Corrélation de spearman :

CORRÉLATION DE SPEARMAN

ETUDIANTS	g1 Score au test de vocabulaire	r(g1) Rangs	g2 Score au test d'arithmétique	r(g2) Rangs
Albert	48	1	48	1
Bernard	54	3.5	56	3
Christian	52	2	62	4
Daniel	54	3.5	67	5
Emile	55	5	53	2

La transformation en rangs ayant été effectuée (par le logiciel)

La **corrélation de Spearman** n'est rien d'autre que la corrélation de Pearson appliquée aux **rangs** plutôt qu'aux valeurs initiales

Remarque :

- Comme pour la corrélation ρ de Pearson, les bornes de la corrélation de Spearman sont : $-1 \leq r_s \leq 1$
- L'hypothèse sous épreuve est : $\rho_s = 0$ (dans la population)
- Lorsque des sujets de l'échantillon portent la même modalité (**ex aequo**), on leur attribue par convention le **rang moyen** de leur ensemble.
- La nullité de la corrélation est rejetée lorsque la valeur obtenue (test bilatéral) est **supérieure** à celle de la **table des valeurs critiques** (5%) pour l'effectif **n** concerné.

Prg : fnpar1_1.sas
Fich : fnpar1.txt

Fichier **fnpar1.txt**

ETUDIANT	VOCAB	ARITH
Albert	48	48
Bernard	54	56
Charles	52	62
Daniel	55	67
Emile	58	53

Le programme SAS **fnpar1_1.sas** s'écrira :

```
/* Programme fnpar1_1.sas */
data un ;
infile 'c:\etudiant\fnpar1.txt' firstobs=2 ;
input etudiant $ vocab arith ;
PROC CORR DATA=un SPEARMAN ;
  VAR vocab arith ;
title 'Corrélation de Spearman' ;
run ;
```

L'exécution du programme SAS **fnpar1_1.sas** a donné les résultats suivants :

Les statistiques élémentaires des deux variables :

- Moyenne
- Ecart-type
- Médianes
- Minimum
- Maximum

2 Variables: vocab arith

Simple Statistics

Variable	N	Mean	Std Dev	Median	Minimum	Maximum
vocab	5	53.40000	3.71484	54.00000	48.00000	58.00000
arith	5	57.20000	7.46324	56.00000	48.00000	67.00000

La corrélation de Spearman et son test de significativité :

- La statistique r_s = 0.30000
- La probabilité **p** = 0.6238 (≥ 0.05) qui conduit à **tolérer** la nullité de la corrélation de Spearman dans la population.

Spearman Correlation Coefficients, N = 5
Prob > |r| under H0: Rho=0

	vocab	arith
vocab	1.00000	0.30000 0.6238
arith	0.30000 0.6238	1.00000

Table des valeurs critiques

n	0,0010	0,0050	0,0100	0,0250	0,0500	0,1000
4	-	-	-	-	0,8000	0,8000
5	-	-	0,9000	0,9000	0,8000	0,7000
6	-	0,9429	0,8857	0,8286	0,7714	0,6000
7	0,9643	0,8929	0,8571	0,7450	0,6786	0,5357
8	0,9286	0,8571	0,8095	0,7143	0,6190	0,5000
9	0,9000	0,8167	0,7667	0,6833	0,5833	0,4667
10	0,8667	0,7818	0,7333	0,6364	0,5515	0,4424
11	0,8364	0,7545	0,7000	0,6091	0,5273	0,4182
12	0,8182	0,7273	0,6713	0,5804	0,4965	0,3986
13	0,7912	0,6978	0,6429	0,5549	0,4780	0,3791
14	0,7670	0,6747	0,6220	0,5341	0,4593	0,3626
15	0,7464	0,6536	0,6000	0,5179	0,4429	0,3500
16	0,7265	0,6324	0,5824	0,5000	0,4265	0,3382
17	0,7083	0,6152	0,5637	0,4853	0,4118	0,3260
18	0,6904	0,5975	0,5480	0,4716	0,3994	0,3148
19	0,6737	0,5825	0,5333	0,4579	0,3895	0,3070
20	0,6586	0,5684	0,5203	0,4451	0,3789	0,2977
21	0,6455	0,5545	0,5078	0,4351	0,3688	0,2909
22	0,6318	0,5426	0,4963	0,4241	0,3597	0,2829
23	0,6186	0,5306	0,4852	0,4150	0,3518	0,2767
24	0,6070	0,5200	0,4748	0,4061	0,3435	0,2704
25	0,5962	0,5100	0,4654	0,3977	0,3362	0,2646
26	0,5856	0,5002	0,4564	0,3894	0,3299	0,2588
27	0,5757	0,4915	0,4481	0,3822	0,3236	0,2540
28	0,5660	0,4828	0,4401	0,3749	0,3175	0,2490
29	0,5567	0,4744	0,4320	0,3685	0,3113	0,2443
30	0,5479	0,4665	0,4251	0,3620	0,3059	0,2400

La valeur critique pour un test bilatéral à 5 % se situe dans la colonne **0.0250**

Pour que la corrélation soit considérée comme **significative**, la valeur obtenue devait être **supérieure** à la valeur de la table pour cet effectif **n**=5, à savoir supérieure à **0.9000**.

Or r_s = **0.3** < **0.9**. La corrélation de Spearman n'est donc pas significative au niveau d'incertitude 5 %.

Corrélation de Kendall :

CORRÉLATION DE KENDALL

➡ Le calcul de la **statistique de Kendall** dans l'échantillon se réalise par :

$$t_k = \frac{P - Q}{n(n-1)/2}$$

(La statistique de Kendall s'écrit τ dans la population et se note t_k dans l'échantillon)

où **P** est le nombre de paires **concordantes**
Q est le nombre de paires **divergentes**
et **N** est l'**effectif** de l'échantillon

Remarque :

- Comme pour la corrélation ρ de Pearson, les bornes de la corrélation de Kendall sont : $-1 \leq \tau \leq 1$
- L'hypothèse sous épreuve est : $\tau = 0$ (dans la population)
- La statistique de Kendall est un **estimateur fidèle** de la corrélation τ (population)
- La nullité de la corrélation est rejetée lorsque la valeur obtenue (test bilatéral) est **supérieure** à celle de la **table des valeurs critiques** (5%) pour l'effectif **n** concerné.

Table des valeurs critiques

α	0,005		0,010		0,025		0,050		0,100	
n	S	τ'	S	τ'	S	τ'	S	τ'	S	τ'
4	8	1,000	8	1,000	8	1,000	6	1,000	6	1,000
5	12	1,000	10	1,000	10	1,000	8	0,800	8	0,800
6	15	1,000	13	0,867	13	0,867	11	0,733	9	0,600
7	19	0,905	17	0,810	15	0,714	13	0,619	11	0,524
8	22	0,786	20	0,714	18	0,643	16	0,571	12	0,429
9	26	0,722	24	0,667	20	0,556	18	0,500	14	0,389
10	29	0,644	27	0,600	23	0,511	21	0,467	17	0,378
11	33	0,600	31	0,564	27	0,491	23	0,418	19	0,345
12	38	0,576	36	0,545	30	0,455	26	0,394	20	0,303
13	44	0,564	40	0,513	34	0,436	28	0,359	24	0,308
14	47	0,516	43	0,473	37	0,407	33	0,363	25	0,275
15	53	0,505	49	0,467	41	0,390	35	0,333	29	0,276
16	58	0,483	52	0,433	46	0,383	38	0,317	30	0,250
17	64	0,471	58	0,426	50	0,368	42	0,309	34	0,250
18	69	0,451	63	0,412	53	0,346	45	0,294	37	0,242
19	75	0,439	67	0,392	57	0,333	49	0,287	39	0,228
20	80	0,421	72	0,379	62	0,326	52	0,274	42	0,221
21	86	0,410	78	0,371	66	0,314	56	0,267	44	0,210
22	91	0,394	83	0,359	71	0,307	61	0,264	47	0,203
23	99	0,391	89	0,352	75	0,296	65	0,257	51	0,202
24	104	0,377	94	0,341	80	0,290	68	0,246	54	0,196

La valeur critique pour un test bilatéral à 5 % se situe dans le bloc **0.025** dans la colonne τ'

Pour que la corrélation soit considérée comme **significative**, la valeur obtenue devrait être **supérieure** à la valeur de la table pour l'effectif, ici **n**=5, à savoir supérieure à **1.000** ?!

Comme t_k = **0.2** < **1.0**. La corrélation de Kendall n'est donc pas significative au niveau d'incertitude 5 %.

CORRÉLATION DE KENDALL

Fichier **fnpar1.txt**

ETUDIANT	VOCAB	ARITH
Albert	48	48
Bernard	54	56
Charles	52	62
Daniel	55	67
Emile	58	53

➡ Le programme SAS **fnpar1_2.sas** s'écrira :

```
/* Programme fnpar1_2.sas */
data un ;
infile 'c:\etudiant\fnpar1.txt' firstobs=2 ;
input etudiant $ vocab arith ;
PROC CORR DATA=un KENDALL ;
  VAR vocab arith ;
title 'Corrélation de Kendall' ;
run ;
```

Coeficientes de correlación Kendall Tau b, N = 13
Prob > |tau| suponiendo H0: Tau=0

	test2	test4
test2	1.00000	0.31014 0.1662
test4	0.31014 0.1662	1.00000

→ Probabilité de dépassement relative à la corrélation de Kendall

la valeur de la corrélation de Kendall

Test de Kruskal-Wallis :

TEST DE KRUSKAL-WALLIS

(Ce test non paramétrique correspond à l'***analyse de variance simple*** pour échantillons **indépendants**)

Principe : Les données initiales sont transformées en ***rangs*** sur l'**ensemble** de l'échantillon

Hypothèse : Egalité des **médianes** entre les groupes

$$Med_1 = Med_2 = Med_3 = \ldots Med_m$$

Statistique : La statistique de Kruskal-Wallis est

$$H = \frac{12}{n(n+1)} \sum_{i=1}^{m} \frac{S_i^2}{n_i} - 3(n+1)$$

où S_i est la **somme des rangs** dans le $i^{ème}$ groupe

Jours d'absence

Conditions expérimentales			
C1	C2	C3	C4
17	14	6	11
9	10	8	2
35	21	5	4
20	18	13	7

Données sous forme de rangs

Conditions expérimentales			
C1	C2	C3	C4
12	11	4	9
7	8	6	1
16	15	3	2
14	13	10	5
49	47	23	17

Fichier **fnpar2.txt**

CONDITION	NOMBRE
C1	17
C1	9
C1	35
C1	20
C2	14
C2	10
C2	21
C2	18
C3	6
C3	8
C3	5
C3	13
C4	11
C4	2
C4	4
C4	7

➡ Le programme SAS **fnpar2.sas** s'écrira :

```
/* Programme fnpar2.sas */
data un ;
infile 'c:\etudiant\fnpar2.txt' firstobs=2 ;
input condition $ nombre ;
PROC NPAR1WAY DATA=un WILCOXON ;
  CLASS condition ;
  VAR nombre ;
title 'Analyse de variance de Kruskal-Wallis' ;
run ;
```

L'exécution du programme SAS **fnpar2.sas** a donné les résultats suivants :

Le tableau des résultats :

- L'effectif de chaque groupe
- Les sommes des rangs obtenus
- Les valeurs attendues sous hypothèse d'égalité des médianes
- Les écart-types correspondants
- Les moyennes des rangs obtenus

Wilcoxon Scores (Rank Sums) for Variable nombre Classified by Variable condition

condition	N	Sum of Scores	Expected Under H0	Std Dev Under H0	Mean Score
C1	4	49.0	34.0	8.246211	12.250
C2	4	47.0	34.0	8.246211	11.750
C3	4	23.0	34.0	8.246211	5.750
C4	4	17.0	34.0	8.246211	4.250

Le test de Kruskal-Wallis :

- La statistique **H** (chi-carré) = **8.8676**
- Le nombre de degrés de liberté (4-1 = **3**)
- La probabilité de dépassement : **0.0311** (< 0.05)

d'où **un rejet de l'égalité des médianes.**

Kruskal-Wallis Test

Chi-Square	8.8676
DF	3
Pr > Chi-Square	0.0311

Le graphique :

Répartition des scores de Wilcoxon entre les quatre groupes.

N.B. : Ce graphique peut être exclu avec l'instruction **ods graphics off**

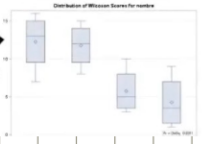

Test de Wilcoxon :

TEST DE WILCOXON
(échantillons indépendants)

(Ce test correspond au ***t de Student*** pour échantillons **indépendants**)

Principe : Les données initiales sont transformées en ***rangs*** sur l'**ensemble** de l'échantillon

Hypothèse : Egalité des **médianes** entre les groupes

Statistique : On détermine

S1 = somme des rangs du premier sous-échantillon
S2 = somme des rangs du deuxième sous-échantillon

➡ La statistique de Wilcoxon est égale à la **somme des rangs** de celui des deux sous-échantillons qui présente le **plus petit** effectif (ici le groupe RETARD)

➡ Statistique de Wilcoxon : $S = 96.5$

groupe	score
RETARD	67
RETARD	55
RETARD	51
RETARD	40
RETARD	25
RETARD	18
RETARD	34
RETARD	44
RETARD	52
RETARD	59
RETARD	54
RETARD	53
NORMAL	95
NORMAL	87
NORMAL	77
NORMAL	73
NORMAL	44
NORMAL	64
NORMAL	68
NORMAL	70
NORMAL	55
NORMAL	59

groupe	score
RETARD	17.5
RETARD	12.5
RETARD	7.0
RETARD	4.0
RETARD	2.0
RETARD	1.0
RETARD	3.0
RETARD	5.5
RETARD	8.5
RETARD	14.5
RETARD	11.0
RETARD	10.0
NORMAL	27.0
NORMAL	23.0
NORMAL	22.0
NORMAL	21.0
NORMAL	5.5
NORMAL	16.0
NORMAL	19.0
NORMAL	20.0
NORMAL	12.5
NORMAL	14.5
NORMAL	17.5
NORMAL	24.0
NORMAL	25.0
NORMAL	26.0
NORMAL	8.5

S1= 96.5

S2= 281.5

Données **Rangs**

TEST DE WILCOXON
(échantillons indépendants)

Fichier **fnpar3.txt**

GROUPE	SCORE
RETARD	67
RETARD	55
RETARD	51
RETARD	40
RETARD	25
RETARD	18
RETARD	34
RETARD	44
RETARD	52
RETARD	59
RETARD	54
RETARD	53
NORMAL	95
NORMAL	87
NORMAL	77
NORMAL	73
NORMAL	44
NORMAL	64
NORMAL	68
NORMAL	70
NORMAL	55
NORMAL	59

➡ Le programme SAS **fnpar3.sas** s'écrira :

```
/* Programme fnpar3.sas */
data un ;
infile 'c:\etudiant\fnpar3.txt' firstobs=2 ;
input groupe $ score ;
PROC NPAR1WAY DATA=un WILCOXON ;
 CLASS groupe ;
 VAR score;
title 'Test de Wilcoxon – Echantillons indépendants' ;
run ;
```

TEST DE WILCOXON
(échantillons indépendants)

L'exécution du programme SAS **fnpar3.sas** a (notamment) donné les résultats suivants :

Le tableau des résultats :

- L'effectif de chaque groupe
- Les sommes des scores de rangs
- Les valeurs attendues sous hypothèse d'égalité des médianes
- Les écart-types correspondants
- Les moyennes des scores observés.

Wilcoxon Scores (Rank Sums) for Variable score Classified by Variable groupe

groupe	N	Sum of Scores	Expected Under H0	Std Dev Under H0	Mean Score
RETARD	12	96.50	168.0	20.478256	8.041667
NORMAL	15	281.50	210.0	20.478256	18.766667

Average scores were used for ties.

Le test de Kruskal-Wallis :
Qu'il vaut mieux ne pas considérer ici puisque sa statistique est alors un χ^2 à un seul degré de liberté !

Kruskal-Wallis Test	
Chi-Square	12.1906
DF	1
Pr > Chi-Square	0.0005

Le graphique :
Répartition des scores de Wilcoxon entre les deux groupes.

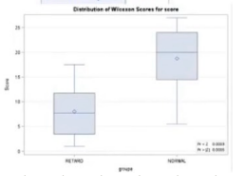

"EXACT WILCOXON" pour tester de façon exacte.

TEST DE WILCOXON
Table des valeurs critiques (niveau 5%)

0.05

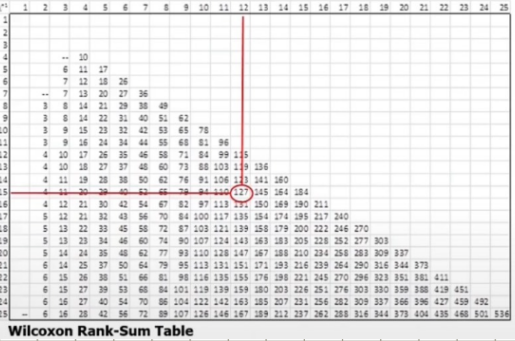

Wilcoxon Rank-Sum Table

Pour notre exemple, la **valeur critique** dans le tableau se trouve au croisement des lignes qui correspondent aux effectifs des deux groupes (à savoir ici ligne **12** et colonne **15**)

La statistique **S** sera significative si sa valeur est **inférieure** à la valeur critique (ici **127**)

S = 96.5 < 127 et donc la différence entre les deux groupes est **significative** au niveau d'incertitude 5%

Remarque : une table similaire existe pour le niveau d'incertitude **1%**

↳ la valeur critique est le chiffre qu'on trouve sur ce tableau

TEST DE WILCOXON
(échantillons indépendants)

L'exécution du programme SAS **fnpar3.sas** a (surtout) donné les résultats suivants :

Le test de Wilcoxon S = 96.5
(et ses probabilité de dépassement approximatives) :

- L'approximation de **p** par la loi normale (**Z**)
- L'approximation par **p** la loi de Student (**t**)

Remarque :

- Ce sont habituellement les probabilités bilatérales qui sont considérées.
- Il est possible d'obtenir un test "exact" de Wilcoxon en ajoutant l'instruction suivante au programme :

```
proc npar1way data=un wilcoxon ;
class groupe ;
var score ;
exact wilcoxon ;
```

Ce qui fournira un **complément** au tableau de droite

Wilcoxon Two-Sample Test	
Statistic	96.5000
Normal Approximation	
Z	-3.4671
One-Sided Pr < Z	0.0003
Two-Sided Pr > |Z|	0.0005
t Approximation	
One-Sided Pr < Z	0.0009
Two-Sided Pr > |Z|	0.0018
Z includes a continuity correction of 0.5.	

Exact Test	
One-Sided Pr <= S	<.0001
Two-Sided Pr >= |S - Mean|	0.0002
Z includes a continuity correction of 0.5.	

Conclusion : Dans chacun des tests, la probabilité de dépassement est < 0.05 d'où **rejet de l'égalité des médianes** entre les deux groupes.

Test de dos muestras de Wilcoxon								
				Aproximación t			Exacto	
Statistic (S)	Z	Pr < Z	Pr > |Z|	Pr < Z	Pr > |Z|	Pr <= S	Pr >= |S-media|
32.0000	-1.3647	0.0862	0.1724	0.0987	0.1974	0.0892	0.1789
Z incluye una corrección de continuidad de 0.5.							

Proba bilatérale

↳ la probabilité relative à la statistique → Pr > Chi Sq

Test de Friedman :

La statistique non paramétri

TEST DE FRIEDMAN

- Comment obtenir les **données texte** dans la **structure** correcte ?

Sujet	Temps1	Temps2	Temps3
1	10	10	15
2	10	15	20
3	11	15	12
4	8	12	10
5	7	12	9
6	15	10	15
7	14	12	18
8	10	14	17
9	9	19	12
10	10	14	16

fnpar6a.txt

En les encodant dans la forme prescrite
En les modifiant via un fichier EXCEL
Par programmation SAS :

```
/* Programme modification */
data modif ;
infile 'c:\etudiant\fnpar6a.txt' firstobs=2 ;
input sujet temps1 temps2 temps3 ;
/* Suppression de variables en fin de traitement */
drop temps1 temps2 temps3 ;
/* Création des variables SCORE et MOMENT */
score = temps1; moment=1 ;output;
score = temps2; moment=2 ;output;
score = temps3; moment=3 ;output;
proc print data=modif ;  /* Optionnel */
/* Insertion de la suite du programme */
run ;
```

(le programme **modification.sas** est disponible)

Sujet	Temps	Score
1	1	10
1	2	10
1	3	15
2	1	10
2	2	15
2	3	20
3	1	11
3	2	15
3	3	12
4	1	8
4	2	12
4	3	10
5	1	7
5	2	12
5	3	9
6	1	15
6	2	10
6	3	15
7	1	14
7	2	12
7	3	18
8	1	10
8	2	14
8	3	17
9	1	9
9	2	19
9	3	12
10	1	10
10	2	14
10	3	16

fnpar6b.txt

```
/* Programme fnpar6.sas */
data un ;
infile 'c:\etudiant\fnpar6b.txt' firstobs=2 ;
input sujet moment temps ;
PROC FREQ data=un ;
  TABLES sujet*moment*temps / cmh2 scores=rank
      noprint ;
title 'Test de Friedman' ;
run ;
```

- **Le test de Friedman mesures répétées :**
  - Les degrés de liberté : **2**
  - La statistique χ^2 = **8.5789**
  - La probabilité de dépassement : **0.0137** (< 0.05)

Cochran-Mantel-Haenszel Statistics (Based on Rank Scores)

Statistic	Alternative Hypothesis	DF	Value	Prob
1	Nonzero Correlation	1	8.2237	0.0041
2	Row Mean Scores Differ	2	8.5789	0.0137

Total Sample Size = 30

La probabilité de dépassement 0.0137 est < 0.05 d'où on **rejette l'égalité des médianes** entre les trois moments de mesure.

TEST DE FRIEDMAN

Table des valeurs critiques

	c = 3		c = 3		c = 4			c = 5			c = 6		
l	5%	1%	l	5%	1%	l	5%	1%	l	5%	1%	l	5%	1%
2	-	-	26	6,077	9,308	2	6,000	-	2	7,800	8,000	2	9,357	9,929
3	6,000	-	27	6,000	9,407	3	7,400	9,000	3	8,533	10,130	3	9,857	11,760
4	6,500	8,000	28	6,500	9,214	4	7,800	9,600	4	8,800	11,200	4	10,390	12,820
5	6,400	8,400	29	6,276	9,172	5	7,800	9,960	5	8,960	11,680			
6	7,000	9,000	30	6,200	9,267	6	7,600	10,200	6	9,067	11,870			
7	7,143	8,857	31	6,000	9,290	7	7,800	10,540	7	9,143	12,110			
8	6,250	9,000	32	6,063	9,250	8	7,650	10,500	8	9,200	12,300			
9	6,222	9,556	33	6,061	9,152	9	7,667	10,730	9	9,244	14,440			
10	6,200	8,600	34	6,059	9,176	10	7,680	10,680						
11	6,545	9,455	35	6,171	9,314	11	7,691	10,750						
12	6,500	9,500	36	6,167	9,389	12	7,700	10,800						
13	6,615	9,385	37	6,054	9,243	13	7,800	10,850						
14	6,143	9,143	38	6,158	9,053	14	7,714	10,890						
15	6,400	8,933	39	6,000	9,282	15	7,720	10,920						
16	6,500	9,375	40	6,050	9,150	16	7,800	10,950						
17	6,118	9,294	41	6,195	9,366	17	7,800	11,050						
18	6,333	9,000	42	6,143	9,190	18	7,733	10,930						
19	6,421	9,579	43	6,186	9,256	19	7,863	11,020						
20	6,300	9,300	44	6,318	9,136	20	7,800	11,100						
21	6,095	9,238	45	6,178	9,244	21	7,800	11,060						
22	6,091	9,091	46	6,043	9,435	22	7,800	11,070						
23	6,348	9,391	47	6,128	9,319									
24	6,250	9,250	48	6,167	9,125									
25	6,080	8,960	49	6,041	9,184									

Il faut d'abord choisir la colonne du nombre de répétitions (ici **3**) et la sous-colonne **5%**

La statistique χ^2 sera significative si sa valeur est **supérieure** à la valeur critique pour l'effectif **n** = 10. Cette valeur critique est ici **6.200**

La valeur obtenue χ^2 = **8.5789** est > **6.200** et, par suite, on **rejette** l'hypothèse d'une égalité des médianes entre les trois résultats obtenus au cours du temps.

Test de Kolmorov-Smirnov :

=> les 2 ech proviennent de la même population ?
Comparer la distribution de 2 échantillons (m et n où $m = n$ / $m \neq n$)

```
/* Programme fnpar7.sas */
data un ;
infile 'c:\etudiant\fnpar7.txt' firstobs=2 ;
input groupe $ taux ;
PROC NPAR1WAY DATA=un D;
 CLASS groupe ;
 VAR taux ;
title 'Test de Kolmogorov-Smirnov' ;
run ;
```

L'exécution du programme SAS **fnpar7.sas** a (notamment) donné le résultat suivant :

Le test de Kolmogorov-Smirnov

- La statistique **D = maximum** | F_1 - F_2 | = **0.4667**
- Sa probabilité de dépassement **p = 0.5925** (≥ 0.05)
- **D+** le maximum des différences positives entre F_1 et F_2 et sa probabilité de dépassement.
- **D-** le maximum des différences négatives entre F_1 et F_2 et sa probabilité de dépassement.

Kolmogorov-Smirnov Two-Sample Test (Asymptotic)	
D = max |F1 - F2|	0.4667
Pr > D	0.5925
D+ = max (F1 - F2)	0.0000
Pr > D+	1.0000
D- = max (F2 - F1)	0.4667
Pr > D-	0.3049

La valeur obtenue pour la statistique **D** et sa probabilité de dépassement ≥ 0.05 amènent à **tolérer l'hypothèse d'égalité des distributions entre les deux échantillons** qui, par suite, peuvent donc être considérés comme provenant d'une même population.

Remarque : L'indice **EDF** fournit par la procédure
Il s'agit ici de la représentation graphique des **fonctions de distributions empiriques** (EDF = *Empirical Distribution Function*) de la variable TAUX dans **les deux groupes**.

Adéquation du chi carré :

on applique si on a des variables discrètes ou dans des situations où les données observées peuvent être classifiées en les m modalités d'une variable catégorielle de manière exhaustive et exclusive

=> la répartition recueillie est compatible avec la distribution théorique en pourcentages

```
/* Programme fnpar8.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\fnpar8.txt' firstobs=2 ;
input cheveu $ nombre ;
/* Détermination de l'adéquation du chi-carré */
PROC FREQ data=un ;
 TABLES cheveu / nocum chisq testp=(30 25 30 3 12) ;
 WEIGHT nombre ;
title 'Adéquation du chi-carré - Couleur des cheveux' ;
run ;
```

les %

⚠ SAS classe les données par ordre alphabétique

ADÉQUATION DU CHI-CARRÉ

L'exécution du programme SAS **fnpar8.sas** a fourni les résultats suivants :

Le tableau des pourcentages observés et testés

cheveu	Frequency	Percent	Test Percent
blond	228	29.92	30.00
brun	182	23.88	25.00
châtain	217	28.48	30.00
noir	22	2.89	3.00
roux	113	14.83	12.00

- La liste des couleurs de cheveux
- Les effectifs observés de chaque modalité (couleurs)
- Les **pourcentages observés** des cinq modalités.
- Les **pourcentages théoriques** à comparer aux pourcentages observés.

Chi-Square Test for Specified Proportions	
Chi-Square	6.0853
DF	4
Pr > ChiSq	0.1929

Le test de l'adéquation du chi-carré

- La **statistique** χ^2 = **6.0853**
- Les degrés de liberté = m − 1 = **4**
- La probabilité de dépassement **p = 0.1929** (≥ 0.05).

Au niveau d'incertitude 5%, on tolère l'adéquation des résultats observés et de la distribution théorique de la couleur des cheveux

Important

Une **source d'erreur** assez fréquente est de ne pas être attentif à la **concordance** de la **liste des pourcentages** dans la commande **testp=** avec les **effectifs observés** lorsque les données texte **identifiantes** ne sont pas présentées par ordre alphabétique.

Exemple : En France, la répartition théorique des groupes sanguins (sans tenir compte du facteur rhésus) est la suivante : **A = 44% B = 10% AB = 4% O = 42%**
Un chercheur teste un échantillon de 200 sujets et il obtient la répartition suivante pour les groupes sanguins de son échantillon :
A = 101 B = 25 AB = 22 O = 52
Le chercheur souhaite déterminer si les effectifs observés dans son échantillon sont compatibles avec les pourcentages théoriques des groupes sangui...

Fichier : **fnpar8b.txt**

Groupe	nombre
A	101
B	25
AB	22
O	52

Programme :

```
/* Programme fnpar8b.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\fnpar8b.txt' firstobs=2 ;
input groupe $ nombre ;
PROC FREQ data=un ;
 TABLES groupe / nocum chisq testp=(44 10 4 42) ;
 WEIGHT nombre ;
run ;
```

Résultat :

groupe	Frequency	Percent	Test Percent
A	101	50.50	44.00
AB	22	11.00	10.00
B	25	12.50	4.00
O	52	26.00	42.00

Chi-Square Test for Specified Proportions	
Chi-Square	50.4309
DF	3
Pr > ChiSq	<.0001

Pourquoi ce résultat apparemment valable est-il incorrect ?

⚠ faire attention lorsque les données sont redondantes car sinon le programme ne s'y retrouvera pas

Comment résoudre cette difficulté ?

Dans notre exemple : Les pourcentages théoriques : **A = 44% B = 10% AB = 4% O = 42%**
La répartition observée : **A = 101 B = 25 AB = 22 O = 52**

Première méthode :

```
/* Programme fnpar8b.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\fnpar8b.txt' firstobs=2 ;
input groupe $ nombre ;
PROC FREQ data=un ;
 TABLES groupe / nocum chisq testp=(44 4 10 42) ;
 WEIGHT nombre ;
run ;
```

(Modification de l'ordre des pourcentages en fonction de l'ordre alphabétique imposé des données par SAS.)

groupe	Frequency	Percent	Test Percent
A	101	50.50	44.00
AB	22	11.00	4.00
B	25	12.50	10.00
O	52	26.00	42.00

Chi-Square Test for Specified Proportions	
Chi-Square	39.8609
DF	3
Pr > ChiSq	<.0001

Deuxième méthode (*la plus élégante*) :

```
/* Programme fnpar8b.sas */
ods graphics off ;
data un ;
infile 'c:\etudiant\fnpar8b.txt' firstobs=2 ;
input groupe $ nombre ;
PROC FREQ data=un ORDER=data ;
 TABLES groupe / nocum chisq testp=(44 10 4 42) ;
 WEIGHT nombre ;
run ;
```

(Imposition de l'ordre des donnée telles qu'elles apparaissent dans le fichier.)

Quand c'est possible !

groupe	Frequency	Percent	Test Percent
A	101	50.50	44.00
B	25	12.50	10.00
AB	22	11.00	4.00
O	52	26.00	42.00

Chi-Square Test for Specified Proportions	
Chi-Square	39.8609
DF	3
Pr > ChiSq	<.0001

garder l'ordre des variables

Test de Wilcoxon :

```
1 data un;
2 infile '/home/u59521151/sasuser.v94/Documents/fnpar5.txt' firstobs=2;
3 input avant apres;
4 diff = avant-apres;
5 proc print data=un;
6 run;
7 proc univariate data=un;
8 var diff;
9 run;
```

H_0 = égalité des médianes
↳ rejetée si S < valeur critique de l'effectif n

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	1.500674	Pr > |t|	0.1771
Signe	M	2	Pr >= |M|	0.2891
Rang signé	S	9	Pr >= |S|	0.2500

Probabilité de dépassement

valeur critique pour le test bilatéral avec incertitude de 5%

n	Two-Tailed Test		One-Tailed Test	
	α = .05	α = .01	α = .05	α = .01
5	--	--	0	--
6	0	--	2	--
7	2	--	3	0
8	3	0	5	1

Ici S = 9 > 3 → NS