COURS PSYC5900

Problèmes statistiques et utilisation de logiciels

Leçon 3

EXERCICES PROPOSÉS



Exercice L3_1

Le fichier "texte" **data31.txt** dont un court extrait figure ci-après contient les **cotes** encodées pour les étudiant(e)s ayant présenté en juin 2016 l'examen de statistique du cours PSY5900 :

```
9  BacLogo
6  BacLogo
17 BacLogo
15 BacLogo
7  BacLogo
...
17 BacPsy
12 BacPsy
9  BacPsy
9  BacPsy
...
12 MLogo
11 MLogo
13 MLogo
...
10 MPsy
8  MPsy
17 MPsy
```

a. Il est demandé de créer une table SAS lisant les données de ce fichier et d'afficher le contenu de cette table à l'écran.

b. Déterminez la **moyenne**, la **médiane** et le **mode** et, au niveau d'incertitude 5 %, l'**intervalle de confiance** sur la moyenne de ces cotes.

c. Quelle est la **moyenne** des cotes obtenue au sein de **chacun** des deux groupes BacPsy et BacLogo ?

d. Quel est le **pourcentage** d'étudiant(e)s ayant obtenu une **cote ≥ 10** ?

Exercice L3_2

Le fichier EXCEL **data32.xlsx** (bref extrait ci-après) reprend les résultats individuels de 60 sujets aux deux items d'un test de performance :

Score1	Score2
1,56	245
1,54	240
1,53	240
1,53	236
1,55	243
1,63	247
1,57	238
1,55	239
...	...

a. On demande de procéder à la lecture de ce fichier externe par SAS et d'afficher la table obtenue à l'écran.

b. Déterminez la **moyenne** et la **variance** des variables **Score1** et **Score2**.

c. Quelles sont les valeurs du **1er et** du **3ème quartile** de la distribution de la variable **Score1** ? Que vaut l'**intervalle interquartile** de cette même distribution ?

d. Quelles sont les valeurs de l'**indice d'asymétrie** et de l'**indice d'aplatissement** pour la variable **Score2** ?

Exercice L3_3

On considère un échantillon dont les données sont reprises dans le fichier EXCEL **data33.xslx** (dont un court extrait figure ci-après) :

Niveau	Genre	x1	x2	x3	x4	test	score1	score2	score3	temps
1	2	43	53	61	62	161	391	323	296	2,79
1	1	38	40	72	66	198	441	395	323	2,39
1	1	27	26	69	59	210	445	347	114	1,11
1	2	36	34	68	58	187	433	374	256	1,85
1	1	39	46	61	62	121	354	290	260	2,47
1	1	36	44	72	66	153	610	491	389	3,55
1	2	27	35	64	68	145	345	339	218	1,63
1	1	45	45	69	63	166	484	419	460	3,88
1	2	41	45	68	68	180	489	429	289	2,72
1	2	26	30	66	67	166	550	449	192	1,42
...	...	...	...	...	...	...	...	...	...	...

Les modalités de la variable **Genre** sont 1='femme' et 2='homme'.
Les modalités de la variable **Niveau** sont 1='inf' 2='moyen' et 3='sup'.

a. Il vous est demandé de faire lire ce fichier par SAS et d'afficher son contenu à l'écran avec l'affichage littéral explicatif des modalités des variables **Genre** et **Niveau**.

b. Déterminez les **moyenne**, **médiane** et **mode** des variables X1, X2, X3 et X4.

c. Déterminez la **moyenne** de la variable **Temps** dans **chaque modalité** de la variable GENRE.

d. Déterminez la **moyenne** de la variable **Test** dans **chaque modalité** de la variable **Niveau**.

e. Donnez les valeurs des **trois quartiles** de la variable **Score1**.

f. Quelle est l'**étendue** des données de la variable **Test** ?

Exercice L3_4

Un extrait du fichier texte **data34.txt** figure ci-dessous :

NOM	SCORE1	SCORE2	AGE
Barbara	8.2	77	77
Bastien	8.1	68	68
Benjamin	7.2	66	66
Bernadette	7.0	69	69
Brenda	6.2	36	36
Bernard	5.9	49	49
Baise	5.3	73	73
...			

Le nom des variables figure sur la première ligne du fichier. Les variables **score1**, **score2** et **age** sont respectivement un indice de santé, un taux de cholestérol et un âge.

a. On demande de faire lire ce fichier par SAS et d'afficher à l'écran les données lues.

b. On demande de transformer la variable **score1** en rangs croissants (la **moyenne des rangs** étant activée en cas d'ex aequo) puis d'afficher à l'écran par rangs croissants la liste des noms et le rang correspondant.

c. Quel est le sujet qui a obtenu un rang égal à 17 ? Quel est le rang attribué à Bruno ? Quels sont les sujets ayant obtenu le plus grand rang en situation d'ex aequo?

d. On souhaite maintenant créer un fichier comportant les rangs décroissants associés aux variables **score1** et **score2** (en activant l'option HIGH en cas d'ex aequo) mais reprenant également les variables initiales en son sein puis d'afficher le contenu de ce fichier à l'écran.

Exercice L3_5

On considère le fichier "texte" **data35.txt** dont un extrait figure ci-après :

nom	genre	score1	score2	test
albert	1	12	15	0.25
béatrice	1	8	16	1.32
cédric	2	16	14	2.12
danielle	2	17	17	0.03
emile	2	4	10	4.01
fanny	1	11	12	5.03
georges	2	13	10	2.12
hélène	1	16	9	.
isabelle	2	15	8	0.15

etc…

a. On vous demande de réaliser un programme SAS qui lit les données de ce fichier et d'afficher celles-ci à l'écran en explicitant les modalités de la variable GENRE qui sont 1='femme' et 2='homme'.

b. Il est demandé de standardiser (moyenne=0 et écart-type=1) les variables score1 et score2 et d'afficher les résultats obtenus

c. on souhaite maintenant standardiser la variable test (moyenne=0 et écart-type=1) mais sans laisser perdurer ses valeurs manquantes à l'écran.

d. Quel est, pour la variable test, le sujet qui présente la plus grande valeur positive de Z ? Quel est le sujet qui présente la plus grande valeur négative de Z ? Quelles sont ces valeurs ?

Exercice L3_6

On utilise à nouveau le fichier EXCEL **data33.xslx** de l'exercice **L3_3**.

a. Quel est le **pourcentage** de sujets de ce fichier pour lesquels la variable X2 est ≥ 30 et < 50 ?

b. Quel est le **nombre** de sujets dans chacune des modalités de la variable NIVEAU ?

c. Quel est le **pourcentage** de femmes et d'hommes dans votre échantillon ?

d. Quel est le **mode** de la variable GENRE ?

RÉPONSES AUX EXERCICES PROPOSÉS

Exercice L3_1

a. On obtient :

The SAS System

Obs	cote	section
1	9	BacLogo
2	6	BacLogo
3	17	BacLogo
4	15	BacLogo
5	7	BacLogo
6	18	BacLogo

etc…

b. Les résultats sont :

Moyenne - Médiane - Mode - Intervalle de confiance

The MEANS Procedure

Analysis Variable : cote					
N	Mean	Median	Mode	Lower 95% CL for Mean	Upper 95% CL for Mean
206	12.9902913	14.0000000	15.0000000	12.3378866	13.6426959

c. En effectuant un tri sur les sections, on obtient (partim) :

Moyenne chez les BacLog et chez les BacPsy

The MEANS Procedure

section=BacLogo

Analysis Variable : cote	
N	Mean
33	13.4242424

section=BacPsy

Analysis Variable : cote	
N	Mean
141	13.1489362

d. En recourant à la procédure de tabulation pour la variable cote, on obtient le tableau (partiellement présenté) des cotes obtenues à l'examen (voir ci-après). On en déduit dès lors que le pourcentage demandé est : 100 – 23.30 = 76.70 %

Répartition des cotes - Echantillon complet

The FREQ Procedure

cote	Frequency	Percent	Cumulative Frequency	Cumulative Percent
1	4	1.94	4	1.94
2	3	1.46	7	3.40
3	7	3.40	14	6.80
5	6	2.91	20	9.71
6	1	0.49	21	10.19
7	10	4.85	31	15.05
8	7	3.40	38	18.45
9	10	4.85	48	23.30
10	4	1.94	52	25.24
11	15	7.28	67	32.52
12	11	5.34	78	37.86

etc…

Exercice L3_2

a. On obtient :

Fichier des données lues

Obs	score1	score2
1	1.56	245
2	1.54	240
3	1.53	240
4	1.53	236
5	1.55	243
6	1.63	247
7	1.57	238
8	1.55	239

etc…

b. Il vient pour la moyenne et la variance des variables **score1** et **score2** :

Moyenne et variance des deux variables

The MEANS Procedure

Variable	N	Mean	Variance
score1	60	1.5798333	0.0012254
score2	60	241.5166667	27.7454802

c. On obtient pour les quartiles et l'étendue de la variable **score1** :

Variable score1 : Quartiles Q1 et Q3 et Etendue

The MEANS Procedure

Analysis Variable : score1			
N	Lower Quartile	Upper Quartile	Quartile Range
60	1.5500000	1.6100000	0.0600000

d. Les indices d'asymétrie et d'aplatissement pour la variable **score2** sont :

Variable score2 : indice d'asymétrie et d'aplatissement

The MEANS Procedure

Analysis Variable : score2		
N	Skewness	Kurtosis
60	-0.1641947	-0.4117760

Exercice L3_3

a. On obtient à l'écran :

Fichier des données lues et explicitées

Obs	niveau	genre	x1	x2	x3	x4	test	score1	score2	score3	temps
1	inf	homme	43	53	61	62	161	391	323	296	2.79
2	inf	femme	38	40	72	66	198	441	395	323	2.39
3	inf	femme	27	26	69	59	210	445	347	114	1.11

…

25	moyen	femme	34	39	67	64	151	458	377	567	4.49
26	moyen	femme	33	36	68	63	151	488	425	313	2.99
27	moyen	femme	29	33	66	66	178	421	375	233	1.90

…

74	sup	femme	47	51	73	66	158	657	499	604	5.21
75	sup	homme	52	54	66	64	155	340	305	242	2.38
76	sup	homme	48	46	69	67	192	407	343	326	3.01

etc…

b. On obtient le résultat suivant :

Moyenne-Médiane-Mode de X1, X2, X3 et X4

The MEANS Procedure

Variable	N	Mean	Median	Mode
x1	92	38.5326087	38.0000000	36.0000000
x2	92	40.7065217	40.0000000	40.0000000
x3	92	69.1304348	69.0000000	69.0000000
x4	92	63.9673913	64.0000000	62.0000000

c. Le résultat obtenu est :

Moyenne de la variable temps par genre

The MEANS Procedure

genre=femme

Analysis Variable : temps	
N	Mean
48	3.0133333

genre=homme

Analysis Variable : temps	
N	Mean
44	2.3218182

d. Les moyennes demandées sont :

Moyenne de la variable test par niveau

The MEANS Procedure

niveau=inf

Analysis Variable : test	
N	Mean
24	179.6250000

niveau=moyen

Analysis Variable : test	
N	Mean
49	181.8163265

niveau=sup

Analysis Variable : test	
N	Mean
19	179.1578947

e. Les trois quartiles demandés sont :

Variable score1 : Q1 Q2=médiane et Q3

The MEANS Procedure

Analysis Variable : score1			
N	Lower Quartile	Median	Upper Quartile
92	433.5000000	486.0000000	547.0000000

f. L'étendue pour la variable **Test** est le suivant :

Etendue de la variable test

The MEANS Procedure

Analysis Variable : test	
N	Range
92	114.0000000

Exercice L3_4

a. Le fichier data34.txt doit apparaître comme dans l'extrait ci-après :

Fichier des données lues

Obs	nom	score1	score2	age
1	Barbara	8.2	77	77
2	Bastien	8.1	68	68
3	Benjamin	7.2	66	66
4	Bernadette	7.0	69	69
5	Brenda	6.2	36	36

etc…

b. On obtient :

Rangs croissants - Variable score1

Obs	nom	score1
1	Babeth	2.0
2	Basile	2.0
3	Bryan	2.0
4	Baptiste	4.5
5	Blandine	4.5
6	Bertrand	6.5
7	Blanche	6.5
8	Betty	8.0
9	Bruno	9.0
10	Boris	10.5
11	Brigitte	10.5
12	Berthe	12.0
13	Baise	13.0
14	Bernard	14.0
15	Brenda	15.0
16	Bernadette	16.0
17	Benjamin	17.0
18	Bastien	18.0
19	Barbara	19.0

c.
C'est Benjamin qui a obtenu le rang 17.
Le rang attribué à Bruno est 9
Les trois plus petits rangs relatifs à un ex aequo sont
Le plus grand rang en situation d'ex aequo est 10.5. Il a été attribué à Boris et Brigitte.

d. On obtient le résultat suivant ;

Rangs décroissants variables score1 et score2

Obs	nom	score1	score2	age	rscore1	rscore2
1	Barbara	8.2	77	77	1	4
2	Bastien	8.1	68	68	2	9
3	Benjamin	7.2	66	66	3	10
4	Bernadette	7.0	69	69	4	8
5	Brenda	6.2	36	36	5	18
6	Bernard	5.9	49	49	6	16
7	Baise	5.3	73	73	7	6
8	Berthe	5.2	52	52	8	15
9	Boris	5.0	77	77	10	4
10	Brigitte	5.0	73	73	10	6
11	Bruno	4.9	62	62	11	12
12	Betty	4.8	54	54	12	14
13	Bertrand	4.7	63	63	14	11
14	Blanche	4.7	23	43	14	19
15	Baptiste	4.6	70	70	16	7
16	Blandine	4.6	59	59	16	13
17	Babeth	4.5	96	86	19	1
18	Basile	4.5	84	84	19	2
19	Bryan	4.5	40	40	19	17

Exercice L3_5

a.

Fichier des données lues

Obs	nom	genre	score1	score2	test
1	albert	femme	12	15	0.25
2	béatrice	femme	8	16	1.32
3	cédric	homme	16	14	2.12
4	danielle	homme	17	17	0.03
5	emile	homme	4	10	4.01
6	fanny	femme	11	12	5.03
7	georges	homme	13	10	2.12
8	hélène	femme	16	9	.

etc…

b.

Valeurs Z standardisées pour les variables score1 et score2

Obs	nom	genre	score1	score2	test
1	albert	1	-0.13892	1.04738	0.25
2	béatrice	1	-1.12677	1.35772	1.32
3	cédric	2	0.84894	0.73705	2.12
4	danielle	2	1.09590	1.66805	0.03
5	emile	2	-2.11463	-0.50430	4.01
6	fanny	1	-0.38588	0.11638	5.03
7	georges	2	0.10805	-0.50430	2.12
8	hélène	1	0.84894	-0.81463	.

etc…

c.

Valeurs Z standardisées pour la variable test avec remplacement des valeurs manquantes

Obs	nom	genre	score1	score2	test
1	albert	1	12	15	-1.22943
2	béatrice	1	8	16	-0.61656
3	cédric	2	16	14	-0.15833
4	danielle	2	17	17	-1.35544
5	emile	2	4	10	0.92422
6	fanny	1	11	12	1.50845
7	georges	2	13	10	-0.15833
8	hélène	1	16	9	0.00000
9	isabelle	2	15	8	-1.28671
10	jean	2	10	7	-1.32680
11	kevin	2	6	7	0.40872
12	louis	1	19	11	1.42827
13	marine	1	15	13	1.49700
14	noémie	1	14	9	-0.10105
15	oscar	2	13	15	0.00000
16	pierre	2	12	13	0.46600

d.
Plus grande valeur positive de Z : 1.50845 de Fanny
Plus grande valeur négative de Z : -1.35544 de Danielle

Exercice L3_6

a. 78.26 %

b.

Nombre de sujets dans les trois niveaux

The FREQ Procedure

niveau	Frequency	Percent	Cumulative Frequency	Cumulative Percent
inf	24	26.09	24	26.09
moyen	49	53.26	73	79.35
bon	19	20.65	92	100.00

Niveau : inf 24 – moyen 49 – bon 19

c.

Pourcentage de femmes et d'hommes dans l'échantillon

The FREQ Procedure

genre	Frequency	Percent	Cumulative Frequency	Cumulative Percent
femme	48	52.17	48	52.17
homme	44	47.83	92	100.00

Genre : femme 52.17 % - homme 47.83 %

d. le mode est : femme