Chapitre 7

Techniques particulières de corrélation

Relations entre variables

Mesures de corrélation

Les valeurs des variables peuvent être ordonnées

Mesures d'association

Les valeurs ne peuvent être ordonnées

Variables nominales

Techniques particulières de corrélation

1. Corrélation bisérielle de point
2. Corrélation de Spearman
3. Coefficient de concordance de Kendall
4. Corrélation partielle

Rappel

Le coefficient de corrélation de Pearson

Relation entre deux variables continues X et Y

Valeur entre –1 et +1

Rappel

Valeur absolue indique le degré de relation

Signe = sens de la relation

Exemple: r = 0,94

r = -0,60

Le coefficient de corrélation de Pearson (*r*)

$$r = \frac{\mathrm{cov}_{XY}}{S_X S_Y}$$

La covariance

Reflète le degré auquel deux variables varient ensemble

$$\mathrm{cov}_{XY} = \frac{\sum \left(X - \overline{X}\right)\left(Y - \overline{Y}\right)}{N - 1}$$

Poids	Taille	$X - \overline{X}$	$Y - \overline{Y}$	$(X - \overline{X})(Y - \overline{Y})$
75	170	-2,3	-4,1	9,43
60	155	-17,3	-19,1	330,43
94	184	16,7	9,9	165,33
75	180	-2,3	5,9	-13,57
72	162	-5,3	-12,1	64,13
100	191	22,7	16,9	383,63
69	169	-8,3	-5,1	42,33
65	172	-12,3	-2,1	25,83
85	175	7,7	0,9	6,93
78	183	0,7	8,9	6,23

$\overline{X} = 77,3$ $\overline{Y} = 174,1$

La covariance

$$\mathrm{cov}_{XY} = \frac{\sum XY - \dfrac{\sum X \sum Y}{N}}{N-1}$$

Poids (X)	Taille (Y)	X^2	Y^2	XY
75	170	5625	28900	12750
60	155	3600	24025	9300
94	184	8836	33856	17296
75	180	5625	32400	13500
72	162	5184	26244	11664
100	191	10000	36481	19100
69	196	4761	28561	11661
65	172	4225	29584	11180
85	175	7225	30625	14875
78	183	6084	33489	14274
773	1741	61165	304165	135600

Calcul du coefficient de corrélation (*r*)

$\Sigma X = 773$	$\Sigma Y = 1741$	$\Sigma X^2 = 61165$	$\Sigma Y^2 = 304165$	$\Sigma XY = 135600$

$$\mathrm{cov}_{XY} = \frac{\sum XY - \frac{\sum X \sum Y}{N}}{N-1} = \frac{135600 - \frac{773 \times 1741}{10}}{9} = 113{,}41$$

Calcul du coefficient de corrélation (*r*)

$\Sigma X = 773$	$\Sigma Y = 1741$	$\Sigma X^2 = 61165$	$\Sigma Y^2 = 304165$	$\Sigma XY = 135600$

$$S_X = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{N}}{N-1}} = \sqrt{\frac{61165 - \frac{773^2}{10}}{9}} = 12{,}53$$

Calcul du coefficient de corrélation (*r*)

$\Sigma X = 773$	$\Sigma Y = 1741$	$\Sigma X^2 = 61165$	$\Sigma Y^2 = 304165$	$\Sigma XY = 135600$

$$S_Y = \sqrt{\frac{\Sigma Y^2 - \frac{(\Sigma Y)^2}{N}}{N-1}} = \sqrt{\frac{304165 - \frac{1741^2}{10}}{9}} = 10{,}84$$

Calcul du coefficient de corrélation (*r*)

$$r = \frac{\mathrm{cov}_{XY}}{S_X S_Y} = \frac{113{,}41}{12{,}53 \times 10{,}84} = 0{,}83$$

coefficient de corrélation (*r*)

= corrélation mesurée sur un échantillon

Test d'hypothèse avec t de Student:

$H_0 : \rho = 0$

$H_A : \rho \neq 0$

La corrélation bisérielle de point

= corrélation avec variable dichotomique

<u>Exemples</u> :

Masculin / Féminin

Réussite / Echec

Marié / Non marié

La corrélation bisérielle de point

Comment calculer une corrélation sur des variables non chiffrées ?

Astuce : Attribuer une valeur arbitraire à chaque catégorie

Zéro et un pour faciliter les calculs

Sujet	Genre	Genre (valeur chiffrée)
1	Masculin	0
2	Masculin	0
3	Masculin	0
4	Masculin	0
5	Féminin	1
6	Féminin	1
7	Masculin	0
8	Féminin	1
9	Féminin	1
10	Masculin	0
11	Féminin	1
12	Masculin	0

Une variable dichotomique et une variable continue

Exemple:

Y a-t-il une relation entre le poids et le genre ?

X = genre (0 = homme / 1 = femme)

Y = Poids

N = 16

Sujet	Genre (X)	Poids (Y)	X^2	Y^2	XY
1	0	63	0	3969	0
2	0	58	0	3364	0
3	0	69	0	4761	0
4	0	88	0	7744	0
5	0	70	0	4900	0
6	0	91	0	8281	0
7	0	82	0	6724	0
8	1	75	1	5625	75
9	1	69	1	4761	69
10	1	54	1	2916	54
…	…	…	…	…	…
Somme	9	1119	9	80063	598

Calcul du coefficient de corrélation

$\Sigma X = 9$	$\Sigma Y = 1119$	$\Sigma X^2 = 9$	$\Sigma Y^2 = 80063$	$\Sigma XY = 598$

$$\mathrm{cov}_{XY} = \frac{\sum XY - \frac{\sum X \sum Y}{N}}{N-1} = \frac{598 - \frac{9 \times 1119}{16}}{15} = -2{,}10$$

Calcul du coefficient de corrélation

$\Sigma X = 9$	$\Sigma Y = 1119$	$\Sigma X^2 = 9$	$\Sigma Y^2 = 80063$	$\Sigma XY = 598$

$$S_X = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{N}}{N-1}} = \sqrt{\frac{9 - \frac{81}{16}}{15}} = 0{,}51$$

Calcul du coefficient de corrélation

$\Sigma X = 9$	$\Sigma Y = 1119$	$\Sigma X^2 = 9$	$\Sigma Y^2 = 80063$	$\Sigma XY = 598$

$$S_Y = \sqrt{\frac{\Sigma Y^2 - \frac{(\Sigma Y)^2}{N}}{N-1}} = \sqrt{\frac{80063 - \frac{1252161}{16}}{15}} = 10{,}96$$

Calcul du coefficient de corrélation

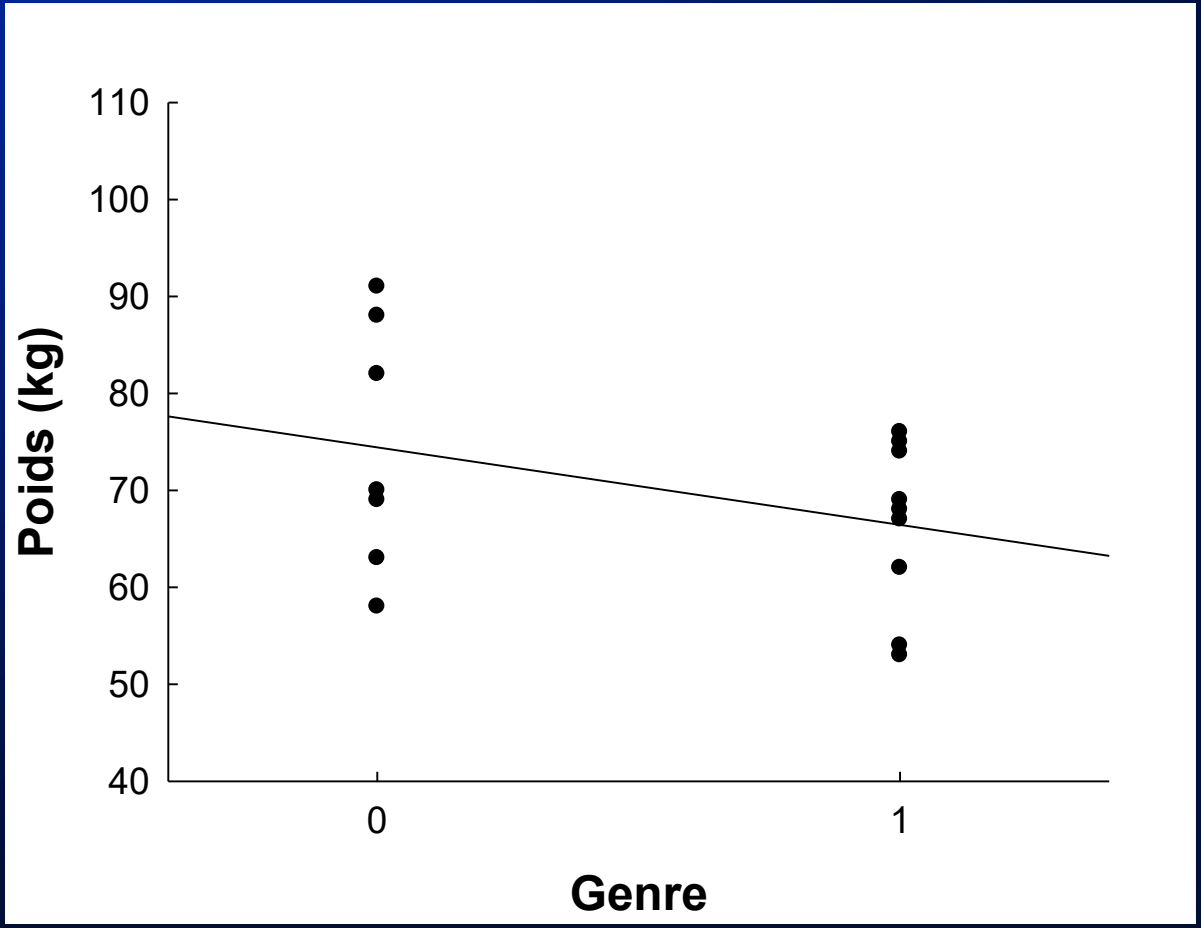
$$r_{pb} = \frac{\mathrm{cov}_{XY}}{S_X S_Y} = \frac{-2{,}10}{0{,}51 \times 10{,}96} = -0{,}38$$

Exemple

Corrélation entre le genre et le poids = 0,38

Le signe du coefficient n'a pas de signification

Diagramme de dispersion



La droite de régression

Elle passe par la moyenne des deux groupes

$$\hat{Y} = bX + a$$

a = Moyenne du groupe auquel est attribué 0

b = Différence entre les moyennes des deux groupes

Calculer l'équation de la droite

Poids moyen des femmes = 66,44

Poids moyen des hommes = 74,43

$a = 74,43$

$b = 66,44 - 74,43 = -7,99$

$\hat{Y} = bX + a = -7,99X + 74,43$

Le coefficient de détermination

$r^2_{pb} = 0,14$

14% de la variabilité du poids peut être expliquée par le sexe.

Tester la signification de la corrélation

Exactement comme pour la corrélation standard

H_0 : $\rho = 0$ (il n'y a pas de relation significative entre le genre et le poids)

H_A : $\rho \neq 0$ (il y a une relation significative entre le genre et le poids)

Tester la signification de la corrélation

N = 16 **dl = 16 – 2 = 14**

r_{pb} = 0,38

α = 0,05 (par défaut)

$$S_r = \sqrt{\frac{1-r^2}{N-2}} = \sqrt{\frac{1-0,14}{16-2}} = 0,25$$

Tester la signification de la corrélation

$$t_{obs} = \frac{r_{pb}}{S_r} = \frac{0,38}{0,25} = 1,52$$

$t_{0,025}$ = 2,145 (test bilatéral et 14 dl)

Puisque 1,52 est inférieur à 2,145, ne pas rejeter H_0

Tester la signification de la corrélation

$$t_{obs} = \frac{r}{S_r} = \frac{0,38}{0,25} = 1,52$$

Ce t est identique à celui obtenu si on teste :

$H_0 : \mu_1 - \mu_2 = 0$

$H_A : \mu_1 - \mu_2 \neq 0$

Deux variables dichotomiques

Exemple:

Y a-t-il une relation entre le genre et la réussite en première année ?

X = genre (0 = garçon / 1 = fille)

Y = résultat (0 = échec / 1 = réussite)

N = 18

Sujet	Genre (X)	Resultat (Y)	X^2	Y^2	XY
1	0	0	0	0	0
2	0	1	0	1	0
3	0	0	0	0	0
4	0	1	0	1	0
5	0	0	0	0	0
6	0	0	0	0	0
7	0	1	0	1	0
8	0	0	0	0	0
9	1	0	1	0	0
10	1	1	1	1	1
…	…	…	…	…	…
Somme	10	9	10	9	6

Calcul du coefficient de corrélation

$\Sigma X = 10$	$\Sigma Y = 9$	$\Sigma X^2 = 10$	$\Sigma Y^2 = 9$	$\Sigma XY = 6$

$$\mathrm{cov}_{XY} = \frac{\sum XY - \frac{\sum X \sum Y}{N}}{N-1} = \frac{6 - \frac{10 \times 9}{18}}{17} = 0{,}055$$

Calcul du coefficient de corrélation

$\Sigma X = 10$	$\Sigma Y = 9$	$\Sigma X^2 = 10$	$\Sigma Y^2 = 9$	$\Sigma XY = 6$

$$S_X = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{N}}{N-1}} = \sqrt{\frac{10 - \frac{100}{18}}{17}} = 0{,}511$$

Calcul du coefficient de corrélation

$\Sigma X = 10$	$\Sigma Y = 9$	$\Sigma X^2 = 10$	$\Sigma Y^2 = 9$	$\Sigma XY = 6$

$$S_Y = \sqrt{\frac{\Sigma Y^2 - \frac{(\Sigma Y)^2}{N}}{N-1}} = \sqrt{\frac{9 - \frac{81}{18}}{17}} = 0{,}514$$

Calcul du coefficient de corrélation

$$r_{pb} = \frac{\mathrm{cov}_{XY}}{S_X S_Y} = \frac{0{,}055}{0{,}511 \times 0{,}514} = 0{,}209$$

Deux variables dichotomiques

Exemple:

$r_{pb} = 0,209$

$r^2_{pb} = 0,04$

4% de la variabilité touchant la réussite peut s'expliquer par le genre

Deux variables dichotomiques

= coefficient phi (Φ) associé au khi-carré

$$\phi = \sqrt{\frac{\chi^2}{N}}$$

	Réussite		
Genre	Oui	Non	Total
Garçon	3 (4)	5 (4)	8
Fille	6 (5)	4 (5)	10
Total	9	9	18

Exemple

$$\chi^2_{obs} = \frac{(3-4)^2}{4} + \frac{(5-4)^2}{4} + \frac{(6-5)^2}{5} + \frac{(4-5)^2}{5} = 0{,}9$$

$$\phi = \sqrt{\frac{\chi^2}{N}} = \sqrt{\frac{0{,}9}{18}} = 0{,}22$$

Tester la corrélation entre deux variables dichotomiques

En utilisant le khi-carré :

$$\phi = \sqrt{\frac{\chi^2}{N}} \longrightarrow \chi^2 = N\phi^2$$

Tester la corrélation entre deux variables dichotomiques

$$\chi^2 = N\phi^2 = 18 \times (0{,}209)^2 = 0{,}79$$

$$\chi^2_{0{,}05}(1) = 3{,}84$$

Puisque 0,79 < 3,84 ne pas rejeter H_0

Corrélation pour données rangées

Rangs plutôt que données brutes

<u>Deux situations</u>

- Données déjà sous forme de rangs = classement
- Violation des conditions de normalité transformer les données en rangs

Corrélation pour données rangées

Deux techniques :

1. **Coefficient de corrélation de Spearman**

2. **Coefficient tau (τ) de Kendall**

Corrélation de Spearman

= Corrélation standard calculée sur rangs

Appliquer la formule standard sur les rangs

$$r_s = 1 - \frac{6\sum D^2}{N(N^2 - 1)}$$

⚠ **Cette formule n'autorise pas les ex-æquos**

Exemple

Y a-t-il une relation entre les résultats à un test de mathématique et un test de biologie ?

N = 10 étudiants

Math	Rangs X	Biologie	Rangs Y	X^2	Y^2	XY
57	3	83	7	9	49	21
45	1	37	1	1	1	1
72	7	41	2	49	4	14
78	8	84	8	64	64	64
53	2	56	3	4	9	6
63	5	85	9	25	81	45
86	9	77	6	81	36	54
98	10	87	10	100	100	100
59	4	70	5	16	25	20
71	6	59	4	36	16	24
682	55	679	55	385	385	349

Calcul du coefficient de corrélation

$\Sigma X = 55$	$\Sigma Y = 55$	$\Sigma X^2 = 385$	$\Sigma Y^2 = 385$	$\Sigma XY = 349$

$$\mathrm{cov}_{XY} = \frac{\sum XY - \frac{\sum X \sum Y}{N}}{N-1} = \frac{349 - \frac{55 \times 55}{10}}{9} = 5{,}17$$

Calcul du coefficient de corrélation

$\Sigma X = 55$ $\Sigma Y = 55$ $\Sigma X^2 = 385$ $\Sigma Y^2 = 385$ $\Sigma XY = 349$

$$S_X = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{N}}{N-1}} = \sqrt{\frac{385 - \frac{55^2}{10}}{9}} = 3{,}03$$

Calcul du coefficient de corrélation

$\Sigma X = 55$ $\Sigma Y = 55$ $\Sigma X^2 = 385$ $\Sigma Y^2 = 385$ $\Sigma XY = 349$

$$S_Y = \sqrt{\frac{\Sigma Y^2 - \frac{(\Sigma Y)^2}{N}}{N-1}} = \sqrt{\frac{385 - \frac{55^2}{10}}{9}} = 3{,}03$$

Calcul du coefficient de corrélation

$$r_s = \frac{\mathrm{cov}_{XY}}{S_X S_Y} = \frac{5{,}17}{3{,}03 \times 3{,}03} = 0{,}56$$

Rangs Math	Rangs Bio	D	D^2
3	7	-4	16
1	1	0	0
7	2	5	25
8	8	0	0
2	3	-1	1
5	9	-4	16
9	6	3	9
10	10	0	0
4	5	-1	1
6	4	2	4
		Somme	72

Corrélation de Spearman

$$r_s = 1 - \frac{6\sum D^2}{N(N^2 - 1)}$$

$$r_s = 1 - \frac{6 \times 72}{10(100 - 1)} = 1 - \frac{432}{990} = 0{,}56$$

Tester une corrélation de Spearman

$H_0 : \rho_s = 0$

$H_A : \rho_s \neq 0$

Procédure complexe et controversée pour les petits échantillons

Table statistique pour corrélation de Spearman

Tester une corrélation de Spearman

$H_0 : \rho_s = 0$

$H_A : \rho_s \neq 0$ N = 10

$r_s = 0{,}56 < r_{s0{,}025} = 0{,}648$ ne pas rejeter H_0

La corrélation n'est pas significative

Coefficient de concordance de Kendall

mesure du degré d'accord entre les classements effectués par plusieurs juges

= Coefficient d'association entre plus de deux classements (données rangées)

Exemple

Etude sur l'attrait des visages

Six photos de visages comme stimuli

Contrôler si il y a un accord sur leur attrait

Exemple

8 sujets (juges) doivent classer les visages par ordre d'attrait

1 = le plus attirant

6 = le moins attirant

Juges	Visages					
	V1	V2	V3	V4	V5	V6
1	1	2	3	5	6	4
2	1	3	2	4	5	6
3	3	1	2	4	5	6
4	2	1	3	4	5	6
5	1	2	3	4	6	5
6	1	3	4	2	5	6
7	3	2	1	5	6	4
8	1	2	4	3	5	6
Somme	13	16	22	31	43	43

Coefficient de concordance de Kendall

Logique du coefficient:

Si tous les juges sont d'accord:

Variabilité maximale entre les totaux

Si classements aléatoires:

Totaux de colonnes similaires

Coefficient de concordance de Kendall

Logique du coefficient:

$$W = \frac{\text{Variance des totaux de colonnes}}{\text{Variance maximale possible des totaux de colonnes}}$$

$$W = \frac{12\sum T_j^2}{k^2 N(N^2-1)} - \frac{3(N+1)}{N-1}$$

Coefficient de concordance de Kendall

$$W = \frac{12\sum T_j^2}{k^2 N(N^2-1)} - \frac{3(N+1)}{N-1}$$

T = totaux de colonnes

k = nombre de juges

N = nombre d'éléments à classer

Coefficient de concordance de Kendall

W prend une valeur entre 0 et 1.

0 = Pas de relation entre les classements

1 = Accord total entre les juges

Calcul du coefficient

N = 6 **k = 8**

$$\sum T_j^2 = 13^2 + 16^2 + 22^2 + 31^2 + 43^2 + 43^2 = 5568$$

$$W = \frac{12\sum T_j^2}{k^2 N(N^2-1)} - \frac{3(N+1)}{N-1} = \frac{12\times 5568}{8^2\times 6\times 35} - \frac{3\times 7}{5}$$

$$= 0{,}77$$

Tester le coefficient W

H_0 : Il n'y a pas d'accord significatif entre les classements des sujets

H_A : Il y a un accord significatif entre les classements des sujets

Tester le coefficient W

Si k ≥ 7, tester avec un khi-carré :

$$\chi^2_{N-1} = k(N-1)W$$

Avec N – 1 degrés de liberté

Tester le coefficient W

dl = N – 1 = 5

$$\chi^2_{obs} = k(N-1)W = 8 \times 5 \times 0{,}77 = 30{,}8$$

$$\chi^2_{0,05}(5) = 11{,}07$$

Puisque 30,08 > 11,07, rejeter H_0

Coefficient de corrélation partielle

= corrélation entre deux variables lorsque l'influence d'une ou plusieurs autres est contrôlée

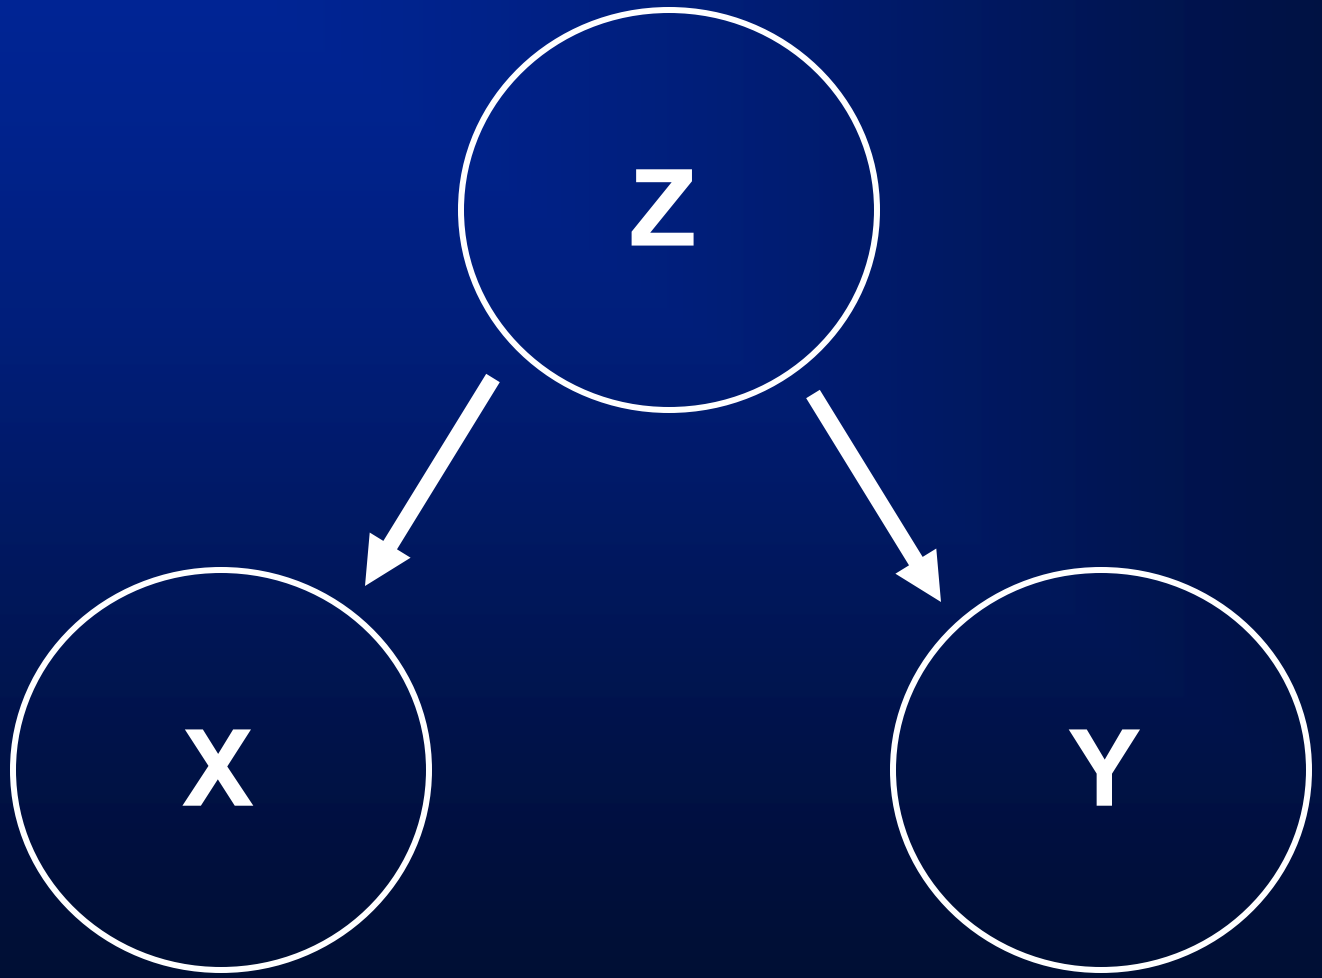
Très utile pour l'interprétation des relations de causalité

Interprétation des corrélations et régressions

Une corrélation ne signifie pas lien de cause à effet !!!

La corrélation entre deux variables peut être totalement due à l'influence d'une variable exogène

Interprétation des corrélations et régressions



Interprétation des corrélations et régressions

Si la corrélation est due à une variable exogène:

Fausse corrélation ou
Corrélation absurde

Coefficient de corrélation partielle

La corrélation partielle permet d'annuler l'effet d'une variable exogène

Exemple

Corrélation négative entre la fréquence du brossage de dents et le poids

Causalité ou fausse corrélation ?

Exemple

Variable exogène potentielle :

Attitude vis-à-vis de sa santé et de son hygiène

Exemple

Refaire une étude en incluant trois variables :

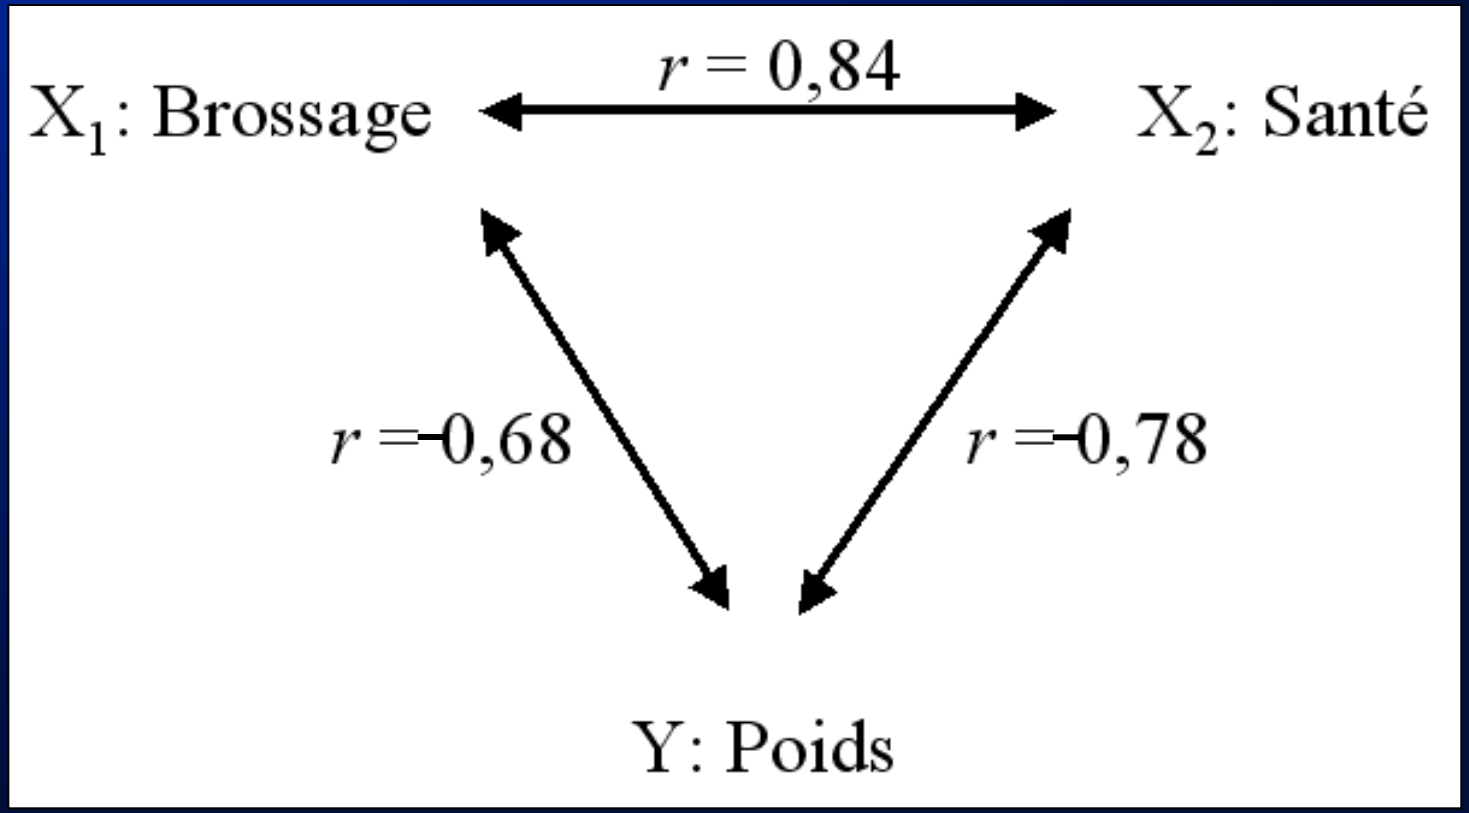
Y = Poids

X_1 = Fréquence du brossage

X_2 = niveau de préocuppation pour l'hygiène et la santé en général

N = 20

Exemple



Notation

Coefficient de corrélation partielle :

$r_{01.23\ldots p}$

Dans notre exemple:

$r_{01.2}$

Calcul du coefficient de corrélation partielle

$$r_{01.2} = \frac{r_{01} - \left(r_{12} \times r_{02}\right)}{\sqrt{1 - r_{12}^2}\sqrt{1 - r_{02}^2}}$$

r_{01} = la corrélation entre Y et X_1

r_{02} = la corrélation entre Y et X_2

r_{12} = la corrélation entre X_1 et X_2

Calcul du coefficient de corrélation partielle

$$r_{01.2} = \frac{-0,68 - \left(0,84 \times \left(-0,78\right)\right)}{\sqrt{1-0,84^2}\sqrt{1-\left(-0,78\right)^2}} = -0,07$$

Lorsque l'influence du facteur « santé » est contrôlé, la corrélation entre le brossage de dents et le poids n'est plus que de -0,07

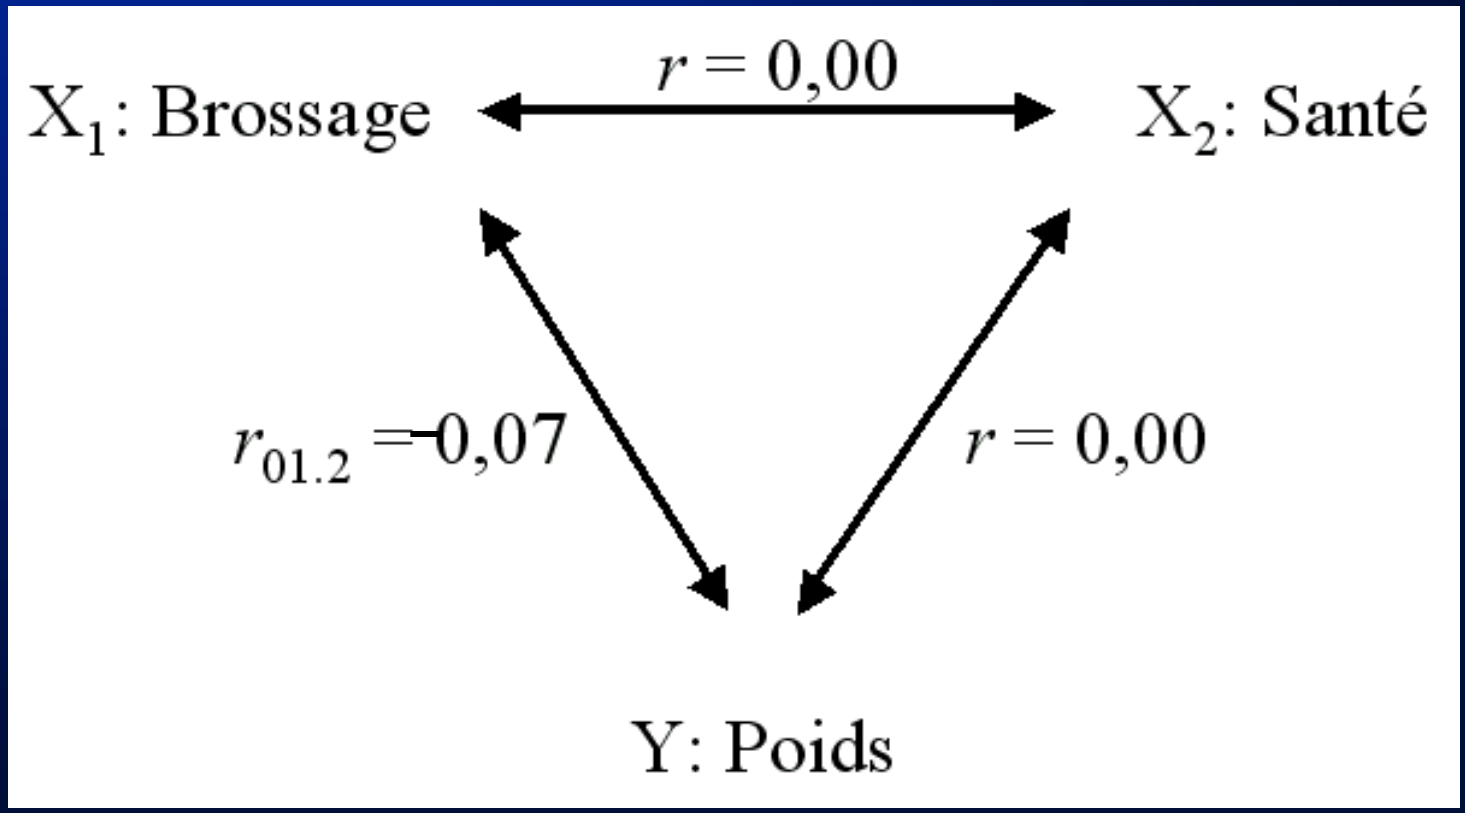
Exemple

Conclusion :

Il s'agissait d'une fausse corrélation

Le brossage de dents n'a aucun effet causal sur le poids

Exemple



Coefficient de corrélation partielle

Trois cas de figure :

1. **Suppression ou réduction de la corrélation initiale**
2. **Pas de modification de la corrélation initiale**
3. **Apparition ou augmentation de la corrélation initiale (variable clarificatrice)**

Coefficient de corrélation partielle

Contrôle de plusieurs variables exogènes

Procédure complexe – Nécessite un logiciel statistique

Tester une corrélation partielle

$H_0 : \rho_{01.2} = 0$

$H_A : \rho_{01.2} \neq 0$

Procédure identique au test sur un coefficient de corrélation standard

Sauf: dl = N – 2 – p

Tester la signification de la corrélation

N = 20 **dl = 20 – 2 – 1 = 17**

$r_{01.2}$ **= 0,07**

α = 0,05 (par défaut)

$$S_r = \sqrt{\frac{1 - r^2}{N - 2 - p}} = \sqrt{\frac{1 - 0{,}0049}{20 - 2 - 1}} = 0{,}24$$

Tester la signification de la corrélation

$$t_{obs} = \frac{r}{S_r} = \frac{0,07}{0,24} = 0,29$$

$t_{0,025} = 2,11$

Puisque 0,29 < 2,11, ne pas rejeter H_0

Mise en garde

Une corrélation partielle significative ne démontre jamais un lien de causalité

Possibilité d'autres variables exogènes non considérées