Chapitre 2

L’analyse de variance à un critère de classification

L’analyse de variance

ANOVA = un de tests les plus communs

Objectif = comparer plus de deux moyennes

ANOVA 1

= Analyse de variance à un critère de classification

= Une seule VI

>< analyse factorielle de variance

Exemple: Effet de la classe sociale sur réussite scolaire

ANOVA 1

Chapitre 2:

ANOVA 1 pour groupes indépendants

Chapitre 5:

ANOVA 1 à mesures répétées (ou liées)

Un exemple

Etude (fictive):

Effet du niveau de responsabilité sur le stress au travail

Trois niveaux de responsabilité:

Techniciens, cadres inférieurs, cadres supérieurs

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	14	16	18
	10	15	22
Moyenne	12	15,8	20,1
Variance	6,22	4,18	3,65

Notation dans une ANOVA 1

Score d'un sujet: X_{ij}

i = place du sujet dans le groupe

j = numéro du groupe

Notation dans une ANOVA 1

Exemples :

$X_{21} = 9$ (2ème sujet du groupe 1)

$X_{32} = 17$ (3ème sujet du groupe 2)

$X_{13} = 21$ (1er sujet du groupe 3)

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	14	16	18
	10	15	22
Moyenne	12	15,8	20,1
Variance	6,22	4,18	3,65

Notation dans une ANOVA 1

Moyennes de groupe: $\overline{X}_j$

Totaux des groupes: T_j

Effectifs des groupes: n_j

Notation dans une ANOVA 1

Moyenne générale: $$\overline{X} = \frac{TG}{N}$$

Total général: $TG = \Sigma\, T_j = \Sigma\, X_{ij}$

Effectif total: $N = \Sigma\, n_j$

La problématique des tests t multiples

Pourquoi ne pas faire trois tests t ?

Inflation du risque de commettre des erreurs de première espèce

La problématique des tests t multiples

Nombre de moyennes	Nombre de tests t	Probabilité d'erreur α
2	1	0,05
3	3	0,14
4	6	0,26
5	10	0,40
6	15	0,54
10	45	0,90

La problématique des tests t multiples

<u>Analyse de variance</u> :

- Une seule analyse

- Maintien α à 0,05

La logique de l'ANOVA

$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k$

(hypothèse nulle globale)

H_A : Toutes les moyennes ne sont pas égales

Pourquoi travailler sur la variabilité (variance) ?

La logique de l'ANOVA

$H_0 : \mu_1 = \mu_2 = \ldots. = \mu_k$

H_A : Toutes les moyennes ne sont pas égales

Si $\mu_1 = \mu_2 = \ldots. = \mu_k$, les moyennes ne varient pas donc le traitement n'a pas d'effet

La logique de l'ANOVA

<u>Du point de vue de la variance</u>

En quoi les scores varient-ils ?

(variabilité totale)

- Variabilité due au facteur étudié
- Variabilité due à tous les autres facteurs

La logique de l'ANOVA

- Variabilité due au facteur étudié

  Variabilité nulle si H_0 est vraie

- Variabilité due à tous les autres facteurs

  = Variabilité due à l'erreur

Terminologie de l'ANOVA

<u>Chapitre 2 (cours Partim 1)</u>

Variance =

$$S^2 = \frac{\sum \left(X_i - \overline{X} \right)^2}{N - 1}$$

<u>Analyse de variance</u>

Carré moyen (CM) =

$$CM = \frac{SC}{dl}$$

La logique de l'ANOVA

Variabilité totale

=

Variabilité facteur + Variabilité erreur

Comment estimer chacun de ces facteurs ?

La variabilité totale

= SC_{total} (CM_{total} pour moyenne)

Variance de l'ensemble des scores:

$$CM_{total} = \frac{SC_{total}}{dl_{total}} = \frac{\sum\left(X_{ij} - \overline{X}\right)^2}{N-1}$$

La variabilité totale

Pour notre exemple:

$$CM_{total} = \frac{SC_{total}}{N-1} = \frac{454{,}97}{29} = 15{,}69$$

La variabilité erreur

= CM_{erreur}

= variance à l'intérieur des groupes

$$CM_{erreur} = \frac{\sum_{j=1}^{k} S_j^2}{k}$$

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	14	16	18
	10	15	22
Moyenne	12	15,8	20,1
Variance	6,22	4,18	3,65

	Techniciens	Cadres inf.	Cadres sup.
CM_{erreur}	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	14	16	18
	10	15	22
Moyenne	12	15,8	20,1
Variance	6,22	4,18	3,65

La variabilité erreur

Pour notre exemple:

$$CM_{erreur} = \frac{\sum_{j=1}^{k} S_j^2}{k} = \frac{6{,}22 + 4{,}18 + 3{,}65}{3} = 4{,}68$$

La variabilité erreur

En cas d'effectifs inégaux:

Prendre une moyenne pondérée par les degrés de liberté

$$CM_{erreur} = \frac{(n_1 - 1)S_1^2 + \ldots + (n_k - 1)S_k^2}{N - k}$$

La variabilité facteur

= CM_{trait}

= variance entre les moyennes des traitements

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	…	…	…
Moyenne	12	15,8	20,1

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	…	…	…
Moyenne	12	15,8	20,1

CM_{trait}

La variabilité facteur

2 problèmes avec CM_{trait}:

1) CM_{trait} n'est pas une estimation pure de la variabilité due au traitement

CM_{trait} = variabilité facteur + variabilité erreur

La variabilité facteur

En comparant CM_{trait} et CM_{erreur} , on peut déduire si H_0 est vraie ou fausse:

Si H_0 est vraie: $CM_{trait} = CM_{erreur}$

Si H_0 est fausse: $CM_{trait} > CM_{erreur}$

La logique de l'ANOVA

CM_{trait} = Variabilité facteur + CM_{erreur}

Si variabilité facteur = 0 $\longrightarrow$ $CM_{trait} = CM_{erreur}$

Si variabilité facteur > 0 $\longrightarrow$ $CM_{trait} > CM_{erreur}$

La variabilité facteur

2) CM_{trait} est une variance entre moyennes de groupe, tandis que CM_{erreur} est une variance entre sujets

$$\sigma^2_{\bar{X}} = \frac{\sigma^2}{N}$$

La variabilité facteur

$$\sigma^2_{\bar{X}} = \frac{\sigma^2}{N}$$

Si H_0 est vraie:

$$CM_{trait} = \frac{CM_{erreur}}{n} \longrightarrow CM_{erreur} = nCM_{trait}$$

La variabilité facteur

CM_{trait} :

$$CM_{trait} = n \times \frac{\sum \left(\overline{X}_j - \overline{X} \right)^2}{k-1}$$

Attention: si n inégaux: formule non applicable

La variabilité facteur

Pour notre exemple:

$$CM_{trait} = n \times \frac{\sum \left(\overline{X}_j - \overline{X}\right)^2}{k-1} =$$

$$10 \times \frac{(12-15{,}97)^2 + (15{,}8-15{,}97)^2 + (20{,}1-15{,}97)^2}{2}$$

$$= 164{,}23$$

Le test d'hypothèse

= comparer deux variances avec la statistique F

$$F = \frac{CM_{trait}}{CM_{erreur}}$$

La logique de l'ANOVA

La statistique F

= comparer CM_{trait} avec CM_{erreur}

$$F = \frac{CM_{trait}}{CM_{erreur}}$$

Si variabilité facteur > 0 :

$CM_{trait} > CM_{erreur}$

F > 1

Le test d'hypothèse

Pour notre exemple,

$$F = \frac{CM_{trait}}{CM_{erreur}} = \frac{164{,}23}{4{,}68} = 35{,}09$$

Les conditions d'application

1. Homogénéité des variances
2. La normalité
3. L'indépendance des observations

Calculs rapides pour l'ANOVA 1

Exercice sur une ANOVA 1:

2 situations

- **Seules données brutes**
- **Moyennes et variances des groupes**

Techniciens	Cadres inf.	Cadres sup.
11	16	21
9	12	18
12	17	18
15	17	21
14	17	23
15	19	18
8	13	21
12	16	21
14	16	18
10	15	22

Situation 1 : Données brutes

Procédure de calcul en 8 étapes:

1) Calculer le facteur de correction

$$FC = \frac{\left(\sum X\right)^2}{N}$$

Situation 1 : Données brutes

Procédure de calcul en 8 étapes:

1) Calculer le facteur de correction

$$FC = \frac{\left(\sum X\right)^2}{N} = \frac{479^2}{30} = 7648{,}03$$

Situation 1 : Données brutes

2) Calculer la SC_{total} : $SC_{total} = \sum X^2 - FC$

$$SC_{total} = (11^2 + 9^2 + \ldots + 18^2 + 22^2) - 7648{,}03$$

$$= 8103 - 7648{,}03$$

$$= 454{,}97$$

Situation 1 : Données brutes

3) Calculer la SC_{trait} :

$$SC_{trait} = \sum \left(\frac{T_j^2}{n_j} \right) - FC$$

$$SC_{trait} = \frac{120^2}{10} + \frac{158^2}{10} + \frac{201^2}{10} - 7648{,}03$$

$$= 328{,}47$$

Situation 1 : Données brutes

4) Calculer la SC_{erreur} :

$$SC_{erreur} = SC_{total} - SC_{trait}$$

$$SC_{erreur} = 454{,}97 - 328{,}47 = 126{,}5$$

Situation 1 : Données brutes

5) Calculer les degrés de liberté :

$dl_{total} = N - 1$ $\qquad$ $dl_{total} = 30 - 1 = 29$

$dl_{trait} = k - 1$ $\qquad$ $dl_{trait} = 3 - 1 = 2$

$dl_{erreur} = N - k$ $\qquad$ $dl_{erreur} = 30 - 3 = 27$

Situation 1 : Données brutes

6) Calculer CM_{trait} et CM_{erreur} :

$$CM_{trait} = \frac{SC_{trait}}{dl_{trait}}$$

$$CM_{erreur} = \frac{SC_{erreur}}{dl_{erreur}}$$

Situation 1 : Données brutes

6) Calculer CM_{trait} et CM_{erreur} :

$$CM_{trait} = \frac{SC_{trait}}{dl_{trait}} = \frac{328,47}{2} = 164,23$$

$$CM_{erreur} = \frac{SC_{erreur}}{dl_{erreur}} = \frac{126,5}{27} = 4,68$$

Situation 1 : Données brutes

7) Calculer F_{obs} :

$$F_{obs} = \frac{CM_{trait}}{CM_{erreur}}$$

$$F_{obs} = \frac{CM_{trait}}{CM_{erreur}} = \frac{164{,}23}{4{,}68} = 35{,}09$$

Situation 1 : Données brutes

8) Trouver la valeur critique de F

dl numérateur = dl_{trait} = 2

dl dénominateur = dl_{erreur} = 27

	Degrés de liberté du numérateur							
	1	2	3	4	5	6	7	8
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27

	Degrés de liberté du numérateur							
	1	2	3	4	5	6	7	8
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27

Situation 1 : Données brutes

Pour notre exemple, si on fixe $\alpha = 0,05$,

$F_{0,05\ ;\ 2\ ;\ 27} = 3,37$

Puisque 35,09 est supérieur à 3,37

rejeter H_0 (p=0,00000003)

Situation 2 : Moyennes et variances des groupes

Calculs plus rapides de CM_{erreur} :

$$CM_{erreur} = \frac{\sum_{j=1}^{k} S_j^2}{k}$$

$$CM_{erreur} = \frac{(n_1 - 1)S_1^2 + \ldots + (n_k - 1)S_k^2}{N - k}$$

	Techniciens	Cadres inf.	Cadres sup.
	11	16	21
	9	12	18
	12	17	18
	15	17	21
	14	17	23
	15	19	18
	8	13	21
	12	16	21
	14	16	18
	10	15	22
Moyenne	12	15,8	20,1
Variance	6,22	4,18	3,65

Situation 2 : Moyennes et variances des groupes

Calculs plus rapides de CM_{erreur} :

$$CM_{erreur} = \frac{\sum_{j=1}^{k} S_j^2}{k} = \frac{6{,}22 + 4{,}18 + 3{,}65}{3} = 4{,}68$$

Situation 2 : Moyennes et variances des groupes

Calculs de CM_{trait} :

$$FC = \frac{\left(\sum X\right)^2}{N} = \frac{479^2}{30} = 7648{,}03$$

$$SC_{trait} = \sum\left(\frac{T_j^2}{n_j}\right) - FC$$

Situation 2 : Moyennes et variances des groupes

Calculs de CM_{trait} :

$$SC_{trait} = \sum \left(\frac{T_j^2}{n_j} \right) - FC =$$

$$\frac{120^2}{10} + \frac{158^2}{10} + \frac{201^2}{10} - 7648{,}03$$

$$= 328{,}47$$

Situation 2 : Moyennes et variances des groupes

Calculs de CM_{trait} :

$$dl_{trait} = k - 1 = 2$$

$$CM_{trait} = \frac{SC_{trait}}{dl_{trait}} = \frac{328{,}47}{2} = 164{,}23$$

Situation 2 : Moyennes et variances des groupes

Calcul F_{obs} :

$$F_{obs} = \frac{CM_{trait}}{CM_{erreur}} = \frac{164{,}23}{4{,}68} = 35{,}09$$

Le tableau résumé de l'ANOVA

Source	SC	dl	CM	F
Traitement	328,47	2	164,23	35,09
Erreur	126,5	27	4,68	
Total	454,97	29		

Représentation graphique

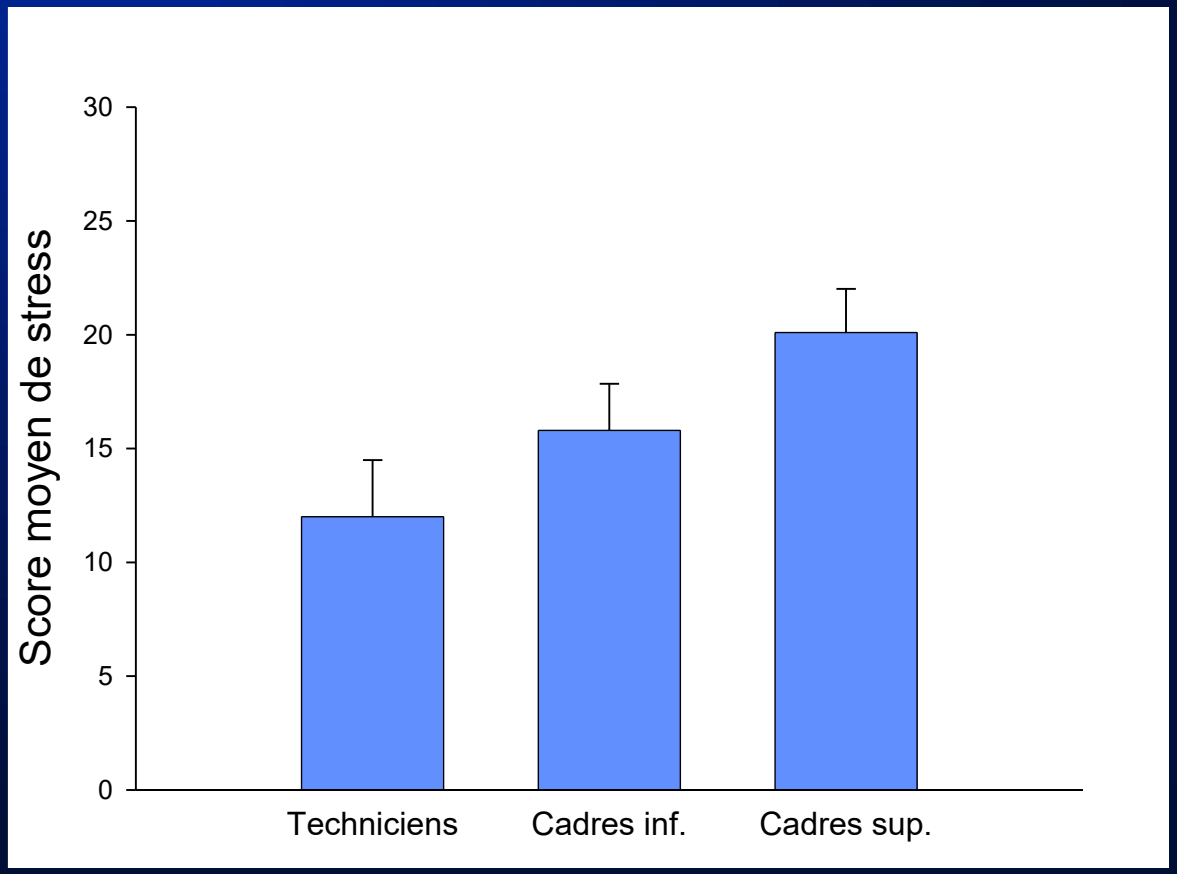

Représentation graphique

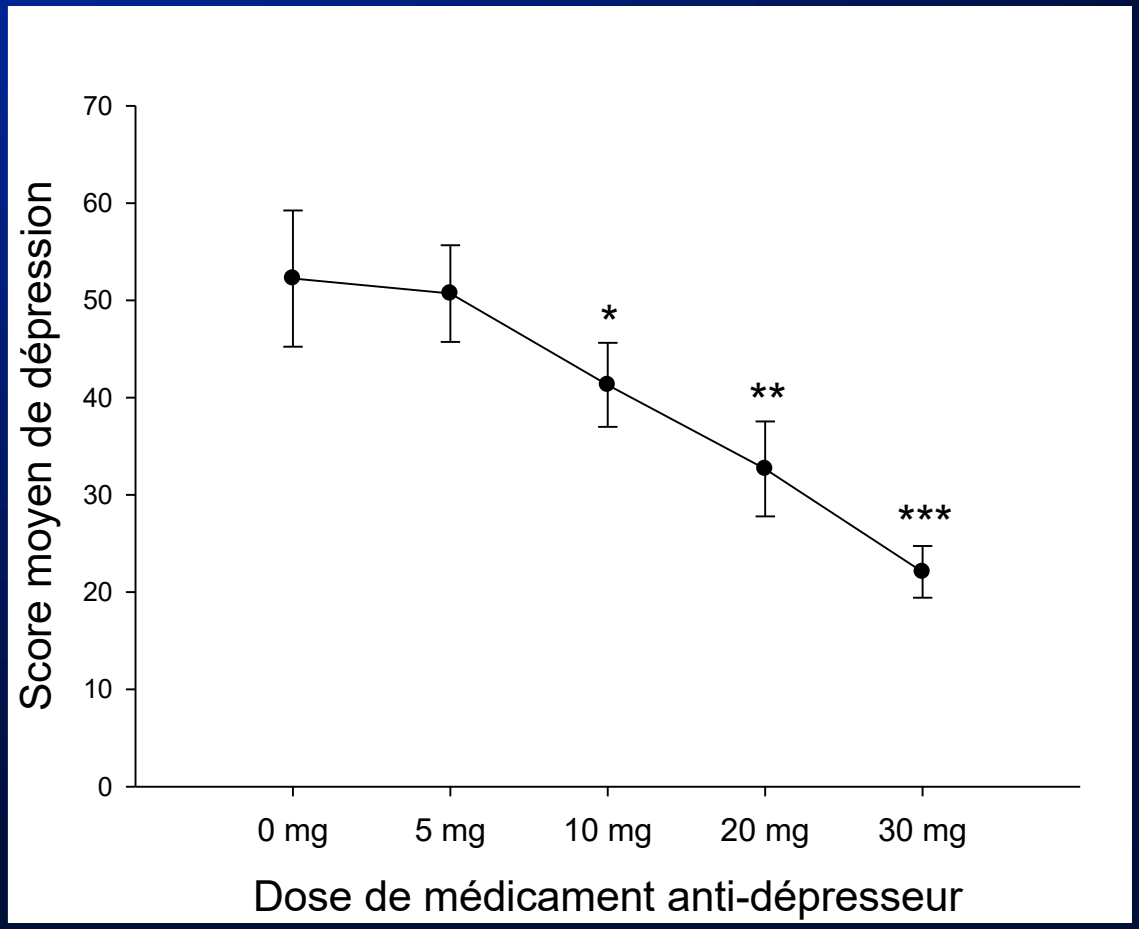

Taille de l'effet

Nombreuses statistiques différentes

(au moins 6)

- **Êta-carré (η^2)**
- **Oméga-carré (ω^2)**

Êta-carré (η^2)

La proportion ou le pourcentage de la variabilité de la VD qui peut être prédite (ou expliquée) par la VI

Êta-carré (η^2)

$$\eta^2 = \frac{SC_{trait}}{SC_{total}}$$

Êta-carré (η^2)

Pour notre exemple :

$$\eta^2 = \frac{SC_{trait}}{SC_{total}} = \frac{328{,}47}{454{,}97} = 0{,}72$$

72% de la variation touchant les scores de stress subjectif peut être attribuée aux différences de niveau de responsabilité

Êta-carré (η^2)

Convention de Cohen

Taille de l'effet	η^2	Définition
Petite	0,01	Effet réel difficile à percevoir
Moyenne	0,06	Effet visible par un observateur attentif
Grande	0,14	Effet facilement détectable

Oméga-carré (ω^2)

Ajustement de Êta-carré :

$$\omega^2 = \frac{SC_{trait} - (k-1)CM_{erreur}}{SC_{total} + CM_{erreur}}$$

Oméga-carré (ω^2)

Pour notre exemple :

$$\omega^2 = \frac{SC_{trait} - (k-1)CM_{erreur}}{SC_{total} + CM_{erreur}} = \frac{328{,}47 - 2(4{,}68)}{454{,}97 + 4{,}68} = 0{,}69$$

La puissance

Calculer la puissance a priori

Calculer le nombre de sujets pour une puissance déterminée

Violation des conditions d'application

Que faire en cas d'hétérogénéité des variances et/ou d'anormalité des données ?

ANOVA = procédure robuste

Hétérogénéité des variances

Plus grande des variances pas plus de 4 fois supérieure à la plus petite

(surtout si N inégaux)

	Techniciens	Cadres inf.	Cadres sup.
Exemple 1	$n_1 = 10$	$n_2 = 10$	$n_3 = 10$
Variances	6,22	4,18	3,65
Exemple 2	$n_1 = 5$	$n_2 = 22$	$n_3 = 10$
Variances	19,2	4,18	3,65
Exemple 3	$n_1 = 10$	$n_2 = 10$	$n_3 = 10$
Variances	40,28	4,18	3,65

Mauvais

Hétérogénéité des variances

Solutions :

1) Tests alternatifs: Procédure de Welch

2) Transformation des données

Hétérogénéité des variances

<u>La transformation des données</u>:

Transformer chacune des données brutes et effectuer l'ANOVA sur les données transformées

Améliore aussi la normalité

Hétérogénéité des variances

1) La transformation logarithmique:

Lorsque l'écart-type est proportionnel à la moyenne

$Y = \log(X)$ ou $Y = \log(X+c)$

Hétérogénéité des variances

	Techniciens	Cadres inf.	Cadres sup.
Effectif	$n_1 = 10$	$n_2 = 10$	$n_3 = 10$
Moyenne	10	30	50
Ecart-type	2,49	7,68	14,14
Variance	6,22	58,98	199,94

Hétérogénéité des variances

2) La transformation racine carré:

Lorsque la variance est proportionnelle à la moyenne

$$Y = \sqrt{X}$$

Hétérogénéité des variances

	Techniciens	Cadres inf.	Cadres sup.
Effectif	$n_1 = 5$	$n_2 = 10$	$n_3 = 20$
Moyenne	10	30	50
Ecart-type	2,49	4,39	5,74
Variance	6,22	19,27	32,94

Hétérogénéité des variances

3) La transformation réciproque:

Lorsque très grandes valeurs en asymétrie positive

$Y = 1/X$

Quand appliquer une transformation ?

Si violation des conditions d'application

Surtout si: - Hétérogénéité des variances
- Forte asymétrie

On peut en essayer plusieurs transformations

Anormalité des données

- Distribution bimodale ?

- Distribution uniforme ?

Violation sévère:

1) Transformation des données

2) test de Kruskal-Wallis

Le test de Kruskal-Wallis

L'ANOVA 1 de Kruskal-Wallis

= extension du test de Wilcoxon

Transformer tous les scores en rangs

Calculer la somme des rangs pour chaque groupe

Dépresseur		Stimulant		Placebo	
Score	Rang	Score	Rang	Score	Rang
55	9	73	15	61	11
0	1,5	85	18	54	8
1	3	51	7	80	16
0	1,5	63	12	47	5
50	6	85	18		
60	10	85	18		
44	4	66	13		
		69	14		
R_i	35		115		40
n_i	7		8		4

Le test de Kruskal-Wallis

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{k} \frac{R_i^2}{n_i} - 3(N+1)$$

k = le nombre de groupes

n_i = le nombre de sujets dans le groupe i

R_i = la somme des rangs du groupe i

N = le nombre total de sujets

Le test de Kruskal-Wallis

Pour notre exemple:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{k} \frac{R_i^2}{n_i} - 3(N+1)$$

$$= \frac{12}{19(20)} \left(\frac{35^2}{7} + \frac{115^2}{8} + \frac{40^2}{4} \right) - 3(19+1) = 10{,}36$$

Le test de Kruskal-Wallis

H est évalué par rapport à la distribution χ^2 avec k –1 dl.

Pour notre exemple:

dl = 3 – 1 = 2

$$\chi^2_{0,05}(2)=5,99$$

Le test de Kruskal-Wallis

Puisque 10,36 est supérieur à 5,99, rejeter H_0

Le nombre de problèmes résolus correctement est significativement affecté par le type de médicament reçu.