

Christian Monseur

Introduction à la psychométrie (PSYC0019-1)

**2^{ème} année du grade de Bachelier en
Sciences psychologiques et de l'Education**

SOMMAIRE

1. PROBLÉMATIQUE DE LA MESURE	1
1.1. INTRODUCTION	1
1.2. PSYCHOMÉTRIE VERSUS ÉDUMÉTRIE	3
1.3. IGNORER LES ERREURS DE MESURE	7
2. LE PROCESSUS DE LA MESURE	11
2.1. ÉTAPE 1 : LE CONCEPT À MESURER	11
2.2. LA COLLECTE DES INFORMATIONS	15
2.3. TRANSFORMATION DES OBSERVATIONS EN DONNÉES	15
2.4. L'APPLICATION DU MODÈLE DE MESURE	16
2.5. TRANSFORMATIONS COMPLÉMENTAIRES ÉVENTUELLES	17
2.6. SYNTHÉTISER LES RÉSULTATS D'UNE BATTERIE DE TEST	20
2.7. CONCLUSIONS	23
3. DES OBSERVATIONS AUX DONNÉES : LA RÉDACTION DES ITEMS D'UN INSTRUMENT DE MESURE.....	24
3.1. REPRÉSENTATIVITÉ DU CADRE D'ÉVALUATION	24
3.2. ELABORATION DES ITEMS D'UNE ÉPREUVE DE PERFORMANCE.....	26
3.2.1. <i>Le choix du format des questions.....</i>	26
3.2.2. <i>Modalités de présentation.....</i>	28
3.2.3. <i>La rédaction des items.....</i>	30
3.2.4. <i>Interactions entre les items et les sujets.....</i>	42
3.3. LES ITEMS DANS UN QUESTIONNAIRE CONTEXTUEL.....	46
3.3.1. <i>Le format des questions.....</i>	46
3.3.2. <i>Mise en forme des items.....</i>	53
4. DES OBSERVATIONS AUX DONNÉES : L'ASSEMBLAGE DU TEST ET LE DISPOSITIF DE COLLECTE DE DONNÉES	58
4.1. L'ASSEMBLAGE DU TEST.....	58
4.1.1. <i>Introduction</i>	58
4.1.2. <i>Développement des Test Designs incomplets.....</i>	61
4.1.3. <i>Écueils à éviter dans la conception d'un test design.....</i>	67
4.2. LE DISPOSITIF DE COLLECTE DE DONNÉES.....	74
5. LA THÉORIE CLASSIQUE DU SCORE VRAI.....	77
5.1. DÉFINITION DU SCORE OBSERVÉ.....	77
5.2. DÉFINITION DU SCORE VRAI.....	82
5.3. POSTULATS DE BASE DE LA THÉORIE CLASSIQUE DU SCORE VRAI	83
5.3.1. <i>Postulat 1.....</i>	83
5.3.2. <i>Postulat 2.....</i>	84
5.3.3. <i>Postulat 3.....</i>	84
5.4. DÉVELOPPEMENTS AUTORISÉS PAR LES POSTULATS : DÉFINITION DE LA FIDÉLITÉ.....	84
5.5. FIDÉLITÉ D'UN TEST ET LONGUEUR.....	89
5.6. OPÉRATIONNALISATION DU CALCUL DE LA FIDÉLITÉ	90
5.6.1. <i>Les méthodes Test-Retest.....</i>	91
5.6.2. <i>Les méthodes de consistance interne</i>	91
5.6.3. <i>Les méthodes mixtes ou méthodes des formes parallèles.....</i>	99
5.6.4. <i>Variance vraie et variance d'erreur selon la méthode de calcul de la fidélité.</i>	100
5.7. L'ANALYSE D'ITEMS	100
5.7.1. <i>L'indice de difficulté</i>	101
5.7.2. <i>L'indice de discrimination</i>	103
5.7.3. <i>Le fonctionnement différentiel de l'item.....</i>	104
5.8. CONCLUSIONS.....	108
6. LES MODÈLES DE RÉPONSE À L'ITEM	109
6.1. INTRODUCTION	109

6.2. LE MODÈLE DE RASCH POUR LES ITEMS DICHOTOMIQUES	110
6.2.1. Introduction	110
6.2.2. Description du modèle de Rasch	111
6.2.3. Calibration	114
6.2.4. Calcul des scores des élèves par maximum de vraisemblance.....	118
6.2.5. Calcul des scores des élèves dans le cas de plans de test incomplets.....	123
6.2.6. Conditions optimales pour les items d'ancrage.....	126
6.2.7. Erreur de mesure.....	128
6.2.8. Une illustration	128
6.3. EXTENSION DU MODELE DE RASCH	133
6.3.1. Modèle de réponse à crédit partiel.....	133
6.3.2. Autres modèles utilisant la Théorie de Réponse à l'Item	134
6.4. CONCLUSION	135
7. LA VALIDITÉ.....	136
7.1. RELATION ENTRE LA FIDÉLITÉ ET LA VALIDITÉ.....	136
7.2. LA VALIDITÉ PRÉDICTIVE	137
7.2.1. Les caractéristiques de la mesure critère.....	138
7.2.2. Méthodes pour déterminer la validité prédictive	139
7.3. LA VALIDITÉ DE CONTENU	140
7.4. LA VALIDITÉ THÉORIQUE	141
8. PRÉREQUIS STATISTIQUES.....	143
8.1. LES INDICES DE TENDANCE CENTRALE	143
8.2. LES INDICES DE DISPERSION.....	145
8.3. LES INDICES D'ASSOCIATION ENTRE DEUX VARIABLES	150
8.4. LES NIVEAUX DE MESURE	155
8.4.1. Les échelles nominales.....	155
8.4.2. Les échelles ordinales.....	156
8.4.3. Les échelles d'intervalles égaux	157
8.5. LES DISTRIBUTIONS THÉORIQUES	159
8.5.1. La fonction de densité.....	161
8.5.2. La fonction de répartition	162
9. ANNEXES.....	165
9.1. ECHELLES DE MESURE DU POIDS ET DE LA TAILLE.....	166
ANALYSE DE L'ÉCHELLE TAILLE	170
Analyse d'items.....	170
Analyse de Rasch	174
Fonctionnement différentiel des items	178
Courbes caractéristiques de l'item.....	179
9.2. EXERCICES	181

1. Problématique de la mesure

1.1. Introduction

Selon, Dicks & al., « la psychométrie concerne l'ensemble des théories et des méthodes de la mesure en psychologie. Elle trouve son application chaque fois que le psychologue attribue des nombres à ses objets d'étude » (1994, p. 11)¹.

L'étude de la mesure en sciences humaines est d'une importance cruciale, comparativement aux sciences dites exactes. En effet, ces dernières, au cours de leur histoire, ont développé des instruments de mesure d'une très grande précision. Il suffit pour s'en convaincre de penser à la précision avec laquelle les physiciens parviennent de nos jours à quantifier, c'est-à-dire à mesurer, certaines propriétés d'objets ou d'événements.

Les physiciens ont pour habitude de distinguer grandeurs fondamentales et grandeurs dérivées. Il existe 7 grandeurs fondamentales, reprises dans le tableau 1.1. A chacune de ces grandeurs correspondent une unité et un symbole.

Tableau 1.1. Les 7 grandeurs fondamentales

<i>Grandeurs fondamentales</i>	<i>Unité</i>	<i>Symbole</i>
Longueur	Mètre	m
Masse	Kilogramme	kg
Temps	Seconde	s
Courant électrique	Ampère	A
Température thermodynamique	Kelvin	K
Quantité de matière	Mole	mol
Intensité lumineuse	Candela	cd

A titre d'information, il est possible, au départ de ces grandeurs fondamentales de définir un grand nombre de grandeurs dérivées. Ainsi

1. l'aire et le volume sont des grandeurs dérivées de la longueur, que l'on peut noter respectivement comme $[L].[L]$ et $[L].[L].[L]$;
2. la vitesse exprime une longueur parcourue en un laps de temps déterminé. Elle peut donc être symbolisée par $[V]=[L].[T]^{-1}$;
3. l'accélération, qui exprime un taux de variation de vitesse, peut s'écrire $[V].[T]^{-1} = [L].[T]^{-1}[T]^{-1}$;
4. une force, dont l'unité est le Newton, est définie comme une masse multipliée par une accélération. Elle peut donc s'écrire $[M].[V].[T]^{-1} = [M].[L].[T]^{-1}[T]^{-1}$.

La mesure physique peut, selon la qualité de l'instrument utilisé, atteindre un très haut niveau de précision et, de la sorte, laisser peu de place à l'erreur de mesure. Par contre, sans l'aide de ces instruments de précision, la mesure peut être beaucoup plus approximative. Ce serait par exemple le cas pour la mesure de la longueur d'une feuille de papier à l'aide d'un mètre étalon non gradué. Le recours à un instrument de mesure gradué au centimètre ou au millimètre permettra quant à lui de réduire considérablement l'erreur.

¹ Dicks, P., Tournois, J., Flieller, A., & Kop, J.L. (1994). *La psychométrie*. Paris : PUF.

Les sciences humaines n'offrent malheureusement pas les mêmes garanties. Il n'existe d'ailleurs pas d'unités de mesure conventionnelles comme en sciences physiques.

Différents éléments engendrent des difficultés pour atteindre une grande qualité de mesure en sciences humaines :

1. **Complexité du concept** : les concepts d'intelligences, de résistance au stress, de compétences en mathématiques, de racisme pour ne citer que quelques exemples recouvrent apparemment une réalité bien plus complexe que la taille ou le poids d'un individu. La complexité du concept relève aussi de l'absence de consensus entre scientifiques. Ainsi, le temps peut être considéré comme une réalité complexe mais qui se voit simplifiée aux yeux du grand public par l'existence d'une unité de mesure universelle. En sciences humaines, d'un auteur à l'autre, les définitions peuvent varier dans des proportions non négligeables. Dans ce contexte, il devient difficile, voire impossible, de définir des unités de mesures communément admises.
2. **Variabilité du sujet** : la longueur d'une table ne peut que très légèrement varier selon les conditions climatiques. En revanche, la performance d'un individu est notamment susceptible de varier selon son état de fatigue, ou selon son taux d'alcoolémie.
3. **Interaction entre le sujet et l'instrument de mesure** : en sciences physiques, l'application d'un instrument de mesure à un objet n'engendre généralement pas de modification de la caractéristique mesurée. Le fait de mesurer la longueur d'une table ne va pas la modifier. En d'autres termes, il n'existe pas d'interaction entre l'objet mesuré et l'instrument de mesure. Par contre, administrer un test de mathématiques peut engendrer des apprentissages auprès de la population testée, sous la forme d'une plus grande familiarité avec le contenu du test et/ou avec les modalités de questionnement. Dans les schémas expérimentaux, cet effet, dénommé *testing*, se définit comme l'impact de la mesure avant expérimentation sur la mesure après expérimentation. D'autres types d'interactions entre le sujet et l'instrument peuvent également altérer la qualité de la mesure. Ainsi, selon qu'une compétence est mesurée par l'intermédiaire de questions ouvertes ou de questions à choix multiples, les résultats peuvent varier. La formulation de la question peut également modifier substantiellement les réponses. Par exemple, sur l'échelle à quatre degrés
 - a. *tout à fait en désaccord*
 - b. *en désaccord*
 - c. *en accord*
 - d. *tout à fait d'accord,*

les deux propositions suivantes, parfaitement identiques, à l'exception de leur forme (affirmative / négative) n'aboutiront pas à la même distribution, même inversée, des réponses :

- a. *Il faut renvoyer tous les illégaux dans leur pays d'origine.*
 - b. *Il ne faut pas renvoyer les illégaux dans leur pays d'origine.*
4. **Interaction entre le sujet et le contexte** : le contexte dans lequel la mesure s'effectue peut également influencer les résultats. Ainsi, la mesure du degré de racisme, selon qu'elle est réalisée par un chercheur, un délégué de la ligue des droits de l'homme, ou par un représentant d'un parti d'extrême droite, aboutira à des résultats différents. De même, dans le cadre des enquêtes à large échelle (*surveys* en anglais) conduites par l'Association Internationale pour l'Evaluation du Rendement Scolaire (IEA) ou par l'Organisation de Coopération et de

Développement Economiques (OCDE), les épreuves de rendement peuvent être administrées soit par une personne extérieure à l'établissement scolaire, soit par un membre du personnel. Il n'existe pas d'études expérimentales sur cette problématique mais on est en droit de suspecter un effet sur les élèves selon que l'administrateur est membre ou non du personnel de l'école.

Comme on peut le constater à travers cette liste non exhaustive, les sources d'erreur dans toute mesure en sciences humaines sont multiples et diverses. Il importe dès lors de s'interroger sur la qualité de cette mesure et d'en tenir compte lors des traitements statistiques ultérieurs qui seront appliqués sur ces mesures.

Il convient aussi de distinguer la psychométrie et l'analyse de données (ou statistique). L'analyse de données a pour objectif d'étudier les relations qui existent entre d'une part des variables dépendantes (dites aussi critères, c'est-à-dire les variables pour lesquelles on cherche à expliquer la variabilité) et d'autre part, des variables indépendantes (dites aussi variables explicatives, c'est-à-dire les variables qui sont susceptibles d'expliquer la variabilité du ou des critères). Par contre, la psychométrie se concentre sur les relations qui existent entre variables manifestes (c'est-à-dire des variables observables, qui peuvent être mesurées directement, comme par exemple le nombre de réponses correctes à un test de performance) et variables latentes (c'est-à-dire des *constructs*, tels que l'intelligence, qui ne peuvent être mesurés ou observés directement).

1.2. Psychométrie versus éduométrie

Convient-il de limiter la psychométrie aux sciences psychologiques et d'utiliser le terme d'éduométrie pour les sciences de l'éducation ?

Selon V. de Landsheere, « *Edumétrie. Mot créé par Carver (1974), sur le modèle de psychométrie, pour désigner l'étude quantitative des variables relatives aux apprentissages suscités par l'éducation : influence d'une action pédagogique, performance effective par rapport à une performance attendue, épreuves centrées sur les objectifs...* » (1988, p. 59)².

Carver (1974) argumente cette distinction comme suit : « *Il ne s'agit pas seulement d'un problème sémantique sous-jacent au mouvement nouveau de création de tests, mais d'un problème essentiel. Le problème réside dans la distinction entre la mesure des différences individuelles et celle de la mesure (des résultats) de l'apprentissage. [...] Le test qui a été développé pour mesurer les différences inter-individuelles a été baptisé du terme de test psychométrique. Cette dimension du test est donc logiquement appelée dimension psychométrique. Un test peut ainsi être évalué en fonction de ses qualités psychométriques, c'est-à-dire, la mesure dans laquelle il reflète correctement des différences inter-individuelles stables, ce qui constitue traditionnellement l'intérêt premier du psychologue. L'autre dimension d'un test peut être appelée dimension éduométrique (cf. Carver, 1972, 1973). Un test peut être évalué en fonction de ses qualités éduométriques, c'est-à-dire la mesure dans laquelle il reflète des différences intra-individuelles liées aux développements des individus eux-mêmes, ce qui constitue plus généralement l'intérêt premier des tests dans le domaine de l'éducation* ».

² de Landsheere, V. (1988). *Faire réussir faire échouer : la compétence minimale et son évaluation*. Paris : PUF.

Cette publication a suscité au sein de la communauté scientifique un certain nombre de réactions, tant favorables que défavorables, dont certaines sont reprises ci-dessous à titre indicatif.

Parmi les réactions défavorables, nous pouvons citer :

1. E. Witt : “ *In today’s common usage (at least in the US) psychometrics includes the measurement of any psychological/behavioral attribute: achievement, performance, aptitudes, attitudes, opinions, values, beliefs, psychopathology, self-reports of just about anything. Thus this also includes most measurement that occurs in educational settings. In my opinion, and that’s all this is, edumetrics would be a subset of psychometrics, unless edumetrics would also include the measurement of things that are of concern to education but do not fit in the category of psychological/behavioral attributes.*”
2. S.K. Rock: “ *This seems to be a distinction that isn’t. The educational dimension is still the psychological behavior of interest. To create “edumetrics” provides no benefit. What next – busometrics? industrometrics? Argrometrics? Medometrics? or [heaven forbid] legometrics? In the broadest sense Psychometrics involves studying the way we measure people’s behavior [and ways we analyze those measures]. Educational behaviors are still behaviors. I didn’t read where the “edumetrics” provided any benefit to us or the consumer. On the contrary, it’s more likely to cause confusion, ...*”
3. P.R. Swank: “ *We have a discipline ... then where it is primarily applied .. so we have statistics ... and applied to education??? biology ??? etc... quite frankly ... I never heard of an educational statistic ... or a biological statistic ... is the mean or correlation coefficient different when applied applied to these different “content” areas?*”.

Au-delà des critiques parfois virulentes proférées à l’égard de sa proposition, Carver introduit une distinction fondamentale entre d’une part les tests qui mesurent des différences inter-individuelles (dits tests normatifs) et tests qui mesurent des différences intra-individuelles (dits tests critériés). Ces deux types de tests ne diffèrent pas uniquement par les finalités poursuivies, mais également par rapport aux théories et aux modèles auxquels ils recourent. Les deux exemples suivants illustrent parfaitement la distinction opérée :

1. Une question réussie par 0 % ou par 100 % des étudiants n’apportera aucune information qui différencie les individus et ne sera donc d’aucune utilité dans le cadre d’un test normatif. Par contre, dans le cadre d’un test critérié, cette question peut revêtir une certaine importance.
2. Les résultats à un test normatif, en tant que tels, ne présentent aucune signification. Ainsi, que signifie un QI (quotient intellectuel) de 125 ? Ce score n’a de valeur et de signification que par rapport à la distribution des résultats de la population ou du moins d’un échantillon représentatif. Par contre, un score à un test critérié informe le sujet de la distance qui le sépare de la maîtrise des objectifs assignés à l’apprentissage.

Cependant, les arguments évoqués par Carver pour défendre sa proposition nous paraissent restrictifs à plus d’un égard :

1. Comme l’indique Dickes & al. (1994, p.12), « *dissipons d’emblée deux confusions répandues : la psychométrie ne se confond pas plus avec l’étude des tests qu’avec l’analyse des données. La psychométrie peut se concevoir sans aucune référence aux tests. L’étude des tests et de leur construction fait certes partie de la*

psychométrie, mais elle n'en est qu'une partie limitée : les tests ne sont qu'une classe d'instruments parmi d'autres ». Un psychologue qui étudie l'apprentissage des couleurs chez le pigeon devra recourir aux théories psychométriques pour construire sa mesure.

2. En second lieu, il serait inapproprié de circonscrire l'étude des différences inter-individuelles aux sciences psychologiques et l'étude des différences intra-individuelles aux sciences de l'éducation. Ces dernières recourent régulièrement aux tests normatifs dans le cadre d'enquêtes à large échelle telles les études de l'IEA ou l'étude PISA³ menée sous l'égide de l'OCDE. De même, de tout temps, les psychologues se sont intéressés à l'apprentissage.

Il nous semble donc plus approprié de distinguer les théories et les méthodes de la mesure en fonction des finalités poursuivies, et non pas, comme Carver semble l'indiquer, selon le champ disciplinaire. Deux dimensions déterminent les problèmes de mesure auxquels le chercheur sera confronté :

1. Mesure-t-on un individu ou mesure-t-on une population ? Dans les deux cas, on cherchera à minimiser l'erreur de mesure mais on utilisera des techniques et des théories différentes selon que la mesure s'adresse à une personne en particulier ou à une population.
2. Mesure-t-on une caractéristique ou une évolution ? En d'autres termes, mesure-t-on un changement ou non ? La mesure d'un changement décuple les problèmes de mesure. La mesure d'un changement chez un individu est confrontée à l'influence d'un apprentissage possible lors du prétest (dit effet de *testing*) sur le post-test. Par ailleurs, on ne peut valablement administrer deux fois le même test à un même sujet. De même, mesurer l'évolution de la performance en mathématiques ou en sciences des élèves de 15 ans entre 2000 et 2009, comme dans l'étude PISA, nécessite la construction de deux tests qui comportent des items communs. Le choix des items communs est susceptible d'influencer la mesure du changement. Ainsi, en 2000, peu nombreux étaient les élèves de 15 ans qui connaissaient le terme « tsunami ». En 2007, la majorité des élèves de 15 ans en connaissent la signification. Cet exemple, qui se base sur des événements dramatiques, a le mérite d'illustrer avec force les difficultés rencontrées lors de toute mesure d'un changement.

Le croisement de ces deux dimensions permet de définir quatre cellules reprises dans le tableau 1.2.

³ Programme International pour le Suivi des Acquis des élèves.

Tableau 1.2. Finalités de la mesure et nature des erreurs

	<i>Une seule mesure</i>	<i>Plusieurs mesures</i>	<i>Finalités de la mesure et nature des erreurs</i>
<i>Individu</i>	• Examen d'entrée, test pronostic • Certification • Test diagnostic	• Mesure d'un apprentissage • Effet d'un traitement thérapeutique	Minimiser l'erreur de mesure au niveau individuel
<i>Population</i>	• Anciennes enquêtes de l'IEA pour l'évaluation de la performance de populations scolaires • Etalonnage d'un test d'intelligence	• Nouvelles enquêtes de l'IEA ou de l'OCDE.	Minimiser l'erreur de mesure au niveau de la population <i>Erreur d'échantillonnage : dans quelle mesure le changement observé est-il imputable à l'échantillon sélectionné ?</i>
		<i>Erreur d'ancrage : dans quelle mesure le changement observé est-il imputable aux items communs sélectionnés ?</i>	

Trois types d'erreurs sont identifiés :

1. **L'erreur d'échantillonnage** : cette erreur résulte de l'observation d'une fraction de la population, fraction appelée échantillon. En règle générale, l'échantillon en tant que tel présente peu d'intérêt. Sa seule utilité est de permettre, sous certaines conditions, la description de la population dont il est issu et qu'il est censé représenter. L'incertitude résultant de ce processus d'échantillonnage est rapportée par la variance d'échantillonnage, ou sa racine carrée, l'erreur type ou erreur standard. Cette erreur type traduit la variabilité de l'estimation du paramètre de population d'un échantillon à l'autre. On recourt à l'observation d'un échantillon et non à l'observation de l'ensemble de la population (ou recensement) car le recensement :
 - a. nécessiterait des moyens financiers considérables pas toujours disponibles ;
 - b. postposerait la publication des résultats ;
 - c. n'apporterait pas nécessairement plus d'information (*Il n'est pas nécessaire de manger tout le bœuf pour se rendre compte que la viande n'est pas bonne*) ;
 - d. et enfin, n'est pas toujours possible car certaines populations sont dites infinies, c'est-à-dire qu'il est impossible de recenser l'ensemble des individus.
2. **L'erreur de mesure** : cette erreur traduit l'imprécision de la mesure. Si l'on mesure la longueur d'une table avec un mètre étalon non gradué, les différences de résultats entre deux ou plusieurs mesures indépendantes seront élevées. Si le mètre est gradué jusqu'au millimètre, les différences seront très petites. En sciences humaines, on recourt souvent à de multiples observations pour estimer une compétence ou un trait psychologique. Ainsi, on posera plusieurs questions de

mathématiques pour avoir une idée plus ou moins précise de la compétence des individus. Dans ce contexte, et par analogie avec l'erreur d'échantillonnage, l'erreur de mesure résulte de l'échantillonnage des observations, et non pas l'échantillonnage des individus. Un test peut en effet être considéré comme un échantillon aléatoire et simple de questions tirées d'une population infinie de questions. Plus l'épreuve comporte de questions, plus elle sera précise et plus l'erreur de mesure sera faible. Globalement, l'erreur de mesure, dans le cadre de l'estimation de la performance d'un individu, traduit la variabilité de la performance de cet individu en fonction du test, ou en d'autres termes, en fonction des questions qui le composent.

3. **L'erreur d'ancrage** : pour mesurer un changement auprès d'un individu particulier, il importe de rapporter les résultats du prétest et du post-test sur une seule et même échelle. Un des moyens couramment utilisé de nos jours est de construire un prétest et un post-test qui comportent un ensemble de questions communes. L'erreur d'ancrage peut donc en quelque sorte être assimilée à la variabilité du changement due à la sélection des items communs. Il s'agit donc d'un cas particulier de l'erreur de mesure.

Comment ces trois types d'erreur affectent-ils les quatre grandes mesures identifiées dans le tableau 1.2 ?

1. L'évaluation de la performance d'un individu est entachée d'une erreur de mesure due à la sélection des items qui composent le test.
2. L'évaluation d'un changement auprès d'un individu est entachée de deux erreurs de mesure (une pour le prétest, une pour le post-test) et d'une erreur d'ancrage due à la sélection des items communs.
3. L'estimation de la performance d'une population est entachée d'une erreur d'échantillonnage due à la sélection des individus qui composent l'échantillon et d'une erreur de mesure due à la sélection des items qui composent le test.
4. L'estimation d'un changement sur une population est entachée d'une erreur d'échantillonnage, de deux erreurs de mesure et d'une erreur d'ancrage.

L'erreur qui résulte de l'échantillonnage des individus ne sera pas abordée dans le cadre de ce cours. Elle est largement discutée dans les cours ou les manuels de statistiques. Par contre, les différentes sources d'erreurs de mesure et d'ancrage seront largement décrites dans les chapitres suivants. Des solutions pour minimiser ces erreurs seront également discutées.

1.3. Ignorer les erreurs de mesure

Trop souvent, les chercheurs analysent leurs données sans prendre en considération les caractéristiques psychométriques de leurs mesures, un peu comme si une fois collectées, les données étaient parfaites, sans erreur de mesure. Malheureusement, les erreurs de mesure n'affectent pas uniquement la qualité de la mesure, mais affectent également certaines estimations des paramètres de population. La simulation suivante concrétise les effets des erreurs de mesure sur certaines statistiques.

Un échantillon de 5250 individus a été généré. A chaque individu sont associées trois valeurs aléatoires selon les règles suivantes :

1. une compétence (c'est-à-dire une variable latente ou *construct*) en compréhension de lecture qui se distribue normalement avec une moyenne de 50 et un écart type de 10 ;
2. un indice socioéconomique qui se distribue normalement avec une moyenne de 0 et un écart type de 1 ;
3. une variable dichotomique (0,1) qui représente le sexe de l'étudiant (0=M ; 1=F) ;
4. trois variables qui représentent les erreurs de mesure. Ces trois variables se distribuent normalement, toutes de moyenne égale à 0 mais d'écarts types variables : ils sont respectivement de 1, 2 et 5. De plus, ces trois variables sont indépendantes des variables *compréhension à la lecture*, *indice socioéconomique* (SES) et *sexe*. En d'autres termes, les erreurs de mesure ne corréleront pas avec les variables *lecture*, *SES* et *sexe*. Ces trois variables dites erreurs de mesure sont additionnées à la variable latente *compréhension de lecture* pour constituer trois mesures ou trois estimations de cette compétence.

Il convient de noter trois caractéristiques fondamentales des erreurs de mesure qui seront formalisées en détail ultérieurement : ces erreurs de mesures

1. se distribuent normalement ;
2. ont une moyenne égale à 0 ;
3. sont indépendantes de toute autre mesure.

Les tableaux suivants fournissent certaines statistiques calculées sur la variable latente compréhension à la lecture et sur les trois estimations de cette compétence, dénommée estimation A ($\sigma = 1$), estimation B ($\sigma = 2$) et estimation C ($\sigma = 5$).

Tableau 1.3. Moyenne, variance et écart type des variables compréhension à la lecture, estimation 1, estimation 2 et estimation 3

	<i>Moyenne</i>	<i>Variance</i>	<i>Ecart-type</i>
Compréhension à la lecture	50,00	100,00	10,00
Estimation A	50,00	101,00	10,05
Estimation B	50,00	104,00	10,20
Estimation C	50,00	125,00	11,18

L'erreur de mesure n'affecte pas l'estimation de la moyenne. En effet, si Y représente la variable *compréhension à la lecture* et si E représente une des trois variables *erreurs de mesure*, alors on peut écrire :

$$\mu_{(Y+E)} = \mu_{(Y)} + \mu_{(E)} = 50 + 0 = 50$$

Par contre, l'erreur de mesure affecte la variance et par conséquent, sa racine carrée ou écart type. En effet :

$$\sigma_{(Y+E)}^2 = \sigma_{(Y)}^2 + \sigma_{(E)}^2 + 2\text{cov}(Y, E)^4$$

Comme les erreurs de mesure sont indépendantes de la variable *compréhension à la lecture*, la covariance est donc égale à 0. En conséquence, la variance de l'estimation A est égale à $100+1=101$, la variance de l'estimation B est donc égale à $100+4=104$ et enfin, la variance de l'estimation C est égale à $100+25=125$. Plus l'erreur de mesure est grande, plus la surestimation de la variance sera importante.

⁴ Voir l'annexe *Prérequis statistiques*.

Tableau 1.4. Corrélation entre la compréhension à la lecture, les trois estimations et les variables *sexe* et *indice socioéconomique*

	<i>Sexe</i>	<i>Indice socioéconomique</i>
Compréhension à la lecture	0.180	0.389
Estimation A	0.175	0.384
Estimation B	0.171	0.383
Estimation C	0.158	0.341

Comme les résultats du tableau 1.4 l'indiquent, l'erreur de mesure engendre une sous-estimation de la corrélation, sous-estimation d'autant plus importante que l'erreur de mesure est grande. En effet, si X représente soit l'indice socioéconomique, soit l'indice sexe, on peut écrire :

$$\rho_{(X,Y)} = \text{corr}(Y + E, X) = \frac{\text{cov}(Y, X) + \text{cov}(E, X)}{\sigma_{(Y+E)} \sigma_{(X)}} = \frac{\text{cov}(Y, X)}{\sqrt{\sigma_{(Y+E)}^2 \sigma_{(X)}^2}} = \frac{\text{cov}(Y, X)}{\sqrt{(\sigma_{(Y)}^2 + \sigma_{(E)}^2) \sigma_{(X)}^2}}$$

Comme l'erreur de mesure est indépendante des autres mesures, la covariance entre cette erreur de mesure et toute autre variable est égale à 0. Donc, $\text{cov}(E, X) = 0$. Le numérateur reste inchangé. Par contre, le dénominateur devient plus grand puisqu'on y retrouve à présent $\sigma_{(E)}^2$. Plus l'erreur de mesure sera grande, plus le dénominateur augmentera et plus la corrélation sera sous-estimée.

Comme on le verra plus tard, on peut corriger cette sous-estimation de la corrélation en appliquant la formule de la correction pour atténuation.

Enfin, l'erreur de mesure affecte également les analyses de régression, comme le montrent les résultats du tableau 1.5

Tableau 1.5. Coefficient de régression, erreurs-types et *T* test

	<i>Coefficient de régression</i>	<i>Erreur type</i>	<i>T test</i>
Compréhension à la lecture	3,82	0,125	30,44
Estimation A	3,82	0,126	30,10
Estimation B	3,82	0,128	30,05
Estimation C	3,82	0,142	26,31

L'erreur de mesure au niveau de la variable dépendante n'affecte pas le coefficient de régression. En effet, dans le cas le plus simple d'une régression linéaire, à savoir une seule variable indépendante, le coefficient de régression est égal à

$$\beta = \frac{\text{cov}(Y, X)}{\sigma_X^2}$$

Il s'ensuit :

$$\beta = \frac{\text{cov}(Y + E, X)}{\sigma_{(X)}^2} = \frac{\text{cov}(Y, X) + \text{cov}(E, X)}{\sigma_{(X)}^2} = \frac{\text{cov}(Y, X)}{\sigma_{(X)}^2}$$


Par contre, l'erreur type sur le coefficient de régression est surestimée et par conséquent, la valeur du T test est sous-estimée. En d'autres termes, il se pourrait que le coefficient de régression soit statistiquement différent de 0 avec la variable latente et ne le soit plus avec une estimation de cette variable latente.

Ces trois exemples, à titre d'illustrations, démontrent l'importance d'étudier la qualité des mesures opérées afin notamment d'en déterminer l'impact sur les différentes analyses statistiques qui seront réalisées.

2. Le processus de la mesure

Dickes & al. (1994, p. 39), dans leur ouvrage intitulé *La psychométrie* définissent la mesure en quatre étapes successives reprises dans la figure 2.1.

Figure 2.1. Les étapes du processus de mesure (Dickes et al., 1994).



2.1. Etape 1 : Le concept à mesurer

Que ce soit en sciences de l'éducation ou en sciences psychologiques, il importe de définir et de circonscrire le concept à mesurer. Cette description théorique de l'objet de la mesure

conditionne la construction de l'instrument de mesure et, par voie de conséquence, les résultats de cette mesure.

Depuis la fin des années 90, il existe deux grands organismes internationaux (à savoir l'Association Internationale pour l'Évaluation du Rendement Scolaire, l'IEA, et l'OCDE) qui évaluent les performances des populations scolaires dans les disciplines fondamentales telles que la compréhension de la lecture dans la langue d'apprentissage, les mathématiques ou les sciences.

Dans sa publication *Mesurer les connaissances et les compétences des élèves : lecture, mathématiques et science : l'évaluation de PISA 2000*, l'OCDE (2000, p. 80) définit la culture scientifique comme « la capacité d'utiliser des connaissances scientifiques, d'identifier les questions relevant de la science et de tirer des conclusions fondées sur des faits, en vue de comprendre le monde naturel ainsi que les changements qui y sont apportés par l'activité humaine et de contribuer à prendre des décisions à leur propos ». Par ailleurs, l'OCDE identifie trois facteurs majeurs susceptibles d'influencer la difficulté des tâches proposées, à savoir :

1. Les processus ou savoir-faire scientifiques :
 - a. Reconnaître les questions auxquelles on peut répondre par une investigation scientifique ;
 - b. Identifier les faits nécessaires à une investigation scientifique
 - c. Tirer ou évaluer des conclusions ;
 - d. Communiquer des conclusions valides ;
 - e. Faire preuve de maîtrise des concepts scientifiques ;
2. Les concepts scientifiques :
 - a. Structure et propriétés de la matière ;
 - b. Changements atmosphériques ;
 - c. Changements physiques et chimiques ;
 - d. Transformation de l'énergie ;
 - e. Forces et mouvements ;
 - f. Forme et fonction ;
 - g. Biologie humaine ;
 - h. Changement physiologique ;
 - i. Biodiversité
 - j. Contrôle génétique ;
 - k. Écosystèmes ;
 - l. La terre et sa place dans l'univers ;
 - m. Changements géologiques ;
3. Les contextes :
 - a. Sciences appliquées à la vie et à la santé ;
 - b. Sciences appliquées à la Terre et à l'environnement ;
 - c. Sciences appliquées à la technologie.

L'IEA, dans le cadre de l'étude « *Trends in International Mathematics and Science Study* » identifie deux dimensions, à savoir :

1. Les contenus :
 - a. Sciences de la vie ;
 - b. Chimie ;
 - c. Physiques ;
 - d. Sciences de la terre ;
 - e. Sciences de l'environnement ;
2. Les domaines cognitifs :
 - a. Connaissances factuelles ;
 - b. Compréhension conceptuelle ;
 - c. Raisonnement et analyses.

Ces deux définitions concrétisent les limites de l'évaluation et garantissent une certaine diversité dans les tâches qui seront soumises aux élèves. En effet, l'épreuve construite devra porter sur les différents contenus et solliciter divers processus cognitifs.

Ces deux cadres de référence divergent à plus d'un égard mais globalement, il apparaît que la définition adoptée par l'I.E.A. se base sur la décomposition classique des sciences et s'apparente davantage à l'organisation des contenus scolaires, comparativement à la définition de l'OCDE qui a plutôt adopté une organisation thématique des contenus.

La définition d'un cadre de référence dans le cadre des *surveys* internationaux en sciences de l'éducation ne se limite pas à la mesure de compétences scolaires. Ainsi, le document intitulé *TIMSS 2007 Assessment Frameworks*⁵ décrit le cadre d'évaluation pour les mathématiques et les sciences mais également pour les questionnaires contextuels, à savoir le questionnaire *Elèves*, le questionnaire *Maître* et le questionnaire *Ecole*, ce dernier étant généralement complété par le chef d'établissement. Depuis la seconde étude internationale de l'IEA en mathématiques, il est d'usage de structurer les informations contextuelles selon deux dimensions : le composant et le niveau concerné. Le tableau 2.1. présente cette structuration.

Tableau 2.1. Cadre d'évaluation des informations contextuelles pour les études de l'IEA.⁶

	<i>Antécédents</i>	<i>Contextes</i>	<i>Curricula</i>
<i>Système éducatif</i>	Caractéristiques du pays (structure fédérale, scission ou non entre l'état et l'église)	Structure des systèmes éducatifs (filières, redoublement ..)	Curriculum officiel
<i>Ecole</i>	Caractéristiques du milieu (rural/urbain) de l'école (taille,...), du type d'école (public, privée)	Politiques d'admission, d'évaluation des élèves, y compris le redoublement, d'activités extra-scolaires, gestion de l'hétérogénéité...	Curriculum implanté
<i>Classe</i>	Caractéristiques des maîtres (sexe, formations initiale et continue...)	Processus d'enseignement	
<i>Elève</i>	Caractéristiques familiales (origine sociale, culturelle) de l'élève, sexe, âge, aspirations professionnelles)	Comportement scolaire de l'élève (motivation, travail en classe et à domicile...)	Curriculum atteint

A ces différents niveaux correspondent différents outils de mesure : *case study* et analyses du curriculum officiel pour le premier niveau, questionnaires essentiellement pour les trois niveaux inférieurs.

⁵ Mullis, I.V.S., Martin, M.O., Ruddock, G.J., O'Sullivan, C.Y., Aora, A. & Erberber, E. (2005). *TIMSS 2007 Assessment Frameworks*. TIMSS & PIRLS International Study Center, Lynch School of Education, Boston College.

⁶ Robitaille, D.F. & Garden, R.A. (Eds) (1989). *The IEA Study of Mathematics II : Contexts and Outcomes of School Mathematics*. Oxford, Pergamon Press.

Le cadre de référence peut aussi concerner des comportements verbaux, voire des comportements non verbaux, tels que des gestes, sourires... émis par un enseignant dans une classe. Ainsi, dans le cadre d'une étude intitulée « Comment les maîtres enseignent » et conduite par G. de Landsheere et E. Bayer, le cadre de référence définit l'unité comportementale verbale en fonction :

1. De sa direction :
 - a. La classe ;
 - b. Un groupe d'élèves ;
 - c. Un élève en particulier ;
2. De son rôle :
 - a. Administratif ;
 - b. Pédagogique ;
 - c. Psychologique ;

La grille de classification comprend les fonctions suivantes :

- | |
|---|
| <ol style="list-style-type: none"> 1. Organisation : <ol style="list-style-type: none"> a. Règle la participation des élèves ; b. Organise les mouvements des élèves en classe ; c. Ordonne ; d. Tranche une situation de conflit ou de concurrence ; 2. Imposition : <ol style="list-style-type: none"> a. Impose des informations ; b. Impose les problèmes ; c. Impose les méthodes de solutions, la façon de procéder ; d. Suggère les réponses ; e. Impose une opinion, un jugement de valeur ; f. Impose une aide non sollicitée ; 3. Développement : <ol style="list-style-type: none"> a. Stimule ; b. Demande une recherche personnelle ; c. Structure la pensée de l'élève ; d. Apporte une aide demandée par l'élève ; 4. Personnalisation : <ol style="list-style-type: none"> a. Accueille une extériorisation personnelle ; b. Invite l'élève à faire part de son expérience personnelle ; c. Interprète une situation personnelle ; d. Individualise l'enseignement ; 5. <i>Feedback</i> positif : <ol style="list-style-type: none"> a. Approuve d'une façon stéréotypée ; b. Approuve en répétant la réponse de l'élève ; c. Approuve d'une façon spécifique ; d. Approuve d'une autre façon ; 6. <i>Feedback</i> négatif : <ol style="list-style-type: none"> a. Désapprouve d'une façon stéréotypée ; b. Désapprouve en répétant la réponse de l'élève ; c. Désapprouve d'une façon spécifique ; d. Désapprouve d'une autre façon ; e. <i>Feedback</i> différé 7. Concrétisation : <ol style="list-style-type: none"> a. Utilise un matériel ; b. Invite l'élève à utiliser un matériel ; c. Technique audio-visuelle ; d. Ecrit au tableau ; 8. Affectivité positive : <ol style="list-style-type: none"> a. Louange, reconnaît le mérite, cite en exemple ; b. Montre la sollicitude ; c. Encourage ; d. Promet une récompense ; e. Témoigne du sens de l'humour ; f. Désigne l'élève d'un mot affectueux ; 9. Affectivité négative : <ol style="list-style-type: none"> a. Critique, accuse, ironise ; b. Menace ; c. Admoneste ; d. Réprimande ; e. Punit ; f. Diffère d'une façon vague ; g. Rejette une extériorisation spontanée ; h. Adopte une attitude cynique. |
|---|

Comme l'indique les dénominations des fonctions, diverses théories pédagogiques ont largement influencé la classification.

2.2. La collecte des informations

Une mesure, au sens large du terme, passe impérativement par des observations. Il peut s'agir, à titre d'illustrations :

1. Des réponses à un test de connaissances, d'intelligence ;
2. Des réponses à un questionnaire d'opinions
 - a. *pas du tout d'accord, pas d'accord, d'accord, tout à fait d'accord ;*
 - b. *jamais, parfois, souvent ;*
3. De l'émission d'un comportement verbal donné (comme par exemple une prise de parole par un élève au sein d'une classe, un chant d'oiseau, la détection d'un signal sonore par un être humain...) ;
4. D'un comportement non verbal (comme par exemple le balancement d'un élève sur une chaise, un dressement de la souris sur ses deux pattes postérieures...).

Ces observations sont réalisées selon un dispositif de collectes de données. Ainsi, dans le cadre de l'étude de de Landsheere et Bayer, les données ont été recueillies par des prises de notes d'observateurs assis au fond de la classe. Ces données auraient pu être collectées par l'intermédiaire d'un matériel audio ou audio-visuel. Différents dispositifs de collecte de données doivent être envisagés et l'influence de ces différents dispositifs sur la qualité des données collectées doit faire l'objet d'une réflexion approfondie. L'expérimentateur retiendra le dispositif qui est susceptible d'engendrer le plus petit nombre de biais.

Quel que soit le dispositif expérimental, l'observation fait intervenir deux ensembles différents : les sujets (c'est-à-dire les individus qui font l'objet de la mesure) et les items (la réponse du sujet, qu'il s'agisse d'une réponse à un test ou questionnaire ou d'un comportement non verbal). « *De la sorte, la collecte des observations consiste à rassembler l'information (en provenance des sujets) relative à des items (en rapport avec l'objet à mesurer), mettant éventuellement en œuvre une technique de collecte bien définie* » (Dickes & al., 1994, p. 40).

En sciences physiques, il existe un certain nombre d'instruments de mesure conventionnels qui nécessitent une seule observation. Ainsi, la mesure de la longueur d'une table nécessite une seule observation pour obtenir une mesure valide. Par contre, en sciences humaines, il n'existe pas de tels instruments et dès lors, on recourt souvent à des observations multiples. Ainsi, un test d'intelligence comprend un grand nombre de questions ou d'items, un test de personnalité nécessite également un grand nombre d'items ou d'observations pour permettre à l'expérimentateur de se forger une certaine idée de la personnalité de son sujet.

2.3. Transformation des observations en données

Les observations qui ont été collectées dans le monde empirique doivent être transformées en données pour qu'un modèle d'analyse ou modèle de mesure puisse leur être appliqué. Un changement de terminologie s'impose puisqu'on n'analyse pas des observations (des

comportements observés) mais une interprétation, une transformation de ces comportements, à savoir les données.

Ainsi, la réponse d'un élève à une question à *choix multiple* nécessite le recodage de cette réponse en termes de 0 (mauvaise réponse) ou 1 (réponse correcte). La réponse d'un élève à une *question ouverte à réponse courte* du type « $25 \times 5 =$ » implique également un recodage en termes de bonne ou de mauvaise réponse. De même, la *question ouverte à réponse longue* « Quel est le but de l'auteur en écrivant ce texte ? » requiert de la part de l'expérimentateur un recodage selon une grille de correction en termes de bonne ou de mauvaise réponse, voire en termes de mauvaise réponse (0), réponse partiellement correcte (1) et réponse correcte (2) (ou réponse à crédit partiel). Dans le cas de la question à choix multiple ou de la question ouverte à réponse courte, aucune place n'est laissée à l'interprétation de l'expérimentateur. Par contre, le codage d'une question ouverte à réponse longue nécessitera une interprétation de l'expérimentateur et cette interprétation est source de biais potentiels, ne serait-ce par exemple à cause de la qualité graphologique, syntaxique et sémantique de la réponse.

De même, l'intervention verbale d'un élève pourra être recodée selon qu'il fournit une réponse à une question du maître, ou qu'il pose une question relative au contenu enseigné, ou qu'il pose une question relative à l'organisation du travail...

Comme l'indique ce dernier exemple, cette transformation dépend essentiellement du cadre de référence (du concept mesuré). Certaines études peuvent uniquement s'intéresser à la distribution du temps de parole des élèves. Par contre, d'autres études peuvent se soucier de la distinction entre prise de parole spontanée, prise de parole sollicitée indirectement (par exemple, répondre à la question « Quelle est la capitale de la Belgique ? ») ou prise de parole sollicitée directement (par exemple, répondre à la question « Eric, quelle est la capitale de la Belgique ? »).

Dans un tout autre registre, l'éthologiste peut définir l'unité comportementale d'un animal selon :

1. Une classification selon la structure du comportement : par exemple le redressement de la souris sur les deux pattes postérieures... ;
2. Une classification selon les conséquences, les effets que ce comportement aura sur l'environnement : par exemple, obtenir de la nourriture, effectuer un comportement de toilettage ou un comportement lié à la parade nuptiale...

Il fait peu de doute que l'interprétation de l'expérimentateur sera plus importante si les comportements sont définis selon une classification en fonction des conséquences du comportement.

La transformation des observations dépend également du modèle de mesure qui sera utilisé lors de l'étape suivante. Ainsi, certains modèles, du moins dans leur conception initiale, n'autorisent que le traitement de réponses dichotomiques (correct, incorrect). Les modèles psychométriques actuels ne présentent plus de telles restrictions.

2.4. L'application du modèle de mesure

Le modèle de mesure transforme les données en mesure. Deux modèles de mesure seront essentiellement envisagés ultérieurement, à savoir :

1. la théorie classique du score vrai ;

2. les modèles de réponse à l'item ;

Chaque modèle de mesure repose sur un certain nombre de postulats, c'est-à-dire de présupposés théoriques. Ainsi, dans le cadre l'évaluation des compétences mathématiques d'une population scolaire par l'intermédiaire d'un test composé de 50 questions dichotomiques, les élèves interrogés se sont vus attribuer un score qui correspond au nombre de réponses correctes. Cette mesure résultante suppose que :

1. la compétence mathématique est une caractéristique unidimensionnelle ;
2. les 50 items ont été correctement choisis pour représenter l'ensemble de cette caractéristique ;
3. l'évaluation d'une personne est équivalente à l'évaluation d'une autre personne. En d'autres termes, il n'existe pas d'interactions entre le sujet et la mesure ;
4. les différences individuelles entre les évaluations d'une même personne sont des erreurs aléatoires.

Il est possible que ces postulats soient tous exacts mais il est également probable qu'ils ne le soient pas tous. Ce modèle de mesure, qui se limite à calculer la somme ou la moyenne arithmétique des données, ne requiert aucun présupposé sur la distribution de la variable latente de la population. D'autres modèles, plus complexes, imposent des postulats relatifs à la distribution de la population.

Durant cette étape, il importe de vérifier la fidélité et la validité de la mesure.

La fidélité renvoie à la précision avec laquelle une mesure résultante (un score) représente la caractéristique mesurée du sujet.

La validité se réfère au degré selon lequel des mesures résultantes prédisent ou rendent compte d'un ou de plusieurs critères externes. En d'autres termes, une mesure résultante est valide si elle prédit quelque chose et si ce quelque chose n'inclut pas la mesure résultante elle-même.

Il existe différentes opérationnalisations de ces concepts de fidélité et de validité. Ces différentes approches seront abordées ultérieurement, ainsi que leurs méthodes de calcul.

2.5. Transformations complémentaires éventuelles

Les mesures résultantes issues de l'application du modèle de mesure peuvent subir une transformation destinée à faciliter l'interprétation. En effet, dans le cadre d'une épreuve normative, au sens défini dans le chapitre 1, tout individu a besoin de connaître la moyenne et l'écart type de l'échelle pour pouvoir interpréter correctement son score.

Ainsi, l'échelle d'intelligence de Wechsler pour enfants (WISC-III) est composée de 13 sous-tests, soit 6 sous-tests verbaux et 7 sous-tests non verbaux. Après l'évaluation d'un sujet, l'expérimentateur doit calculer les résultats partiels à tous les sous-tests (par simple sommation des réponses correctes). Il doit ensuite, à l'aide d'une table de conversion, transformer ces scores en quotients intellectuels. Cette transformation permet ainsi d'obtenir une nouvelle mesure résultante dont la moyenne est de 100 et l'écart type de 15. Un individu peut donc situer son score dans la population.

Les résultats à des tests psychologiques sont régulièrement transmis sous une des formes présentées dans le tableau 2.3 et représentées graphiquement dans la figure 2.2. Ces différents

scores poursuivent essentiellement le même but, à savoir faciliter l'interprétation des scores individuels.

Tableau 2.2. Différents scores possibles

	Echelle	Moyenne	Ecart type
Note z ou note standard	Continue	0	1
Score T	Continue	50	10
Stens	10 échelons	5.5	2
Stanines	9 échelons	5	2

Les scores T s'obtiennent aisément en deux étapes :

1. transformer les résultats en note z (pour rappel, il s'agit de la différence du score de l'individu par rapport à la moyenne divisée par l'écart type);
2. multiplier la note z par l'écart type et ajouter la moyenne.

Ainsi, un sujet qui obtiendrait un score de 30 à un test dont la moyenne s'élève à 25 et l'écart type à 5 se verrait attribuer un score de 60 sur l'échelle T. En effet :

$$z = \frac{30 - 25}{5} = 1$$

$$T = (z \cdot 10) + 50 = (1 \cdot 10) + 50 = 60$$

L'échelle des *stens* est une échelle discontinue qui comporte 10 niveaux, notés de 1 à 10. Pour calculer les scores sur cette échelle, on peut recourir à deux méthodes :

1. Comme pour l'échelle T, on standardise les résultats et puis on transforme les notes z pour obtenir une nouvelle échelle de moyenne 5.5 et d'écart type 2. Il suffit ensuite d'arrondir à l'unité.
2. On peut utiliser la table de conversion reprise dans le tableau 2.3.

L'échelle des *stanines* est également une échelle discontinue qui comporte 9 niveaux. Elle peut s'obtenir de manière identique aux *stens*, à l'exception près que l'on ajoute 5 et non pas 5.5 à la note z ou en utilisant la table de conversion reprise dans le tableau 2.4.


Tableau 2.3. Table de conversion pour les *Stens*

Note Z	Stens
Plus petit que -2.00	1
De -2.00 à -1.50	2
De -1.50 à -1.00	3
De -1.00 à -0.50	4
De -0.50 à 0.00	5
De 0.00 à 0.50	6
De 0.50 à 1.00	7
De 1.00 à 1.50	8
De 1.50 à 2.00	9
Plus grand que 2.00	10

Tableau 2.3. Table de conversion pour les *Stanines*

Note Z	Stanines
Plus petit que -1.75	1
De -1.75 à -1.25	2
De -1.25 à -0.75	3
De -0.75 à -0.25	4
De -0.25 à 0.25	5
De 0.25 à 0.75	6
De 0.75 à 1.25	7
De 1.25 à 1.75	8
Plus grand que 1.75	9

Figure 2.2. Représentation graphique des différents scores



Les évaluations internationales en sciences de l'éducation utilisent les modèles de réponse à l'item (MRI)⁷ pour étalonner les données. Ces modèles renvoient des scores élèves qui varient généralement entre -4 et +4. Ces mesures résultantes sont ensuite transformées pour obtenir une échelle dont la moyenne internationale est égale à 500 et l'écart type international est égal à 100.

2.6. Synthétiser les résultats d'une batterie de test

Dans le cadre d'une batterie de test, les résultats à différentes épreuves peuvent être synthétisés pour ne fournir qu'un seul score aux candidats ou sujets ayant pris part à l'expérimentation.

Ce score total peut notamment s'obtenir par une sommation des résultats aux différentes épreuves. Il existe, dans ce cadre, essentiellement quatre méthodes, à savoir :

1. addition des résultats aux différentes épreuves ;
2. addition pondérée des résultats aux différentes épreuves ;
3. addition des résultats aux différentes épreuves après standardisation ;
4. addition pondérée des résultats aux différentes épreuves après standardisation.

Ces différentes méthodes peuvent conduire à des résultats différents non sans conséquences pour certains individus dans le cadre d'un recrutement par exemple. Le tableau 1.2 présente les résultats et le classement final selon la méthode de l'addition et selon la méthode de l'addition de scores standardisés.

Tableau 2.2 : Calcul du score global

Test 1 Brut	Test 2 Brut	Total Brut	Rang Brut	Test 1 Note Z	Test 2 Note Z	Total Note Z	Rang Note Z	Différence de rang
1	15	16	20	-1,67	-1,36	-3,03	20	0
2	16	18	19	-1,49	-0,60	-2,09	17	2
3	16	19	17	-1,31	-0,60	-1,92	16	1
4	15	19	17	-1,14	-1,36	-2,49	19	-2
5	15	20	16	-0,96	-1,36	-2,32	18	-2
6	16	22	15	-0,78	-0,60	-1,38	15	0
7	16	23	14	-0,60	-0,60	-1,21	14	0
8	17	25	13	-0,43	0,15	-0,28	11	2
9	17	26	11	-0,25	0,15	-0,10	10	1
10	16	26	11	-0,07	-0,60	-0,67	13	-2
11	16	27	10	0,11	-0,60	-0,50	12	-2
12	17	29	9	0,28	0,15	0,43	9	0
13	18	31	8	0,46	0,90	1,37	7	1
14	18	32	7	0,64	0,90	1,54	6	1
15	20	35	3	0,82	2,41	3,23	1	2
16	18	34	5	0,99	0,90	1,90	4	1
17	19	36	2	1,17	1,66	2,83	2	0
18	16	34	5	1,35	-0,60	0,75	8	-3
17	18	35	3	1,17	0,90	2,08	3	0
20	17	37	1	1,70	0,15	1,85	5	-4

⁷ Item Response Theory, en anglais, ou IRT.

Les deux premières colonnes du tableau 2.2 représentent les scores bruts à deux tests dont le score maximum est de 20. Les deux dernières colonnes présentent le classement final des candidats selon que le score total a été obtenu par addition des scores bruts ou addition des scores standardisés ou notes Z. La dernière colonne représente la différence entre les deux classements. Comme on peut le constater, les deux méthodes aboutissent à des classements distincts.

Le passage par la note Z (ou toute autre forme de standardisation du type score T ou score C) garantit que les deux tests contribueront de façon quasiment identique à la composition du score global. Par contre, dans la méthode de l'addition des scores bruts, la contribution des tests au score total sera proportionnelle à la variance des différentes épreuves. Plus une épreuve présente une variance élevée, plus sa contribution au score total sera élevée. A l'inverse, si une épreuve présente peu de variations, et qu'elle est réussie ou ratée par tous les répondants, elle contribuera peu au score global. Par exemple, supposons deux sous-tests. Le premier, sur 20, est réussi par tous les répondants (tout le monde à 20/20). La réussite au second, noté sur 10, est très variable, certains ont 0, 1, 2... 9 ou 10. Dans ce cas de figure, même si le premier test contribue à 2/3 de la note totale sur 30, c'est uniquement le second test qui sera déterminant pour le classement des individus. Comme la standardisation transforme les scores bruts des différentes épreuves en des scores présentant des indices de dispersion identiques, la contribution de chaque épreuve au score global sera équivalente.

Si la standardisation des notes brutes suffit à garantir que deux tests contribueront de manière identique à un score global, elle reste cependant insuffisante lorsque le score global se compose de plus de deux tests. En effet, la variance du score total est égale à la somme des variances de chacun des tests plus le double produit de l'ensemble des covariances entre tests. Mathématiquement, la variance du score total est égale à :

$$\sigma_{(Total)}^2 = \sum_{i=1}^k \sigma_{(k)}^2 + \sum_{i=1}^{k-1} \sum_{j=i+1}^k 2\text{cov}(i, j)$$

Lorsque le score global se compose de trois tests (A, B, et C), la variance totale sera égale à :

$$\sigma_{(Total)}^2 = \sigma_{(A+B+C)}^2 = \sigma_{(A)}^2 + \sigma_{(B)}^2 + \sigma_{(C)}^2 + 2\text{cov}(A, B) + 2\text{cov}(A, C) + 2\text{cov}(B, C)$$

La contribution du test A au score global peut se définir comme suit :

$$C_A = \frac{\sigma_{(A)}^2 + \text{cov}(A, B) + \text{cov}(A, C)}{\sigma_{(Total)}^2}$$

Comme l'indique la formule, la contribution d'un test sera proportionnelle à sa variance et aux covariances avec les autres tests.

La somme des contributions sera égale à 1. En effet :

$$C_A + C_B + C_C = \frac{\sigma_{(A)}^2 + \text{cov}(A, B) + \text{cov}(A, C)}{\sigma_{(Total)}^2} + \frac{\sigma_{(B)}^2 + \text{cov}(A, B) + \text{cov}(B, C)}{\sigma_{(Total)}^2} + \frac{\sigma_{(C)}^2 + \text{cov}(A, C) + \text{cov}(B, C)}{\sigma_{(Total)}^2}$$

$$C_A + C_B + C_C = \frac{\sigma_{(A)}^2 + \sigma_{(B)}^2 + \sigma_{(C)}^2 + 2\text{cov}(A, B) + 2\text{cov}(A, C) + 2\text{cov}(B, C)}{\sigma_{(Total)}^2} = 1$$

Le tableau 2.3. présente le score de 20 individus à trois tests, ainsi que le score global obtenu par simple sommation.

Tableau 2.3. : Scores de 20 individus à 3 tests et score global

Individu	Test 1	Test 2	Test 3	Total
1	1	15	12	28
2	2	16	19	37
3	3	16	18	37
4	4	15	15	34
5	5	14	16	35
6	6	13	16	35
7	8	15	18	41
8	9	16	14	39
9	10	16	13	39
10	11	18	15	44
11	12	17	18	47
12	13	17	9	39
13	14	19	13	46
14	15	18	11	44
15	16	19	18	53
16	17	17	19	53
17	18	16	20	54
18	19	20	19	58
19	20	20	18	58
Moyenne	10,68	16,68	15,84	43,21
Variance	34,32	3,58	9,29	71,32
Covariance	Test 1	8,43	3,21	
	Test 2		0,43	

Les covariances entre les différents tests sont respectivement égales à 8,43 entre le test 1 et le test 2, à 3,21 entre le test 1 et le test 3 et à 0,42 entre le test 2 et le test 3.

La contribution du test 1 dans le score global est donc de :

$$C_A = \frac{\sigma_{(A)}^2 + \text{cov}(A, B) + \text{cov}(A, C)}{\sigma_{(Total)}^2} = \frac{34.32 + 8.43 + 3.21}{71.32} = \frac{45.96}{71.32} = 0.64$$

Le test 1 a donc une contribution très élevée dans le score total.

Si les différentes variables ont préalablement été standardisées en notes Z, la contribution d'un test peut se calculer de la façon suivante :

$$C_A = \frac{1 + \rho_{(A,B)} + \rho_{(A,C)}}{\sigma_{(Total)}^2}$$

En d'autres termes, après standardisation, la contribution d'un test sera proportionnelle aux corrélations que ce test présente avec les autres tests. Si les corrélations entre les différents tests sont relativement voisines, les contributions seront relativement proches. Par contre, si certains tests présentent des corrélations particulièrement élevées ou particulièrement faibles, les contributions respectives de chacun des tests varieront davantage.

Il convient par ailleurs de noter que le rang final n'est nullement déterminé par la moyenne. Supposons par exemple qu'un test est coté sur 20 et l'autre sur 100. Si tous les individus obtiennent tous un score de 80 sur 100 au deuxième test, sa contribution au classement final sera nulle.

La démarche recommandée pour le calcul du score global passe donc par une standardisation des notes brutes. Si pour des raisons théoriques, un sous-test s'avérait plus important que les autres (par exemple, si l'on juge que le test de compréhension en lecture doit compter davantage que le test d'orthographe dans le score global), on pourrait alors appliquer une pondération sur la note standardisée.

2.7. Conclusions

Toute mesure comporte 4 étapes essentielles et indissociables. La première étape, qui définit le concept à mesurer, relève des différentes théories psychologiques, pédagogiques et épistémologiques de l'intelligence, de la personnalité, de l'apprentissage à titre d'exemples. Cette étape ne sera pas décrite davantage dans le cadre de ce cours d'introduction aux théories et aux méthodes de la mesure en sciences psychologiques et en sciences de l'éducation.

Par contre, les étapes 2 et les étapes 4 seront largement détaillées dans les chapitres suivants.

3. Des observations aux données : la rédaction des items d'un instrument de mesure

Une fois le cadre de référence défini, le chercheur doit obtenir des observations. A cette fin, il doit donc construire :

1. un instrument de mesure ;
2. un dispositif de collecte des observations.

Ce chapitre se consacre exclusivement à l'élaboration des items de l'instrument de mesure. L'assemblage des items en test et la conception du dispositif de collecte des observations seront abordés dans le chapitre 4.

Sans ignorer la diversité et l'utilité des mesures opérées par les psychologues et les pédagogues, ce chapitre se centrera exclusivement sur les mesures qui font intervenir un test (d'intelligence, de personnalité), un questionnaire d'opinions ou une épreuve de rendement.

3.1. Représentativité du cadre d'évaluation

Les observations sont généralement extraites d'un ensemble infini d'observations potentielles. En effet, un pédagogue intéressé par la mesure des compétences en mathématiques d'une population scolaire donnée (par exemple, les élèves de 4^e année de l'enseignement secondaire) va construire un test de performance qui ne représentera qu'une infime partie de l'ensemble des questions de mathématiques que l'on pourrait poser à ce niveau d'enseignement. C'est pour cette raison que l'on parle d'un ensemble infini d'observations potentielles.

De même, lorsqu'un psychologue évalue l'intelligence d'un enfant à l'aide de la WISC-III ou la personnalité d'un adulte par l'intermédiaire de l'inventaire de personnalité multiphasique du Minnesota-2, ou lorsqu'un pédagogue évalue la compréhension à la lecture d'un enfant, il souhaite généraliser la mesure à l'ensemble du domaine évalué. En effet, le psychologue ne cherche pas à déterminer la performance d'un enfant aux seuls items présentés dans la WISC-III. Ce résultat en lui-même ne présente aucun intérêt. Par contre, si ce score peut être généralisé et ainsi représenter l'intelligence de l'enfant, et si, par ailleurs, ce score permet de prédire sa réussite scolaire, voire d'identifier des déficiences susceptibles d'entraver son parcours scolaire, ce score présente un intérêt réel.

Dans ce contexte, l'introduction d'une nouvelle question ou d'un nouveau groupe de questions ne doit pas venir perturber les résultats. Si tel était le cas, la mesure perdrait de sa *généralisabilité*. Il importe donc de s'assurer que les items repris dans l'instrument de mesure couvrent bien le domaine évalué dans ses différentes dimensions.

Il convient donc de vérifier que le cadre d'évaluation défini lors de la première étape du processus de mesure est correctement représenté par l'outil de mesure. Pour assurer cette représentativité, différentes techniques d'échantillonnage des items ont été développées. Ce processus de sélection des items ne concerne pas uniquement le contenu abordé ou les processus mentaux mis en oeuvre, il concerne également la forme de la question. Ainsi, des données peuvent être présentées sous forme de textes, de tableaux ou de graphiques. La forme

de la question concerne également les modalités de réponse. Le sujet peut simplement devoir choisir une réponse parmi un ensemble de propositions (questions à choix multiple) ou il peut être amené à produire lui-même une réponse (questions ouvertes à réponse courte, questions ouvertes à réponse longue). L'importance relative des questions selon ces différentes dimensions devrait, en principe, être précisée dans le cadre d'évaluation. Ainsi, le cadre d'évaluation de l'étude TIMSS, évoqué dans le chapitre 2, structure les contenus et les savoir-faire qui relèvent du concept mesuré et qui devraient figurer dans l'instrument de mesure.

Dans la section suivante, nous détaillons à titre d'illustration, la taxonomie de Bloom.

B.S. Bloom (1969) a recueilli et analysé un très grand nombre de questions posées par des professeurs américains à leurs élèves. Ses travaux ont abouti à l'élaboration d'une taxonomie des processus cognitifs à six niveaux. Ces différents niveaux peuvent à présent servir l'élaboration de nouvelles épreuves afin d'éviter que celles-ci portent essentiellement, voire uniquement sur des processus tels que la connaissance ou l'application. Les différents niveaux de la taxonomie de Bloom sont répertoriés ci-dessous.

1. Connaissance
 - 1.1. Connaissance des données particulières
 - 1.1.1. Connaissance de la terminologie
 - 1.1.2. Connaissance des faits particuliers
 - 1.2. Connaissance des moyens permettant l'utilisation de données particulières
 - 1.2.1. Connaissance des conventions
 - 1.2.2. Connaissance des tendances et des séquences
 - 1.2.3. Connaissance des classifications
 - 1.2.4. Connaissance des critères
 - 1.2.5. Connaissance des méthodes
 - 1.3. Connaissance des représentations abstraites
 - 1.3.1. Connaissance des principes et des lois
 - 1.3.2. Connaissance des théories
2. Compréhension
 - 2.1. Transposition
 - 2.2. Interprétation
 - 2.3. Extrapolation
3. Application
4. Analyse
 - 4.1. Analyse des éléments
 - 4.2. Recherche de relation
 - 4.3. Recherche des principes d'organisation
5. Synthèse
 - 5.1. Production d'une oeuvre personnelle
 - 5.2. Elaboration d'un plan d'action
 - 5.3. Dérivation d'un ensemble de relations abstraites
6. Evaluation

3.2. Elaboration des items d'une épreuve de performance

Cette section donne des indications pour l'élaboration des items d'un test de performance. La dernière section du chapitre sera consacrée la création d'items pour les questionnaires contextuels.

Il est classique de distinguer les items en fonction :

1. des modalités de présentation ;
2. des formats de réponse.

Les avantages et inconvénients des différents types de format de réponse et des modalités de présentation sont décrits dans les deux sections suivantes. La 3^e section fournit des règles pour la rédaction des items, en fonction de leur format. Enfin, les biais liés aux items seront présentés.

3.2.1. Le choix du format des questions

Les premières études de l'IEA qui se sont déroulées dans les années 60, 70 ou 80 ont utilisé des tests de performance qui comportaient exclusivement ou majoritairement des questions à choix multiple (QCM). Le succès de ces QCM dans le cadre des études internationales à grande échelle réside dans :

1. la standardisation de la correction, d'où l'absence ou la quasi-absence de toute subjectivité du correcteur ;
2. la réduction des coûts : il n'est pas nécessaire de recourir à un codage (correction) des réponses des élèves, codage qui nécessite :
 - a. la rédaction de consignes de corrections ;
 - b. la formation des codeurs ;
 - c. le codage en lui-même ;
 - d. des études de qualité du codage.

Cependant, des critiques de plus en plus nombreuses ont été formulées à l'égard de ce type de questionnement dont la majorité portait sur la réduction des savoirs et des savoir-faire à un processus de reconnaissance. La compétence mesurée via ce type de questions consisterait plus à détecter la proposition correcte parmi des propositions erronées. On ne vérifierait donc pas la capacité de l'élève à produire une réponse correcte.

Des questions communément appelées questions ouvertes ont donc été introduites progressivement dans les tests internationaux. Le tableau 3.1. présente la répartition en pourcentage des questions ouvertes et des questions à choix multiple dans le cadre des grands *surveys* internationaux de l'IEA et de l'OCDE de ces dix dernières années.

Tableau 3.1. : Pourcentages de QCM et de questions ouvertes dans quelques *surveys* internationaux

	<i>Domaine</i>	<i>Niveau</i>	<i>% de QCM</i>	<i>% de questions ouvertes</i>
TIMSS 95	Math	Secondaire	83	17
TIMSS 99	Math	Secondaire	77	23
TIMSS 03	Math	Secondaire	66	34
IEA RL 91	Lecture	Primaire	100	0
IEA RL 91	Lecture	Secondaire	75	25
PIRLS 2001	Lecture	Primaire	47	53
PISA 2000	Lecture	Secondaire	45	55
PISA 2003	Math	Secondaire	33	67
PISA 2006	Sciences	Secondaire	63	37

Comme l'indique le tableau 3.1, la répartition des questions selon leur format tend à s'équilibrer, voire même dans certains cas, à s'inverser. Cet équilibrage correspond à la volonté d'évaluer une plus grande diversité de processus cognitifs, ainsi qu'à la volonté de proposer aux étudiants des formats de questions auxquels ils sont habitués (certains pays jugeant les QCM très inhabituelles dans leur contexte national).

Par ailleurs, parmi les questions ouvertes, il est d'usage de distinguer les réponses ouvertes à réponse courte et les réponses ouvertes à réponse longue. Outre la longueur de la réponse attendue, ces questions se différencient également par la diversité des réponses correctes, la nécessité de concevoir un guide de correction détaillé et l'importance relative de la subjectivité du codeur dans la correction de la réponse. En effet, une question du type « $15+17=$ » est une question ouverte qui laisse peu de place à l'interprétation. Par contre, pour une question du type « Quelle est l'intention de l'auteur de ce texte ? », la subjectivité du codeur risque d'influencer le score qu'il attribuera à la réponse de l'élève, ne serait-ce notamment que par la qualité calligraphique, syntaxique ou lexicale de la réponse.

Convient-il de privilégier un type de questions au détriment des autres ? Chaque type de questions présente des avantages et des inconvénients et il n'est pas dès lors pas possible de trancher en faveur d'un type de questions ou d'un autre.

Une répartition entre différents types de questions permettra à la fois de varier les processus cognitifs sollicités, de minimiser les comportements différentiels des items en fonction de certaines caractéristiques personnelles et/ou culturelles des personnes évaluées et de garantir une certaine faisabilité pratique nécessaire à la conduite d'une étude à large échelle. Mais l'élément primordial à considérer dans le choix d'une répartition relève des finalités poursuivies définies dans le cadre d'évaluation.

3.2.2. Modalités de présentation

Il est également possible de différencier les questions, non plus selon le format de réponse, mais en fonction du dispositif de présentation de la question. Une question se compose souvent d'un stimulus et puis de la question proprement dite, également appelée item.

Dans les études TIMSS de l'IEA, à un stimulus correspond un et un seul item. Dans ce cas, les différents items qui composent le test sont considérés comme indépendants. En effet, la probabilité de réussir un item ne dépend nullement de la probabilité de réussir l'item précédent, puisque ces deux items ne dépendent pas du même stimulus.

Par contre, les items des tests de performance PISA ne possèdent pas cette propriété. En effet, que ce soit pour la compréhension en lecture que pour les cultures mathématique et scientifique, un stimulus (texte, tableau, graphique...) est proposé aux élèves et plusieurs items sont généralement proposés au départ du même stimulus.

La figure 3.1 présente une unité de mathématique du test de PISA 2003. Dans le jargon PISA, le terme unité désigne l'ensemble formé par un stimulus et les items qui en dépendent. Dans l'exemple suivant, trois questions sont posées au départ d'un seul graphique. Ces trois items ne sont pas indépendants au sens strict du terme. En effet, si l'élève éprouve des difficultés à comprendre le stimulus, il aura moins de chances de réussir les questions qui s'y rapportent. Il y a donc dans ce cas une certaine dépendance entre items due au fait qu'ils dépendent d'un même stimulus. Cependant, la réponse à un item ne dépend nullement de la réponse à un autre item. Ainsi, le fait de réussir ou d'échouer à la question 1 n'aura aucun impact sur la réussite à la question 2.

L'exemple de la figure 3.2 illustre quant à lui un cas de dépendance entre items au sens strict du terme. En effet, la réussite à la question 2 dépend notamment de la réussite à la question 1, puisqu'une réponse incorrecte à la question 1 conduira automatiquement à une réponse incorrecte à la question 2.

La dépendance entre items est en règle générale déconseillée, voire proscrite dans le cadre des modèles de réponse à l'item, car elle peut biaiser certains indices statistiques ou psychométriques. Ainsi, dans l'exemple de la figure 3.2., la question 1 porte sur les propriétés du triangle isocèle et la question 2, sur la transformation de la mesure d'un angle. Ces deux objectifs ne sont pas liés sur le plan du savoir mathématique, du moins au-delà de la notion d'angle. En effet, il est aisé d'imaginer la maîtrise du premier sans le second ou inversement. En évaluant simultanément ces deux objectifs comme dans l'exemple de la figure 3.2, il devient impossible pour un élève de démontrer la maîtrise du second objectif sans la maîtrise du premier objectif. En d'autres termes, on génère artificiellement une corrélation entre ces deux objectifs. De ce fait, la corrélation entre ces deux items est surestimée. Or, comme la fidélité d'un test est proportionnelle à la corrélation moyenne entre les items, l'absence d'indépendance entre items conduit à une surestimation de la fidélité du test.

La dépendance entre items risque également de défavoriser les élèves les plus faibles. En effet, comme ces derniers ont plus de chances de ne pouvoir répondre correctement à la question 1, ils seront plus souvent placés dans l'impossibilité de répondre correctement à la question 2, quand bien même ils maîtrisent la transformation des angles de l'unité *degré* vers l'unité *radian*. La performance des élèves faibles sera donc plus souvent sous-estimée que ne le sera la performance des élèves les plus performants. Il s'ensuit aussi que la variabilité des résultats sera surestimée.

Figure 3.1. : Exemple d'items dépendant d'un même stimulus [OCDE - PISA 2003]





Figure 3.2. : Exemple de dépendance entre items



3.2.3. La rédaction des items

3.2.3.1. La rédaction des questions fermées


Dans les questions fermées, on distingue généralement les questions du type « Vrai-Faux » et les questions à choix multiple (QCM). A l'inverse des QCM, les questions de type « Vrai-Faux » (ou ses différentes variantes « Oui-Non », etc.) sont relativement faciles à rédiger puisqu'elles comportent seulement une proposition. Elles possèdent les mêmes avantages que la QCM en termes d'automatisation de la correction. Par contre, elles augmentent la possibilité d'obtenir une réponse correcte en choisissant au hasard. En effet, pour chaque item, le sujet a une chance sur deux d'obtenir une bonne réponse en répondant strictement au hasard. Le tableau 3.2. présente une liste d'écueils à éviter lors de la rédaction de question du type « Vrai-Faux ».

Certaines modalités de rédaction des QCM permettent de réduire la probabilité qu'un étudiant puisse obtenir une bonne réponse en répondant au hasard. Plus la question comporte de distracteurs, plus cette probabilité sera faible. Cependant, le travail de conception n'est nullement comparable à celui des questions « Vrai-Faux ». Leclercq (1986), dans son livre *La conception de questions à choix multiple*, énumère 20 règles dont il convient de se souvenir lors de la rédaction de toute QCM.




Tableau 3.2. : Règles de rédaction des questions fermées de type « Vrai-Faux » (d'après Nitko, 2004)

<i>Questions</i>	<i>Mauvais exemples</i>	<i>Bons exemples ou commentaires</i>
<i>La proposition est-elle réellement vraie ou réellement fausse sans devoir ajouter d'autres conditions ?</i> <i>1. Il faut utiliser des propositions aussi courtes que possible.</i> <i>2. Il faut utiliser un langage précis.</i> <i>3. Il faut utiliser des propositions à la forme affirmative et éviter les doubles négations.</i>	<i>Même si un item est une mesure non fiable et même s'il est souvent difficile d'écrire de nouveaux items, la fidélité d'un test peut être améliorée en augmentant la longueur du test et ainsi en augmentant le nombre de fois où les comportements des élèves sont observés.</i> <i>La rivière Monongahela ne s'écoule pas vers le nord.</i>	<i>Les tests qui comportent plus d'items sont généralement plus fidèles que les tests plus courts.</i> <i>La rivière Monongahela s'écoule vers le sud.</i>
<i>La longueur des propositions vraies est-elle identique à la longueur des propositions fausses ?</i>		Il semblerait que les propositions vraies soient en général plus longues que les propositions fausses.
<i>Evite-t-on de présenter les items selon un pattern donné, du type VVFFVV,</i>		
<i>L'item évite-t-il de donner des informations qui conduiraient à la réponse ?</i>	<i>C'est toujours mieux d'utiliser un test long qu'un test court.</i> <i>Habituellement, c'est mieux d'utiliser un test long qu'un test court.</i>	Des termes tels que « toujours, jamais, chaque » rendent souvent les propositions fausses. Par contre, des termes tels que « habituellement, fréquemment, souvent » rendent souvent les propositions vraies.
<i>Si l'item présente une opinion, la source est-elle indiquée ?</i>		
<i>Si la proposition n'évalue pas la connaissance d'une relation entre deux idées, présente-t-elle seulement une idée ?</i>	<i>La rivière Monongahela s'écoule vers le nord pour rejoindre la rivière Allegheny à Columbus, pour former la rivière Ohio.</i>	<i>La rivière Monongahela et la rivière Allegheny se rejoignent pour former la rivière Ohio.</i>

Tableau 3.3. : Règles de rédaction des questions à choix multiple (d'après Leclercq, 1986)

	<i>Règles</i>	<i>Mauvais exemples</i>	<i>Commentaires ou bons exemples</i>
1	<i>N'utiliser la QCM que si elle est le type de question le plus approprié à mesurer ce que l'on vise.</i>	<i>La Chine</i> 1. Est communiste. 2. A une superficie de 9 580 000 km². 3. A 800 millions d'habitant au moins. 4. A pour capitale PEKIN.	Cette question pourrait être remplacée par quatre questions « Vrai-Faux ».
2	<i>La QCM doit correspondre à l'objectif visé, au comportement à évaluer.</i>	2a) Où est la tanche ? 1.  2.  3.  4.  2b) Ce poisson est : 1. Un brochet 2. Une truite 3. Une carpe 4. Une tanche	La question 2a correspond à la situation du poissonnier qui doit reconnaître, parmi les diverses espèces présentes sur son étal, le poisson demandé par le client. La question 2b représente la situation du pêcheur à la ligne qui, même dans le meilleur cas, n'a qu'un seul poisson au bout de sa ligne et doit lui donner un nom.
3	<i>La QCM ne doit pas perturber les apprentissages.</i>	<i>Quelle phrase ne contient pas de faute d'orthographe ?</i> 1. Je vous ai fait patienter. 2. Vous êtes arrivez. 3. J'ai jouer. 4. Vous venez.	Il est déconseillé de proposer aux élèves des distracteurs qui risquent de perturber leurs apprentissages, en l'occurrence, des participes passés mal orthographiés.
4	<i>La QCM doit renseigner l'évaluateur sur le processus mental utilisé par l'étudiant.</i>	<i>Quelle est la surface de la figure ci-dessous ?</i>  1. 5 cm² 2. 6 cm² 3. 7 cm²	On peut répondre à cette question en utilisant la formule de l'aire d'un trapèze ou en comptant les carrés de 1 cm ² .

	<i>Règles</i>	<i>Mauvais exemples</i>	<i>Commentaires ou bons exemples</i>
5	Les distracteurs doivent indiquer le type d'erreur commise ou le cheminement incorrect suivi par l'élève.	Un spécialiste en oto-rhino-laryngologie indique généralement sur sa plaque « nez-gorge-oreille ». Le rhinocéros a une corne à l'avant du museau. Celui qui souffre de rhinite se mouche fréquemment Le mot grec RHIS,RHINOS signifie : 1. Maladie. 2. Visage. 3. Nez. 4. Corne. 5. Front. 6. Gorge.	Cette question est destinée à des étudiants qui ne connaissent pas le grec. Elle relève du niveau 2 de la taxonomie de Bloom, à savoir la compréhension. Gorge est le deuxième mot de « nez-gorge-oreille », au même titre que rhino est le deuxième mot de l'expression « oto-rhino-laryngologie ».
6	On doit préciser sur quelle partie de l'énoncé porte la question.	Au VIII^e siècle, Charles Martel a battu les Arabes à Poitiers, les chassant ainsi d'Europe. 1. Vrai 2. Faux	Seule la dernière partie est fausse (car les arabes sont encore restés en Espagne après la bataille).
7	La question doit être compatible avec la consigne.	Lequel des aliments ci-dessous apporte des lipides ? 1. Œuf 2. Viande 3. Huile	Plus d'un aliment cité contient des lipides. Or, la consigne générale était une seule bonne réponse par question.
8	Proposer des phrases syntaxiquement correctes.	L'organe qui secrète l'insuline est le 1. Pancréas. 2. Rate. 3. Thyroïde. 4. Hypophyse. 5. Foie.	Certains des distracteurs sont masculins, d'autres féminins, or, le « le » de l'amorce ne convient pas aux distracteurs féminins.
9	Pas de terme vague dans l'énoncé.	Quel est l'élément du sang qui transporte l'oxygène 1. Le fer. 2. L'hémoglobine. 3. Les globules rouges.	Le terme élément est très vague dans le contexte de cette question. Il est pris comme composant alors que des chimistes auraient tendance prendre élément au sens du tableau périodique.
10	Eviter les formes négatives (syntaxiques et sémantiques), a fortiori proscrire leur accumulation.	N'est-il pas faux de nier que l'absence d'arrêt à un signal « STOP » n'entraîne pas automatiquement le retrait du permis de conduire ? 1. Oui 2. Non	

11	Séparer informations et questions.	Lequel des 3 dessins ci-dessous représente une embarcation armée en pointe (le rameur tire l'aviron des deux mains) avec barreur (l'équipier qui tient la barre du gouvernail) ? Dans une embarcation armée en couple, il y a deux avirons par barreur. La définition d'aviron est « rame élargie à un bout en forme de pelle ». Le mot « aviron » vient de l'ancien français « viron » qui signifiait « tour ». 1.  2.  3. 	Dans une embarcation armée : en pointe, le rameur tire un aviron des deux mains en couple, chaque rameur tire un aviron des deux mains. La définition d'aviron est « rame élargie à un bout en forme de pelle ». Le barreur est l'équipier qui tient la barre du gouvernail. Lequel de trois dessins ci-dessous représente une embarcation armée en pointe avec barreur ?
12	Regrouper dans l'amorce les éléments communs aux solutions proposées.	La température du corps humain : 1. ne peut jamais dépasser 37° C sous peine de mort. 2. ne peut jamais dépasser 40° C sous peine de mort. 3. ne peut jamais dépasser 42° C sous peine de mort.	L'homme meurt si sa température interne dépasse : 1. 37° 2. 40° 3. 42°
13	Assurer l'indépendance syntaxique.	Le muscle du bras dont la contraction permet d'effectuer le mouvement représenté ci-dessous est :  1. le deltoïde 2. le triceps 3. au contraire, le biceps 4. en plus, le cubitus de la main	Dans cet exemple caricatural, les expressions « au contraire », « en plus », lient ces solutions à d'autres : c'est un défaut grave.

14	Les solutions proposées doivent être « conceptuellement » indépendantes les unes des autres.	Une solution d'eau saturée en sel de cuisine peut descendre sans geler jusqu'à une température de : 1. 0° C 2. -2° C 3. -4° C 4. -6° C	Choisir la solution 4 équivaut à accepter toutes les autres (si l'eau peut descendre jusqu'à -6°C, elle peut aussi descendre à -4°C, -2°C, 0°C).
15	Eviter de donner des éléments de réponse dans l'amorce.	Quel est le nom de l'organisme de police international ? 1. C.I.A. 2. F.B.I. 3. Interpol 4. S.A.S	Les mêmes racines (inter et pol) se retrouvent dans l'amorce et dans une des solutions, ce qui donne à celle-ci une bien plus grande attractivité.
16	Produire des distracteurs de même vraisemblance.	Quel groupe sanguin est « receveur universel » ? 1. A 2. B 3. AB 4. O 5. AO	Cet exemple est caricatural. Pourquoi créer de faux groupes sanguins dans ce cas ?
17	Produire des distracteurs de même complexité : la solution correcte ne doit pas être systématiquement plus longue que les autres.	Le mot « spinnekar » désigne : 1. Un chien écossais. 2. Une voile triangulaire de grande surface, légère et très creuse, que les yachts envoient dans la marche au vent arrière. 3. Un chant tyrolien. 4. Un instrument de musique	Il est difficile pour le rédacteur d'éviter cette asymétrie. Trouver des solutions indiscutablement fausses est aisé, il est beaucoup plus difficile d'en fournir d'irréprochablement correctes.
18	Produire des distracteurs de même complexité.	Un incendie se déclare dans la cuisine. L'occupant n'arrive pas à le maîtriser. Que doit-il faire ? 1. Couper l'arrivée de gaz au compteur. 2. Téléphoner aux pompiers. 3. Evacuer les enfants. 4. 1 et 2. 5. 2 et 3. 6. 1,2 et 3.	Cette question comprend des précautions à prendre et des opérations techniques à effectuer. Dans ce genre de contenu, le constructeur des questions est tenté de construire la solution correcte en accumulant simplement l'ensemble des précautions et des opérations. Si cette tendance est systématique chez le constructeur, alors il suffit à l'élève de rechercher la solution la plus complète.

19	<i>Produire des distracteurs de même niveau de généralité dans les indicateurs (temps, modificateurs,...).</i>	<i>Le terme « épicéa » désigne :</i> <i>tous les arbres résineux.</i> <i>tous les pins.</i> <i>certains types de pins</i>	Dans cette question, la solution 3 est rendue plus attractive que les deux autres, en raison de l'emploi de « certains », terme moins absolu que « tous ».
20	<i>Produire des distracteurs de même degré de technicité du vocabulaire dans toutes les solutions proposées.</i>	<i>Dans l'islam chiïte, un ayatollah est</i> <i>un iman.</i> <i>un uléma.</i> <i>une autorité religieuse.</i> <i>un derviche.</i>	Les étudiants peu compétents ont tendance à éviter les solutions comportant des termes techniques. Dans cette question, les solutions 1, 2 et 4 contiennent pour l'étudiant ignorant, des mots plus difficiles que ceux de l'énoncé. La solution 3 est donc avantagée.

Comme on peut le constater à la lecture de ces 20 règles, la rédaction d'une question à choix multiple est plus complexe qu'il n'y paraît de prime abord. Il est parfois conseillé aux rédacteurs de recourir dans un premier temps à des questions ouvertes afin de recueillir un ensemble de réponses qui pourront ultérieurement servir de base pour la rédaction des distracteurs.

3.2.3.2. La rédaction de questions ouvertes

Comme mentionné précédemment, on différencie, dans les questions ouvertes, les questions à réponse courte et les questions à réponse longue.

3.2.3.2.1. La rédaction de questions ouvertes à réponse courte

Les questions ouvertes à réponse courte exigent comme réponse un ou quelques mot(s), une phrase courte, un nombre ou un symbole. Il y a essentiellement trois types de questions à réponse courte :

1. la phrase interrogative : on pose une question directement à l'élève ;
2. la phrase lacunaire : on présente à l'élève une phrase incomplète et exige de l'élève d'ajouter un ou plusieurs mots pour la compléter ;
3. l'association : on présente à l'élève une liste de termes ou d'images pour lesquels l'élève doit fournir des nombres, des noms, symboles ou autres termes.

La figure 3.3 présente un exemple pour ces trois types de questions ouvertes à réponse courte.

Figure 3.3. : Exemples de questions ouvertes à réponse courte

Q1 : Quelle est la capitale du Mali ?	
(Bamako)	
Q2 : La capitale du Sénégal est	
(Dakar)	
Q3 : A côté de chaque unité de mesure, indique le symbole :	
Unité de mesure	Symbole
Mètre	
Kilo	
Minutes	

Les questions ouvertes à réponse courte peuvent évaluer la performance des étudiants à un éventail de compétences de niveau inférieur. Dans la taxonomie de Bloom, il s'agit essentiellement des niveaux (i) connaissance, (ii) compréhension et (iii) application.

Les questions ouvertes à réponse courte connaissent de nos jours un certain succès car elles ne présentent aucune difficulté majeure dans leur conception et leur rédaction et elles peuvent facilement être corrigées. Il serait cependant erroné de considérer que la subjectivité du correcteur n'intervient nullement dans ce type de questions. En effet, il n'est pas toujours possible d'anticiper toutes les réponses possibles. De même, une piètre écriture, des erreurs orthographiques ou syntaxiques peuvent nécessiter de la part du correcteur une certaine

subjectivité dans le déchiffrement. Les consignes de correction devront préciser le comportement à adopter par le correcteur en cas d'écriture peu lisible, fautes d'orthographe ou grammaticale. Ces consignes peuvent par ailleurs varier d'une question à l'autre, en fonction de l'objectif poursuivi par la question. En effet, on peut tolérer des erreurs orthographiques à une question portant sur un nom propre. Par contre, à une question relative à l'accord du participe passé, l'erreur orthographique ne sera pas autorisée.

Enfin, comparativement aux questions à choix multiple, les questions à réponse courte neutralisent les choix au hasard, puisqu'il ne s'agit pas de choisir parmi des propositions mais de produire une réponse, fût-elle très brève. Nitko (2004, p. 128) présente une liste de contrôle pour l'évaluation de la qualité des questions ouvertes à réponse courte. Cette liste est reprise dans le tableau 3.4.

3.2.3.2.2. La rédaction de questions ouvertes à réponse longue

Les questions ouvertes à réponse longue, ou construite, ont pour objectif d'évaluer des processus cognitifs élevés du type analyse, synthèse et évaluation sur la taxonomie de Bloom. Ces questions peuvent notamment demander à l'élève :

1. de rassembler des idées pour décrire ou expliquer ;
2. de comparer des éléments ou idées ;
3. de contraster des éléments ou idées ;
4. de définir un terme ;
5. d'identifier les éléments d'un texte qui appuient une thèse ;
6. d'identifier les avantages et les désavantages ;
7. d'analyser des graphiques, des tableaux, des données.

Il importe de préciser dans la question ce qu'on attend de l'élève. A cet égard, des verbes comme « *compare, défini, contraste* » laissent peu de place à l'interprétation ou à l'ambiguïté. A eux seuls, ces verbes précisent le type de raisonnement demandé.

Il convient par ailleurs dans la question de ne pas inclure des informations inutiles qui pourraient modifier la perception de l'étudiant relativement à ce qu'on attend de lui.


Les difficultés majeures rencontrées avec ce type de questions résident dans la difficulté de concevoir les consignes de correction qui laissent peu de place à la subjectivité du correcteur et, par conséquent, dans la réduction de la fidélité de la mesure. Il importe donc que ces consignes de correction envisagent les différentes réponses correctes et précisent les limites tolérées par rapport à la réponse prototype. L'essai sur le terrain (prétest) fournit une base d'information très précieuse pour la révision des consignes de correction, puisque ces dernières peuvent être aménagées en fonction des difficultés rencontrées pour la correction de réponses non prévues initialement. Il est recommandé d'inciter les correcteurs de lister les difficultés rencontrées lors du codage et de transmettre ces informations aux rédacteurs qui pourront réajuster leurs consignes avant la collecte définitive des données.

Les figures 3.4 et 3.5 présentent successivement une question à réponse longue et ses consignes de correction. Cet exemple est issu de PISA 2003. Comme l'illustre la figure 3.4, le guide de correction peut prévoir de créditer les réponses d'un score plus ou moins important en fonction de leur élaboration. Ainsi, un « crédit complet » est réservé aux réponses considérées comme totalement correctes, et un « crédit partiel » est réservé aux réponses partiellement correctes. A l'intérieur de ces deux catégories de réponses, on peut également

tenter de classer encore les réponses selon la nature du processus cognitif en jeu. C'est pour cette raison que le crédit partiel à deux points de la figure 3.4 prévoit plusieurs codes différents. Il faut cependant noter que la multiplication des codes de correction peut rendre le travail des correcteurs plus ardu ou plus lent, et potentiellement moins fiable et plus coûteux.

Figure 3.4. : Exemple de question à réponse longue [OCDE - PISA 2003]

MARCHE A PIED



L'image montre les traces de pas d'un homme en train de marcher. La longueur de pas P est la distance entre l'arrière de deux traces de pas consécutives.

Pour les hommes, la formule $\frac{n}{P} = 140$ donne un rapport approximatif entre n et P ,
où :

n = nombre de pas par minute,
 P = longueur de pas en mètres.

Question 3 : MARCHE À PIED

M124Q03 - 00 11 21 22 23 24 31 99

Bernard sait que la longueur de son pas est de 0,80 mètre. La formule s'applique à sa façon de marcher.

Calculez la vitesse à laquelle marche Bernard en mètres par minute et en kilomètres par heure. Montrez vos calculs.

**Figure 3.5. : Exemple de consignes de correction d'une question à réponse longue
[OCDE - PISA 2003]**

MARCHE À PIED : CONSIGNES DE CORRECTION Q 3

Crédit complet

Code 31 : Réponses correctes fournies à la fois pour les mètres par minute et les km par heure (les unités ne sont pas exigées) :
 $n = 140 \times 0,80 = 112$.
En une minute, il parcourt $112 \times 0,80$ mètre = 89,6 mètres.
Sa vitesse est donc de 89,6 mètres par minute.
Par conséquent, sa vitesse est de 5,38 km/h ou 5,4 km/h.

Coder 31 si les deux réponses correctes sont fournies (89,6 et 5,4), que l'élève ait montré ou non son travail. Noter que les erreurs d'arrondi sont acceptables. Par exemple, 90 mètres par minute et 5,3 km/h (89 X 60) sont acceptables.

- 89,6 ; 5,4.
- 90 et 5,376 km/h.
- 89,8 et 5376 m/h [à noter que si le second chiffre n'avait pas été fourni avec les unités, cette réponse aurait été codée 22].

Crédit partiel (2 points)

Code 21 : Comme pour le code 31, mais oublie de multiplier par 0,80 pour convertir les pas par minute en mètres par minute. Par exemple, sa vitesse est de 112 mètres par minute et 6,72 km/h.

- 112 et 6,72 km/h.

Code 22 : La vitesse en mètres par minute est correcte (89,6 mètres par minute) mais la conversion en kilomètres/heure est incorrecte ou omise.

- 89,6 mètres par minute, 8 960 km/h.
- 89,6 et 5376.
- 89,6 et 53,76.
- 89,6 ; 0,087 km/h
- 89,6 et 1,49 Km/h.

Code 23 : Méthode correcte (explicitement montrée), mais erreur(s) de calcul mineure(s), non couverte(s) par les codes 21 et 22. Aucune des deux réponses n'est correcte.

- $n = 140 \times 0,8 = 1120$; $1120 \times 0,8 = 896$. Il marche à une vitesse de 896m/min, soit 53,76 km/h.
- $n = 140 \times 0,8 = 116$; $116 \times 0,8 = 92,8$. 92,8 m/min -> 5,57 km/h.

Code 24 : Fournit seulement la réponse 5,4 km/h, et non 89,6 m/min (les calculs intermédiaires ne sont pas montrés).

- 5,4
- 5,376 km/h.
- 5 376 m/h.

Crédit partiel (1 point)

Code 11 : $n = 140 \times 0,80 = 112$. Pas d'autre calcul montré, ou calcul erroné après ceci.

- 112.
- $n = 112$; 0,112 km/h.
- $n = 112$; 1120 km/h.
- 112 m/min ; 504 km/h.

Pas de crédit

Code 00 : Autres réponses.

Code 99 : Omission.

Note de traduction : Les prénoms peuvent être adaptés, mais doivent rester des prénoms masculins.

Tableau 3.4. : Règles de rédaction des questions ouvertes à réponse courte (d'après Nitko, 2004)

<i>Questions</i>	<i>Mauvais exemples</i>	<i>Bons exemples ou commentaires</i>
<i>Pour autant que cela soit possible, l'item est-il écrit sous forme de question ?</i>	<i>Pourquoi les consignes de correction sont-elles nécessaire pour les questions ouvertes à réponse longue ?</i>	<i>La raison principale pour utiliser des consignes de correction pour une question ouverte à réponse longue est d'augmenter de la correction.</i> Les items écrits sous forme de questions prêtent moins à confusion. Il s'agit donc du format préféré pour les questions à réponse courte. Cependant, dans certains cas, comme dans l'exemple, un autre format peut s'avérer plus approprié.
<i>L'item est-il écrit de façon claire de sorte que la réponse correcte puisse être fournie par un mot, un symbole, un nombre ou une phrase courte ?</i>	<i>Où est situé Pittsburgh, en Pennsylvanie ?</i>	<i>Au confluent de quelles rivières Pittsburgh, en Pennsylvanie, est-il situé ?</i> La mauvaise version de la question peut aboutir à une grande diversité de réponses correctes. Le rédacteur doit donc préciser dans la question la réponse attendue.
<i>L'espace prévu pour la réponse est-il à la fin de la phrase ?</i>	<i>..... est la capitale de l'état d'Illinois.</i>	<i>Le nom de la capitale de l'Illinois est</i> Si l'espace est situé en début ou en milieu de phrase, l'élève doit dans un premier temps formuler la phrase sous forme de question avant de pouvoir y répondre.
<i>Si l'item relève de la catégorie texte lacunaire, le mot manquant est-il un mot important ?</i>		Le mot manquant doit porter sur une connaissance importante. Il convient donc, à cet égard, d'éviter les verbes, à l'exception bien entendu des questions grammaticales qui porteraient sur l'accord du verbe.
<i>L'espace réservé à la réponse a la même longueur que l'espace réservé dans les autres questions.</i>		Les étudiants peuvent utiliser la longueur de l'espace réservé comme indice. Il convient donc de garder le même espace au sein d'une question ou à travers questions.
<i>Si nécessaire, l'item informe-t-il l'élève sur le degré de précision ou l'unité ou de détails requis pour la réponse ?</i>	<i>Si chaque lettre à envoyer par la poste pèse $20\frac{1}{8}$ g , combien pèsent 10 lettres ?</i>	<i>Si chaque lettre à envoyer par la poste pèse $20\frac{1}{8}$ g , combien pèsent (au nombre entier le plus proche) 10 lettres ?</i>
<i>L'item évite-t-il des informations de type grammatical par exemple qui pourrait aider l'élève ?</i>	<i>Un animal vertébré qui allaite ses enfants s'appelle un</i>	<i>Un animal vertébré qui allaite ses enfants s'appelle un(e)</i>

3.2.4. Interactions entre les items et les sujets

Il arrive fréquemment que des items présentent des interactions avec certaines caractéristiques des sujets interrogés. Cette interaction se produit lorsque deux individus, de compétences égales, n'ont pas la même probabilité de réussir un item. A cet égard, il convient tout d'abord de distinguer deux concepts : le biais d'item et le comportement différentiel de l'item (DIF). On observe un DIF lorsque, à niveau de compétence équivalent, des sujets appartenant à différents groupes (le critère commun aux élèves d'un même groupe peut être le pays d'appartenance, la langue, le sexe...) ont des probabilités différentes de réussir l'item. Ainsi, dans un test de compréhension en lecture, on trouvera souvent des DIF à l'avantage des filles, en particulier pour des réponses ouvertes longues portant sur des textes littéraires. Le fait d'observer un DIF ne signifie pas nécessairement que l'item présente un biais, il s'agit d'une condition nécessaire, mais pas suffisante, pour parler de biais d'item. En effet, dans l'exemple précédent, la différence filles/garçons ne résulte pas d'un biais dans la conception de l'épreuve, mais d'une plus grande aisance des filles dans ce type d'items. Le biais d'item, quant à lui, existe lorsqu'un groupe de sujets a moins de chance de réussir un item que les sujets d'un autre groupe en raison de certaines caractéristiques de l'item ou des conditions de *testing non reprises dans le cadre d'évaluation*. En d'autres termes, le biais d'item résulte d'un défaut au niveau de la conception du test ou de ses modalités d'administration, dans la mesure où il s'agit d'une différence non souhaitée ou non expliquée dans les résultats de certains groupes, alors que certains DIF peuvent quant à eux, si pas être souhaités, être cohérents par rapport à la littérature de recherche, comme cela va être plus amplement illustré ci-après.

Globalement, l'interaction entre certaines caractéristiques du sujet et l'item peut concerner le type de stimulus, la modalité de réponse de l'item, le contenu de l'item, les processus cognitifs évalués par l'item.

3.2.4.1. Le type de stimulus

Sur la base des données PISA 2000, Lafontaine et Monseur⁸ ont montré que la différence entre les filles et les garçons en compréhension de lecture était largement inférieure lorsque les questions portent sur des textes non continus (tableaux, graphiques...) que lorsqu'elles portent sur des textes continus (textes narratifs par exemple). Le tableau 3.5 présente la moyenne des différences filles-garçons pour les pays de l'OCDE, selon le type de questions et selon le type de textes (textes continus *versus* textes non continus).

⁸ Lafontaine, D. et Monseur, C. (2008). Impact of test characteristics on gender equity indicators in the assessment of reading comprehension. *European Educational Research Journal. Special issue on PISA and gender*, 8(1), 69-79.

Tableau 3.5.: Moyenne des différences de rendement entre filles et garçons en fonction du type de textes et en fonction du format de la question

	Textes continus		Textes non continus	
	QCM	Questions ouvertes	QCM	Questions ouvertes
Moyenne des différences F-G pour les pays de l'OCDE	33 (0.89)	48 (0.94)	12 (1.05)	21 (0.99)

La plus grande différence de performance entre les filles et les garçons s'observe pour les questions ouvertes relatives à des textes continus et la plus petite différence, pour les questions à choix multiple relatives à des textes non continus. Comme le confirment les résultats du tableau 3.5., les questions posées au départ d'un texte non continu sont donc relativement plus faciles pour les garçons, alors que les questions posées au départ de textes continus sont relativement plus faciles pour les filles.

3.2.4.2. La modalité de réponse de l'item

L'exemple le plus connu d'interaction entre caractéristiques du sujet et modalité de réponse concerne le sexe. Différentes études, dont celle de Lafontaine et Monseur, ont montré que les sujets se comportent différemment selon leur sexe aux questions à choix multiple et aux questions ouvertes. En effet, à niveau de compétences égales, les filles obtiennent en règle générale de meilleurs résultats aux questions ouvertes et les garçons, de meilleurs résultats aux questions à choix multiple. Différentes hypothèses sont avancées pour expliquer cette différence :

1. les personnes de sexe masculin seraient plus enclines à recourir au choix au hasard ;
2. la question ouverte nécessite l'évaluation de la qualité de la réponse par un codeur selon des règles préétablies. Les personnes de sexe féminin auraient une meilleure écriture, une meilleure orthographe et le codeur, de par l'effet de halo, attribuerait de meilleures notes aux filles.

3.2.4.3. Le contenu de l'item

Nul ne peut contester les différences d'intérêts, de loisirs selon le sexe du sujet, son lieu de résidence (milieu rural *versus* milieu urbain), sa nationalité, le niveau d'éducation de ses parents... Il s'ensuit que certains contenus peuvent paraître plus familiers à certains qu'à d'autres, ce qui peut engendrer quelques modifications au niveau de la probabilité de réussite d'un item. Ainsi, dans le cadre d'une évaluation de la performance en lecture, un texte qui décrirait les mérites du métier d'agriculteur pourrait avantager les élèves vivant en milieu rural.

On observe par ailleurs régulièrement des interactions entre sous-domaines de la discipline évaluée et le sexe de l'étudiant. Ainsi, comme l'indique le tableau 3.6. au départ de la base de données PISA 2003, les garçons ont des performances nettement plus

élevées pour les concepts géométriques alors qu'ils surpassent légèrement leurs condisciples féminines pour les concepts liés aux quantités. Le tableau 3.6 présente la moyenne des différences filles-garçons pour les pays de l'OCDE selon les quatre sous-disciplines mathématiques évaluées dans PISA.

Tableau 3.6. : Moyenne des différences filles-garçons par sous-disciplines mathématiques (PISA 2003).

Sous-disciplines mathématiques	Moyenne des différences
Quantité	6 (0.8)
Espace et formes	17 (0.9)
Variations et Relations	11 (0.9)
Incertitude	13 (0.8)

3.2.2.4. Les processus cognitifs évalués par l'item

Il importe de rester vigilant au comportement différentiel des items selon le processus cognitif sollicité par la question. Certaines caractéristiques telles que le sexe, l'origine sociale et culturelle de l'élève, peuvent affecter la probabilité de réussite à un item, après neutralisation du niveau moyen de performance. Ainsi, dans le cadre du *surveys* PISA 2000, la différence entre les filles et les garçons présente des variations importantes selon le processus cognitif : la différence la plus faible s'observe sur l'échelle *Retrouver des informations* et la différence la plus élevée, sur l'échelle *Réfléchir sur le contenu du texte*, comme l'indique le tableau 3.7.

Tableau 3.7. : Moyenne des différences de rendement entre filles et garçons en fonction du types de texte et en fonction du format de la question

	Retrouver des informations		Interpréter		Evaluer le contenu ou la forme du texte	
	QCM	Questions ouvertes	QCM	Questions ouvertes	QCM	Questions ouvertes
Moyenne des différences	19 (0.95)	29 (0.99)	29 (0.86)	35 (0.92)	32 (1.12)	47 (0.93)

3.2.4.5. Conclusion

Comme on peut le constater, l'importance relative que l'on accorde à tel type de questions plutôt qu'à tel autre type, à tel contenu plutôt qu'à tel autre, à tel processus plutôt qu'à tel autre, à telle présentation plutôt qu'à telle autre, risque de favoriser ou défavoriser tel groupe d'élèves. Le contenu du test peut donc influencer substantiellement certains indicateurs statistiques tels que les différences entre filles et garçons, entre élèves issus d'un milieu favorisé et les élèves issus d'un milieu défavorisé ...

Le cadre d'évaluation doit donc prévoir et envisager l'influence de ces différentes composantes et préciser la place respective à leur accorder. Si l'on veut mesurer la compréhension de textes continus, les différences entre les filles et les garçons ne seront pas considérées comme des biais, mais comme des comportements différentiels d'items logiques par rapport aux connaissances scientifiques actuelles. Par contre, si un test prétend mesurer la compréhension en lecture, et qu'il ne propose que des textes continus, les différences entre les garçons et les filles seront en partie biaisées par le choix des supports d'évaluation. D'où l'importance de la définition théorique préalable du cadre d'évaluation. Dans tous les cas cependant, seule une analyse des résultats au prétest permettra de confirmer ou d'infirmier l'existence de DIF ou de biais d'items.

3.3. Les items dans un questionnaire contextuel

Les questionnaires contextuels sont les instruments de mesure via lesquels on recueille par exemple des données sociodémographiques sur les élèves, et pour lesquels il est tout aussi important de disposer de mesures fiables, car bon nombre d'indicateurs sur l'efficacité ou l'équité d'un système éducatif utilisent les variables construites à partir de ces questionnaires.

3.3.1. Le format des questions

Les questionnaires contextuels, au même titre qu'un test de performance, constituent une mesure à part entière. Les différents types de questions définies dans le cadre du test de performance sont également d'application dans le cadre de ces questionnaires contextuels. Toutefois, à l'inverse des tests de performance, il n'y a pas de bonnes réponses ou de mauvaises réponses.

Les questions dichotomiques, du type « Vrai-Faux » par analogie au test de performance, proposent deux alternatives parmi lesquelles l'individu doit choisir. Les figures 3.6. et 3.7. proposent deux exemples de questions dichotomiques issues du questionnaire élèves PISA 2003.

Figure 3.6. : Exemple de question dichotomique du type « Oui-Non » [OCDE - PISA 2003]

Q17 À la maison, disposez-vous des choses suivantes ?

(<Cochez> toutes les cases qui conviennent).

Oui

a) Un bureau pour travailler ☐₁

b) Une chambre pour vous seul(e) ☐₁

c) Un endroit calme pour travailler ☐₁

d) Un ordinateur dont vous pouvez vous
servir pour votre travail scolaire ☐₁

Figure 3.7. : Exemple de question dichotomique [OCDE - PISA 2003]

Q3	Êtes-vous < une fille> ou <un garçon> ?	
	<i>Fille</i>	<i>Garçon</i>
	☐ ₁	☐ ₂

La question 17 du questionnaire élèves de PISA 2003 s'apparente à une question du type « Oui-Non », si ce n'est que l'élève n'a pas la possibilité de répondre par la négative. L'absence de réponse est donc assimilée à « Non ». Cette modalité de réponse occasionne toutefois un problème non négligeable, à savoir la confusion dans l'exemple repris dans la figure 3.6. entre « un élève qui ne dispose d'aucun des biens matériels proposés » et « l'élève qui refuse de répondre à la question ». Pour résoudre ce problème, il conviendrait soit d'offrir la possibilité à l'élève de répondre par la négative, soit d'ajouter un item du type « Je ne possède aucun de ces biens ».

Les questions dichotomiques peuvent également être utilisées pour filtrer les réponses. La figure 3.8. présente une question filtrante issue du questionnaire élèves PIRLS 2001.

Figure 3.8. : Exemple de question dichotomique filtrante [IEA - PIRLS 2001]

11 _____

Do you ever use a computer?
(Do not include Nintendo®, GameBoy®, or other TV/video game computers.)

Yes -- ☐ No -- ☐ *(If No, go to #12)*

If Yes...

11a. How often do you use a computer in each of these places?
Fill one circle for each line.

	Every day or almost every day	Once or twice a week	Once or twice a month	Never or almost never
a) I use a computer at home -----	☐	☐	☐	☐
b) I use a computer at school -----	☐	☐	☐	☐
c) I use a computer at some other place -----	☐	☐	☐	☐

Sans la question filtrante, les étudiants qui n'ont jamais utilisé d'ordinateur ne sauraient que répondre à la question 11a, ou les concepteurs seraient obligés d'ajouter une cinquième modalité de réponse, à savoir « Je n'ai jamais utilisé d'ordinateur ». L'élève devrait alors sélectionner cette modalité pour chacune des propositions, ce qui pourrait l'inciter, après une ou deux réponses, à passer à la question suivante et ainsi accroître le taux de non-réponse.

Les questions à choix multiple sont largement utilisées dans le cadre des questionnaires contextuels. La figure 3.9. présente un exemple de QCM issu du questionnaire PISA 2003.

Figure 3.9. : Exemple de question à choix multiple [OCDE - PISA 2003]

Q5	Quelle activité exerce actuellement votre mère ?
<i>(Ne <cochez> qu'une seule case).</i>	
a) Travail <rémunéré> à temps plein.	☐ ₁
b) Travail <rémunéré> à temps partiel.	☐ ₂
c) Ne travaille pas mais cherche un emploi.	☐ ₃
d) Autre (par ex. : femme au foyer, retraitée)	☐ ₄

Les catégories d'une QCM dans un questionnaire contextuel doivent être mutuellement exclusives et exhaustives. A une question relative à l'âge du sujet, les catégories :

1. Entre 10 et 20 ans.
2. Entre 20 et 30 ans.

ne sont pas mutuellement exclusives puisqu'une personne âgée de 20 ans pourrait tout aussi bien choisir la modalité 1 ou la modalité 2.

Les modalités suivantes pour le statut matrimonial d'un sujet ne sont pas exhaustives puisqu'une personne veuve ne pourra correctement décrire sa situation.

1. Célibataire.
2. Marié.
3. Divorcé ou séparé.

Pour assurer l'exhaustivité sans toutefois allonger indéfiniment la liste des modalités, il est d'usage de terminer la question en proposant la modalité « autre », comme dans le cas de la question présentée à la figure 3.9.

Parfois, la question s'apparente à une question à choix multiple, mais en réalité, il s'agit d'un ensemble d'items dichotomiques, comme dans le cadre de la figure 3.10. Dans ce cas, le concepteur n'oubliera pas de mentionner qu'il est possible de sélectionner plusieurs propositions.

Figure 3.10. : Exemple de QCM à plusieurs choix possibles [OCDE - PISA 2003]

Q11 Votre mère a-t-elle terminé les <niveaux d'études> suivants ?

(<Cochez> toutes les cases qui conviennent).

a) <Niveau CITE 3A> ☐₁

b) <Niveau CITE 3B, 3C> ☐₁

c) <Niveau CITE 2> ☐₁

d) <Niveau CITE 1> ☐₁

e) Aucun de ces <niveaux d'études> ☐₁

Certaines questions peuvent également demander au sujet de classer des éléments ou de choisir un nombre donné d'éléments parmi un ensemble plus grand.

Figure 3.11. : Exemple de classement à choix forcé

Classez les cours suivants par ordre de préférence
(1= cours le plus apprécié4= cours le moins apprécié)

Français MathématiquesEtude du milieuGymnastique

La liste ne doit pas être trop longue. Si tous les items doivent être classés, une liste de cinq items semble un maximum. Si plus de 5 éléments sont présentés au sujet, on peut demander de sélectionner 5 éléments selon un critère donné.

Les échelles d'évaluation constituent une autre catégorie de questions largement présente dans les questionnaires contextuels. Les modalités de réponse se situent sur une échelle ordinale et le répondant doit en choisir une pour chaque proposition. La plus connue des échelles d'évaluation est sans aucun doute l'échelle de Likert. La figure 3.12 en donne un exemple.

Figure 3.12. : Exemple d'échelle de Likert [OCDE - PISA 2003]

Q24 *Pensez à ce que vous avez appris à l'école :*

Dans quelle mesure êtes-vous d'accord avec les affirmations suivantes ?

(<Cochez> une seule case par ligne).

	<i>Tout à fait d'accord</i>	<i>D'accord</i>	<i>Pas d'accord</i>	<i>Pas du tout d'accord</i>
a) L'école n'a pas fait grand chose pour me préparer à la vie d'adulte.....	☐ ₁	☐ ₂	☐ ₃	☐ ₄
b) L'école a été une perte de temps.....	☐ ₁	☐ ₂	☐ ₃	☐ ₄
c) L'école a contribué à me donner confiance en moi pour prendre des décisions.....	☐ ₁	☐ ₂	☐ ₃	☐ ₄
d) L'école m'a appris des choses qui pourront m'être utiles dans mon futur travail.....	☐ ₁	☐ ₂	☐ ₃	☐ ₄

D'autres échelles ordinales peuvent également être utilisées. A titre d'exemples :

1. Degré d'importance :
 - a. Pas du tout important ;
 - b. Pas important ;
 - c. Important ;
 - d. Très important ;
2. Degré de fréquence :
 - a. A chaque cours ;
 - b. A la plupart des cours ;
 - c. A quelques cours ;
 - d. Jamais ou presque jamais ;
3. Degré de fréquence :
 - a. Moins d'une fois par mois ;
 - b. Une ou deux fois par mois ;
 - c. Une ou deux fois par semaine ;
 - d. Plus de deux fois par semaine ;
4. Degré d'assurance :
 - a. Pas du tout sûr(e) ;
 - b. Pas sûr(e) ;
 - c. Sûr(e) ;
 - d. Tout à fait sûr(e) ;

Le différentiateur sémantique d'Osgood est une variante d'échelle d'évaluation où l'on place deux adjectifs de sens contraire aux deux pôles de l'échelle. Un exemple est fourni à la figure 3.13. Si le différentiateur sémantique évite l'interprétation variable d'un sujet à l'autre de vocables tels que « tout à fait d'accord » ou « souvent », il n'échappe pas cependant à des variations de significations d'un répondant à l'autre, voire à des changements de réponse pour un individu donné selon l'échelle numérique adoptée.

Figure 3.13. : Exemple de différentiateur sémantique d'Osgood

Vous trouvez l'utilisation de manuels scolaires en classe:

inutile 1 2 3 4 5 6 7 utile

Les informations recueillies sous la forme d'une échelle de Likert ou par l'intermédiaire d'un différentiateur d'Osgood sont souvent synthétisées sous la forme d'un indice, soit en recourant à la théorie du score vrai, soit en utilisant un modèle de réponse à l'item. En d'autres termes, l'item a la valeur d'un indicateur d'un phénomène plus complexe que l'on ne peut mesurer directement. En effet, sur le plan théorique, il est plus logique de rechercher les relations entre ce phénomène plus complexe et la performance qu'entre l'item et la performance. Ainsi, la présence d'un lave-vaisselle est associée, dans un grand nombre de pays, avec un gain de performance. Ce n'est pas le lave-vaisselle en tant que tel qui permet d'améliorer la performance de l'étudiant mais bien l'aisance financière de la famille qu'il représente.

Enfin, les questions ouvertes sont parfois utilisées dans le cadre de questionnaires contextuels. Cependant, les concepteurs évitent autant que possible ce type de questions pour les raisons suivantes :

1. nécessité de codage, ce qui accroît considérablement les coûts d'enquêtes ;
2. introduction d'une source supplémentaire d'erreurs liées aux codeurs ;
3. risque d'accroître le pourcentage de données manquantes ;
4. délai supplémentaire nécessaire pour le codage.

La figure 3.14 présente un exemple de question ouverte qui ne nécessite aucun codage préalable à la saisie des données et la figure 3.15 un exemple qui nécessite un codage préalable.

Figure 3.14. : Exemple de question ouverte sans codage préalable

Q1a Quel <grade> fréquentez-vous ? _____ <grade>

Figure 3.15. : Exemple de question ouverte avec codage préalable

Q7 Quel est l'emploi principal de votre mère ? (Par ex., <enseignante, infirmière, directrice des ventes>) <i>(Si elle ne travaille pas actuellement, veuillez indiquer son dernier emploi principal).</i> Écrivez le <nom du métier> :
Q8 Que fait votre mère dans le cadre de son emploi principal ? (Par ex., <elle donne cours à des élèves, soigne des patients, dirige une équipe de vente>) <i>(En une phrase, indiquez en quoi consiste ou consistait son métier).</i> _____

3.3.2. Mise en forme des items

Les caractéristiques des items constituent une source d'erreurs de mesure parmi d'autres qui affectent les qualités psychométriques des mesures mais également la distribution des réponses, et par voie de conséquence, la distribution des mesures résultantes.

La méthodologie utilisée dans les travaux sur l'influence des caractéristiques des items est surtout expérimentale : on fait varier systématiquement une ou plusieurs caractéristiques des items proposés à des groupes différents de sujets et on examine les différences de réponse.

On distingue en général les dispositifs de présentation et les dispositifs de réponse.

3.3.2.1. Les dispositifs de présentation

En ce qui concerne les travaux portant sur les questionnaires, on s'est particulièrement intéressé à l'influence :

1. des caractéristiques sémantiques ;
2. des caractéristiques formelles des items, c'est-à-dire la longueur, la complexité (forme passive versus forme active) et la forme (interrogative, négative) ;
3. du contexte.

Ainsi, de très légers changements dans le choix des termes utilisés peuvent modifier le sens de l'item et, par conséquent, les réponses des sujets. Ainsi, Molenaar (1991) montre que lorsqu'on demande à des Américains s'ils pensent que les Etats-Unis doivent interdire les discours contre la démocratie, 21 % répondent positivement et 79 % répondent négativement. Lorsqu'on leur demande si les Etats-Unis doivent autoriser les discours contre la démocratie, 52 % acquiescent et 48 % refusent. Cet exemple sur l'asymétrie autorisation / interdiction démontre la sensibilité des caractéristiques sémantiques des items sur les résultats.

Pilotte et Gable (1990) ont montré que les sujets ont tendance à répondre en choisissant des catégories plutôt centrales lorsque les items sont formulés négativement. De plus, ils observent des indices de fidélité plus bas avec de tels items.

Différentes études ont également analysé l'influence de la longueur des items. Cependant, les résultats sont contradictoires : certaines études recommandent d'écrire des énoncés courts alors que d'autres recommandent des énoncés plus longs afin d'éliminer les sources d'ambiguïté.

3.3.2.2. Les dispositifs de réponse

Différents aspects doivent être pris en considération pour les questions fermées contextuelles ou dans un test de personnalité qui recourent aux échelles de Likert.

Combien d'échelons convient-il de retenir ? Selon Cox (1980), le nombre optimum se situe entre 5 et 9. En deçà ou au-delà, la fidélité de la mesure diminue.

Quel étiquetage adopter ? Faut-il privilégier les étiquettes numériques ou les étiquettes verbales ? Une étude de Schwarz & al. (1991) montre que lorsqu'on demande à un échantillon d'Américains d'évaluer le degré de réussite de leur vie, selon que l'échelle adoptée varie de 0 (pas du tout réussie) à 10 (tout à fait réussie) ou de -5 à + 5, les résultats varient considérablement. Dans le premier cas, 34 % des sujets interrogés choisissent une réponse de 0 à 5 alors qu'ils ne sont que 13 % à choisir une valeur comprise entre -5 et 0 dans le second cas.

Les étiquettes verbales ne sont pas sans problèmes. Ainsi, Pace et Friedlander (1981) montrent que, parmi les gens qui ont répondu *souvent* sur une échelle de fréquence (*jamais, occasionnellement, souvent et très souvent*), 41 % avaient eu l'activité en

question au moins une fois par semaine, 33 % une ou deux fois par semaine et 26 % moins d'une fois par semaine.

Le problème de la présence ou de l'absence d'une *réponse médiane*, problème qui se traduit aussi par le choix entre un nombre pair et un nombre impair de modalités de réponse, a suscité un grand nombre de recherches. Il ressort de ces études que l'absence d'une réponse médiane accroît le pourcentage de non-réponses. En effet, les personnes interrogées qui n'ont pas d'avis par rapport à la question posée préfèrent s'abstenir de répondre plutôt que de choisir une attitude favorable ou défavorable. Par ailleurs, il apparaît que la présence d'une catégorie médiane n'altère pas ou peu la distribution des autres réponses.

Convient-il, lorsque cela se justifie, d'insérer une modalité de réponse *je ne sais pas* ? Dans le cadre des *surveys* internationaux en sciences de l'éducation, un certain nombre de questions relatives à l'environnement familial sont posées aux élèves, les plus classiques étant le nombre de livres à la maison, le type de profession exercé par le père et la mère, le niveau de qualification des deux parents. Lors de la troisième étude internationale en mathématiques et en sciences de l'éducation (TIMSS 1995), la question relative au niveau d'éducation des parents comportait les catégories suivantes :

1. A fini l'université.
2. A fini l'enseignement secondaire mais n'a pas fini l'université.
3. A fini l'enseignement primaire mais n'a pas terminé l'enseignement secondaire.
4. Ne sais pas.

Les élèves de la Communauté française de Belgique qui ont choisi la modalité 1 obtiennent en mathématiques un score moyen de 557, ceux qui ont sélectionné la modalité 2 obtiennent un score moyen de 537, ceux qui ont choisi la modalité 3, un score moyen de 491 et ceux qui ne savent pas obtiennent en moyenne 501. Par ailleurs, quelque 27 % des élèves ne savent pas, ou du moins ont répondu qu'ils ne connaissaient pas, le niveau de qualification de leurs parents. Ces élèves auraient sans doute choisi au hasard une des trois autres catégories si cette modalité de réponse n'était pas présente, entraînant ainsi une réduction de la fidélité de la mesure et une réduction des différences de rendement entre les catégories.

3.3.2.3. *Recommandations générales*

Dans la rédaction des items d'un questionnaire, il convient d'éviter :

1. les questions « orientées » qui permettent au répondant d'anticiper la réponse attendue (désirabilité sociale) ;
2. les questions trop complexes, tant sur le plan du contenu que sur les plans syntaxique ou lexical. L'objectif est de recueillir des informations aussi précises que possible. Ce n'est pas un test de compréhension de lecture ;
3. les questions irritantes ou trop intrusives dans la vie du répondant ;
4. les ordres dans les consignes ;
5. les questions négatives et a fortiori, les doubles négations ;
6. le recours à trop de questions ouvertes ;

7. les questions ambiguës. A cet égard, éviter d'utiliser des termes comme « régulièrement », « parfois », « souvent » ;
8. les doubles questions.

Il est par ailleurs conseillé de commencer le questionnaire par des questions anodines, simples mais qui présentent néanmoins un certain intérêt pour encourager la participation, ou du moins pour éviter que le répondant ne développe une attitude négative. Les questions sensibles seront placées ultérieurement.

On conseille souvent de structurer le questionnaire comme suit :

1. commencer par le recueil d'informations factuelles (âge, sexe, ancienneté, profession...) ;
2. passer aux questions fermées ;
3. terminer par les questions ouvertes et personnalisées.

La mise en page revêt également une importante capitale. Le concepteur sera notamment vigilant à :

1. utiliser une taille de caractère raisonnable et à espacer les questions ;
2. fournir, en début de questionnaire, des consignes générales claires et précises, notamment en proposant des exemples de type de questions et comment y répondre ;
3. indiquer dans ces consignes, que l'anonymat sera respecté ;
4. répéter ces consignes aussi souvent que nécessaire, en utilisant une police de caractère différente ou en les mettant en gras, ou italique ;
5. numéroté les questions et les items au sein des questions ;
6. remercier à la fin du questionnaire le répondant pour sa participation.

On sera par ailleurs vigilant, lors de la conception et lors de l'interprétation des résultats, à certains phénomènes qui altèrent la qualité des réponses fournies, tels que la tendance à l'indécision, la tendance à l'acquiescement, la tendance à répondre au hasard, la tendance à la falsification, la tendance à privilégier la vitesse sur l'exactitude, etc. (Dickes et al., 1994, p. 94).

La désirabilité sociale ou *la tendance à la falsification* résulte de normes collectives relatives à certains traits ou certains comportements. Le sujet interrogé répond à une question non pas en fonction de sa personnalité ou de ses convictions mais en fonction de normes collectives. Ainsi, un sujet pourrait masquer certains comportements racistes ou des comportements d'intolérance simplement parce que nos sociétés occidentales, de par leur diversité culturelle et ethnique croissante, prônent de plus en plus des valeurs de tolérance. Des items trop explicites à cet égard n'apporteront donc aucune information.

La tendance à l'acquiescement consiste à répondre positivement à un item indépendamment de son contenu. Pour éviter ce biais, on peut inverser par exemple la moitié des items, soit en introduisant une négation, soit en reformulant la proposition (interdire *versus* autoriser par exemple). Ces deux solutions ne sont nullement idéales puisqu'une modification de la phrase ou l'introduction d'une négation peut soit modifier la distribution des réponses, soit les qualités psychométriques de l'outil de mesure.

Enfin, les réponses des élèves au questionnaire seront saisies pour être traitées par des logiciels d'analyse de données. Il importe d'automatiser autant que possible ce travail et de limiter le recours à la mémoire ou à l'interprétation auprès des personnes en charge de l'encodage. Il est vivement conseillé que les codes attribués aux modalités des différentes questions respectent l'ordre de lecture. Ainsi, pour l'essentiel des langues, on lit de gauche à droite et de haut en bas. Dès lors, le code attribué à gauche sera inférieur au code attribué à droite. De même, le code attribué en haut sera inférieur au code attribué à la modalité juste en dessous. On veillera enfin à commencer la numérotation par le même chiffre. Commencer par 0 à certaines questions et par 1 à d'autres est source d'erreur.

4. Des observations aux données : l'assemblage du test et le dispositif de collecte de données

4.1. L'assemblage du test

4.1.1. Introduction

Les tests d'intelligence, de personnalité ou les questionnaires d'opinions sont généralement conçus de telle sorte que l'ensemble des items sont administrés à tous les sujets.

Ce dispositif de collecte de données se justifie aisément car il permet, à toute personne qui administre le test, de calculer aisément le score de l'individu, souvent par une simple sommation, sans l'aide d'un matériel particulier, et de pouvoir ainsi l'interpréter en référence aux résultats de l'ensemble des sujets ayant passé le même test ou par rapport à une norme.

Ainsi, l'inventaire de dépression de Beck (IDB)⁹, dont l'objet est de quantifier l'intensité des sentiments dépressifs de personnes âgées de 13 à 80 ans, comporte dans sa version initiale 21 items qui possèdent tous 4 énoncés (5 dans la version française), comme l'illustre le tableau 4.1 qui présente les deux premiers items de l'IDB. Ces énoncés sont évalués sur une échelle graduée de 4 points (de 0 à 3). Les scores totaux peuvent donc varier de 0 à 63.

Tableau 4.1. : Consignes et deux exemples d'items de l'échelle de dépression IDB

Ceci est un questionnaire contenant plusieurs groupes de phrases. Pour chacun des groupes :	
1) Lisez attentivement toutes les phrases	
2) Placer un « X » dans la parenthèse à côté de la phrase qui décrit le mieux comment vous vous sentez dans le moment présent.	
Enoncés	Score
1. () Je ne me sens pas triste.	0
() Je me sens morose ou triste.	1
() Je suis morose ou triste tout le temps et je ne peux pas me remettre d'aplomb.	2
() Je suis tellement triste ou malheureux(se) que cela me fait mal.	2
() Je suis tellement triste ou malheureux(se) que je ne peux plus le supporter	3
2. () Je ne suis pas particulièrement pessimiste ou dérangé(e) à propos du futur.	0
() Je me sens découragé(e) à propos du futur.	1
() Je sens que je n'ai rien à attendre du futur.	2
() Je sens que je n'arriverai jamais à surmonter mes difficultés.	2
() Je sens que le futur est sans espoir et que les choses ne peuvent pas s'améliorer	3

L'administrateur de test peut, par simple sommation des réponses du sujet, calculer son score total et l'interpréter selon les normes suivantes :

⁹ Beck A.T., Ward C.H., Mendelson M. et al..1961. An inventory for measuring depression. *Archives of General Psychiatry*. 4, 561-571.

1. Un score compris entre 0 et 11 témoigne de l'absence de dépression ;
2. Un score de 12 à 19 révèle une dépression légère ;
3. Un score de 20 à 27 témoigne d'une dépression modérée ;
4. Un score supérieur à 27 sera considéré comme le témoin d'une dépression sévère.

Notez que l'IDB n'est pas un test diagnostique de la dépression mais un test de sévérité de la dépression.

Lemyre, Tessier et Fillion¹⁰ ont développé un test de mesure du stress psychologique (M.S.P.) dont le but est d'évaluer l'intensité de l'expérience subjective de se sentir stressé. Ce test comporte 49 items répartis en 3 types d'indicateurs : (i) cognitivo-affectifs, (ii) somatiques et (iii) comportementaux.

Les auteurs ont décidé d'opter pour une échelle de Likert à 8 modalités, comme l'indique la figure 4.1, extraite du manuel du test.

Figure 4.1. Exemple d'items du test M.S.P.

M.S.P.-49							
— Après <i>CHAQUE</i> item, <i>ENCERCLEZ</i> le chiffre de 1 à 8 en indiquant jusqu'à quel degré l'item vous décrit bien <i>dernièrement</i> , c'est-à-dire depuis les 4 ou 5 derniers jours.							
— Les chiffres de 1 à 8 signifient:							
1	2	3	4	5	6	7	8
pas du tout	pas vraiment	très peu	un peu	plutôt oui	passablement	beaucoup	énormément
DERNIÈREMENT, C'EST-À-DIRE EN PENSANT AUX 4 OU 5 DERNIERS JOURS:							
1. Je suis tendu-e ou crispé-e.	1	2	3	4	5	6	7 8
2. Je me sens la gorge serrée ou j'ai la bouche sèche.	1	2	3	4	5	6	7 8
3. Je me sens pressé-e par le temps, coincé-e par le temps, je manque de temps.	1	2	3	4	5	6	7 8

Le score brut d'un individu s'obtient par simple sommation de ses réponses. Les scores varient donc de 49 à 392. La figure 4.2. présente les normes de la M.S.P. 49. Cette table donne, pour chaque score brut, l'équivalent en score T et en centile. Il est donc aisé de situer un individu comparativement à la population.

¹⁰ (http://www.gapsante.uottawa.ca/English/hyperlinks_English/M.S.P.%20ManuelFR.pdf).

Figure 4.2. Normes de la M.S.P. 49.

MSP	CENTILE	SCORE T	MSP (suite)	CENTILE	SCORE T
≤ 68	1	≤ 35	138	51	48.6
69-72	2	35.5	139	52	48.8
73-74	3	36	140-141	53	49
75-76	4	36.5	142	54	49.3
77-78	5	37	143-144	55	49.6
79-80	6	37.5	145-146	56	50
81-82	7	37.7	147	57	50.3
83-84	8	38	148	58	50.5
85	9	38.5	149	59	50.7
86-88	10	39	150-151	60	51
89-90	11	39.3	152-153	61	51.3
91	12	39.5	154-155	62	51.7
92	13	39.7	156	63	52
93	14	39.9	157	64	52.2
94	15	40	158-159	65	52.5
95	16	40.3	160	66	52.8
96-97	17	40.5	161-162	67	53
98	18	40.9	163	68	53.4
99-100	19	41	164-165	69	53.6
101	20	41.5	166-167	70	54
103-104	22	42	168-169	71	54.5
105-106	23	42.3	170-171	72	54.8
107	24	42.6	172	73	55
108	25	42.8	173-174	74	55.5
109	26	43	175-177	75	56
110-111	27	43.2	178-179	76	56.4
112	28	43.5	180-182	77	57
113	29	43.7	183	78	57.2
114	30	44	184-185	79	57.5
115	31	44.1	186-188	80	58
116	32	44.3	189-191	81	58.7
117	33	44.5	192-193	82	59
118	34	44.7	194-195	83	59.5
119-120	35	45	196-199	84	60
121	36	45.3	200-201	85	60.5
122	37	45.5	202-205	86	61
123	38	45.7	206-210	87	62
124	39	45.9	211-213	88	63
125	40	46	214-216	89	64
126	41	46.2	217-222	90	64.5
127	42	46.4	223-227	91	65
128	43	46.7	228-232	92	66.5
129-130	44	47	233-240	93	67.5
131	45	47.2	241-247	94	69
132	46	47.4	248-256	95	70.5
133	47	47.6	257-266	96	73
134	48	47.8	267-280	97	75
135	49	48	281-295	98	77
136-137	50	48.2	≥ 296	99	80

Ces deux exemples de test psychologique illustrent comment un administrateur de test peut aisément calculer le score d'un individu et l'interpréter immédiatement. Dans le cadre de l'IDB, aucune norme de population n'est fournie. L'interprétation se base sur des seuils, indépendamment de la distribution des scores d'une population de référence. Le second exemple illustre les tests normatifs pour lesquels un score individuel doit s'interpréter par rapport à la distribution des scores de la population.

4.1.2. Développement des *Test Designs* incomplets

Les études internationales en éducation telles que PISA sont conçues pour estimer non pas la performance d'un élève donné mais la performance d'une population d'élèves d'un âge donné ou fréquentant une année scolaire spécifique dans des domaines tels que les mathématiques, les sciences, la compréhension en lecture.

Pour qu'une étude puisse être considérée comme valide, il faut développer de nombreux items et les inclure dans les tests définitifs. Les publications de l'OCDE relatives aux cadres d'évaluation indiquent l'ampleur et le registre des domaines retenus par PISA, montrant que de nombreux items sont nécessaires pour pouvoir évaluer des concepts aussi larges que, par exemple, la culture mathématique.

Pourtant il ne serait pas raisonnable, voire peut-être indésirable, de faire passer à chaque élève échantillonné la batterie de test entière pour les raisons suivantes :

1. Après un certain temps consacré à répondre à un test, les élèves commencent à ressentir les effets de la fatigue et leurs résultats en souffrent, entraînant ainsi un certain biais dans les résultats de l'étude.
2. Les directeurs d'écoles auraient tendance à refuser la participation de leurs élèves à un test d'une très longue durée. Cela risquerait donc de réduire le taux de participation des écoles, ce qui à son tour pourrait entraîner certains biais dans les résultats.

Afin de pouvoir répondre à la fois à la demande d'un temps réduit de test et à une couverture suffisamment large des domaines d'évaluation, différentes formes parallèles du test sont développées de sorte que les personnes interrogées ne répondent qu'à un sous-ensemble de la batterie d'items. Cela signifie aussi que chaque item n'est passé que par un sous-ensemble d'élèves.

Lors de la première étude internationale en mathématiques de l'IEA (*First International Mathematics Study- FIMS 1965*), tous les élèves d'une population-cible donnée (c'est-à-dire une année d'études) devaient répondre à l'ensemble des questions. Cependant, comme l'indique le tableau 4.2, les questions développées pour les différentes populations-cibles ont été réparties en blocs de questions dont certains se retrouvaient dans plus d'une épreuve de rendement, autorisant ainsi des comparaisons entre les différentes populations-cibles (années d'études) concernées par l'étude.

Tableau 4.2 : Test Design de l'étude FIMS

		Test design
Population 1a	Elèves de 13 ans	1,2,3
Population 1b	Année d'étude qui comporte la majorité des élèves de 13 ans	3,4,5
Population 3a	Fin secondaire – spécialiste du domaine évalué	5,7,8,9
Population 3b	Fin secondaire – non spécialiste du domaine évalué	3,5,6

Ainsi, l'épreuve conçue pour les élèves de 13 ans comportait les blocs de questions 1, 2 et 3. Le bloc 3 est par ailleurs repris dans les épreuves de la population 1b et de la population 3b.

Une évolution importante apparut lors de la première étude internationale en sciences de l'IEA (*First International Science Study – FISS 1971*). “A problem affecting Population IV (pre-university students) produced an interesting solution. How could the achievement of science specialists (Population IVS) be compared with that of similar students receiving a more general education and being tested as Population IV? An answer was found by including in one of the two tests of Population IV six items from the corresponding IVS tests. Each Population IV student would therefore respond to six IVS items. But in order to gain more information over a wider range of subject matter and behavioral objectives, six sets of six questions were used in rotation so that for every group of six students, 36 items were used and data accumulated. These items are referred to as rotating items” (Comber & Keeves, 1973, p. 49)¹¹.

La seconde étude en sciences (*Second International Science Study SISS*) a accentué le recours aux items dits d'ancrage. Quatre formes dites parallèles ont été développées tant au niveau de la population-cible de l'enseignement primaire qu'au niveau de la population-cible de l'enseignement secondaire. Le tableau 4.3 reproduit le test design pour ces deux populations de référence.

Tableau 4.3 : Test Design de l'étude SISS

	Forme A	Forme B	Forme C	Forme F
Enseignement primaire	Core test : questions 1 à 24			
	25 à 32	32 à 40	41 à 48	49 à 56
Enseignement secondaire	Core test : questions 1 à 30			
	31 à 40	41 à 50	51 à 60	61 à 70

Les épreuves de rendement pour la population de l'enseignement primaire comportent au total 56 questions, dont 24 sont administrées à l'ensemble des élèves interrogés (cette partie est classiquement dénommée *Core Test*). Les 32 autres questions se répartissent dans les 4 formes parallèles. Comme on peut le constater, ce *test design* permet de mieux couvrir le domaine évalué (on dispose d'un total de 56 questions) tout en limitant le nombre de questions posées à chaque élève (à savoir 30 questions).

Les études internationales en sciences de l'éducation privilégient depuis environ une décennie les *Balanced Incomplete Bloc design* (BIB). Comme l'a écrit Johnson (1992)¹² *In a balanced bloc design, the subject area blocs are assigned to booklets in such a way that each bloc appears in the same number of booklets and every pair of blocs of a certain type appears together in at least one booklet. This is a balanced part of the method; the*

¹¹ Comber, L. C., & Keeves, J. P. (1973). *Science education in nineteen countries*. Stockholm: Almqvist & Wiksell, and New York: John Wiley & Sons.

¹² Johnson, E.G. (1992). The design of the National Assessment of Educational Progress. *Journal of Educational Measurement*. Vol 29 (2) pp. 95-110.

incomplete part refers to the fact that no booklet contains all items, and hence incomplete data is yielded for each assessed student.

Le tableau 4.4 présente un BIB *test design* à 7 livrets et à 3 positions par livret.

Tableau 4.4 : BIB à 7 livrets.

	Position 1	Position 2	Position 3
Livret 1	A	B	D
Livret 2	B	C	E
Livret 3	C	D	F
Livret 4	D	E	G
Livret 5	E	F	A
Livret 6	F	G	B
Livret 7	G	A	C

Pour répondre aux critères relatifs au concept de *design balancé*, chaque bloc de questions doit apparaître le même nombre de fois dans chaque position (afin d'annuler des phénomènes de biais de fatigue qui auraient lieu si par exemple un bloc n'apparaissait qu'en fin de test) et chaque paire de blocs doit apparaître le même nombre de fois.

Le *test design* repris dans le tableau 4.4 répond à la première condition, à savoir chaque bloc de questions apparaît le même nombre de fois (une seule fois dans le cas présent) dans chacune des 3 positions, à savoir en début de test, en milieu de test et en fin de test. Il répond également à la seconde condition puisque chaque paire de blocs apparaît une et une seule fois. En effet, (A, B) est présent dans le livret 1, (A, C) dans le livret 7, (A, D) dans le livret 1, (A, E) et (A, F) dans le livret 5 et enfin (A, G) dans le livret 7. Le même exercice peut être conduit pour les autres blocs.

Chaque sujet interrogé reçoit donc $\frac{3}{7}$ de l'ensemble du matériel d'évaluation. En d'autres termes, si l'on considère que la longueur d'un test passé par un élève est de 120 minutes, l'ensemble du matériel d'évaluation représente $120 \times \frac{7}{3}$, soit 280 minutes.

L'étude PISA 2003, PISA 2006 et PISA 2009 ont utilisé un *test design* semblable mais qui comporte 4 positions et 13 livrets. Le tableau 4.5 présente ce BIB à quatre positions.

Tableau 4.5 : BIB à 13 livrets.

	Position 1	Position 2	Position 3	Position 4
Livret 1	A	B	D	J
Livret 2	B	C	E	K
Livret 3	C	D	F	L
Livret 4	D	E	G	M
Livret 5	E	F	H	A
Livret 6	F	G	I	B
Livret 7	G	H	J	C
Livret 8	H	I	K	D
Livret 9	I	J	L	E
Livret 10	J	K	M	F
Livret 11	K	L	A	G
Livret 12	L	M	B	H
Livret 13	M	A	C	I

On peut vérifier que chaque bloc de questions apparaît une et une seule fois dans chacune des 4 positions et que chaque paire de blocs apparaît une et une seule fois.

Dans ce second *design*, chaque sujet interrogé reçoit 4/13 de l'ensemble du matériel d'évaluation. En d'autres termes, si l'on considère que la longueur d'un test est de 120 minutes, l'ensemble du matériel d'évaluation représente 390 minutes.

Grâce à ces *test designs*, les domaines évalués sont relativement bien couverts puisque l'ensemble du matériel peut facilement correspondre à quelque 300 minutes de *testing*, tout en maintenant un temps d'évaluation par sujet interrogé dans des normes acceptables, qui limitent les effets de la fatigue et qui ne mettent pas en péril la participation des écoles.

Le tableau 4.6 présente quant à lui un BIB design à 2 positions où chaque bloc apparaît deux fois et où chaque paire apparaît une et une seule fois.

Tableau 4.6 : BIB à 10 livrets et 2 positions

	Position 1	Position 2
Livret 1	A	B
Livret 2	B	C
Livret 3	C	D
Livret 4	D	E
Livret 5	E	A
Livret 6	A	C
Livret 7	B	D
Livret 8	C	E
Livret 9	D	A
Livret 10	E	B

Dans ce *test design*, chaque bloc de questions apparaît 2 fois dans chacune des positions et chaque paire de bloc apparaît une et une seule fois. Si l'on considère qu'un bloc représente 30 minutes de *testing*, l'ensemble du matériel de ce *test design* correspond à 150 minutes.

Comment peut-on savoir à priori s'il existe un *test design* pour lequel chaque bloc de questions apparaît le même nombre de fois et pour lequel chaque paire apparaît une et une seule fois ?

Prenons d'abord le *test design* représenté dans le tableau 4.4. Ce test design comporte 7 blocs de questions. Il existe donc au total $\frac{7*6}{2} = 21$ paires distinctes de blocs. Chaque livret comporte 3 blocs. Par livret, il y a donc 3 paires de blocs possibles. Il s'ensuit que chaque paire peut théoriquement être présente puisque 7 livrets à 3 paires par livret, cela représente 21 paires.

Le test design 4.5 comporte 13 blocs de questions. Par livret, il y a 6 paires possibles. Sur l'ensemble des 13 livrets, il y a donc 78 paires possibles, soit l'équivalent de ce qui est nécessaire.

Si l'on souhaite limiter davantage le temps de *testing* par élève dans le *design* 4.4, on peut par exemple adopter une solution semblable au *test design* 4.6. , à savoir 2 blocs par livret. Pour rappel, le *test design* requiert 21 paires de blocs. Sachant que chaque livret ne peut couvrir qu'une seule paire, il sera nécessaire d'avoir 21 livrets. Chacun des 7 blocs de questions apparaîtra donc 3 fois dans chacune des deux positions.

Tableau 4.7. BIB à 21 livrets et 2 positions

	Position 1	Position 2
Livret 1	A	B
Livret 2	B	C
Livret 3	C	D
Livret 4	D	E
Livret 5	E	F
Livret 6	F	G
Livret 7	G	A
Livret 8	A	C
Livret 9	B	D
Livret 10	C	E
Livret 11	D	F
Livret 12	E	G
Livret 13	F	A
Livret 14	G	B
Livret 15	A	D
Livret 16	B	E
Livret 17	C	F
Livret 18	D	G
Livret 19	E	A
Livret 20	F	B
Livret 21	G	C

Si le nombre de livrets ne constitue pas une contrainte dans le cadre de la recherche, il est probablement préférable de limiter le temps d'administration de l'épreuve afin d'éviter un effet de fatigue auprès des sujets interrogés, comme nous le verrons ultérieurement. Il faut toutefois noter que l'accroissement du nombre de livrets peut accentuer

considérablement les problèmes logistiques et par conséquent, générer des erreurs qui pourraient s'avérer irréversibles pour la qualité des données.

Enfin, il convient d'évoquer l'existence du *partial Balanced Incomplete Bloc design* (pBIB). Ces derniers *designs* n'exigent plus que toutes les paires de blocs soient représentées. Le tableau 4.8 présente un exemple de pBIB.

Tableau 4.8. : Partial Balanced Incomplete Bloc Design

	Position 1	Position 2		Position 1	Position 2
Livret 1	A	C	Livret 9	F	G
Livret 2	B	A	Livret 10	G	H
Livret 3	C	D	Livret 11	G	E
Livret 4	D	B	Livret 12	H	F
Livret 5	A	D	Livret 13	C	G
Livret 6	B	C	Livret 14	D	H
Livret 7	H	E	Livret 15	E	B
Livret 8	E	F	Livret 16	F	A

Chacun des 8 blocs de questions apparaît deux fois dans chacune des deux positions. Le tableau 4.9 présente les paires de blocs représentées dans ce *design*.

Tableau 4.9. : Paires de blocs présentes du design *Partial Balanced Incomplete Bloc Design*

Items	A	B	C	D	E	F	G	H
A								
B	1							
C	1	1						
D	1	1	1					
E	0	1	0	0				
F	1	0	0	0	1			
G	0	0	1	0	1	1		
H	0	0	0	1	1	1	1	

Ce schéma est particulièrement approprié lorsque deux sous-dimensions d'un domaine sont évaluées et que l'on souhaite calculer des scores par sous-dimension. Ainsi, on peut imaginer une évaluation en compréhension de l'écrit qui souhaiterait rapporter les résultats séparément pour les textes continus (supposons représentés par les blocs A, B, C et D) et les textes discontinus (représentés par les blocs E, F, G, H). Au sein d'une dimension, toutes les paires sont présentes et seulement quelques-unes des paires entre les deux sous-dimensions sont représentées. Notons que ce schéma pourrait très bien s'appliquer à une évaluation de deux dimensions, telles que les mathématiques et la compréhension de l'écrit.

Il est par ailleurs possible de concevoir des tests design avec *mesures répétées*. Ainsi, imaginez une recherche en sciences de l'éducation dont l'objectif serait de démontrer l'efficacité des cercles de lecture dans les classes de première année primaire. Les classes de l'échantillon sont réparties selon une procédure aléatoire entre groupe expérimental et groupe contrôle. Cinq évaluations du niveau de performance doivent être conduites au cours de l'année scolaire avec, comme impératifs que :

1. les résultats des groupes expérimental et contrôle puissent être comparés ;
2. les résultats des 5 évaluations soient situés sur une seule et même échelle, ce qui nécessite des items d'ancrage entre deux ou plusieurs tests ;
3. un item ne puisse être présenté qu'une seule fois à un même élève ;
4. les évaluations soient identiques au sein d'une classe afin de permettre à l'enseignant de donner des consignes orales.

Le tableau 4.10 présente le *test design* qui permet de répondre à ces exigences. Comme pour les précédents *test design*, chaque lettre représente un ensemble particulier de questions.

Tableau 4.10. *Test design* pour une étude longitudinale

	Test 1	Test 2	Test 3	Test 4	Test 5
Groupe expérimental	AB	DC	EF	HG	IJ
Groupe contrôle	AC	EB	DG	IF	HJ

Lors du test 1, le bloc de questions A permet de rapporter les résultats des deux groupes sur une seule et même échelle. Pour s'assurer que les résultats aux différentes épreuves soient rapportés sur la même échelle, un nouveau bloc distinct de questions est assigné à chacun des deux groupes, et pour l'évaluation suivante, il y a inversion de ces deux nouveaux blocs entre les deux groupes. Ainsi, le bloc B, spécifique au groupe expérimental lors du test 1, est assigné au groupe contrôle, lors du test 2. Ce procédé permet de maintenir le lien entre les deux groupes et de ne pas présenter plus d'une fois un item aux mêmes élèves.

4.1.3. Ecueils à éviter dans la conception d'un *test design*

4.1.3.1. Longueur des formes parallèles

Pour garantir que les différents livrets d'un *test design* (du type BIB ou pBIB à titre d'exemples) puissent être rapportés sur une seule et même échelle, il est préférable mais non obligatoire que chaque bloc de questions soit plus ou moins de la même difficulté moyenne. Mais il importe surtout de s'assurer qu'il nécessite un temps de passation identique.

L'étude PISA 2000 a ainsi été confrontée à ce que les responsables de l'étude ont appelé un *booklet effect*. Le tableau 4.11 présente le *test design* de cette étude. PISA évalue le niveau de performance des élèves de 15 ans dans les trois domaines suivants :

1. La compréhension de l'écrit ;
2. La culture mathématique ;
3. La culture scientifique.

L'enquête a lieu tous les trois ans depuis l'an 2000. Elle évalue à chaque fois les trois domaines, en mettant l'accent sur un domaine en particulier : la lecture en 2000, la

culture mathématique en 2003 et la culture scientifique en 2006. Lors de la dernière enquête, administrée dans les écoles secondaires au printemps 2009, c'est à nouveau la lecture qui a constitué le domaine majeur, deux tiers du temps d'évaluation lui étant dès lors consacrés.

Le tableau 4.11. présente le *test design* de l'étude de 2000.

Tableau 4.11 : Test design de PISA 2000.

	Position 1	Position 2	Position 3	Position 4
Livret 1	R1	R2	R4	M1-M2
Livret 2	R2	R3	R5	S1-S2
Livret 3	R3	R4	R6	M3-M4
Livret 4	R4	R5	R7	S3-S4
Livret 5	R5	R6	R1	M2-M3
Livret 6	R6	R7	R2	S2-S3
Livret 7	R7	R1	R3	R8
Livret 8	M4-M2	S1-S3	R8	R9
Livret 9	S4-S2	M1-M3	R9	R8

Le test design comprend 9 blocs de lecture de 30 minutes chacun, dénommés R1 à R9, 4 blocs de 15 minutes de mathématiques (M1 à M4) et de 4 blocs de 15 minutes de sciences (S1 à S4).

Ce *test design* n'est pas un BIB puisque les blocs de lecture R1 à R7 n'apparaissent jamais en position 4 et que les blocs R8 à R9 n'apparaissent qu'en troisième et dernière positions. De même, les items de sciences et de mathématiques apparaissent essentiellement en dernière position. Notons toutefois que les blocs R1 à R7 sont organisés selon un schéma BIB pour les 7 premiers livrets et les trois premières positions.

Chaque élève disposait de deux heures pour répondre à l'ensemble des questions, avec une pause après 1 heure. Cependant, après la pause, l'étudiant n'était pas autorisé à revenir sur les questions de la première partie du test (à savoir les items des positions 1 et 2).

Un item sans réponse suivi d'un item avec réponse témoigne l'impossibilité pour l'élève d'y répondre et sera donc considéré comme réponse incorrecte (une omission a donc le même statut qu'une réponse fausse). Par contre, les items sans réponse *à la fin du test* reflètent que l'élève n'a pas eu le temps d'y répondre. Lorsqu'un élève ne répond pas aux derniers items d'un test, on considère généralement que ces items n'ont pas été atteints par l'élève (d'où leur appellation d'items non atteints, en anglais *non reached items*). Ils seront considérés comme items non atteints. Considérer les items non atteints comme réponse incorrecte conduirait à estimer les items plus difficiles qu'ils ne sont réellement. C'est pour cette raison qu'ils ne sont pas pris en considération pour le calcul de la difficulté des items.

Par contre, il est d'usage de les considérer comme réponse incorrecte lors du calcul du score de l'élève.

Lors de PISA 2000, puisque les élèves n'étaient pas autorisés à retravailler la première partie après la pause, les derniers items non répondus par les élèves ont donc été recodés en items non atteints. Le tableau 4.12 présente la distribution du pourcentage d'élèves en fonction du nombre d'items non atteints pour la première partie et pour la deuxième partie.

Tableau 4.12 : Distribution des élèves en fonction du nombre d'items non atteints – PISA2000

Nombre d'items non atteints	Livret 1	Livret 2	Livret 3	Livret 4	Livret 5	Livret 6	Livret 7	Livret 8	Livret 9
Session 1									
0	86.7	95.1	87.4	70.9	79.5	85.9	83.7	81.9	84.1
1	2.7	0.3	0.7	3.0	1.2	1.0	2.7	3.9	3.4
2	2.3	0.9	1.6	4.8	1.6	0.8	3.9	1.3	1.0
3	2.2	0.3	3.9	3.3	4.4	1.7	2.5	0.9	1.8
4	1.1	0.7	0.2	2.7	1.0	4.7	0.4	1.8	1.4
5	2.2	0.4	0.9	3.8	0.5	1.6	0.5	0.7	2.3
6	0.2	1.8	0.4	1.5	1.0	0.6	0.4	0.8	1.5
>6	2.6	0.5	4.9	10.0	10.8	3.7	5.9	8.7	4.5
Session 2									
0	76.2	78.7	89.6	85.4	87.3	95.1	91.8	86.9	79.6
1	3.9	12.3	3.1	1.6	3.0	1.4	2.2	1.0	4.2
2	2.9	0.9	2.0	1.9	0.9	0.4	1.1	1.1	2.4
3	6.9	0.6	1.3	2.3	1.5	0.2	0.6	1.0	1.4
4	1.5	1.4	0.5	1.2	1.0	0.5	1.1	1.5	2.8
5	0.7	0.5	0.3	0.7	1.9	0.2	1.0	0.6	3.1
6	3.7	0.4	0.3	0.5	1.3	0.3	0.5	1.4	1.2
>6	4.2	5.2	2.9	6.4	3.1	1.9	1.7	6.5	5.3

Ainsi, au terme de la session 1, quelque 10% d'élèves qui ont reçu le livret 4 ou le livret 5 ont au moins 6 items non atteints, alors qu'ils sont moins de 1% pour le livret 2. De telles différences s'observent également pour la seconde session. Ainsi plus de 95% des élèves ayant le livret 6 ne présentent aucun item non atteint, alors qu'ils sont moins de 80% pour les livrets 1, 2 et 9. Ces différences indiquent que les différents livrets étaient de longueur variable.

Afin d'étudier l'impact de ces taux variables d'élèves avec des items non atteints, les résultats des élèves ont été standardisés (moyenne de 10 et écart type de 2) par pays. La figure 4.3., extraite du rapport technique PISA 2000¹³, présente, par pays et par livret, le score moyen des élèves.

¹³ Adams, R., & Wu, M. (2002). *PISA 2000 Technical report*. Paris : OECD.

Figure 4.3. Performance moyenne en lecture, par pays et par livret

Booklet									Mean
1	2	3	4	5	6	7	8	9	
10.07	10.43	10.15	9.63	10.04	10.32	9.99	9.64	9.73	10.00
10.48	10.18	10.09	9.64	10.02	9.95	9.84	9.68	10.13	10.00
10.05	10.24	10.13	9.72	10.08	10.11	9.96	9.88	9.87	10.00
9.89	10.22	10.22	9.73	10.04	10.14	10.22	9.80	9.74	10.00
10.13	10.41	10.12	9.75	10.01	10.17	9.89	9.73	9.78	10.00
9.95	10.22	10.01	9.88	9.89	10.15	10.06	9.87	9.97	10.00
10.06	10.44	10.11	9.66	9.98	10.27	9.91	9.53	10.03	10.00
9.85	10.26	10.21	9.96	10.13	10.11	10.07	9.70	9.71	10.00
9.98	10.38	10.14	9.81	10.09	10.05	9.98	9.71	9.88	10.00
10.18	10.38	10.08	9.82	10.03	10.01	10.14	9.83	9.96	10.00
10.07	10.07	10.17	9.84	10.11	10.23	9.96	9.81	9.96	10.00
10.15	10.31	10.21	9.79	9.99	10.09	10.13	9.52	9.81	10.00
10.26	10.36	10.26	9.86	9.90	10.03	9.77	9.75	9.82	10.00
9.98	10.44	9.94	9.65	9.98	10.13	10.10	9.90	9.89	10.00
10.23	10.21	9.99	9.78	9.89	10.20	9.75	9.92	10.02	10.00
10.07	10.39	10.13	9.83	9.86	10.20	9.94	9.84	9.70	10.00
10.13	10.23	10.03	9.82	9.92	10.07	10.02	9.80	9.97	10.00
9.98	10.16	10.00	9.78	10.00	10.25	9.97	10.35	10.42	10.00
10.10	10.31	10.10	9.72	9.99	10.07	9.93	9.77	10.00	10.00
10.01	10.34	10.14	9.88	10.06	10.00	9.96	9.66	9.93	10.00
10.25	10.47	9.87	9.64	9.80	10.18	9.94	9.95	9.91	10.00
10.09	10.46	10.08	9.61	9.99	10.08	9.98	9.71	10.00	10.00
10.35	10.70	10.38	10.07	10.13	10.50	10.39	10.20	10.33	10.00
10.20	10.45	10.21	9.78	10.10	10.25	10.04	10.00	10.11	10.00
10.24	10.58	10.07	9.63	9.94	9.99	9.92	9.51	10.14	10.00
10.00	10.50	10.00	9.80	9.99	10.20	9.95	9.84	9.69	10.00
10.21	10.51	10.00	9.67	10.01	10.01	10.09	9.71	9.81	10.00
10.23	10.42	10.14	9.61	9.98	10.21	10.03	9.56	9.95	10.00
9.96	10.29	10.22	9.79	10.00	10.17	10.04	9.68	9.87	10.00
10.07	10.39	10.24	9.78	10.04	10.28	10.08	9.68	10.09	10.00
9.99	10.29	10.12	9.82	9.93	10.15	9.98	9.89	9.82	10.00
10.12	10.33	10.08	9.92	10.15	10.19	9.85	9.70	9.84	10.00
10.06	10.42	10.16	9.87	10.05	10.27	10.04	9.82	9.66	10.00
10.10	10.36	10.11	9.77	10.00	10.14	9.99	9.78	9.94	10.00
10.11	10.34	10.11	9.78	10.01	10.15	9.99	9.78	9.90	

Alors que l'on devrait s'attendre à des moyennes par livret proches de 10.00, on constate que les élèves qui ont reçu le livret 2 obtiennent des résultats sensiblement meilleurs que leurs condisciples. Inversement, les élèves qui ont reçu le livret 4, tout comme ceux ayant reçu le livret 8, semblent désavantagés puisque dans tous les pays, à quelques exceptions près, la performance moyenne de ces élèves est toujours inférieure à 10.

D'aucuns pourraient incriminer le *test design* non balancé de PISA 2000. Mais malgré l'adoption d'un *test design* balancé (semblable au test design présenté dans le tableau 4.5) lors de PISA 2003 et PISA 2006, de tels *booklets effects* ont encore été observés.

4.1.3.2. Effet de fatigue

Après une heure de test, la performance d'un élève régresse en raison d'un effet de la fatigue et/ou d'une réduction son attention.

Le tableau 4.13 présente le test design de PISA 2003.

Tableau 4.13 : Test design de PISA 2003.

	Position 1	Position 2	Position 3	Position 4
Livret 1	M1	M2	M4	S1
Livret 2	M2	M3	M5	S2
Livret 3	M3	M4	M6	P1
Livret 4	M4	M5	M7	P2
Livret 5	M5	M6	R1	M1
Livret 6	M6	M7	R2	M2
Livret 7	M7	R1	S1	M3
Livret 8	R1	R2	S2	M4
Livret 9	R2	S1	P1	M5
Livret 10	S1	S2	P2	M6
Livret 11	S2	P1	M1	M7
Livret 12	P1	P2	M2	R1
Livret 13	P2	M1	M3	R2

Ce *test design* comporte 13 livrets, 7 blocs de mathématiques, 2 blocs de compréhension à la lecture, 2 blocs de sciences et 2 blocs de résolution de problèmes.

Le tableau 4.14 présente la moyenne et l'écart type du nombre de bonnes réponses pour le bloc M5, par position pour les élèves belges **ayant fournis une réponse à toutes les questions**.


Tableau 4.14 moyenne et écart type du nombre de bonnes réponses au bloc m5 PISA 2003.

	Position 1	Position 2	Position 3	Position 4
Livret	Livret 5	Livret 4	Livret 2	Livret 9
Moyenne	8.65	8.70	8.30	7.29
Ecart type	3.27	3.45	3.56	4.10

Comme on peut le constater sur l'échantillon belge de PISA 2003, au fur et à mesure que les élèves avancent dans le test, la moyenne des bonnes réponses diminue et l'écart type augmente.

Cet effet de fatigue peut avoir des effets cumulatifs si le *test design* n'est pas bien conçu. Pour démontrer cet effet cumulatif, des données ont été simulées selon le *test design* repris dans la figure 4.4.

Figure 4.4. Test design pour étudier l'effet de fatigue



Chaque bloc de questions a été conçu pour avoir une difficulté initiale en moyenne parfaitement égale. Le livret 1 comporte les questions 1 à 20, le livret 2 ; de 11 à 30 et ainsi de suite, comme illustré dans la figure 4.4.

La probabilité de réussite d'un sujet à une question donnée se voit réduite de 0.05 lorsque la question appartient au second bloc du test. Ainsi, la probabilité de réussite des items 11 à 20 a été réduite 0.05 pour tous les sujets ayant reçu le livret 1. De même, la probabilité de réussite des items 21 à 30 a été réduite 0.05 pour tous les sujets ayant reçu le livret 2.

Les données ont ensuite été calibrées avec un modèle de réponses à l'item (cfr chapitre 6) en prenant en considération dans un premier temps les 7 premiers livrets, dans un second temps, les six premiers livrets seulement. Le tableau 4.15 présente le changement de score moyen pour la calibration à 7 livrets et la calibration à 6 livrets.

Tableau 4.15 Changement dans le score moyen

	Différence de performances moyennes
Livret 1	-0.23
Livret 2	-0.07
Livret 3	-0.02
Livret 4	+0.02
Livret 5	+0.08
Livret 6	+0.30

Les sujets qui ont dû répondre au livret 1 obtiennent en moyenne de moins bons résultats que les sujets ayant dû répondre aux autres livrets. On peut comprendre le phénomène de la manière suivante : le lien entre le livret 1 et le livret 2 est assuré par le bloc de questions B. Puisque le taux moyen de réussite a été diminué de 5 pour cent pour le bloc B du livret 1, les élèves qui ont répondu à ce livret apparaissent, aux yeux du modèle, moins performants que les élèves qui ont répondu au livret 2. Le score attribué aux élèves doit donc refléter cette différence.

Ce phénomène se poursuit avec les livrets suivants et les effets se cumulent dès lors puisque les élèves du livret 3, de par le lien établi par le bloc C, apparaissent plus performants que les élèves du livret 2. L'existence du livret 7, au-delà de sa nécessité pour obtenir un *design balancé*, permet de neutraliser cet effet cumulatif. En effet, ces élèves répondent au bloc A en second lieu et leur réussite moyenne est donc inférieure à la réussite moyenne du bloc A dans le livret 1.

Ces changements témoignent de l'importance d'un *test design* balancé pour neutraliser les effets de fatigue.

Cet effet de fatigue peut également générer un biais dans les études à mesures répétées, qu'il s'agisse d'une étude de suivi d'élèves ou d'une étude internationale dont l'objectif est de produire des indicateurs de tendance.

Le *test design* pour l'étude longitudinale repris dans le tableau 4.10 contrôle le biais dû à l'effet de fatigue. En effet, un bloc repris dans plus d'un test est toujours situé, soit en première position, soit en deuxième position. Ainsi, le bloc C apparaît en deuxième position dans le test 1 et dans le test 2. Le placer en position 1 lors du test 1 et le placer en position 2 lors du second test conduirait à une sous-estimation des progrès. Inversement, le placer en position 2 lors du test 1 et en position 1 lors d'un test ultérieur conduirait à une surestimation des progrès.

La comparaison des *test design* de PISA 2000 et de PISA 2003 interpellent. En effet, les deux blocs (R1 et R2) du test de PISA 2003 (tableau 4.13) sont composés de questions issues uniquement des blocs R1 à R7 du test de PISA 2000 (tableau 4.11). En d'autres termes, le matériel d'ancrage en lecture en 2000 se situait en position 1 à 3 alors que ce même matériel occupe les 4 positions en 2003. Il s'ensuit que les données de 2003

devraient être affectées davantage par l'effet de fatigue que les données de 2000. Inversement, le matériel de mathématiques et de sciences se situe principalement en position 4. L'effet de fatigue devrait donc influencer davantage les données de 2000. Le tableau 4.16 synthétise les changements significatifs entre 2000 et 2003. Sur les 32 pays pour lesquels une comparaison entre 2000 et 2003 est possible, 15 pays présentent un changement significatif pour le sous-domaine mathématique « *Changements et relations* », dont 14 améliorations et 1 déclin. Un tel profil est également observé pour le sous-domaine mathématique « *Espace et Forme* » et pour les sciences. Par contre, en compréhension de la lecture, on observe davantage de déclin significatifs que d'améliorations significatives. Ces résultats confirment les prédictions.

Tableau 4.16 : Nombre de pays avec changement significatif de performances entre 2000 et 2003

Domaine	Amélioration significative	Déclin significatif
Mathématiques: Changements et relations	14	1
Mathématiques: Espace et forme	11	3
Sciences	13	5
Compréhension de l'écrit	5	9

4.2. Le dispositif de collecte de données

Comme le définit Pichot (1968, p. 5)¹⁴, « Un test, c'est une situation standardisée servant de stimulus à un comportement. Ce comportement est évalué par comparaison avec celui d'individus placés dans la même situation, afin de classer le sujet, soit quantitativement, soit typologiquement ». On dit d'un test qu'il est standardisé lorsque les conditions d'administration et de correction sont uniformisées.

Une modification des conditions de passation risque d'invalider les résultats. Les tests psychométriques devraient donc en principe toujours contenir une section qui décrit les conditions d'administration de l'épreuve.

Globalement, un test peut s'administrer de manière individuelle ou de manière collective. L'administrateur doit :

1. s'assurer que les participants comprennent les consignes ;
2. distribuer le matériel ;
3. respecter les limites de temps ;
4. recueillir les réponses des participants.

¹⁴ Pichot, P. (1968). *Les tests mentaux*. Paris : Presses Universitaires de France.

La figure 4.5 présente la table des matières du manuel de l'administrateur de test de PISA 2003.

Figure 4.5. Table des matières du manuel de l'administrateur de test de PISA 2003.

1. INTRODUCTION.....	5
1.1 LE PROGRAMME INTERNATIONAL DE L'OCDE POUR LE SUIVI DES ACQUIS DES ÉLÈVES (PISA)	5
1.2 LE RÔLE DE L'ADMINISTRATEUR DE TEST (AT)	5
1.3 LISTE DE CONTRÔLE DES ACTIVITÉS	7
2. PRÉPARER L'ÉVALUATION.....	8
2.1 SUIVRE LA FORMATION DESTINÉE AUX ADMINISTRATEURS DE TEST PISA.....	8
2.2 TRAVAILLER AVEC LE COORDINATEUR SCOLAIRE	8
2.3 RECEVOIR LE MATÉRIEL DE TEST ET LE METTRE EN LIEU SÛR.....	9
2.4 METTRE À JOUR LE FORMULAIRE DE SUIVI DES ÉLÈVES (STF)	10
2.5 PROGRAMMES D'ÉTUDES : COLONNE 7 DU <i>STF</i>	11
2.6 BESOINS ÉDUCATIFS SPÉCIFIQUES ET INCLUSION : COLONNES 8 ET 9 DU <i>STF</i>	11
2.7 PRÉVOIR L'AIDE D'UN ASSISTANT (FACULTATIF).....	13
2.8 CONFIRMER AVEC LE CS LA DATE, L'HEURE ET LES AUTRES ASPECTS LOGISTIQUES DU TEST	13
3. CONDUIRE LA SÉANCE D'ÉVALUATION.....	14
3.1 À VOTRE ARRIVÉE, LE JOUR DE L'ÉVALUATION	14
3.2 PRÉPARER LES CARNETS DE TEST À DISTRIBUER AUX ÉLÈVES	14
3.3 DISTRIBUER LE MATÉRIEL DE TEST AUX ÉLÈVES	15
3.4 CHRONOMÉTRER LES SÉANCES D'ÉVALUATION.....	15
3.5 LIRE LES CONSIGNES FIGURANT DANS LE « SCRIPT »	16
3.6 SUPERVISER LA SÉANCE.....	16
3.7 CLÔTURER LA SÉANCE	17
4. TERMINER LES ACTIVITÉS RELATIVES À L'ÉVALUATION.....	18
4.1 CONSIGNER LE STATUT DE PARTICIPATION / NON-PARTICIPATION DES ÉLÈVES SUR LE <i>FORMULAIRE DE SUIVI DES ÉLÈVES</i>	18
4.2 DÉTERMINER SI UNE SÉANCE DE RATTRAPAGE EST NÉCESSAIRE.....	18
4.3 COMPLÉTER LE FORMULAIRE DE <i>RAPPORT DE SÉANCE DE TEST</i>	19
4.4 RÉCUPÉRER LE QUESTIONNAIRE ÉTABLISSEMENT	19
4.5 EMBALLER ET RÉEXPÉDIER LE MATÉRIEL DE TEST.....	19
ANNEXE 1. « SCRIPT » POUR L'ADMINISTRATION DU TEST, À LIRE LORS DES SÉANCES D'ÉVALUATION.....	21
ANNEXE 2. FORMULAIRE OCDE/PISA DE RAPPORT DE SÉANCE.....	35
ANNEXE 3. FORMULAIRE DE RÉEXPÉDITION.....	39
ANNEXE 4. NOTES EXPLICATIVES SUR LES QUESTIONS DU QUESTIONNAIRE ÉLÈVE.....	41
ANNEXE 5. EXEMPLE DE <i>FORMULAIRE DE SUIVI DES ÉLÈVES</i> AVEC LES COLONNES 8 (« BES ») ET 9 (« INCLUSION ») REMPLIES.....	49
ANNEXE 6. EXEMPLE DE <i>FORMULAIRE DE SUIVI DES ÉLÈVES</i> AVEC LES COLONNES 11 ET 12 (« STATUT DE PARTICIPATION ») REMPLIES	53

Ce manuel décrit dans les moindres détails les différentes activités que l'administrateur doit entreprendre. Ces activités sont regroupées en 3 grandes catégories : préparer la séance, conduire la séance et terminer les activités relatives à la séance. Le script d'une quinzaine de pages fournit le texte que l'administrateur doit lire, sans suppression ou sans ajout, aux différents moments de l'administration (soit au cours des 3 heures que dure le test).

Ce manuel, dont la version originale est développée en anglais, est traduit dans la (les) langue(s) nationale(s) des différents pays participants et ces différentes traductions sont ensuite vérifiées pour s'assurer que les pays, par mégarde, n'ont pas omis certains passages.

Des consignes très strictes sont également fournies aux pays en ce qui concerne les personnes qui peuvent assurer cette fonction. Dans le cadre de PISA, on peut lire dans le manuel de l'administrateur de test (AT) :

En tant qu'administrateurs de test pour un ou plusieurs établissements de l'échantillon PISA, vous assumez un rôle essentiel dans le bon déroulement de l'étude. PISA a établi les critères suivants pour les Administrateurs de Test (AT) :

1. Il est exigé que l'Administrateur de Test ne soit pas un des professeurs chargés du cours de langue maternelle, de mathématiques ou de sciences de l'un des élèves auxquels il / elle fera passer le test.
2. Il est recommandé que l'Administrateur de Test ne soit pas un des membres du personnel d'une des écoles où il / elle administrera le test.
3. Il est préférable que l'Administrateur de Test ne soit pas membre du personnel d'une des écoles de l'échantillon PISA.

En d'autres termes, l'administrateur de test peut soit être membre du personnel de l'école, soit un membre extérieur.

Ces différentes consignes d'administration, largement détaillées dans le cadre d'un *surveys* international en sciences de l'éducation, ont pour seul objectif d'assurer la comparabilité des résultats.

Dans le cadre de l'administration d'un test psychologique, les consignes d'administration ont pour objectif essentiel de maintenir la validité des normes. En effet, le résultat d'un test normatif n'a de sens que par rapport à la population de référence. En soi, un QI de 115 ne signifie strictement rien. Il prend son sens si l'on sait qu'il se situe à + 1 écart type, et qu'en raison de la normalité des QI, on peut en déduire que 84 % de la population ont un QI inférieur à 115 et seulement 16 % un QI supérieur.

Changer les conditions d'administration n'autorise plus à situer la performance d'un individu par rapport à cette distribution normale de moyenne 100 et d'écart type 15. En effet, si un sujet dispose en principe de deux heures pour compléter un test d'intelligence et que par négligence, un psychologue lui accorde 15 minutes supplémentaires, les normes ne sont plus correctes.

5. La théorie classique du score vrai¹⁵

Comme l'indiquent Dickes & al. (p. 165), dans leur ouvrage intitulé *La psychométrie*, la théorie classique du score vrai propose un modèle qui sert essentiellement à estimer la fidélité. « *On considère qu'un instrument de mesure est fidèle si le résultat qu'il produit est reproductible. En d'autres termes, si on applique le même instrument (ou des versions comparables de cet instrument) à une personne plusieurs fois de suite, cette personne doit être caractérisée par le même score. On s'intéresse donc à la précision avec laquelle une caractéristique psychologique est mesurée.* ».

Mais qu'entend-on par score dans la théorie classique du score vrai ?

5.1. Définition du score observé

Comme nous l'avons indiqué dans le chapitre 4, les tests d'intelligence, de personnalité ou les questionnaires d'opinions sont généralement conçus de telle sorte que l'ensemble des items sont administrés à tous les sujets. Ce dispositif de collecte de données se justifie aisément car il permet, à toute personne qui administre le test, de calculer aisément le score de l'individu, souvent par une simple sommation, sans l'aide d'un matériel particulier, et de pouvoir ainsi l'interpréter en référence aux résultats de l'ensemble des sujets ayant passé le même test ou par rapport à une norme.

Dans le modèle de la théorie classique du score vrai, un score attribué à un sujet correspond à la somme des scores obtenus à chacun des items qui composent le test.

Tableau 5.1 : matrice de donnée

	<i>It_1</i>	<i>It_2</i>	<i>It_3</i>	<i>It_4</i>	<i>It_5</i>	<i>It_6</i>	<i>It_7</i>	<i>It_8</i>	<i>It_9</i>	<i>It_10</i>	<i>Total</i>
<i>Sujet 1</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 2</i>	1	0	0	0	0	0	0	0	0	0	1
<i>Sujet 3</i>	1	1	0	0	0	0	0	0	0	0	2
<i>Sujet 4</i>	1	1	1	0	0	0	0	0	0	0	3
<i>Sujet 5</i>	1	1	1	0	1	0	0	0	0	0	4
<i>Sujet 6</i>	1	1	1	1	1	0	0	0	0	0	5
<i>Sujet 7</i>	1	1	1	1	1	0	1	0	0	0	6
<i>Sujet 8</i>	1	1	1	1	1	1	1	0	0	0	7
<i>Sujet 9</i>	1	1	1	1	1	1	1	0	1	0	8
<i>Sujet 10</i>	1	1	1	1	1	1	1	1	1	0	9
<i>Sujet 11</i>	1	1	1	1	1	1	1	1	1	1	10
<i>Nombre de bonnes réponses</i>	10	9	8	6	7	4	5	2	3	1	55
<i>Moyenne</i>	0.91	0.82	0.73	0.55	0.64	0.36	0.45	0.18	0.27	0.09	5

¹⁵ Les démonstrations reprises dans le cadre de ce chapitre et placées dans des encadrés ne sont pas à mémoriser. Par contre, vous devez être capable de les expliquer.

Cette matrice de données présente les résultats de 11 sujets (*Sujet 1 à Sujet 11*) à un test de 10 questions (*It_1 à It_10*). Le score total d'un sujet, repris dans la dernière colonne du tableau, correspond à la somme des scores de ce sujet à chacun des items. En d'autres termes, le score total, dénommé score observé et symbolisé par X_i , correspond au nombre de réponses correctes fournies par chacun des sujets.

L'avant dernière ligne du tableau reprend, par question, le nombre de réponses correctes et la dernière ligne, le pourcentage de réussite par question, c'est-à-dire le nombre de réponses correctes fournies par question, divisé par le nombre de sujets.

Etant donné que le score observé correspond à la somme des scores à chacun des items, on peut déduire :

1. que la moyenne des scores observés (de 5 dans l'exemple repris ci-dessus) est égale à :
 - a. la moyenne du nombre de bonnes réponses par item (soit 55/11), ou
 - b. la somme des moyennes d'items.
2. que la variance des scores observés est égale à la variance de la somme des scores à chacun des items. Mathématiquement,

$$\sigma_{(X_i)}^2 = \sigma_{(item_1 + item_2 + \dots + item_k)}^2 = \sigma_{(\sum_{i=1}^k item_i)}^2$$

De par :

1. la généralisation de la formule présentée dans les prérequis statistiques, à savoir $\sigma_{(X+Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 + 2\text{cov}(X, Y)$;
2. et la définition de la corrélation, à savoir:

$$\rho_{(X,Y)} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} \rightarrow \text{cov}(X,Y) = \rho_{(X,Y)} \sigma_X \sigma_Y ,$$

On peut également écrire :

$$\sigma_{(X_i)}^2 = \sum_{i=1}^k \sigma_{(item_i)}^2 + 2 \sum_{i=1}^{k-1} \sum_{j=i+1}^k \rho_{(item_i, item_j)} \sigma_{(item_i)} \sigma_{(item_j)}$$

Les caractéristiques des items déterminent en partie les valeurs de la moyenne et de la variance des scores observés. On peut en effet aisément imaginer qu'en fonction de la difficulté des questions et/ou en fonction de la compétence des individus interrogés, la moyenne des scores observés peut soit augmenter, soit diminuer.

Par contre, comment la difficulté des items peut-elle modifier la variance totale ? Pour mieux cerner cette question, essayons de maximiser la variance observée.

La variance observée, $\sigma_{(X_t)}^2 = \sum_{i=1}^k \sigma_{(item_i)}^2 + 2 \sum_{i=1}^{k-1} \sum_{j=i+1}^k \rho_{(item_i, item_j)} \sigma_{(item_i)} \sigma_{(item_j)}$ sera maximale:

1. Si $\sum_{i=1}^k \sigma_{(item_i)}^2$ est maximale, c'est-à-dire si chacune des variances d'items est maximale ;
2. Si $\sum_{i=1}^{k-1} \sum_{j=i+1}^k \rho_{(item_i, item_j)} \sigma_{(item_i)} \sigma_{(item_j)}$ est maximale, c'est-à-dire si les écarts types des items sont maximaux et si les corrélations inter-items sont toutes égales à 1.

La variance d'un item dichotomique sera maximale si et seulement si le pourcentage de réponses correctes est égale à 0.50. En effet, si p_i représente le pourcentage de réussite et si $q_i = 1 - p_i$ représente le pourcentage d'échec, alors on peut démontrer:

Encadré 5.1 : la variance d'un item dichotomique

$$\sigma_{(X_t)}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - p)^2$$

$$\sigma_{(X_t)}^2 = \frac{n_0(0-p)^2 + n_1(1-p)^2}{n} = \frac{n_0(0-p)^2}{n} + \frac{n_1(1-p)^2}{n}$$

$$\sigma_{(X_t)}^2 = q(0-p)^2 + p(1-p)^2 = q(-p)^2 + p(q)^2 = p^2q + pq^2$$

$$\sigma_{(X_t)}^2 = p[q^2 + pq] = pq[p + q] = pq[1] = pq$$

En d'autres termes, la variance d'un item dichotomique est égale à $p_i q_i$. Le tableau 5.2 présente les variances d'items en fonction du pourcentage de réponses correctes.

Tableau 5.2 : pourcentage de réussite et variance d'items

p_i	q_i	$p_i q_i$ (variance d'items)	Écart-type
0,0	1,0	0,00	0.00
0,1	0,9	0,09	0.30
0,2	0,8	0,16	0.40
0,3	0,7	0,21	0.46
0,4	0,6	0,24	0.49
0,5	0,5	0,25	0.50
0,6	0,4	0,24	0.49
0,7	0,3	0,21	0.46
0,8	0,2	0,16	0.40
0,9	0,1	0,09	0.30
1,0	0,0	0,00	0.00

En d'autres termes, la variance observée d'un test sera maximale si et seulement si :

1. Les items ont tous un pourcentage de réussite égal à 0,50 ;
2. Les corrélations inter-items sont toutes égales à 1 ;

Le tableau 5.3 présente une matrice de données qui répond à ces deux critères.


Tableau 5.3 : matrice de données avec variance observée maximale

	<i>It_1</i>	<i>It_2</i>	<i>It_3</i>	<i>It_4</i>	<i>It_5</i>	<i>It_6</i>	<i>It_7</i>	<i>It_8</i>	<i>It_9</i>	<i>It_10</i>	<i>Total</i>
<i>Sujet 1</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 2</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 3</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 4</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 5</i>	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 6</i>	1	1	1	1	1	1	1	1	1	1	10
<i>Sujet 7</i>	1	1	1	1	1	1	1	1	1	1	10
<i>Sujet 8</i>	1	1	1	1	1	1	1	1	1	1	10
<i>Sujet 9</i>	1	1	1	1	1	1	1	1	1	1	10
<i>Sujet 10</i>	1	1	1	1	1	1	1	1	1	1	10

Dans cette matrice de données, tous les items sont réussis par la moitié des élèves. De plus, comme les élèves fournissent, à chaque item, les mêmes réponses, les corrélations inter-items sont toutes égales à 1.00. Il s'ensuit que la moitié des élèves obtiennent un score de 0 et l'autre moitié, un score maximal, soit 10 dans l'exemple ci-dessus.

La figure 5.1 représente graphiquement la distribution des scores totaux ou observés.

Figure 5.1 : distribution des scores totaux



Comme il a été indiqué dans le chapitre consacré aux prérequis statistiques, la variance d'une variable sera maximale (pour rappel, l'écart-type a comme valeur maximale la moitié de son amplitude) si et seulement si 50 % des sujets observés obtiennent la valeur minimale et si les 50 autres % obtiennent la valeur maximale.

Au fur et à mesure que la difficulté des items s'écarte de 0,50 et que les corrélations entre items s'éloignent de 1.00, la variance diminuera.

La difficulté des items influence la valeur de la variance, comme on vient de le voir, et par conséquent, elle influence également la forme de la distribution des scores observés. Ainsi, lorsque le test ne comprend que des questions très difficiles, on observera une distribution en *i* des scores totaux. Un grand nombre d'individus obtiendront des résultats très faibles, voire nuls et seulement les individus les plus compétents se détacheront du reste de la distribution. Poser uniquement des questions difficiles permettra de distinguer les individus très compétents des autres individus mais ne permettra pas de différencier les individus faibles ou moyens des individus les plus faibles.

Ce type de situation est particulièrement approprié pour sélectionner les quelques individus les plus forts parmi une population. Il ne sera dès lors pas étonnant d'observer ce type de situation dans le cadre d'examens de recrutement.

Si le test comporte à la fois des questions faciles, moyennes et difficiles, la distribution des scores observés, pour autant que les corrélations entre items en moyenne avoisinent les 0.30, s'apparentera à une distribution normale. Ce type de test permet d'offrir une discrimination acceptable tout le long du continuum.

Enfin, si le test ne comporte que des questions faciles, alors la majorité des individus obtiendront un score très élevé. Ce type de test permet de différencier les individus très faibles du reste de la population mais ne présente aucun pouvoir discriminatif pour les individus moyens ou forts.

Ces différentes situations montrent clairement que la distribution du score observé à un test dépend essentiellement de la difficulté des items et des corrélations inter-items. ***Une distribution normale des scores observés ne peut, en aucun cas, être considérée comme une preuve de la normalité du trait latent.***

5.2. Définition du score vrai

Les scores observés ne sont malheureusement pas exempts d'erreurs. On peut donc considérer qu'un score observé X_t à un test résulte de la somme de deux composantes, une composante vraie, notée X_∞ , et une composante d'erreur, notée X_e , qui affecte la mesure de la compétence du sujet. Cette composante d'erreur est une variable aléatoire qui résulte de l'addition de différentes sources (conditions de passation, par exemple luminosité, température, conditions liées au sujet, par exemple fatigue...).

On peut donc écrire :

$$X_t = X_\infty + X_e$$

Le score observé, le score vrai et le score d'erreur se situent sur la même échelle. Il peut s'agir des points obtenus à un test, du nombre d'erreurs enregistrées à une épreuve...

On peut définir le score vrai X_∞ de trois manières :

1. X_∞ est le score qu'un individu obtiendrait dans des conditions idéales avec un instrument parfait. Un tel instrument de mesure, même en sciences exactes, n'existe pas. Cependant, cette définition confère au score vrai une existence réelle. Ainsi, une table a une longueur donnée. *“For a specific measurement g and person a , we might hypothesize that the person has some unique naturally defined true value on the measurement being taken. (...) In the physical sciences, this conception is a very reasonable one. (...) However, this conception of true score does not provide a satisfactory axiomatic basis for psychological theories, since these theories are typically based on unexplained, inexact constructs.”* (Lord & Novick, 1968, p. 28).

2. X_{∞} est la moyenne des scores obtenus par un sujet au départ d'un grand nombre d'administrations indépendantes du même instrument. Plus le nombre de mesures augmente, plus la moyenne converge vers le score vrai. Par indépendantes, on entend que les erreurs commises lors d'une mesure ne corrélaient pas avec les erreurs commises lors d'une autre administration. Cette opérationnalisation du score vrai suppose que la mesure en tant que telle n'affecte pas la caractéristique mesurée du sujet. Ainsi, si l'on demande à 100 individus de mesurer la longueur d'une seule et même table, elle ne deviendra pas plus grande ou plus petite à cause des différentes mesures opérées. Par contre, mesurer la compétence mathématique d'un élève à l'aide d'un test est susceptible d'affecter cette compétence puisque le test constitue une occasion de pratiquer cette compétence et, dès lors, de la renforcer, voire de l'améliorer. Dans ce cas, le score vrai pourrait être assimilé au score qu'un individu obtiendrait à un test de longueur infinie (on retrouve ici la notion de répliques où chaque question est assimilée à une mesure). Cette définition fait donc appel à la loi des grands nombres.
3. *"The true score of a person on a measurement is defined as the expected value of the observed score"* (Lord & Novick, 1968, p. 30). Le score vrai est donc assimilé à la valeur attendue du score observé.

Dans la majorité des situations en sciences humaines, on ne peut administrer indéfiniment un instrument de mesure à un individu pour en connaître le score vrai. On ne pourra donc pas opérationnaliser le score vrai. Or, $X_t = X_{\infty} + X_e$. Si on ne peut pas estimer le score vrai, on ne peut pas non plus estimer le score d'erreur. En d'autres termes, un élément observable (le score observé) se voit défini par deux éléments non observables (à savoir le score vrai et le score d'erreur). La théorie classique a néanmoins développé différentes procédures statistiques pour étudier les qualités psychométriques du test et du score observé.

5.3. Postulats de base de la théorie classique du score vrai

Par définition, un postulat est un principe premier, indémontrable ou non démontré. Il s'agit donc d'une règle que l'on accepte sans pour autant être en mesure de vérifier sa véracité. L'utilité des postulats réside dans les développements théoriques qu'ils autorisent.

La théorie classique du score vrai énonce trois postulats fondamentaux :

5.3.1. Postulat 1

La moyenne des erreurs commises est égale à 0. En d'autres termes, il n'existe pas de biais systématiques qui conduiraient à surestimer ou sous-estimer les différents sujets qui font l'objet d'une mesure. Mathématiquement, on peut écrire :

$$\mu_{X_e} = 0$$

Par analogie, un mètre étalon tronqué dont la longueur ne serait que de 90 cm conduirait systématiquement à surestimer la longueur de tous les objets mesurés.

5.3.2. Postulat 2

La corrélation entre les scores vrais et les scores d'erreur est égale à 0. Il n'existe pas de mécanismes qui conduiraient :

1. à surestimer par exemple les sujets compétents et sous-estimer les sujets peu compétents (dans ce cas, la corrélation serait positive) ;
2. à surestimer par exemple les sujets peu compétents et à sous-estimer les sujets compétents (dans ce cas, la corrélation serait négative).

Mathématiquement, on peut écrire que :

$$\rho_{(X_{\infty}, X_e)} = 0$$

5.3.3. Postulat 3

Le troisième et dernier postulat impose que les différents types d'erreurs soient indépendants. En d'autres termes, les corrélations entre erreurs sont toutes nulles. Mathématiquement, on peut écrire :

$$\rho_{(X_{ei}, X_{ej})} = 0$$

Ce postulat 3 autorise aussi, sur base du théorème de limite centrale, de postuler la normalité de l'erreur. Il signifie aussi que les items doivent être indépendants.

5.4. Développements autorisés par les postulats : définition de la fidélité

De part les propriétés de la variance :

$$\begin{aligned}\sigma_{(A+B)}^2 &= \sigma_{(A)}^2 + \sigma_{(B)}^2 + 2\text{cov}(A, B) \\ \sigma_{(A+B)}^2 &= \sigma_{(A)}^2 + \sigma_{(B)}^2 + 2\rho_{(A,B)}\sigma_{(A)}\sigma_B\end{aligned}$$

on peut écrire


$$\begin{aligned}\sigma_{(X_t)}^2 &= \sigma_{(X_{\infty} + X_e)}^2 \\ \sigma_{(X_t)}^2 &= \sigma_{(X_{\infty})}^2 + \sigma_{(X_e)}^2 + 2\text{cov}(X_{\infty}, X_e) \\ \sigma_{(X_t)}^2 &= \sigma_{(X_{\infty})}^2 + \sigma_{(X_e)}^2\end{aligned}$$

En effet, la corrélation entre le score vrai et le score d'erreur est par définition égale à 0. La variance totale est égale à la somme de la variance vraie et de la variance d'erreur.

Comme toute variance, la variance d'erreur est positive ou nulle. Cependant, une variance d'erreur nulle signifierait aussi que tous les scores d'erreurs seraient nuls, ou que l'instrument serait parfait. Comme un tel instrument n'existe pas, la variance d'erreur sera toujours plus grande que 0.

Graphiquement, on peut représenter les variances vraies et les variances observées comme suit :

Figure 5.2 : distribution des scores vrais et des scores observés



La courbe noire représente la distribution des scores vrais. Comme une erreur entache chaque mesure, certains des étudiants peu performants voient leur score surestimé tandis que d'autres tout aussi peu performants voient leur score sous-estimé. Il en est de même pour les élèves très performants. Il s'ensuit que l'amplitude des scores observés est plus élevée que l'amplitude des scores vrais, et par voie de conséquence, la variance observée sera plus élevée que la variance vraie.

Plus l'instrument de mesure sera imprécis, plus la variance d'erreur sera importante et plus la distribution des scores observés s'écartera aux extrémités de la distribution des scores vrais.

On peut définir la fidélité d'un test, notée ρ_{tt} , comme la corrélation de ce test avec lui-même. En effet, plus le test est fidèle, plus les corrélations entre les scores d'un individu lors de différentes administrations seront élevées. A la limite, si les individus obtiennent exactement les mêmes scores lors de deux administrations, la corrélation sera égale à 1, indiquant une fidélité parfaite.

Encadré 5.2 : définition de la fidélité d'un test

$$\begin{aligned}
 Corr(T_1, T_2) &= \frac{COV(T_1, T_2)}{\sqrt{\sigma_{T_1}^2 \sigma_{T_2}^2}} = \frac{COV(X_\infty + X_{e1}, X_\infty + X_{e2})}{\sqrt{(\sigma_{X_\infty}^2 + \sigma_{X_{e1}}^2)(\sigma_{X_\infty}^2 + \sigma_{X_{e2}}^2)}} \\
 &= \frac{COV(X_\infty, X_\infty) + COV(X_\infty, X_{e2}) + COV(X_{e1}, X_\infty) + COV(X_{e1}, X_{e2})}{\sqrt{(\sigma_{X_\infty}^2 + \sigma_{X_e}^2)^2}} \\
 &= \frac{\sigma_{X_\infty}^2}{\sigma_{X_\infty}^2 + \sigma_{X_e}^2} = \frac{\sigma_{X_\infty}^2}{\sigma_{X_t}^2} \\
 \Rightarrow Corr(X_\infty, X_t) &= \frac{\sigma_{X_\infty}^2}{\sqrt{\sigma_{X_\infty}^2 \sigma_{X_t}^2}} \\
 \Rightarrow Corr(X_\infty, X_t)^2 &= \frac{\sigma_{X_\infty}^2 \sigma_{X_\infty}^2}{\sigma_{X_\infty}^2 \sigma_{X_t}^2} = \frac{\sigma_{X_\infty}^2}{\sigma_{X_t}^2}
 \end{aligned}$$

Cette démonstration montre l'utilité des postulats. En effet, de par les différents postulats, les différentes covariances qui font intervenir au moins une erreur sont toutes égales à 0. Le numérateur se réduit donc à la variance des scores vrais. Les variances des scores vrais et des scores d'erreurs d'un test lors de deux administrations consécutives sur un même échantillon peuvent être considérées comme identiques. Il s'ensuit que la fidélité d'un test se résume à la proportion de la variance des scores vrais par rapport à la variance des scores observés. Mathématiquement, on peut écrire :

$$\rho_{tt} = \frac{\sigma_{(X_\infty)}^2}{\sigma_{(X_t)}^2}$$

Il s'agit donc du pourcentage de vrai dans ce qui est observé. La seconde partie de l'encadré montre que la fidélité est aussi égale au carré de la corrélation entre le score vrai et le score observé.

On peut aussi écrire :

$$\rho_{tt} = \frac{\sigma_{(X_\infty)}^2}{\sigma_{(X_t)}^2} = \frac{\sigma_{(X_t)}^2 - \sigma_{(X_e)}^2}{\sigma_{(X_t)}^2} = \frac{\sigma_{(X_t)}^2}{\sigma_{(X_t)}^2} - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2} = 1 - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2}$$

A présent, on peut donc estimer la variance et l'écart type des scores vrais comme suit :

$$\sigma_{(X_{\infty})}^2 = \rho_{tt} \sigma_{(X_t)}^2$$

$$\sigma_{(X_{\infty})} = \sqrt{\rho_{tt} \sigma_{(X_t)}^2}$$

Encadré 5.3 : Variance des scores vrais

$$\rho_{tt} = \frac{\sigma_{(X_{\infty})}^2}{\sigma_{(X_t)}^2}$$

$$\Rightarrow \rho_{tt} \sigma_{(X_t)}^2 = \sigma_{(X_{\infty})}^2$$

De même, on peut à présent estimer la variance et l'écart type des scores d'erreurs comme suit :

$$\sigma_{(X_e)}^2 = \sigma_{(X_t)}^2 (1 - \rho_{tt})$$

$$\sigma_{(X_e)} = \sigma_{(X_t)} \sqrt{1 - \rho_{tt}}$$

Encadré 5.4 : Variance des scores d'erreurs

$$\rho_{tt} = 1 - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2}$$


$$\Rightarrow \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2} = 1 - \rho_{tt}$$

$$\Rightarrow \sigma_{(X_e)}^2 = \sigma_{(X_t)}^2 (1 - \rho_{tt})$$

L'écart type des scores d'erreurs, communément appelé *erreur standard de mesure*, traduit l'incertitude associée à l'estimation du trait latent mesuré, c'est-à-dire à titre d'exemple, la compétence dans le cadre d'un test cognitif. Comme il a été mentionné précédemment, la distribution du score d'erreur s'apparente à une distribution normale. Dans ces conditions, il est possible d'utiliser les propriétés mathématiques de cette distribution théorique pour construire un intervalle de confiance autour d'une estimation individuelle.

La figure 5.3 représente graphiquement la distribution des scores observés et les distributions des scores d'erreurs pour deux estimations individuelles.

Figure 5.3. : distributions des scores observés et des scores d'erreurs




Cette distribution des scores d'erreurs autour d'une estimation individuelle traduit la variabilité des différents scores observés possibles pour un individu. Un exemple au départ du Quotient Intellectuel (QI) permettra de concrétiser ce concept fondamental d'erreur de mesure et son utilité.

Pour rappel, le Quotient Intellectuel a une moyenne de 100, un écart type de 15 et une fidélité de 0.89. En conséquence, l'erreur de mesure (ou écart type des scores d'erreurs) est égale à :

$$ESM = \sigma_{(x_e)} = \sigma_{(x_t)} \sqrt{1 - \rho_{tt}} = 15 \sqrt{1 - 0,89} = 4,97$$

La figure 5.4 représente graphiquement la distribution du QI et la distribution des scores d'erreurs pour un individu ayant obtenu un QI de 110.

Figure 5.4 : distribution du QI et erreur de mesure



Sur base des propriétés de la distribution normale, on peut affirmer, avec 5 chances sur 100 de se tromper que :

$$[110 - (1,96 * ESM); 110 + (1,96 * ESM)]$$

$$[110 - (1,96 * 4,97); 110 + (1,96 * 4,97)]$$

$$[100,26; 119,74]$$

Le quotient intellectuel de cet individu se situe entre 100,26 et 119,74. Comme 100 ne figure pas dans l'intervalle de confiance, on peut aussi affirmer, avec 5 chances sur 100 de se tromper (cf. 1,96 introduit ci-dessus), que cet individu a un QI statistiquement supérieur à la moyenne.

5.5. Fidélité d'un test et longueur

Comme un mètre étalon qui comporte 100 graduations sera plus précis qu'un mètre étalon qui comporte seulement 10 graduations, un test qui comporte 100 questions devrait être plus précis qu'un test qui comporte seulement 10 questions.

La **formule de Spearman-Brown** permet d'estimer la fidélité d'un test dont la longueur serait multipliée par un coefficient n . Cette formule suppose l'homogénéité du test, c'est-à-dire que les items initiaux mesurent une seule compétence et que les nouveaux items soient comparables à ceux qui le composent déjà.

Soit, par exemple, un test T_1 dont on va doubler la longueur en lui adjoignant un deuxième test T_2 de même longueur et mesurant exactement les mêmes compétences. Le test de longueur double sera désigné par T .

On peut aisément démontrer que la fidélité du test T sera égale à :

$$\rho_{tt} = \frac{2\rho_{t_1t_1}}{1 + \rho_{t_1t_1}}$$

A titre d'exemple, si on double la longueur d'un test dont la fidélité est égale à 0.80, la fidélité du test double sera égale à :

$$\rho_{tt} = \frac{2\rho_{t_1t_1}}{1 + \rho_{t_1t_1}} = \frac{2(0,80)}{1 + 0,80} = \frac{1,6}{1,8} = 0,89$$

Par généralisation, on peut écrire que la fidélité d'un test dont la longueur est multipliée par un coefficient n sera égale à :

$$\rho_{nt} = \frac{n\rho_{tt}}{1 + (n-1)\rho_{tt}}$$

Cette formule, connue sous le nom de **formule de Spearman-Brown**, permet donc d'exprimer la fidélité attendue d'un test n fois plus long que le test original à partir de la fidélité de celui-ci. La valeur de n ne doit pas nécessairement être un nombre entier et par

ailleurs peut être aussi compris entre 0 et 1. Cette formule permet donc aussi de calculer la fidélité d'un test dont on supprimerait une partie des items.

Cette formule, par transformation, permet également de déterminer le nombre d'items nécessaire pour atteindre une fidélité donnée. Mathématiquement, le coefficient d'allongement est égal à :

$$n = \frac{\rho_{tt}(1 - \rho_{tt})}{\rho_{tt}(1 - \rho_{tt})}$$

A titre d'exemple, un psychologue développe un test de 20 items. Après le prétest, il obtient une fidélité de 0.85. Il souhaite obtenir une fidélité de 0.90. Il devrait donc allonger son test par un coefficient de :

$$n = \frac{\rho_{tt}(1 - \rho_{tt})}{\rho_{tt}(1 - \rho_{tt})} = \frac{0,90(1 - 0,85)}{0,85(1 - 0,90)} = \frac{0,135}{0,085} = 1,588$$

Le nombre de questions que son test devra comporter est égal à 1,588 multiplié par 20, soit 32 questions.

5.6. Opérationnalisation du calcul de la fidélité

Jusqu'à présent, la fidélité a été définie sur le plan théorique et les éléments susceptibles de l'améliorer ont été décrits. Cependant, les éléments théoriques envisagés ne permettent toujours pas d'estimer la variance vraie ou la variance d'erreur, éléments indispensables pour l'estimation de la fidélité.

Dans les sections suivantes, les principales techniques de calcul de la fidélité seront présentées. Certaines ne sont que très rarement utilisées de nos jours mais elles se rencontrent toujours dans la littérature scientifique.

Chacune de ces techniques, à un moment ou à un autre, définit d'une manière ou d'une autre ce qu'est une erreur. Sans cette définition préalable, l'estimation de la fidélité d'un test ne peut être opérée.

Il existe trois grandes méthodes de calcul de la fidélité :

1. Les méthodes Test-Retest ;
2. Les méthodes de consistance interne ;
 - a. La méthode de Rulon
 - b. La méthode Pairs-Impairs
 - c. Les méthodes de Kuder-Richardson
 - d. L'alpha de Cronbach
 - e. La méthode des scores composites
3. Les formes mixtes ou formes parallèles.

5.6.1. Les méthodes Test-Retest

Cette famille de méthodes ne postule nullement l'existence d'une consistance interne, c'est-à-dire de l'unidimensionalité de la mesure. En fait, les différentes parties du test pourraient avoir, à la limite, une corrélation nulle et, cependant, la corrélation entre une première administration et une seconde administration du test (soit la fidélité Test-Retest) pourrait être élevée. Le concept clé est ici celui de la stabilité dans le temps. Une corrélation élevée signifie que le classement des individus demeure stable à travers le temps. Si la moyenne et l'écart type observés lors de la première et de la seconde administrations restent stables, on peut également en déduire que les scores des individus restent inchangés, à l'exception de l'erreur de mesure, à travers le temps.

Cette méthode présuppose que le trait latent mesuré n'est pas susceptible d'évoluer à travers le temps, ou du moins que les individus n'ont pas fait l'objet d'un enseignement ou qu'ils n'ont pas eu l'occasion de s'exercer afin d'améliorer leur performance.

L'erreur de mesure dans le cadre de ces méthodes se limite donc à l'instabilité des résultats à travers le temps.

Pour estimer la fidélité selon la méthode Test-Retest, un même échantillon d'individus doit répondre au même test à deux reprises. La fidélité sera dès lors estimée par le coefficient de corrélation de Bravais-Pearson.

5.6.2. Les méthodes de consistance interne

Les méthodes basées sur le postulat de consistance interne prennent comme présupposés de base :

1. Soit les items du test mesurent tous le même trait latent ;
2. Soit les différents sous-tests qui composent la batterie du test mesurent le même trait latent.

L'avantage considérable des méthodes de consistance interne qui a contribué à leur popularité réside dans le fait qu'elles ne requièrent qu'une seule administration.

5.6.2.1. La méthode de Rulon

Rulon a développé une formule simple qui suit la définition de base de la fidélité, à savoir la proportion de variance vraie dans un test.

La méthode consiste à diviser le test en deux parties qui comportent le même nombre d'items et de calculer le score obtenu par chaque individu aux deux sous-tests. Ensuite, la différence entre ces deux sous-scores est calculée et sa variance, notée σ_d^2 est alors considérée comme variance d'erreur.

Mathématiquement, la formule de *Rulon* s'écrit :

$$\rho_{tt} = 1 - \frac{\sigma^2_{(X_{dif})}}{\sigma^2_{(X_t)}}$$

Tableau 5.4 : Matrice de données

	<i>It_1</i>	<i>It_2</i>	<i>It_3</i>	<i>It_4</i>	<i>It_5</i>	<i>It_6</i>	<i>It_7</i>	<i>It_8</i>	<i>It_9</i>	<i>It_10</i>	<i>Total</i>	<i>Items Impairs</i>	<i>Items Pairs</i>	<i>dif</i>
<i>Sujet 1</i>	0	0	0	0	0	0	0	0	0	0	0	0	0	0
<i>Sujet 2</i>	1	0	0	0	0	0	0	0	0	0	1	1	0	1
<i>Sujet 3</i>	1	1	0	0	0	0	0	0	0	0	2	1	1	0
<i>Sujet 4</i>	1	1	1	0	0	0	0	0	0	0	3	2	1	1
<i>Sujet 5</i>	1	1	1	0	1	0	0	0	0	0	4	3	1	2
<i>Sujet 6</i>	1	1	1	1	1	0	0	0	0	0	5	3	2	1
<i>Sujet 7</i>	1	1	1	1	1	0	1	0	0	0	6	4	2	2
<i>Sujet 8</i>	1	1	1	1	1	1	1	0	0	0	7	4	3	1
<i>Sujet 9</i>	1	1	1	1	1	1	1	0	1	0	8	5	3	2
<i>Sujet 10</i>	1	1	1	1	1	1	1	1	1	0	9	5	4	1
<i>Sujet 11</i>	1	1	1	1	1	1	1	1	1	1	10	5	5	0
<i>Nombre de bonnes réponses</i>	10	9	8	6	7	4	5	2	3	1	55	33	22	11

La matrice de données 5.4 présente les réponses de 11 sujets à un test comportant 10 questions. A l'ensemble du test, le *Sujet 1* obtient un score de 0, le *Sujet 8* un score de 7, et ainsi de suite.

Le test a été divisé artificiellement en deux sous-tests : le sous-test 1 composé des items impairs (*It_1*, *It_3*, *It_5*, *It_7*, *It_9*) et le sous-test 2 composé des items pairs (*It_2*, *It_4*, *It_6*, *It_8*, *It_10*). Le score de chaque élève à chacun des deux sous-tests a été calculé et la différence entre ces deux sous-scores figure dans la dernière colonne du tableau 5.4.

Pour calculer l'indice de fidélité selon la méthode de *Rulon*, il faut :

1. Calculer la moyenne du score total ;

$$\mu_{(X_t)} = \frac{1}{n} \sum_{i=1}^n X_t = \frac{55}{11} = 5$$

2. Calculer la variance du score total ;

$$\sigma^2_{(X_t)} = \frac{1}{n} \sum_{i=1}^n (X_t - \mu_{(X_t)})^2 = \frac{[(0-5)^2 + \dots + (10-5)^2]}{n} = \frac{110}{11} = 10$$

3. Calculer la moyenne des différences ;

$$\mu_{(X_{dif})} = \frac{1}{n} \sum_{i=1}^n X_{dif} = \frac{11}{11} = 1$$

4. Calculer la variance des différences ;

$$\sigma^2_{(X_{dif})} = \frac{1}{n} \sum_{i=1}^n (X_{dif} - \mu_{(X_{dif})})^2 = \frac{[(0-1)^2 + \dots + (0-1)^2]}{n} = \frac{6}{11} = 0.545$$

5. Calculer l'indice de fidélité

$$\rho_{tt} = 1 - \frac{\sigma^2_{(X_{diff})}}{\sigma^2_{(X_t)}} = 1 - \frac{0.545}{10} = 0.945$$

Il convient de noter que selon le regroupement des items opéré pour constituer les deux sous-tests, l'estimation de la fidélité peut varier. Par ailleurs, constituer deux sous-tests qui ne comportent pas le même nombre d'items va également amplifier la variance des différences, et, par conséquent, diminuer l'indice de fidélité.

5.6.2.2. La méthode Pairs-Impairs

Comme dans la méthode de *Rulon*, la méthode paires-impairs consiste à regrouper les items en deux sous-tests en imposant, à l'inverse de *Rulon*, que le regroupement soit opéré sur la base des items pairs et des items impairs. Il suffit ensuite de calculer la corrélation entre les scores aux items pairs et les scores aux items impairs, puis de corriger la corrélation par la formule de *Spearman-Brown*.

Pour calculer l'indice de fidélité selon la méthode *pairs-impairs*, il faut :

1. Calculer la moyenne des scores aux items pairs

$$\mu_{(X_{pairs})} = 2$$

2. Calculer la variance aux items pairs

$$\sigma^2_{(X_{pairs})} = 2.36$$

3. Calculer la moyenne des scores aux items impairs

$$\mu_{(X_{impairs})} = 3$$

4. Calculer la variance aux items impairs

$$\sigma^2_{(X_{impairs})} = 2.91$$

5. Calculer la covariance entre les scores aux items pairs et aux items impairs

$$Cov(X_{pairs}, X_{impairs}) = \frac{1}{n} \sum_{i=1}^n [(X_{pairs} - \mu_{(X_{pairs})})(X_{impairs} - \mu_{(X_{impairs})})]$$

$$Cov(X_{pairs}, X_{impairs}) = 2.36$$

6. Calculer la corrélation entre les scores aux items pairs et aux items impairs

$$\rho_{(X_{pairs}, X_{impairs})} = \frac{Cov(X_{pairs}, X_{impairs})}{\sqrt{\sigma^2_{(X_{pairs})} \sigma^2_{(X_{impairs})}}} = \frac{2.36}{\sqrt{2.91 * 2.36}} = 0.90$$

7. Corriger la corrélation par la formule de Spearman-Brown

$$\rho_{nt} = \frac{n\rho_{tt}}{1 + (n-1)\rho_{tt}} = \frac{2(0.90)}{1 + (2-1)(0.90)} = \frac{1.8}{1.9} = 0.95$$

La fidélité estimée est donc de 0,95.

Si les variances des scores aux items pairs et aux items impairs sont identiques, alors la fidélité obtenue via la formule de Rulon ou par l'intermédiaire de la formule de Spearman-Brown sont identiques, comme le montre l'encadré 5.5.

Encadré 5.5. méthode de Rulon (avec scission entre items pairs et items impairs) et méthode pairs-impairs

$$\begin{aligned}
 \rho_{tt} &= 1 - \frac{\sigma^2_{(X_{dif})}}{\sigma^2_{(X_t)}} \\
 &= \frac{(\sigma^2_{pairs} + \sigma^2_{impairs} + 2Corr(X_{pairs}, X_{impairs})\sigma_{pairs}\sigma_{impairs}) - (\sigma^2_{pairs} + \sigma^2_{impairs} - 2Corr(X_{pairs}, X_{impairs})\sigma_{pairs}\sigma_{impairs})}{(\sigma^2_{pairs} + \sigma^2_{impairs} + 2Corr(X_{pairs}, X_{impairs})\sigma_{pairs}\sigma_{impairs})} \\
 &= \frac{4Corr(X_{pairs}, X_{impairs})\sigma_{pairs}\sigma_{impairs}}{(\sigma^2_{pairs} + \sigma^2_{impairs} + 2Corr(X_{pairs}, X_{impairs})\sigma_{pairs}\sigma_{impairs})} = \frac{4Corr(X_{pairs}, X_{impairs})\sigma_{pairs}^2}{2\sigma_{pairs}^2 + 2Corr(X_{pairs}, X_{impairs})\sigma_{pairs}^2} \\
 &= \frac{2\sigma_{pairs}^2 2Corr(X_{pairs}, X_{impairs})}{2\sigma_{pairs}^2 (1 + Corr(X_{pairs}, X_{impairs}))} = \frac{2Corr(X_{pairs}, X_{impairs})}{1 + Corr(X_{pairs}, X_{impairs})}
 \end{aligned}$$

5.6.2.3. Les méthodes de Kuder-Richardson

Kuder et *Richardson* ont développé un groupe de procédures basées sur les statistiques d'items. En effet, on peut objecter aux deux méthodes décrites précédemment qu'il existe un très grand nombre de manières de scinder un test de k items en deux parties de $\frac{k}{2}$ items et qu'il n'y a pas beaucoup de raisons de recourir davantage à un regroupement plutôt qu'à un autre.

Kuder et *Richardson* proposent donc de découper le test en k parties de un item, ce qui résout ainsi le problème de l'arbitraire dans les partitions. Le postulat de base est, dans ce cas, que tous les items mesurent le même trait latent et relèvent donc ainsi d'une seule et même dimension.

Ils ont développé deux formules de calcul, notées KR20 et KR21 qui s'appliquent aux items dichotomiques. Mathématiquement, on écrit :

$$\rho_{tt} = kr20 = \frac{k}{k-1} \frac{\left(\sigma^2_{(X_t)} - \sum_{i=1}^k p_i q_i \right)}{\sigma^2_{(X_t)}}$$

$$\rho_{tt} = kr21 = \frac{k}{k-1} \frac{(\sigma_{(X_t)}^2 - kp_m q_m)}{\sigma_{(X_t)}^2}$$

Pour calculer l'indice de fidélité selon la méthode du KR20, il faut :

1. Calculer la variance du score total ;
2. Calculer la variance des k items qui composent le test. Pour rappel, la variance d'un item dichotomique est égale à $p_i q_i$. Le tableau 5.5 présente les moyennes ou pourcentages de réussite (p_i) et les variances ($p_i q_i$) des 10 items du tableau 5.4;
3. Calculer l'indice de fidélité

$$\rho_{tt} = kr20 = \frac{k}{k-1} \frac{\left(\sigma_t^2 - \sum_{i=1}^k p_i q_i \right)}{\sigma_t^2} = \frac{10}{9} \left(\frac{10 - 1.82}{10} \right) = 0.90$$

Tableau 5.5 : moyenne et variance des 10 items du tableau 5.4.

	<i>It 1</i>	<i>It 2</i>	<i>It 3</i>	<i>It 4</i>	<i>It 5</i>	<i>It 6</i>	<i>It 7</i>	<i>It 8</i>	<i>It 9</i>	<i>It 10</i>
Moyenne	0.91	0.82	0.73	0.55	0.64	0.36	0.45	0.18	0.27	0.09
Variance	0.08	0.15	0.20	0.25	0.23	0.23	0.25	0.15	0.20	0.08

Pour calculer l'indice de fidélité selon la méthode du KR21, il faut :

1. Calculer le pourcentage moyen de réussite et le pourcentage moyen d'échec;

$$p_m = \frac{\sum_{i=1}^k p_i}{k} = 0.5$$

$$q_m = 1 - p_m = 1 - 0,5 = 0,5$$

2. Calculer l'indice de fidélité ;

$$\rho_{tt} = kr21 = \frac{k}{k-1} \frac{(\sigma_{(X_t)}^2 - (k \bar{p} \bar{q}))}{\sigma_{(X_t)}^2} = \frac{10}{9} \left(\frac{10 - (10 * 0.5 * 0.5)}{10} \right) = 0.83$$

5.6.2.4. L'alpha de Cronbach

Cronbach a développé une formule plus générale que celles de Kuder-Richardson. La formule de *Cronbach* s'écrit :

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2}$$

Elle correspond à la formule du KR20, si ce n'est que les $p_i q_i$ ont été remplacés par le symbole σ_i^2 . En d'autres termes, contrairement au KR20, l'alpha de *Cronbach* ne se limite pas aux tests composés uniquement d'items dichotomiques mais peut également s'appliquer aux items à crédit partiel (0,1,2,...) ou aux échelles de *Likert*.

L'alpha de *Cronbach* peut s'utiliser dans deux types de situations.

Situation 1 : Il s'agit de calculer la fidélité d'une batterie composée de k sous-tests. Le tableau 5.6 présente les résultats de 10 sujets à une batterie composée de trois sous-tests.

Tableau 5.6 : données relatives à trois sous-tests

	<i>Sous Test 1</i>	<i>Sous Test 2</i>	<i>Sous Test 3</i>	<i>Total</i>
<i>Sujet 1</i>	1	2	6	9
<i>Sujet 2</i>	2	1	4	7
<i>Sujet 3</i>	3	3	5	11
<i>Sujet 4</i>	4	6	3	13
<i>Sujet 5</i>	5	5	2	12
<i>Sujet 6</i>	6	4	1	11
<i>Sujet 7</i>	7	9	8	24
<i>Sujet 8</i>	8	7	7	22
<i>Sujet 9</i>	9	8	10	27
<i>Sujet 10</i>	10	10	9	29
<i>Variance</i>	8,25	8,25	8,25	59,25

La variance des trois sous-tests est égale à 8,25 et la variance totale est égale à 59,25. La fidélité de la batterie de tests est donc égale à :

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2} = \frac{3}{2} \frac{[59,25 - (8,25 + 8,25 + 8,25)]}{59,25} = 0,87$$

Cette formule est cependant sensible à la variance respective des différents sous-tests. Plus la variance d'un sous-test est élevée, plus la contribution de ce sous-test dans le score total sera importante (*cfr* chapitre 2) et plus ce sous-test affectera la fidélité de la batterie de tests. Ainsi, si le score obtenu au troisième sous-test est multiplié par 3, la variance de ce sous-test sera de 74,25 (soit 8,25 multiplié par 9) et la variance totale sera à présent de 165,45. Dans ces conditions, l'alpha serait égal à :

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2} = \frac{3}{2} \frac{[164,45 - (8,25 + 8,25 + 74,25)]}{164,45} = 0,67$$

Pour neutraliser l'effet des variances de chacun des différents sous-tests dans le calcul de la fidélité, *Cronbach* a développé un coefficient standardisé qui attribue à chaque sous-test le même poids. Mathématiquement, cet indice standardisé de *Cronbach* est égal à :

$$\alpha = \frac{k\bar{\rho}}{1 + ((k-1)\bar{\rho})}$$

avec $\bar{\rho}$ la moyenne des corrélations entre les k sous-tests. Ainsi, au départ des données du tableau 5.6, la corrélation entre le sous-test 1 et le sous-test 2 est égale à 0,90, la corrélation entre le sous-test 1 et le sous-test 3 est égale à 0,56 et la corrélation entre le sous-test 2 et le sous-test 3 est égale à 0,62. La corrélation moyenne est donc égale à :

$$\bar{\rho} = \frac{0,90 + 0,56 + 0,62}{3} = 0,70$$

L'alpha de *Cronbach* est donc égal à :

$$\alpha = \frac{k\bar{\rho}}{1 + ((k-1)\bar{\rho})} = \frac{(3*0,70)}{1 + (3-1)0,70} = 0,87$$

soit la fidélité obtenue lorsque les différents sous-tests ont la même variance.

Il convient, en premier lieu, de noter la ressemblance entre la formule de *Spearman-Brown* et le coefficient standardisé de *Cronbach*.

En second lieu, ce coefficient standardisé montre l'influence des corrélations entre les différents sous-tests sur la fidélité d'une batterie de tests. Plus les corrélations entre sous-tests sont élevées, plus la fidélité sera élevée. En d'autres termes, l'utilisation de l'alpha dans le cadre d'une batterie de tests se justifie si et seulement si cette batterie évalue une seule variable latente. Si elle mesure plus d'une variable latente, les corrélations entre sous-tests seront faibles et dès lors, l'alpha de *Cronbach* sous-estimera la fidélité de la batterie.

Situation 2: il ne s'agit que d'un seul test mais les items qui composent le test ne sont pas dichotomiques. Les sciences de l'éducation et les sciences psychologiques recourent fréquemment aux échelles dites de *Likert* avec, par exemple, comme modalités de réponses *tout à fait en désaccord*, *en désaccord*, *en accord*, *tout à fait en accord*. Lorsque l'item est positif, on associe souvent le score 1 avec la catégorie *tout à fait en désaccord*, le score 2 avec la catégorie *en désaccord*, le score 3 avec la catégorie *en accord*, et le score 4 avec la catégorie *tout à fait en accord*. Le score total d'un sujet correspond à la somme des scores obtenus à chacun des items.

La figure 5.5 présente l'échelle Likert de PISA 2000 pour l'engagement à la lecture et le tableau 5.7 présente des données fictives qui serviront à un exemple de calcul de la fidélité selon l'alpha de *Cronbach*.

Figure 5.5 : échelle d'engagement à la lecture (PISA2000)

Q 1 Dans quelle mesure êtes-vous d'accord avec les affirmations suivantes à propos de la lecture ?
(Ne cochez qu'une seule case par ligne.)

	Pas du tout d'accord	Pas d'accord	D'accord	Tout à fait d'accord
a) Je ne lis que si j'y suis obligé(e).....	☐	☐	☐	☐
b) La lecture est un de mes loisirs favoris.	☐	☐	☐	☐
c) J'aime parler de livres avec d'autres personnes.	☐	☐	☐	☐
d) J'ai du mal à finir les livres.	☐	☐	☐	☐
e) Je suis content(e) quand je reçois un livre en cadeau.....	☐	☐	☐	☐
f) Pour moi, la lecture est une perte de temps.	☐	☐	☐	☐
g) J'aime aller dans un librairie ou une bibliothèque.	☐	☐	☐	☐
h) Je ne lis que pour trouver les informations dont j'ai besoin.	☐	☐	☐	☐

Tableau 5.7 : Données d'engagement à la lecture

	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>	<i>e</i>	<i>f</i>	<i>g</i>	<i>h</i>	<i>Total</i>
<i>Sujet 1</i>	1	2	1	2	1	3	2	1	13
<i>Sujet 2</i>	4	3	4	3	2	3	4	3	26
<i>Sujet 3</i>	2	3	3	3	3	4	4	4	26
<i>Sujet 4</i>	2	2	3	2	2	3	2	2	18
<i>Sujet 5</i>	4	3	3	3	4	3	4	3	27
<i>Sujet 6</i>	2	3	4	4	3	4	4	4	28
<i>Sujet 7</i>	2	2	3	2	2	3	2	2	18
<i>Sujet 8</i>	2	3	2	3	3	3	4	3	23
<i>Sujet 9</i>	2	3	4	2	3	4	4	4	26
<i>Sujet 10</i>	1	2	1	2	1	3	2	1	13
<i>Sujet 11</i>	4	3	4	3	2	3	4	3	26
<i>Variance</i>	1,14	0,23	1,17	0,41	0,78	0,20	0,93	1,11	29,06

La dernière ligne du tableau 5.7 donne la variance des 8 items qui composent l'échelle.

La somme des variances est égale à :

$$\sum_{i=1}^8 \sigma_i^2 = (1,14 + 0,23 + 1,17 + 0,41 + 0,78 + 0,20 + 0,93 + 1,11) = 5,97$$

La fidélité de cette échelle *Likert* qui mesure l'engagement des sujets à la lecture est égale à :

$$\rho_{tt} = \alpha = \frac{k}{k-1} \frac{\left(\sigma_{(X_t)}^2 - \sum_{i=1}^k \sigma_i^2 \right)}{\sigma_{(X_t)}^2} = \frac{8}{7} \left[\frac{29,06 - 5,97}{29,06} \right] = 0,91$$

5.6.2.5. La fidélité des scores composites

Dans la section précédente, on a vu que la fidélité d'une batterie de tests pouvait être estimée par l'intermédiaire de l'alpha de *Cronbach*. Cependant, cet indice de fidélité,

comme nous l'avons vu, présuppose la mesure d'une seule variable latente. De plus il ne prend pas directement en considération la fidélité respective des différents sous-tests. En effet, dans l'exemple donné précédemment, que les sous-tests aient une fidélité de 0,60, 0,70 ou 0,90 à titre d'exemples, la fidélité de la batterie de tests reste inchangée.

Moiser a développé une formule qui permet d'estimer la fidélité d'un score composite au départ des fidélités de chacun des sous-tests.

$$\rho_{cc} = 1 - \frac{\sum p_j^2 \sigma_j^2 - \sum p_j^2 \sigma_j^2 \rho_{jj}}{\sum p_j^2 \sigma_j^2 + 2 \sum \sum p_j p_k \sigma_j \sigma_k \rho_{jk}}$$

Cette formule permet de calculer la fidélité du score composite obtenu en combinant deux ou plusieurs tests. Les indices j et k font référence à deux tests particuliers, la valeur de k étant supérieure à j . L'application de cette formule nécessite la connaissance des éléments suivants pour chacun des sous-tests :

1. La variance du score total à chacun des sous-tests j , notée σ_j^2 ;
2. La fidélité de chacun des sous-tests j , notée ρ_{jj} ;
3. Le poids attribué à chaque sous-test j dans le calcul du score global, noté p_j .

Cette formule, de prime abord rébarbative, peut se comprendre aisément. Premièrement, l'ensemble de la formule s'apparente à la définition générale de la fidélité, à savoir

$$\rho_{tt} = 1 - \frac{\sigma_{(X_e)}^2}{\sigma_{(X_t)}^2}$$

Le dénominateur de la fraction n'est rien d'autre que la variance du score global à la batterie de tests et est obtenu par la formule généralisée de :

$$\sigma_{(A+B)}^2 = \sigma_{(A)}^2 + \sigma_{(B)}^2 + 2\rho_{(A,B)}\sigma_{(A)}\sigma_{(B)}$$

Enfin, le numérateur de la fraction peut également s'écrire :

$$\sum p_j^2 \sigma_j^2 (1 - \rho_{jj})$$

En d'autres termes, il s'agit de la somme pondérée des variances d'erreurs de chacun des sous-tests j .

5.6.3. Les méthodes mixtes ou méthodes des formes parallèles

Par définition, ces méthodes mixtes présentent des analogies avec les méthodes Test-Retest et les méthodes de consistance interne. Ici, le résultat obtenu informe sur l'équivalence du contenu psychologique mesuré aux moyens de deux formes parallèles, c'est-à-dire de 2 formes de test censées mesurer le même trait latent. Si ces deux formes ont été administrées endéans un intervalle de temps court, on mesure quelque chose de proche de la consistance interne, mais on risque de voir apparaître un *effet de testing*.

Dans le cas contraire, si on présente les deux formes parallèles à une certaine distance temporelle, on mesure tout à la fois la consistance interne et la stabilité.

L'indice de fidélité s'obtient en calculant la corrélation entre les scores totaux aux deux formes parallèles.

5.6.4. Variance vraie et variance d'erreur selon la méthode de calcul de la fidélité.

Le tableau 5.8 synthétise la signification des variances vraies et des variances d'erreurs pour les trois grandes méthodes de calcul de la fidélité.

Tableau 5.8 : Variances vraies et variances d'erreur

	<i>Variance vraie</i>	<i>Variance d'erreur</i>
Consistance interne	Covariance entre items ou groupes d'items à l'intérieur d'un même test	Les items (ou groupes d'items) ne mesurent pas la même chose
Test-retest	Covariance entre les résultats du test présenté à deux occasions (test et retest)	A deux occasions, des résultats supposés identiques diffèrent en raison de conditions extérieures (fatigue différente = aléatoire car variable d'un sujet à l'autre / effet de testing = systématique, la mémorisation jouant plus ou moins fortement selon la nature du test)
Formes parallèles	Covariance entre les deux formes à deux moments différents	A deux occasions, les résultats diffèrent (cf. test-retest) Les résultats aux deux formes diffèrent (cf. différences à l'intérieur d'un même test, comme dans l'étude de la consistance interne)

5.7. L'analyse d'items

Le calcul du coefficient de fidélité par des méthodes de consistance interne peut révéler un manque d'unidimensionnalité du test. Pour rappel, le KR20 vérifie si les différents items mesurent bien une seule et même dimension. L'alpha standardisé de *Cronbach* montre par ailleurs l'importance des corrélations entre les différentes parties du test, ces différentes parties pouvant, à la limite, être des items.

Si un ou plusieurs items présentent des corrélations faibles avec les autres items, la fidélité du test diminuera. Il importe donc, pour assurer l'unidimensionnalité de la mesure, de vérifier si les items mesurent bel et bien tous le même trait latent. En d'autres termes, il importe d'étudier les propriétés psychométriques des items.

Trois indices sont généralement pris en considération :

1. L'indice de difficulté ;
2. L'indice de discrimination ;
3. Fonctionnement différentiel de l'item.

5.7.1. L'indice de difficulté

Si l'item est corrigé de manière dichotomique (0 ou 1), l'indice le plus élémentaire est le pourcentage de réponses correctes ou p_i . L'indice p_i constitue un indice de difficulté moyenne pour l'ensemble des individus testés, c'est-à-dire la probabilité de réussite de l'item pour les différents individus testés. Par contre, cet indice ne nous renseigne pas sur la probabilité de réussite d'un individu particulier. Comme on le verra dans le chapitre suivant, les modèles de réponse à l'item modélisent la probabilité de réussite des items en fonction de la compétence des individus.

Dans le cadre d'un item avec plus de deux modalités de réponses (0,1 et 2 par exemple) l'indice de difficulté moyen peut s'obtenir en multipliant les pourcentages par leur score respectif, en sommant ces produits puis en les divisant par le score maximum. Ainsi, si 20% des élèves obtiennent un score nul, 50% des élèves obtiennent un score de 1 et 30% des élèves obtiennent un score de 2, l'indice moyen de difficulté p_i sera égal à :

$$p_i = \frac{(0.20 * 0) + (0.50 * 1) + (0.30 * 2)}{2} = 0,55$$

En règle générale, les tests ont pour objectif de différencier les individus. Dès lors, un item qui serait réussi par moins de 15% des élèves ou par plus de 85% des élèves apporte relativement peu d'informations. Pour ces raisons, on privilégiera les items dont les indices de difficulté varient de 0,15 à 0,85.

Dans le cadre des questions à choix multiple, un individu peut obtenir une réponse correcte en choisissant un des solutions proposées au hasard. Ainsi, si 100 individus répondent strictement au hasard à une question Vrai-Faux, on doit s'attendre à observer 50 réponses correctes et 50 réponses incorrectes. L'indice moyen de difficulté p_i est donc surestimé. En d'autres termes, la question apparaît plus facile qu'elle ne l'est réellement. Ces réponses au hasard introduisent une erreur supplémentaire dans la mesure et réduisent donc la fidélité du test.

Il existe plusieurs méthodes qui permettent de réduire ou de contrôler les phénomènes de réponses influencées par la chance dans des questions à choix multiple :

1. Augmentation du nombre de solutions proposées;
2. Ajout de solutions proposées du type « toutes les réponses sont correctes », « toutes les réponses sont fausses », ... ;
3. Pénalisation des réponses fausses ;
4. Utilisation des degrés de certitude qui créditent de manière plus ou moins généreuse ou sévère les bonnes ou les mauvaises réponses des sujets en fonction de la confiance qu'ils déclarent accorder à leur réponse.

Parmi les quatre solutions proposées, on envisagera uniquement la pénalisation des réponses fausses. Cette méthode est certainement la plus simple et la plus couramment utilisée, malgré quelques faiblesses qui seront discutées ultérieurement.

Plaçons nous d'abord au niveau d'un individu.

Imaginons un individu devant répondre à un test composé de 100 questions à choix multiple, chacune de ces questions comportant 5 solutions proposées. Le sujet connaît la réponse à 50 questions et pour les 50 autres questions, il répond au hasard. Il obtient donc un score de 50 sur 100 pour la première série de questions. Combien de bonnes réponses va-t-il obtenir pour la seconde série de questions à laquelle il répond strictement au hasard ? Pour chaque question, il a donc $\frac{1}{5}$ chance de trouver la bonne réponse. Sur 50

questions, il choisira $(50) \frac{1}{5} = 10$ bonnes réponses. A l'ensemble du test, l'individu obtiendra donc un score de 60 sur 100. Malheureusement, dans la réalité, on ne connaît pas le nombre de réponses que l'individu obtient sur base d'une connaissance réelle et le nombre de bonnes réponses que l'individu obtient en choisissant au hasard. Par contre, ce que l'on sait, c'est le nombre de réponses incorrectes.

Le raisonnement qui suit fait l'hypothèse que *toutes* les réponses incorrectes résultent d'un choix au hasard. Soit un individu qui répond uniquement au hasard à n questions à choix multiple comportant k solutions proposées (n étant plus petit ou égal au nombre d'items dans le test). Pour chaque question répondue au hasard, l'individu a $\frac{1}{k}$ chance de trouver la bonne réponse. Puisque l'individu répond uniquement au hasard à n questions, mathématiquement, l'individu obtiendra $n \frac{1}{k}$ bonnes réponses. Cependant, on ne connaît pas n , c'est-à-dire on ne connaît pas le nombre de réponses correctes que l'individu a obtenu en répondant au hasard. Par contre, on connaît le nombre de mauvaises réponses. Soit x le nombre de réponses incorrectes. Puisque nous faisons l'hypothèse que toutes les réponses incorrectes résultent d'un choix au hasard, on peut donc écrire que $x = n - \left(n \frac{1}{k}\right)$, avec n le nombre de questions répondues au hasard et $n \frac{1}{k}$ le nombre de réponses correctes obtenues en choisissant au hasard.

Pour que le score de l'individu traduise uniquement le nombre de réponses correctes obtenues en ne choisissant pas au hasard, il faut appliquer une pénalité de $-\frac{1}{(k-1)}$ par réponse incorrecte.

Supposons un test de 20 questions pour lesquelles 5 solutions sont proposées. On enregistre pour un sujet particulier 12 réponses correctes et 8 réponses incorrectes. La pénalité totale sera donc égale à :

$$-8 \frac{1}{(5-1)} = -8 \frac{1}{4} = -2$$

En d'autres termes, on attribuera à l'individu un score de $12-2=10$.

Cette pénalisation suppose que toute réponse incorrecte résulte uniquement d'un choix au hasard. Si un étudiant répond incorrectement sans choisir au hasard, il se verra indûment pénalisé. De plus, cette correction ne prend pas en considération la chance variable d'un sujet à l'autre. Si cette correction semble appropriée en moyenne, elle peut s'avérer trop sévère ou trop laxiste en fonction de la chance de l'individu. Enfin, cette correction fait l'hypothèse que les différentes solutions proposées ont un même pouvoir d'attraction. Si ce n'est pas le cas, alors la correction sera trop peu sévère. A titre d'exemple, si à la question « Quelle est la capitale du Mali ? », les quatre solutions proposées sont (i) Bamako, (ii) Bruxelles, (iii) Lomé et (iv) Paris, on peut suspecter que cette question se réduise à une question dichotomique à deux solutions, à savoir la solution (i) et la solution (iii). Dans ce contexte, la pénalité de $-\frac{1}{(k-1)} = -\frac{1}{3}$ serait trop laxiste et les candidats auraient tout intérêt à répondre au hasard.

Au niveau de l'item, le pourcentage moyen de réussite corrigé pour choix au hasard sera égal à :

$$p_c = p_r - \frac{p_e}{k-1}$$

Avec p_c le pourcentage de réussite corrigé, p_r le pourcentage de réussite non corrigé, p_e le pourcentage d'échec et k le nombre de distracteurs.

Supposons un item à 5 distracteurs pour lequel on obtient 62% de réponses correctes, 26% de réponses incorrectes et 12% d'omissions.

$$p_c = p_r - \frac{p_e}{k-1} = 0.62 - \frac{0.26}{5-1} = 0,555$$

Le pourcentage de réussite corrigé pour choix au hasard est donc de 0,55.

5.7.2. L'indice de discrimination

Pour accroître la fidélité d'un test, il importe de maximaliser la corrélation entre items. Cependant, avec un test de 50 items, il serait nécessaire de calculer 1225 corrélations inter-items.

Une procédure plus économique consiste à vérifier que l'item mesure bien la même chose que le test dans sa globalité. En d'autres termes, cela revient à calculer la corrélation de *Bravais-Pearson* entre l'item et le score total. Si l'item mesure bien le même trait latent que le test dans sa globalité, alors la corrélation entre l'item et le score global sera positive. Si la corrélation est nulle ou négative, alors l'item mesure autre chose que le test dans sa globalité.

En présence d'un item dichotomique (0,1) la corrélation de Bravais-Pearson se simplifie considérablement. Dans ce cas, on parle de corrélation bisériale de point. Mathématiquement,

$$r_{pbis} = \frac{M_r - M_e}{\sigma_{(X_t)}} \sqrt{p_i q_i}$$

Dans cette formule,

1. M_r représente la moyenne des scores totaux pour les seuls sujets qui ont réussi l'item i ;
2. M_e représente la moyenne des scores totaux pour les seuls sujets qui ont échoué à l'item i ;
3. $\sigma_{(X_t)}$ représente l'écart type du score total et ;
4. $\sqrt{p_i q_i}$ l'écart type de l'item.

Calculons la corrélation bisériale de point de l'item 3 de la matrice de données reprises dans le tableau 4.4.

$$M_r = \frac{(3+4+5+6+7+8+9+10)}{8} = 6.5$$

$$M_e = \frac{(0+1+2)}{3} = 1$$

La corrélation bisériale de point de l'item 3 est donc égale à :

$$r_{pbis} = \frac{M_r - M_e}{\sigma_t} \sqrt{p_i q_i} = \frac{6.5-1}{\sqrt{10}} \sqrt{\frac{3}{11} \frac{8}{11}} = 0.77$$

Cela signifie que l'item mesure bien le même trait latent que le test.

En règle générale, on retiendra dans un test les items qui ont une corrélation bisériale de point supérieure à 0,25.

5.7.3. Le fonctionnement différentiel de l'item.

Au chapitre 3, nous avons défini le concept de Fonctionnement Différentiel des Items (DIF en anglais pour *Differential Item Functioning*). Pour rappel, on observe un DIF lorsque, à niveau équivalent de compétence, des sujets appartenant à différents groupes (le critère commun aux élèves d'un même groupe peut être le pays d'appartenance, la langue, le sexe...) ont des probabilités différentes de réussir l'item. Ainsi, dans un test de compréhension en lecture, on trouvera souvent des DIF à l'avantage des filles, en particulier pour des réponses ouvertes longues portant sur des textes littéraires.

Ce fonctionnement différentiel des items peut être illustré par les données à partir du questionnaire repris à l'annexe 9.1. Ces données sont relatives au poids et à la taille des étudiants de deuxième bachelier en psychologie de l'université de Liège. Les items dichotomiques B1 à B7 sont utilisés pour créer une échelle *Taille des individus* qui varie


de 0 à 7 si chaque item est codé 0 ou 1. Le tableau 5.9 présente, par score total, par sexe, la distribution des réponses à l'item 1 « *Quand j'étais jeune, on me donnait toujours plus que mon âge* ».

Tableau 5.9 : Répartition des étudiants à l'item B1, en fonction (i) de leur score à l'échelle Taille et (ii) de leur sexe

<i>Score total</i>	<i>Sexe féminin</i>		<i>Sexe masculin</i>	
	<i>Non = 0</i>	<i>Oui=1</i>	<i>Non = 0</i>	<i>Oui=1</i>
0	10	0	0	0
1	24	0	1	0
2	22	5	3	0
3	15	5	4	1
4	31	11	6	1
5	16	26	9	2
6	6	23	6	4
7	0	10	0	5

On peut également visualiser ce fonctionnement différentiel de l'item B1 sous forme graphique.

Figure 5.6 : Pourcentage de réponses affirmatives (oui) à l'item B1, en fonction (i) du sexe et (ii) du score total à l'échelle Taille.



Statistiquement, dans le cadre de la théorie classique du score vrai, la détection du fonctionnement différentiel d'un item peut être réalisée au départ du tableau 5.9 par l'intermédiaire du test d'indépendance χ^2 . Cependant, ce test exige au minimum 5 observations par cellule, ce qui peut constituer une contrainte majeure dans bon nombre de situations.

La régression logistique offre une alternative intéressante. La régression logistique s'apparente à la régression linéaire classique, si ce n'est que la variable dépendante est une variable dichotomique (codes 0 et 1). Les médecins, à titre d'exemple, y recourent régulièrement pour modéliser les risques d'une crise cardiaque ou d'un cancer. La variable dépendante indique si l'individu a ou n'a pas eu une crise cardiaque (0= n'a pas eu de crise cardiaque et 1= a eu une crise cardiaque). Parmi les variables indépendantes, on peut retrouver les différents facteurs de risques tels que l'âge, le poids, l'absence de pratique de sports, consommation de tabac, d'alcool..., régime alimentaire... La modélisation se réalise sur un échantillon et ultérieurement, on peut, connaissant les valeurs pour les différentes variables indépendantes, calculer la probabilité, pour un individu donné, de présenter un arrêt cardiaque.

Dans le cadre du fonctionnement différentiel des items d'un test ou d'un questionnaire, la réponse à un item, codée 0 ou 1, constitue la variable dépendante. Comme première variable indépendante, on retrouve le score total des individus, et comme deuxième variable indépendante, la caractéristique pour laquelle on souhaite déterminer l'impact sur l'item.

Appliquée aux données reprises dans le tableau 5.9, la régression logistique renvoie les résultats suivants :

Tableau 5.10 : Résultats de l'analyse de régression logistique pour l'identification d'un fonctionnement différentiel pour l'item B1¹⁶.

<i>Paramètres</i>	<i>Estimation</i>	<i>Erreur Type</i>	<i>Probabilité</i>
Intercept	-4,29	0,59	<0.0001
Score total	0,94	0,13	<0.0001
Sexe	-1,35	0,44	0.0022

Les résultats indiquent clairement que, sous contrôle du score total, la probabilité de réponse affirmative à l'item 1 diffère statistiquement entre les filles et les garçons. Au départ de l'équation, on peut calculer pour chaque individu la probabilité d'une réponse affirmative à l'item B1. Le tableau 5.11 reprend ces probabilités théoriques.

¹⁶ Mathématiquement, l'équation de la régression logistique peut s'écrire :

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1(score_total) + \beta_2(sexe)$$


Tableau 5.11 : probabilité théorique de réponse affirmative à l'item B1.

taille_tot	Filles	Garçons
0	0,014	
1	0,034	0,009
2	0,083	0,023
3	0,187	0,056
4	0,372	0,133
5	0,603	0,282
6	0,795	0,501
7	0,909	0,720

Comme l'indique clairement le tableau 5.11, à compétences égales, les filles ont une probabilité plus élevée que les garçons de répondre affirmativement à l'item B1. Cet item présente donc un DIF.

On peut enfin modéliser l'interaction entre les deux variables indépendantes (le score au test et la caractéristique individuelle, dans le cas présent : le genre de l'étudiant) dans la régression logistique. Dans ce cas, on teste si la discrimination varie entre les deux groupes. La figure 5.7 illustre la distinction entre ce qu'il est d'usage d'appeler un fonctionnement différentiel uniforme (partie de gauche) et un fonctionnement différentiel non uniforme (partie de droite).

Figure 5.7 : Fonctionnement différentiel de l'item uniforme et non uniforme.



L'abscisse représente la compétence des sujets et l'ordonnée, la probabilité de réussite à un item. Comme l'indique la figure 5.7, plus la compétence d'un sujet augmente, plus sa probabilité de réussite augmente aussi. L'inclinaison des courbes est proportionnelle à la discrimination de l'item. Plus un item discrimine les élèves, plus la pente de la courbe sera élevée et inversement.

La partie gauche du graphique présente un fonctionnement différentiel uniforme de l'item. En effet, on peut constater que les deux courbes sont parallèles, indiquant une discrimination identique entre les deux groupes. Par contre, on peut constater que l'item

présente un DIF uniforme, puisque à compétence égale, la probabilité de réussite à l'item pour un groupe est toujours supérieure à la probabilité de l'autre groupe.

La partie droite du graphique montre un DIF non uniforme. On peut constater que les deux courbes ne sont pas parallèles, la pente de l'une étant plus élevée que l'autre. Avant le croisement des deux courbes, à compétences égales, le premier groupe a une probabilité plus élevée de réussir l'item. Après le croisement, les probabilités s'inversent.

5.8. Conclusions

La popularité de la théorie classique du score vrai réside dans sa simplicité. Il s'agit d'un modèle linéaire entre la variable latente (le score vrai) et la variable manifeste (score observé). Par ailleurs, il ne nécessite pas de logiciels spécialisés.

En outre, ce modèle peut être mis en œuvre dans un grand nombre de situations (tests cognitifs, tests de personnalité, échelles de *Likert*...).

Ce modèle permet d'estimer la fidélité de la mesure et, par ailleurs, permet d'identifier aisément les items qui semblent ne pas convenir au construit.

Les limites essentielles de la théorie classique sont les suivantes :

1. Elle ne permet pas de modéliser la probabilité de réussite d'un individu particulier à un item donné ;
2. Elle ne propose pas de solutions satisfaisantes dans le cadre d'un plan d'évaluation incomplet.

6. Les modèles de réponse à l'item

6.1. Introduction

Depuis le début des années 60, les modèles de réponses à l'item (MRI¹⁷) ont connu un essor considérable et sont largement utilisés de nos jours dans des disciplines aussi variées que les sciences de l'éducation, la psychologie, la médecine

Comme l'indiquent Embretson et Reise (2000, p6), « *In fact, some new rules of measurement conflict directly with the old rules. IRT is based on fundamentally different principles than CTT*¹⁸. *That is, IRT is model-based measurement that controls various confounding factors in some comparisons by a more complete parameterization of the measurement situation* ». En effet, avec ces modèles, l'estimation de la performance des sujets dépend à la fois de leurs réponses mais également des propriétés psychométriques des items qui leur ont été administrés.

Dans la théorie classique du score vrai, le score observé d'un sujet dépend de sa performance mais également de la difficulté du test. En conséquence, avec un test facile, ce score sera élevé alors qu'il le sera moins avec un test difficile. En d'autres termes, la théorie classique du score vrai ne prend pas en considération les caractéristiques des items pour estimer la performance du sujet.

Dans les modèles de réponse à l'item, une ou plusieurs caractéristiques des items interviennent dans le calcul de l'estimation de la performance des sujets. Il devient dès lors possible de rapporter la performance des sujets à des tests partiellement différents sur un seul et même continuum et ainsi de les comparer.

Il existe de nombreux modèles de réponse à l'item que l'on peut principalement différencier selon les caractéristiques suivantes :

1. le nombre de paramètres utilisés pour caractériser les items (un, deux ou trois paramètres) ;
2. le nombre de dimensions latentes (modèles unidimensionnels ou multidimensionnels) ;
3. le nombre de catégories par réponse (réponses dichotomiques ou polytomiques) ;
4. la fonction mathématique utilisée (fonction *logit* ou fonction *probit*¹⁹).

Ce chapitre se centrera essentiellement sur le modèle dit de *Rasch*, modèle logistique à un seul paramètre. Les modèles unidimensionnels logistiques à deux et à trois paramètres y seront brièvement abordés.

¹⁷ en anglais, *Item Response Theory, IRT*

¹⁸ *Classical Test Theory*.

¹⁹ La fonction probit se définit par l'inverse de la fonction de répartition de la distribution normale

6.2. Le modèle de Rasch pour les items dichotomiques


6.2.1. Introduction

Supposons que l'on veuille estimer la performance d'un athlète au saut en hauteur. Cette compétence pourrait s'exprimer selon :

1. Son record individuel.
2. Son record individuel lors d'une compétition officielle et internationale.
3. Sa performance moyenne sur une période donnée.
4. Sa performance la plus fréquente sur une période donnée.
5. ...

La figure 6.1. présente le taux de réussite de deux athlètes en fonction de la hauteur de la barre.


Figure 6.1.: Taux de réussite en fonction de la hauteur du saut.



Les deux athlètes ont toujours réussi à franchir la barre placée à une hauteur de 165 cm. Ensuite, le taux de réussite diminue progressivement pour arriver à 0. Cependant, le taux de réussite du premier athlète commence à diminuer à une hauteur de 170 cm, à 185 cm pour le second.

Ces données peuvent être représentées selon un modèle de régression logistique. Ces analyses statistiques consistent à expliquer une variable dichotomique par une variable continue. Dans l'exemple donné, la variable continue traduira le succès ou l'échec d'un des deux athlètes en fonction de la hauteur du saut. Le résultat de cette analyse permettra alors d'estimer la probabilité de réussite en fonction de la hauteur. La figure 6.2. présente la probabilité de réussite en fonction de la hauteur de la barre pour chacun des deux athlètes.

Figure 6.2.: Probabilité de réussite en fonction de la hauteur du saut pour chacun des athlètes.



Ces deux fonctions modélisent la probabilité de réussite pour les deux athlètes. La courbe noire représente la probabilité de réussite du premier athlète et celle en gris, la probabilité de réussite du second.

Par analogie avec la convention appliquée au modèle de Rasch, on définit le niveau de performance par la hauteur à laquelle la probabilité de réussite du saut est de 0,50. Cela est logique puisque sous ce niveau, la probabilité de réussite est inférieure à la probabilité d'échec et inversement.

Dans l'exemple donné, la performance des deux athlètes est respectivement de 190 et 202,5 cm. Remarquez que dans la figure 1, la performance du premier athlète est directement observable alors que celle du second ne l'est pas, il faut l'estimer à partir du modèle. Le fait que la hauteur de la barre et la performance des athlètes soient exprimées sur la même échelle métrique constitue une propriété clé de ce genre d'approche.


La mise à l'échelle (étalonnage) des données cognitives selon le modèle de Rasch suit le même principe. La difficulté des items est analogue à la difficulté du saut. En outre, tout comme une tentative de saut peut avoir deux résultats possibles (réussite ou échec), la réponse d'un élève à un item donné peut être bonne ou mauvaise. Enfin, tout comme la performance de chacun des athlètes était définie au point où la probabilité de réussite était de 0,5, la performance/apptitude de l'élève est mesurée là où la probabilité de réussite est égale à 0,5.

6.2.2. Description du modèle de Rasch

Le modèle de Rasch, tout comme les autres modèles de réponse à l'item, crée un continuum sur lequel seront localisées à la fois la performance des élèves et la difficulté

de l'item, liées entre elles par une fonction probabilistique. Les élèves « faibles » et les items faciles seront situés sur la partie gauche du continuum ou de l'échelle, tandis que les élèves « forts » et les items difficiles seront à droite. La figure 6.3 présente la probabilité de réussite (courbe grise) et la probabilité d'échec (courbe noire) pour un item de difficulté 0.

Figure 6.3.: Probabilité de réussite à un item de difficulté 0 en fonction de l'aptitude de l'élève.



Comme le montre la figure 6.3., pour un item de difficulté 0 :

- un élève avec une aptitude de zéro a une probabilité de réussite de 0,5 et une probabilité d'échec de 0,5.
- un élève avec une aptitude de -2 a, lui, une probabilité de réussite d'un peu plus de 0,10 et une probabilité d'échec de 0,90. Mais cet élève aura une probabilité de réussite de 0,5 pour un item de difficulté -2.

D'un point de vue mathématique, la probabilité qu'un élève i , avec une aptitude β_i , fournisse une réponse exacte à un item j de difficulté δ_j est égale à :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = \frac{\exp(\beta_i - \delta_j)}{1 + \exp(\beta_i - \delta_j)}$$

La probabilité d'échec est donc égale à :

$$P(X_{ij} = 0 | \beta_i, \delta_j) = \frac{1}{1 + \exp(\beta_i - \delta_j)}$$

On peut aisément démontrer que :

$$P(X_{ij} = 1 | \beta_i, \delta_j) + P(X_{ij} = 0 | \beta_i, \delta_j) = 1$$

Cela signifie donc que la somme de la probabilité d'échec et de la probabilité de réussite est toujours égale à un. Les tableaux 6.1. à 6.5. présentent la probabilité de réussite d'élèves d'aptitudes diverses à des items de difficultés différentes.

Tableau 6.1.: Probabilité de réussite lorsque l'aptitude de l'élève est égale à la difficulté de l'item.

<i>Aptitude de l'élève</i>	<i>Difficulté de l'item</i>	<i>Probabilité de réussite</i>
-2	-2	0,50
-1	-1	0,50
0	0	0,50
1	1	0,50
2	2	0,50

Tableau 6.2.: Probabilité de réussite lorsque l'aptitude de l'élève est inférieure d'une unité à la difficulté de l'item.

<i>Aptitude de l'élève</i>	<i>Difficulté de l'item</i>	<i>Probabilité de réussite</i>
-2	-1	0,27
-1	-0	0,27
0	1	0,27
1	2	0,27
2	3	0,27

Tableau 6.3.: Probabilité de réussite lorsque l'aptitude de l'élève est supérieure d'une unité à la difficulté de l'item.

<i>Aptitude de l'élève</i>	<i>Difficulté de l'item</i>	<i>Probabilité de réussite</i>
-2	-3	0,73
-1	-2	0,73
0	-1	0,73
1	0	0,73
2	1	0,73

Tableau 6.4.: Probabilité de réussite lorsque l'aptitude de l'élève est inférieure de deux unités à la difficulté de l'item.

<i>Aptitude de l'élève</i>	<i>Difficulté de l'item</i>	<i>Probabilité de réussite</i>
-2	0	0,12
-1	1	0,12
0	2	0,12
1	3	0,12
2	4	0,12

Tableau 6.5.: Probabilité de réussite lorsque l'aptitude de l'élève est supérieure de deux unités à la difficulté de l'item.

<i>Aptitude de l'élève</i>	<i>Difficulté de l'item</i>	<i>Probabilité de réussite</i>
-2	-4	0,88
-1	-3	0,88
0	-2	0,88
1	-1	0,88
2	0	0,88

On peut observer que :

1. Lorsque l'aptitude de l'élève est égale à la difficulté de l'item, la probabilité de réussite est toujours égale à 0,5, quel que soit l'endroit où se situent l'aptitude de l'élève et la difficulté de l'item sur le continuum.
2. Si la difficulté de l'item est supérieure d'une unité Rasch (appelée logit) à l'aptitude de l'élève, la probabilité de réussite sera alors toujours égale à 0,27, quel que soit l'endroit où se situe l'aptitude de l'élève sur le continuum.
3. Si l'aptitude de l'élève est supérieure d'un logit à la difficulté de l'item, la probabilité de réussite sera toujours égale à 0,73, quel que soit l'endroit où se situe l'aptitude de l'élève sur le continuum.
4. S'il y a une différence de deux unités (logits) entre l'aptitude de l'élève et la difficulté de l'item, les probabilités de réussite seront respectivement de 0,12 et de 0,88.

A partir de ces observations, il est évident que le seul facteur influençant la probabilité de réussite est la différence entre l'aptitude de l'élève et la difficulté de l'item sur le continuum de Rasch.

Ces exemples permettent également d'illustrer la symétrie de l'échelle. Lorsque l'aptitude de l'élève est inférieure d'un logit à la difficulté de l'item, la probabilité de réussite est alors de 0,27, ce qui est inférieur de 0,23 à la probabilité de réussite quand l'aptitude et la difficulté sont égales. Symétriquement, lorsque l'aptitude de l'élève est supérieure d'un logit à la difficulté de l'item, la probabilité de réussite est de 0,73, ce qui est supérieur de 0,23 à la probabilité de réussite quand l'aptitude et la difficulté sont égales. De même, une différence de deux logits produira une variation de 0,38.

6.2.3. Calibration

Bien évidemment, dans un contexte réel, la réponse d'un élève sera soit exacte, soit erronée. Quelle est donc la signification de cette probabilité de réussite de 0,5 en termes de réponses correctes ou non ? Les énoncés suivants en sont une interprétation simple :

1. Si 100 élèves ayant chacun une aptitude de 0 doivent répondre à un item de difficulté 0, le modèle prévoit 50 réponses exactes et 50 erronées.
2. Si un élève ayant une aptitude de 0 doit répondre à 100 items, tous de difficulté 0, le modèle prévoit 50 réponses exactes et 50 erronées.

Comme décrit précédemment, le modèle de Rasch permet, via une fonction probabilistique, de situer l'aptitude des sujets et la difficulté des items sur un même continuum. Dans l'exemple relatif aux athlètes du saut en hauteur, ce continuum existe déjà : il s'agit du continuum physique de la hauteur en centimètres. En revanche, dans le cas des données cognitives, il faudra construire ce continuum. Par analogie, cela reviendrait donc à construire un continuum sur lequel la hauteur inconnue de la barre, c'est-à-dire la difficulté d'un item, serait située.

Il existe trois grandes méthodes d'estimation des paramètres d'items, à savoir (i) *Joint Maximum Likelihood*, (ii) *Marginal Maximum Likelihood* et (iii) *Conditional Maximum Likelihood*. Cependant, en raison de leur complexité mathématique, ces méthodes ne seront pas décrites ici.

Dans le cadre de ce chapitre, une méthode approchée d'estimation telle que décrite par Rasch (1960) sera décrite à travers un exemple emprunté à Embretson et Reise (pp 190-195). Cette méthode approchée donne d'ailleurs des résultats satisfaisants dans le cadre d'un plan de test complet. Néanmoins, pour les plans de test incomplets, une des trois méthodes précitées doit impérativement être utilisée.

Notons que les logiciels d'analyses de données selon les modèles de réponses à l'item permettent, de nos jours, d'éviter cette méthode approchée et ainsi de recourir à des méthodes plus sophistiquées et plus exactes, même dans le cadre d'un plan de test complet.

Le tableau 6.6 présente le pourcentage de réponses correctes d'un échantillon de 818 sujets à un test de 10 items, en fonction des scores obtenus.


Tableau 6.6. : Données de base pour la méthode heuristique d'estimation des paramètres

	Scores possibles au test de 10 items								
	1 (18)	2 (40)	3 (96)	4 (101)	5 (132)	6 (133)	7 (111)	8 (88)	9 (68)
Item 1	0.39	0.40	0.69	0.81	0.89	0.86	0.94	0.98	1.00
Item 2	0.22	0.57	0.63	0.75	0.85	0.91	0.91	0.97	0.96
Item 3	0.11	0.18	0.28	0.46	0.62	0.79	0.86	0.90	0.99
Item 4	0.00	0.13	0.38	0.52	0.61	0.74	0.87	0.93	0.97
Item 5	0.00	0.15	0.34	0.39	0.52	0.69	0.82	0.85	0.93
Item 6	0.11	0.18	0.14	0.30	0.34	0.54	0.60	0.80	0.91
Item 7	0.01	0.15	0.19	0.21	0.32	0.56	0.64	0.67	0.87
Item 8	0.01	0.01	0.16	0.25	0.39	0.32	0.54	0.61	0.87
Item 9	0.00	0.01	0.15	0.23	0.27	0.34	0.49	0.73	0.85
Item 10	0.00	0.10	0.01	0.01	0.19	0.24	0.32	0.57	0.66

Seuls les scores 1 à 9 sont repris car les scores nuls ou les scores parfaits ne peuvent intervenir dans le calcul de la difficulté des items. En effet, ces scores extrêmes n'apportent aucune information utile sur les différences entre items puisque les sujets ayant des scores de 0 ou de 10 ont respectivement échoué et réussi à tous les items.

Pour le score 1, 39 pourcents des individus ont réussi l'item le plus facile, dénommé item 1. Comme on peut aisément le constater par l'intermédiaire du tableau 6.6 ou de la figure 6.4, la probabilité de réussite augmente au fur et à mesure que le score de l'individu augmente.

Figure 6.4 : Pourcentage de réussite à trois items selon le score des individus



Dans un premier temps, les pourcentages de réussite doivent être transformés en *logit*. Mathématiquement, la fonction *logit* s'écrit :

$$\text{Logit}(p) = \ln\left(\frac{p}{1-p}\right)$$

Il s'agit donc du logarithme népérien de p, divisé par 1-p. Le tableau 6.7 présente la correspondance entre quelques valeurs de p et leur transformation en *logit*.

Tableau 6.7 : Table de conversion des pourcentages de réussite en *logit*.

P	Logit(P)
0,1	-2,20
0,2	-1,39
0,3	-0,85
0,4	-0,41
0,5	0,00
0,6	0,41
0,7	0,85
0,8	1,39
0,9	2,20

Le tableau 6.8 présente la conversion en *logit* des pourcentages de réussite, par item et par score.

Tableau 6.8 : Conversion en *logit* des pourcentages de réussite, par item et par score.

	Score 1	Score 2	Score 3	Score 4	Score 5	Score 6	Score 7	Score 8	Score 9	Moyenne	Difficulté Rasch
Item 1	-0,45	-0,41	0,80	1,45	2,09	1,82	2,75	3,89	4,84	1,87	-1,92
Item 2	-1,27	0,28	0,53	1,10	1,73	2,31	2,31	3,48	3,18	1,52	-1,57
Item 3	-2,09	-1,52	-0,94	-0,16	0,49	1,32	1,82	2,20	4,60	0,63	-0,68
Item 4	-3,48	-1,90	-0,49	0,08	0,45	1,05	1,90	2,59	3,48	0,41	-0,46
Item 5	-3,48	-1,73	-0,66	-0,45	0,08	0,80	1,52	1,73	2,59	0,04	-0,10
Item 6	-2,09	-1,52	-1,82	-0,85	-0,66	0,16	0,41	1,39	2,31	-0,30	0,25
Item 7	-3,48	-1,73	-1,45	-1,32	-0,75	0,24	0,58	0,71	1,90	-0,59	0,54
Item 8	-3,48	-4,60	-1,66	-1,10	-0,45	-0,75	0,16	0,45	1,90	-1,06	1,01
Item 9	-3,48	-4,60	-1,73	-1,21	-0,99	-0,66	-0,04	0,99	1,73	-1,11	1,06
Item 10	-3,48	-2,20	-4,60	-4,60	-1,45	-1,15	-0,75	0,28	0,66	-1,92	1,87
Moyenne	-2,68	-1,99	-1,20	-0,71	0,05	0,51	1,06	1,77	2,72	-0,05	
Compétence Rasch	-2,73	-2,04	-1,25	-0,76	0,00	0,46	1,01	1,72	2,67		

Les moyennes des *logits* sont ensuite calculées, par item et par score. Le calcul des moyennes ne prend pas en considération le nombre d'individus par colonne. Enfin, la moyenne générale, calculée au départ de la moyenne des items, est égale à -0,05.

Une moyenne ajustée par item est ensuite calculée, il s'agit de la moyenne générale moins la moyenne de l'item. Ainsi, pour l'item 1, on obtient : $-0,05 - 1,87 = -1,92$. Il reste finalement à calculer l'estimation de la compétence des sujets. Cette compétence *Rasch* s'obtient en ajoutant la moyenne générale à la moyenne des *logits* des items pour un score donné. Ainsi, pour le score 1, elle sera de $-2,68 + (-0,05) = -2,73$.

Comme l'indiquent les résultats présentés dans le tableau 6.8, tous les sujets qui obtiennent un score de 1 se voient attribuer la même compétence *Rasch*, et ce, indépendamment des items réussis. Ainsi, un sujet qui obtient un score de 1 se verra attribuer le score *Rasch* de -2,73, qu'il ait réussi l'item le plus facile ou l'item le plus difficile.

Le calcul de l'estimation de la compétence *Rasch* par la méthode du maximum de vraisemblance permet de mieux cerner pourquoi il en est ainsi. De plus, cette description permet également de mieux comprendre l'une des conditions fondamentales de l'utilisation des modèles de réponse à l'item, à savoir l'*indépendance locale des items*.

6.2.4. Calcul des scores des élèves par maximum de vraisemblance

Précédemment, il était mentionné que la probabilité qu'un élève i , avec une aptitude β_i , fournisse une réponse exacte à un item j de difficulté δ_j est égale à :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = \frac{\exp(\beta_i - \delta_j)}{1 + \exp(\beta_i - \delta_j)}$$

La probabilité d'échec est égale à :

$$P(X_{ij} = 0 | \beta_i, \delta_j) = \frac{1}{1 + \exp(\beta_i - \delta_j)}$$

Le modèle de Rasch fait l'hypothèse que les items sont indépendants, ce qui signifie que la probabilité de donner une réponse exacte ne dépend pas des réponses données aux autres items. Par conséquent, la probabilité d'observer un pattern de réponses donné est égale au produit des probabilités de chaque item.

Considérons un test composé de quatre items de difficultés : -1, -0,5, 0,5 et 1. Seize patterns différents de réponses peuvent être obtenus. Le tableau 6.9. présente ces 16 combinaisons.

Tableau 6.9.: Combinaisons de réponses possibles pour un test composé de 4 items.

<i>Score brut</i>	<i>Combinaisons de réponse</i>
0	(0,0,0,0)
1	(1,0,0,0), (0,1,0,0), (0,0,1,0), (0,0,0,1)
2	(1,1,0,0), (1,0,1,0), (1,0,0,1), (0,1,1,0), (0,1,0,1), (0,0,1,1)
3	(1,1,1,0), (1,1,0,1), (1,0,1,1), (0,1,1,1)
4	(1,1,1,1)

Pour toute aptitude élève d'aptitude β_i , il est possible de calculer la probabilité de tous les patterns de réponses. Calculons la probabilité du pattern de réponses (1, 1, 0, 0) pour trois élèves d'aptitudes -1, 0, 1.

Tableau 6.10.: Probabilité de la combinaison de réponses (1, 1, 0, 0) pour trois aptitudes d'élèves.

			$\beta_i = -1$	$\beta_i = 0$	$\beta_i = 1$
Item 1	$\delta_1 = -1$	Réponse=1	0,50	0,73	0,88
Item 2	$\delta_2 = -0,5$	Réponse=1	0,38	0,62	0,82
Item 3	$\delta_3 = 0,5$	Réponse=0	0,82	0,62	0,38
Item 4	$\delta_4 = 1$	Réponse=0	0,88	0,73	0,50
Probabilité d'obtenir la combinaison de réponses.			0,14	0,21	0,14

Le premier élève a une probabilité de réussir le premier item égale à :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = P(X_{1,1} = 1 | -1, -1) \frac{\exp(-1 - (-1))}{1 + \exp(-1 - (-1))} = 0,5$$

Le premier élève a une probabilité de réussir le deuxième item égale à :

$$P(X_{ij} = 1 | \beta_i, \delta_j) = P(X_{1,2} = 1 | -1, -0,5) \frac{\exp(-1 - (-0,5))}{1 + \exp(-1 - (-0,5))} = 0,38$$

Le premier élève a une probabilité d'échouer au troisième item égale à :

$$P(X_{ij} = 0 | \beta_i, \delta_j) = P(X_{1,3} = 0 | -1, 0,5) \frac{1}{1 + \exp(-1 - 0,5)} = 0,82$$

Le premier élève a une probabilité d'échouer au quatrième item égale à :

$$P(X_{ij} = 0 | \beta_i, \delta_j) = P(X_{1,4} = 0 | -1, 1) \frac{1}{1 + \exp(-1 - 1)} = 0,88$$

Étant donné que ces quatre items sont considérés comme indépendants, la probabilité du pattern de réponses (1, 1, 0, 0) pour un élève d'aptitude $\beta_i = -1$ est égale à :


$$0,50 * 0,38 * 0,82 * 0,88 = 0,14.$$

Selon les difficultés des items, un élève avec une aptitude $\beta_i = -1$ a donc 14 chances sur 100 de fournir une réponse exacte aux items 1 et 2 et une réponse erronée aux items 3 et 4. De manière similaire, un élève avec une aptitude $\beta_i = 0$ a une probabilité de 0,21 de

fournir la même combinaison de réponses et un élève avec une aptitude de $\beta_i=1$, une probabilité de 0,14.


Ce procédé peut s'appliquer à un large éventail d'aptitudes d'élèves et à toutes les combinaisons de réponses possibles. Sur la base des mêmes items que ceux de l'exemple précédent, la figure 6.5. présente la probabilité d'observer le pattern de réponses (1, 1, 0, 0) pour toutes les aptitudes d'élèves entre -6 et +6. Comme on peut le voir, la valeur la plus probable est celle qui correspond à une aptitude de 0. Le modèle de Rasch estimera donc l'aptitude de tous les élèves ayant une combinaison de réponses (1, 1, 0, 0) comme étant de 0.

Figure 6.5.: Probabilités pour le pattern de réponse (1, 1, 0, 0)



La figure 6.6 présente la distribution des probabilités de toutes les combinaisons de réponses pour un seul item correct. Comme on peut le voir dans le tableau 6.9, il y a 4 combinaisons de réponses où un seul item est correct : (1,0,0,0), (0,1,0,0), (0,0,1,0), (0,0,0,1)

Figure 6.6.: Probabilités de combinaisons de réponses pour un score brut de 1.



La figure 6.6 montre clairement que :

1. Pour tous les élèves qui n'ont réussi qu'un seul item, la combinaison de réponses la plus probable est (1,0,0,0) et la moins probable est (0,0,0,1). Lorsqu'un élève ne fournit qu'une seule réponse exacte, on s'attend davantage à ce que cette réponse exacte soit donnée pour l'item le plus facile (l'item 1) que pour l'item le plus difficile (l'item 4).
2. Quelle que soit la combinaison de réponses, la valeur la plus probable correspond à une même valeur pour l'aptitude des élèves. Par exemple, l'aptitude des élèves la plus probable pour la combinaison de réponses (1,0,0,0) est d'environ -1,25. Cette valeur correspond également à l'aptitude des élèves pour les autres combinaisons de réponses possibles.

Le modèle de Rasch donnera donc une valeur de -1,25 pour tout élève qui n'a fourni qu'une réponse exacte, quel que soit l'item auquel il a répondu correctement.

De même, comme le montrent les figures 6.7. et 6.8. :

1. Pour deux items corrects sur quatre, la combinaison de réponses la plus probable est (1,1,0,0).
2. L'aptitude des élèves la plus probable est toujours la même quelle que soit la combinaison de réponses comprenant deux réponses exactes (0 dans ce cas).
3. Pour trois items corrects sur quatre, la combinaison de réponses la plus probable est (1,1,1,0).
4. L'aptitude des élèves la plus probable est toujours la même quelle que soit la combinaison de réponses comprenant trois réponses exactes (+1,25 dans ce cas).

Figure 6.7.: Probabilités de patterns de réponses pour un score brut de 2.






Figure 6.8.: Probabilités de patterns de réponses pour un score brut de 3.



Ce type d'estimation des aptitudes selon le modèle de Rasch est habituellement appelé estimation par maximum de vraisemblance. Comme le montrent les figures précédentes, à chaque score brut correspond un et un seul maximum de vraisemblance.

La figure 6.9 présente la probabilité d'observer les 5 combinaisons de réponses les plus probables (à savoir, (0,0,0,0), (1,0,0,0), (1,1,0,0), (1,1,1,0) et (1,1,1,1)) en fonction de la compétence des sujets.

Figure 6.9: Probabilités des 5 combinaisons de réponses les plus probables.



Comme le montre la figure 6.9., le modèle de Rasch ne peut estimer correctement l'aptitude des élèves qui ne fournissent aucune bonne réponse ou que des réponses correctes. En effet, dans ces deux cas, les maxima de vraisemblance se situent respectivement à $-\infty$ ou à $+\infty$. Pour mieux comprendre ces deux cas particuliers, imaginons les situations suivantes :

1. Un élève qui obtiendrait 0 à un test de mathématiques de deuxième master en mathématiques peut très bien se trouver en deuxième master en mathématiques ou en première secondaire.
2. Un élève qui obtiendrait le maximum à un test de mathématiques de première année primaire pourrait se trouver en première secondaire ou en deuxième master en mathématiques

Le modèle de Rasch, dans ces deux cas précis, procède par extrapolation sous l'hypothèse que ces élèves appartiennent à la même population que les autres élèves.

6.2.5. Calcul des scores des élèves dans le cas de plans de test incomplets

Pour rappel, on désigne par plan incomplet, un plan de test où différents sous-ensembles d'items sont attribués aux élèves. Les principes énoncés dans la section précédente pour

calculer l'estimation de l'aptitude individuelle de chaque élève restent applicables dans le cas de plans incomplets.


Supposons que deux élèves d'aptitudes -1 et 1 doivent répondre à 2 des quatre items présentés dans le tableau 6.8. L'élève avec l'aptitude $\beta_i = -1$ doit répondre aux deux premiers items (les deux items les plus faciles) et l'élève avec l'aptitude $\beta_i = 1$ doit répondre aux deux derniers items (les deux items les plus difficiles). Ces deux élèves ont donné une bonne réponse à leur premier item respectif mais ont échoué au second.

Tableau 6.11.: Probabilités de combinaison de réponses (1,0) pour deux élèves d'aptitudes différentes dans le cadre d'un plan de test incomplet.

			$\beta_i = -1$	$\beta_i = 1$
Item 1	$\delta_1 = -1$	Réponse=1	0.50	
Item 2	$\delta_2 = -0.5$	Réponse=0	0.62	
Item 3	$\delta_3 = 0.5$	Réponse=1		0.62
Item 4	$\delta_4 = 1$	Réponse=0		0.50
Pattern de réponses			0.31	0.31

Les deux combinaisons ont une probabilité de 0,31 que ce soit pour une aptitude de -1 ou de 1. Comme précédemment, ces probabilités peuvent être calculées pour un large éventail d'aptitudes des élèves. La figure 6.10. présente les probabilités de combinaison de réponses (1,0) pour le test facile (ligne bleue) et pour le test difficile (ligne rose).

Figure 6.10: Vraisemblance de combinaison de réponses pour un test facile et un test difficile.



D'après la figure 6.10, pour chaque élève qui a réussi un item du test facile, le modèle estimera son aptitude à -0,75, et pour chaque élève ayant réussi un item du test difficile, le modèle estimera son aptitude à 0,75. Si les scores bruts avaient été utilisés en tant qu'estimations de l'aptitude de l'élève, nous aurions obtenu 1 sur 2 (soit 0,5) dans les deux cas.

Pour résumer, lors de leur estimation, les scores bruts ne tiennent pas compte de la difficulté de l'item, ce qui rend leur interprétation dépendante des difficultés des items. En revanche, le modèle de Rasch utilise le nombre de réponses exactes ainsi que les difficultés des items administrés à un élève donné pour estimer son aptitude. Le score obtenu selon ce modèle peut donc être interprété indépendamment des difficultés des items. Tant que tous les items peuvent être situés sur le même continuum, le modèle de Rasch peut générer des estimations des aptitudes des élèves totalement comparables, même dans le cas où les élèves sont testés à partir de différents sous-ensembles d'items. Remarquez, cependant, que la validité des scores des élèves obtenus selon le modèle de Rasch dépend de la connaissance précise des difficultés des items.

Cette possibilité des modèles de réponse à l'item de rapporter des scores sur un seul continuum pour des plans de tests incomplets est particulièrement intéressante pour résoudre le problème des données manquantes dans le cadre des échelles de Likert. Prenons un exemple au départ de l'échelle d'engagement à la lecture de PISA 2000

présentée dans le chapitre sur la théorie classique du score vrai et reprise à la figure 6.11. Supposons qu'un individu n'ait pas répondu aux items g et h. Comment peut-on alors calculer un score qui soit comparable aux scores des individus qui ont répondu à l'ensemble des items ?

Figure 6.11. : Échelle d'engagement à la lecture (PISA2000)

Q 1 Dans quelle mesure êtes-vous d'accord avec les affirmations suivantes à propos de la lecture ?
(Ne cochez qu'une seule case par ligne.)

	Pas du tout d'accord	Pas d'accord	D'accord	Tout à fait d'accord
a) Je ne lis que si j'y suis obligé(e).....	☐	☐	☐	☐
b) La lecture est un de mes loisirs favoris.	☐	☐	☐	☐
c) J'aime parler de livres avec d'autres personnes.	☐	☐	☐	☐
d) J'ai du mal à finir les livres.	☐	☐	☐	☐
e) Je suis content(e) quand je reçois un livre en cadeau.....	☐	☐	☐	☐
f) Pour moi, la lecture est une perte de temps.....	☐	☐	☐	☐
g) J'aime aller dans un librairie ou une bibliothèque.	☐	☐	☐	☐
h) Je ne lis que pour trouver les informations dont j'ai besoin.	☐	☐	☐	☐

Avec la théorie classique du score vrai, deux possibilités peuvent être envisagées. Voyons en quoi elles ne peuvent garantir la comparabilité :

1. Calcul de la moyenne pour les seuls items répondus : pour démontrer que cette solution ne garantit pas la comparabilité, prenons la situation suivante : à un test donné, un individu ne répond qu'aux seuls items pour lesquels il est certain de sa réponse. En calculant la moyenne, il obtiendra un score de 1 alors que les autres individus obtiendront probablement moins que 1 puisqu'ils auront commis des erreurs en répondant aux items plus difficiles.
2. Remplacement des données manquantes par l'indice de difficulté de la question : on ne garantit pas non plus la comparabilité puisque la probabilité de réussite d'un élève faible à une question difficile est probablement inférieure à l'indice de difficulté.

6.2.6. Conditions optimales pour les items d'ancrage


Lorsque divers tests sont utilisés, certaines conditions doivent être respectées. Tout d'abord, les données recueillies lors des différents tests doivent pouvoir être ancrées. S'il n'y avait pas d'ancrage, les données recueillies lors de deux tests différents ne pourraient être mises sur une même échelle. Habituellement, l'ancrage est effectué par l'attribution d'items communs aux divers tests à différents élèves ou par l'attribution des différents tests à un même élève.

Supposons qu'un chercheur veuille estimer l'augmentation de la performance en lecture entre des élèves de 2^{ème} année et des élèves de 4^{ème} année. Deux tests seront développés et chacun ciblera le niveau de performance attendu pour chacune des populations. Pour garantir que les deux tests pourront être étalonnés sur le même continuum, quelques-uns

des items difficiles de deuxième année seront inclus dans le test de quatrième. Supposons qu'il s'agisse des items 7, 34, 19, 23 et 12.

La figure 6.12 représente le processus d'ancrage des items. La partie de gauche de cette figure présente les résultats de l'étalonnage des données du test de deuxième année, centrés à zéro. Pour l'étalonnage des données de quatrième année, le point de référence sera la difficulté des items d'ancrage en deuxième année. La difficulté des autres items administrés en quatrième année sera déterminée en fonction de ce point de référence, comme le montre la partie de droite de la figure.

Figure 12: Ancrage des items selon le modèle de Rasch



En suivant ce processus d'ancrage, les difficultés des items seront localisées sur un seul et même continuum. Les aptitudes des élèves de 2^{ème} et 4^{ème} années seront donc également situées sur un même continuum.

Pour pouvoir estimer de façon précise l'augmentation de la performance entre les élèves de 2^{ème} et 4^{ème} année, le chercheur s'assurera que la position des items d'ancrage est semblable dans les deux tests et ce, pour éviter que l'effet de fatigue puisse influencer différemment la performance.

6.2.7. Erreur de mesure

A l'inverse du modèle de la théorie classique pour laquelle l'erreur de mesure est uniquement fonction de la variance totale et de la fidélité du test, l'erreur de mesure dans le cadre des modèles de réponses à l'item est fonction de la compétence des sujets, de la difficulté des items et du nombre d'items. Mathématiquement, l'erreur de mesure dans le cadre du modèle de Rasch est égale à :

$$ESM = \frac{1}{\sqrt{\sum_{i=1}^j p_i q_i}}$$

avec p_i et q_i les probabilités de réussite et d'échec à l'item i . Cette erreur est donc fonction :

1. du nombre d'items. En effet, plus le nombre d'items augmente, plus la somme sera grande et plus l'erreur de mesure sera petite ;
2. de la difficulté relative de l'item pour le sujet. En effet, le produit $p_i q_i$ sera le plus élevé si p_i est égal à 0,5.

6.2.8. Une illustration

Les données issues de la mesure de la taille des étudiants de psychologie ont été mises à l'échelle avec le modèle de *Rasch*. La figure 6.12 présente les 7 items dichotomiques concernés par cette analyse.

Une partie des résultats de l'analyse d'items est reprise dans la figure 6.13. Pour chaque item, on dispose :

1. par catégorie de réponse :
 - a. du nombre d'individus,
 - b. du pourcentage que ces individus représentent ;
 - c. de la corrélation bisériale de point et d'un test t pour déterminer si cette corrélation diffère significativement de 0 ;
 - d. de la moyenne et de l'écart type sur le continuum de *Rasch* de la performance des individus;
2. par item :
 - a. de la difficulté *Rasch* de l'item ;

- b. d'une mesure d'ajustement de l'item au modèle de *Rasch* (Weighted MNSQ) dont la valeur doit être comprise entre 0,75 et 1.25
 - c. de la discrimination de l'item ;
- 3. pour l'ensemble du test :
 - a. du nombre d'individus repris dans l'analyse ;
 - b. du score moyen qui correspond à la moyenne des scores observés selon la théorie classique du score vrai ;
 - c. de l'écart type ;
 - d. de la variance ;
 - e. de l'erreur standard pour l'estimation de la moyenne ;
 - f. de l'erreur standard de mesure ;
 - g. de l' α de Cronbach.

Enfin, la figure 6.14 présente une partie des résultats spécifiques au modèle de *Rasch*. On dispose pour les différents items repris dans l'analyse :

- 1. de l'indice de difficulté *Rasch* ;
- 2. de son erreur standard ;
- 3. des indices d'ajustement (pondérés et non pondérés) avec un intervalle de confiance et un test t ;

La figure 6.14 comprend également une représentation graphique de la distribution de la difficulté des items et de la distribution de la performance des individus sur le continuum de *Rasch*.

Figure 6.12. : Items dichotomiques pour la mesure de la taille

		<i>Oui</i>	<i>Non</i>
B1)	Quand j'étais jeune, on me donnait toujours plus que mon âge.	☐ ₁	☐ ₂
B2)	On a déjà dit de moi « <i>tout ce qui est petit est joli</i> ».	☐ ₁	☐ ₂
B3)	Je parviens à voir la scène sans aucune difficulté dans un concert en plein air	☐ ₁	☐ ₂
B4)	Si je ne prends pas une grande taille pour mes chemises, les manches seront trop courtes.	☐ ₁	☐ ₂
B5)	Dans les toilettes publiques, il arrive que les miroirs soient placés trop haut.	☐ ₁	☐ ₂
B6)	Debout dans un bus bondé, je ne vois que des dos et des sacs.	☐ ₁	☐ ₂
B7)	J'ai toujours été dans les plus petits de ma classe.	☐ ₁	☐ ₂

Figure 6.13. : Analyse d'items

Item 1

item:1 (1)

Cases for this item 126 Discrimination 0.56

Item Threshold(s): 1.40 Weighted MNSQ 1.25

Item Delta(s): 1.40

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	82	65.08	-0.56	-7.56(.000)	-0.50	2.10
2	1.00	44	34.92	0.56	7.56(.000)	1.83	1.78

=====

Item 7

item:7 (7)

Cases for this item 126 Discrimination 0.77

Item Threshold(s): -1.02 Weighted MNSQ 0.84

Item Delta(s): -1.02

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	40	31.75	-0.77	-13.40(.000)	-1.88	1.60
2	1.00	86	68.25	0.77	13.40(.000)	1.33	1.77

=====

N 126

Mean 3.75

Standard Deviation 1.96


Variance 3.85

Standard error of mean 0.17

Standard error of measurement 0.94

Coefficient Alpha 0.77

Figure 6.14. : Indices de difficulté et d'ajustement et représentations graphiques des distributions



Il est également possible avec les modèles de réponse à l'item d'étudier le fonctionnement différentiel des items. Il suffit d'estimer de manière indépendante ou conjointe la difficulté des items pour les deux groupes et ensuite de comparer, item par item, la difficulté estimée pour le groupe 1 et la difficulté estimée pour le groupe 2. On peut également comparer la difficulté générale de l'item avec la difficulté spécifique à un groupe. La figure 6.15 reprend du fonctionnement différentiel des items en fonction du genre de l'étudiant pour les items B1 à b7.

Figure 6.15. : Estimation du fonctionnement différentiel des items

=====										
TERM 3: item*sexe										
VARIABLES				UNWEIGHTED FIT			WEIGHTED FIT			
item	sexe	ESTIMATE	ERROR^	MNSQ	CI	T	MNSQ	CI	T	
1	1	-0.941	0.125	1.75	(0.81, 1.19)	6.2	1.31	(0.82, 1.18)	3.1	
2	2	0.104	0.126	0.73	(0.81, 1.19)	-2.9	0.82	(0.82, 1.18)	-2.0	
3	3	0.529	0.128	0.73	(0.81, 1.19)	-3.0	0.98	(0.79, 1.21)	-0.2	
4	4	0.411	0.144	1.15	(0.81, 1.19)	1.4	0.96	(0.66, 1.34)	-0.1	
5	5	0.061	0.154	0.54	(0.81, 1.19)	-5.5	0.82	(0.65, 1.35)	-1.0	
6	6	0.213	0.136	0.68	(0.81, 1.19)	-3.6	0.94	(0.77, 1.23)	-0.5	
7	7	-0.377*	0.333	0.48	(0.81, 1.19)	-6.5	0.72	(0.79, 1.21)	-2.9	
1	1	0.941*	0.125	1.69	(0.57, 1.43)	2.7	1.37	(0.61, 1.39)	1.7	
2	2	-0.104*	0.126	0.71	(0.57, 1.43)	-1.4	1.07	(0.51, 1.49)	0.4	
3	3	-0.529*	0.128	0.83	(0.57, 1.43)	-0.8	0.88	(0.66, 1.34)	-0.7	
4	4	-0.411*	0.144	0.59	(0.57, 1.43)	-2.2	0.81	(0.61, 1.39)	-1.0	
5	5	-0.061*	0.154	0.13	(0.57, 1.43)	-6.6	1.21	(0.00, 3.28)	0.6	
6	6	-0.213*	0.136	0.55	(0.57, 1.43)	-2.4	1.41	(0.00, 2.15)	0.8	
7	7	0.377*	0.333	0.55	(0.57, 1.43)	-2.4	0.99	(0.46, 1.54)	0.1	

Ainsi, pour l'item B1, la différence entre l'indice de difficulté générale et l'indice de difficulté spécifique à la sous-population de filles s'élèvent à -0,941, avec une erreur type de 0,125. Cette différence est statistiquement significative. Cet item B1 est donc « plus facile » pour les filles, témoignant ainsi d'une proportion plus élevée de réponses affirmatives, comme nous l'avons déjà observé dans le chapitre précédent.

6.3. Extension du modèle de Rasch

6.3.1. Modèle de réponse à crédit partiel

Wright et Masters ont étendu le modèle d'origine de Rasch aux items polytomiques, ce modèle est généralement appelé le modèle à crédit partiel (PCM : Partial Credit Model) (Wright and Masters, 1982). Ce modèle permet de corriger les items en considérant que la réponse peut être correcte, partiellement correcte ou incorrecte.

Mathématiquement, dans le cadre d'un item codé 0,1,2, la probabilité de réussite

$$P(X_{ni} = 0) = \frac{1}{1 + \exp(\beta_n - \delta_j - t_{i1}) + \exp(2\beta_n - 2\delta_j - t_{i1} - t_{i2})}$$

$$P(X_{ni} = 1) = \frac{\exp(\beta_n - \delta_j - t_{i1})}{1 + \exp(\beta_n - \delta_j - t_{i1}) + \exp(2\beta_n - 2\delta_j - t_{i1} - t_{i2})}$$


$$P(X_{ni} = 2) = \frac{\exp(2\beta_n - 2\delta_j - t_{i1} - t_{i2})}{1 + \exp(\beta_n - \delta_j - t_{i1}) + \exp(2\beta_n - 2\delta_j - t_{i1} - t_{i2})}$$

t_{i1} représente l'accroissement de performance nécessaire pour passer du score 0 au score 1.

t_{i2} représente l'accroissement de performance nécessaire pour passer du score 1 au score 2.

La courbe caractéristique de l'item à crédit partiel est présentée à la figure 6.16

Figure 6.16.: courbe caractéristique d'un item à crédit partiel 0,1,2



Le modèle pour les items polytomiques peut également être appliqué aux données obtenues par des échelles de Likert. Dans ce cas, il n'y a bien évidemment pas de bonnes ou de mauvaises réponses mais les principes de base restent les mêmes : les réponses possibles peuvent être classées selon un certain ordre. Les données des questionnaires PISA sont étalonnées selon le modèle logistique à un paramètre pour les items polytomiques.

6.3.2. Autres modèles utilisant la Théorie de Réponse à l'Item

Les divers modèles se servant de la théorie de réponse à l'item se distinguent notamment par le nombre de paramètres utilisés pour décrire les items. Le modèle de Rasch est un modèle à un paramètre car les courbes caractéristiques des items ne dépendent que de la difficulté des items. Par contre, dans le modèle logistique à trois paramètres, les courbes des caractéristiques des items dépendent de : i) le paramètre de difficulté des items, ii) le paramètre de discrimination des items et iii) un paramètre lié à la probabilité de « deviner » la bonne réponse (guessing). Ce dernier paramètre tient compte du fait que, lors d'un test à choix multiple, tous les élèves ont une certaine chance de répondre correctement à l'item, peu importe la difficulté de l'item.


La formule suivante permet de calculer la probabilité d'un élève, en fonction de sa performance β de réussir un item à choix multiple, en fonction de sa difficulté δ , de sa discrimination a , et du paramètre de guessing, C :

$$P(X_{ij} = 0 | \beta_i, \delta_j, a_j, c_j) = c_j + \frac{1 - c_j}{1 + \exp(-a_j(\beta_i - \delta_j))}$$

La figure 6.17 représente graphiquement :

- la courbe caractéristique de l'item selon un modèle à 1 paramètre : sa difficulté δ_j (en rouge).
- un modèle à 2 paramètres : sa difficulté δ_j , sa discrimination a_i (en bleu).
- un modèle à trois paramètres : sa difficulté δ_j , sa discrimination a_j et son paramètre de guessing c_j (en vert).

Figure 6.17.: Courbes caractéristiques pour modèle à 1 paramètre, à 2 paramètres et à 3 paramètres



6.4. Conclusion

Le modèle de *Rasch* a été conçu pour construire un continuum symétrique sur lequel la difficulté des items et les aptitudes de l'élève sont localisées. La difficulté de l'item et l'aptitude de l'élève sont reliées par une fonction logistique. Grâce à cette fonction, il est possible de calculer la probabilité de répondre correctement à un item.

De plus, puisque ce lien probabiliste existe, il n'est pas nécessaire d'administrer l'entièreté de la batterie d'item à chaque élève. Dans le cas où des items d'ancrage sont garantis, le modèle de *Rasch* pourra créer une échelle sur laquelle chaque élève et chaque items seront situés. Cette dernière caractéristique du modèle de *Rasch* est une des raisons principales pour lesquelles le modèle de *Rasch* est devenu la référence dans les *surveys* internationaux en éducation.

7. La validité

Selon Legendre (1993, cité par Bernier & Pietrulenwicz, p. 179), « *la validité est la capacité d'un instrument à mesurer réellement ce qu'il doit mesurer, selon l'utilisation que l'on veut en faire* ». La validité peut donc être définie comme étant :

1. Le degré auquel un test mesure un trait latent ;
2. La relation entre les scores obtenus à un test et une mesure à un critère externe.

A ces deux définitions correspondent des conceptions différentes de la validité : validité de contenu (cf. 7.3) et validité théorique (cf. 7.4) pour la première acceptation, validité prédictive (cf. 7.2) pour la seconde.

Bernier & Pietrulenwicz (2006, p. 179) énumèrent les questions suivantes auxquelles le concept de validité essaie de répondre :

1. *Le type de test utilisé convient-il vraiment à l'usage auquel il est destiné ?*
2. *Quels sont les traits mesurés par le test ?*
3. *Le test mesure-t-il ce qu'il est censé mesurer ?*
4. *Les informations fournies par le test sont-elles utiles pour prendre des décisions ?*
5. *Quelles interprétations peut-on faire des scores obtenus au test ?*
6. *Quelles prédictions peut-on tirer des scores obtenus au test ?*
7. *Quel degré de variance découle de la variable mesurée par le test ?*

La validité d'un test doit toujours être contextualisée. Un test peut s'avérer valide pour prédire les résultats scolaires d'étudiants universitaires mais non valide pour prédire la réussite professionnelle des étudiants universitaires diplômés.

7.1. Relation entre la fidélité et la validité

Selon la théorie classique, la variance des scores observés est égale à la somme de la variance des scores vrais et de la variance des scores d'erreurs. La relation qu'un test peut avoir avec une variable externe, comme par exemple la réussite universitaire ou la réussite professionnelle, permet de décomposer la variance vraie en deux composantes : la composante vraie commune avec le critère externe et la composante vraie unique. Pour rappel l'erreur devant être aléatoire, elle ne peut corrélérer avec une variable externe.

Par ailleurs, la mesure de cette variable externe, dénommée également critère, est entachée d'erreurs. Ces erreurs de mesure au niveau du test X et du critère Y conduisent à sous-estimer la corrélation qui existe entre les deux variables latentes. En effet, si $E1$ et $E2$ représentent respectivement les erreurs sur les variables X et Y , alors :

$$\text{cov}(X + E1, Y + E2) = \text{cov}(X, Y) + \text{cov}(X, E2) + \text{cov}(E1, Y) + \text{cov}(E1, E2)$$

Les postulats 2 et 3 permettent de conclure que les covariances qui incluent un terme d'erreur sont automatiquement égales à 0. Il s'ensuit que :

$$\text{cov}(X + E1, Y + E2) = \text{cov}(X, Y)$$

Par contre, les variances et par conséquent, les écarts types sont surestimés de par les erreurs de mesure. Il s'ensuit que :

$$\rho_{(X+E1, Y+E2)} = \frac{\text{cov}(X, Y)}{\sqrt{(\sigma_{(X)}^2 + \sigma_{(E1)}^2)(\sigma_{(Y)}^2 + \sigma_{(E2)}^2)}}$$

Le numérateur reste inchangé mais le dénominateur augmente en raison des erreurs de mesure $E1$ et $E2$. Il s'ensuit que la corrélation entre les variables observées sera plus petite que la corrélation entre les deux variables latentes, c'est la raison pour laquelle on parle de sous-estimation de la corrélation des variables latentes.

La corrélation entre les deux variables latentes, s'obtient comme suit : si ∞ représente la variable latente mesurée par le test X et ω représente la variable latente du critère externe, alors :

$$\rho_{(\infty, \omega)} = \frac{\rho_{(X, Y)}}{\sqrt{\rho_{(X, X)} \rho_{(Y, Y)}}}$$

Imaginons maintenant que ∞ et ω corréleront à 1.00 et que les fidélités de X et de Y soient toutes les deux de 0,90. Sur base de la formule ci-dessus, la corrélation entre X et Y serait de 0,90. En effet,

$$\rho_{(\infty, \omega)} = \frac{\rho_{(X, Y)}}{\sqrt{\rho_{(X, X)} \rho_{(Y, Y)}}} = \frac{0,90}{\sqrt{0,90 * 0,90}} = 1$$

A partir de cette formule, on peut aisément déduire que $\rho_{(X, Y)} \leq \rho_{(X, X)}$. En d'autres termes, la validité ne peut qu'être égale ou inférieure à la fidélité.

7.2. La validité prédictive

On utilise souvent les tests pour prédire des rendements à un critère externe. La validité prédictive peut être définie comme la capacité d'un test à prédire un critère. En pratique, on cherche à savoir si les scores obtenus à un test X permettent de prédire le rendement à un critère externe Y.

L'élément le plus important dans ce type de situation est sans aucun doute le critère externe puisque le test X est essentiellement, voire uniquement, développé pour prédire ce critère externe. Le contenu du test en lui-même est secondaire. Ainsi, les tests d'aptitudes scolaires servent à prédire les chances de réussite à l'école, les inventaires d'intérêts permettent de cerner les champs d'intérêts professionnels, les inventaires de

personnalité sont utiles pour détecter les désordres psychologiques qui pourraient mener à commettre tel acte ou prédisposer aux accidents, ...

La validité prédictive est souvent associée ou confondue avec la validité empirique et la validité concourante ou concomitante. En ce qui concerne la validité empirique, cette confusion vient du fait que la détermination de la validité prédictive exige toujours la collecte de données empiriques pour établir la relation entre les scores obtenus au test et les scores obtenus au critère externe.

Dans le cadre de la validité concourante (appelée aussi validité concomitante), le critère externe est un test déjà validé. En d'autres termes, on valide un test par la relation qu'il entretient avec un test déjà validé. La validité concourante se différencie également de la validité prédictive par le recueil simultané des données relatives au test X et au critère Y alors que, en ce qui concerne la validité prédictive, les données du critère Y sont recueillies bien plus tard. Ainsi, un test qui aurait pour objet de prédire la réussite universitaire doit attendre 4 ou 5 ans avant de pouvoir disposer des données relatives au critère externe Y.

7.2.1. Les caractéristiques de la mesure critère

On établit généralement la distinction entre le critère conceptuel et la mesure-critère. Le critère conceptuel est le critère que l'on cherche à mesurer, comme par exemple la réussite universitaire, et la mesure-critère est la façon dont on va opérationnaliser ce critère pour le mesurer. Cette opérationnalisation peut prendre plusieurs formes pour un même critère conceptuel. A titre d'exemple, la réussite à l'université constitue un critère conceptuel qui peut être mesuré par une mesure-critère comme la moyenne cumulée des notes de cours obtenues lors des études, ou par une autre mesure-critère comme le grade obtenu en dernière année.

La mesure critère doit posséder un certain nombre de propriétés :

1. La mesure-critère doit être pertinente, c'est-à-dire qu'elle doit prendre en considération les différents aspects fondamentaux du critère conceptuel. La réussite professionnelle ne peut pas seulement se mesurer par le niveau salarial. D'autres composantes tout aussi importantes doivent intervenir dans l'évaluation du critère ;
2. La mesure-critère doit être fidèle, au sens défini dans le chapitre 5 ;
3. La mesure-critère ne peut pas être contaminée. Ainsi, si un examinateur doit évaluer le critère externe auprès des sujets, la connaissance des scores au test pourrait induire l'évaluation de l'examineur et conduire ainsi à une surestimation de la validité (effet de type halo...)

Il existe quatre grandes catégories de mesure-critère :

1. Mesure directe du rendement (niveau salarial, masse des ventes, nombre d'accidents par mois...) ;
2. Rendement à un test ;

3. Appartenance à un groupe : les tests de personnalité sont souvent considérés comme valides s'ils aboutissent à une bonne classification des individus dans des groupes bien précis ;
4. Indices statistiques, de type coefficient de saturation dans le cadre d'analyses factorielles.

7.2.2. Méthodes pour déterminer la validité prédictive

Il existe trois grandes méthodes pour déterminer la validité prédictive :

1. Le coefficient de corrélation ;
2. L'indice d'efficacité ;
3. L'indice de séparation des groupes.

7.2.2.1. Le coefficient de corrélation

C'est la méthode la plus couramment utilisée. Il s'agit simplement de calculer la corrélation de *Bravais-Pearson* entre les scores au test X et les scores au critère externe Y.

Si la relation entre le test X et la variable Y n'est pas linéaire, les données seront transformées ou, d'autres méthodes corrélationnelles seront utilisées.

7.2.2.2. L'indice d'efficacité

Un test conçu dans une perspective prédictive aboutit généralement à une décision. Il est dès lors logique d'analyser la proportion de bonnes décisions prises à partir du test. Plus cette proportion est grande, plus le test est efficace ou valide.

Pour calculer l'indice d'efficacité, il suffit de classer les décisions suggérées par le test prédicteur en deux catégories mutuellement exclusives, de faire de même avec la mesure-critère et puis d'analyser les données du tableau ainsi construit. Cette répartition suppose l'existence d'un seuil ; au-delà duquel l'individu sera classé dans une catégorie, et en deçà duquel l'individu sera classé dans l'autre catégorie.

Tableau 7.1 : modèle pour déterminer l'indice d'efficacité

		Mesure-critère	
		<i>Echec</i>	<i>Réussite</i>
Test prédicteur	<i>Réussite</i>	A (+) (-) Inexacte	B (+) (+) Exacte
	<i>Echec</i>	C (-)(-) Exacte	D (-)(+) Inexacte

Au départ de ce tableau, il est possible de calculer deux indices.

Le premier indice est la proportion de bonnes décisions. Mathématiquement,

$$P = \frac{B + C}{A + B + C + D}$$

Il arrive parfois aussi que l'on s'intéresse uniquement aux bonnes décisions qui donneront des résultats positifs, tel le responsable des ressources humaines qui veut déterminer la proportion des personnes qu'il va engager qui effectueront correctement leur travail. Dans ce cas, l'indice d'efficacité sera égal à

$$P = \frac{B}{A + B}$$

7.2.2.3. L'indice de séparation des groupes

Une autre façon de déterminer la validité consiste à comparer au moins deux groupes définis selon la mesure-critère et de vérifier si le score prédictif moyen permet de distinguer les groupes.

Il s'agit ensuite de réaliser un test *t* de *student* pour déterminer si la différence est significative. Cependant, cette technique ne permet pas de déterminer l'ampleur de la relation qui unit le test X et la mesure-critère. De surcroît, il suffit d'augmenter la taille des échantillons pour que les différences observées deviennent significatives.

7.3. La validité de contenu

Lorsqu'un professeur veut évaluer les connaissances de ses étudiants dans une matière donnée, il doit construire un examen ou un test dont les questions constituent un échantillon représentatif de toute la matière. Il est alors confronté à un problème de validité de contenu, laquelle constitue une mesure du degré de représentativité de l'échantillon de questions. La question qui se pose ici est de savoir si le test reprend bien les différents aspects, tant au niveau des savoirs que des savoir-faire, de la matière ou du domaine qui est censé être évalué.

Ce type de validité est étudié au moyen d'une analyse rationnelle du contenu du test et elle est déterminée par un jugement de valeur. La décision est subjective, il n'y a pas d'indice numérique prédéfini.

Les spécialistes différencient la validité apparente et la validité logique :

1. La **validité apparente** est déterminée par le jugement d'un expert qui examine le test et conclut que celui-ci mesure vraiment le trait qu'il est censé mesurer ;
2. La **validité logique** ou d'échantillonnage est établie de façon plus concrète que la validité apparente. Elle se présente généralement sous la forme d'un tableau de spécifications qui peut, à titre d'exemple, croiser les savoirs et les savoir-faire.

Ce type de validité est à mettre en rapport avec la première étape du processus de la mesure, à savoir la définition du concept à mesurer.

7.4. La validité théorique

La validité théorique, aussi appelée la *validité de construit* ou *validité hypothético-déductive* a été proposée afin de pouvoir évaluer la validité d'une mesure en l'absence de critère et en l'absence d'univers d'items déterminé. Elle vise en fait à assurer l'existence de la variable latente mesurée et à en éclairer la signification.

A titre d'exemple, c'est la définition ou plutôt la théorie relative à l'intelligence ou à la personnalité qui conduit à définir opérationnellement un ensemble d'épreuves susceptibles de mesurer le niveau atteint par un sujet particulier sur l'échelle d'intelligence ou dans certains domaines de la personnalité. Parfois, on assiste même au processus inverse, à savoir que ce sont les résultats aux tests qui permettent de formaliser les théories. A cet égard, on peut se rappeler l'adage de Binet, à savoir, *l'intelligence, c'est ce que mon test mesure*.

On distingue généralement dans la validité théorique la validité convergente (ou intraconcepts) et la validité divergente (ou interconcepts).

Dans la **validité convergente**, on cherche à démontrer que les scores attribués aux sujets ne sont pas affectés par le processus de la mesure. Autrement dit, on s'attend à ce que deux mesures différentes du même concept aboutissent au même résultat. Pour vérifier la validité convergente, on va donc faire varier les sujets, les items, le modèle de mesure, le dispositif de collecte de données. Ce type de validité s'inscrit dans une problématique plus générale qui vise à éliminer du processus de la mesure tous les facteurs non pertinents.

Pour étudier la validité convergente, on peut recourir aux matrices *multitraits-multiméthodes* qui reprennent les corrélations entre la mesure de différentes variables latentes, recueillies selon des méthodes différentes. Imaginons par exemple trois concepts à mesurer :

1. estime de soi, noté A ;
2. sociabilité, noté B ;
3. contrôle de soi, noté C.

Ces concepts ou traits sont mesurés selon trois méthodes :

1. test papier crayon complété par l'élève ;
2. évaluation de l'enseignant ;
3. évaluation des parents.

Le tableau 7.2 reprend les différentes corrélations que l'on obtiendrait dans cette situation.

Tableau 7.2. Matrice multitraits-multiméthodes.

		<i>Méthode 1</i>			<i>Méthode 2</i>			<i>Méthode 3</i>		
		A1	B1	C1	A2	B2	C2	A3	B3	C3
Méthode 1	A1	0,89								
	B1	0,51	0,89							
	C1	0,38	0,37	0,76						
Méthode 2	A2	0,57	0,22	0,09	0,93					
	B2	0,22	0,57	0,10	0,68	0,94				
	C2	0,11	0,11	0,46	0,59	0,58	0,84			
Méthode 3	A3	0,56	0,22	0,11	0,67	0,42	0,33	0,94		
	B3	0,23	0,58	0,12	0,43	0,66	0,34	0,67	0,92	
	C3	0,11	0,11	0,45	0,34	0,32	0,58	0,58	0,60	0,85

Il existe quatre types de corrélations dans cette matrice :

1. **Même trait même méthode** (cellules rouges) : ces corrélations, situées sur la diagonale auraient dû être égales à 1. Cependant, ces valeurs ont été remplacées par une estimation de la fidélité de chacune de ces mesures. Ces corrélations doivent être les plus élevées. En effet, un trait devrait corrélérer davantage avec lui-même qu'avec n'importe quelle autre chose.
2. **Même trait, méthodes différentes** (cellules jaunes) : on s'attend à observer des corrélations élevées puisqu'un seul trait est mesuré et que l'on cherche à minimiser l'influence de la procédure de collecte des données. Il convient de noter que ces corrélations se situent sur des diagonales également.
3. **Différents traits, même méthode** (cellules vertes) : des corrélations élevées indiquent la présence d'une influence de la méthode sur les mesures, influence que l'on cherche par ailleurs à éviter. Il convient de noter que ces corrélations forment des triangles dans la matrice des données.
4. **Différents traits, différentes méthodes** (cellules blanches) : ces corrélations devraient être les plus faibles dans la matrice.

Pour que la validité convergente des mesures soit prouvée, il faut :

1. que les corrélations entre les mêmes traits mais selon des méthodes différentes soient élevées (cellules jaunes dans le tableau). Comme on peut le constater, la majorité de ces corrélations sont supérieures à 0,50. Dans la suite, appelons ces corrélations les indices de validité.
2. que ces indices de validité soient supérieurs aux corrélations de la même ligne ou de la même colonne, pour autant que les méthodes diffèrent ;
3. que ces indices de validité soient supérieurs aux corrélations présentées dans les triangles monométhode ;

Dans la **validité divergente**, on regarde si le construit n'est déjà pas recouvert par d'autres construits ou traits déjà existants. Dans ce cas, on devrait observer des corrélations faibles entre les différents traits mesurés, que ce soit par la même méthode ou des méthodes différentes.

8. Prérequis statistiques

Les techniques psychométriques se réfèrent régulièrement à un certain nombre de concepts statistiques dont les plus importants sont rappelés brièvement ci-dessous.

Lorsque 5 individus sont interrogés ou observés, il est possible de mémoriser l'ensemble des mesures pour tous les individus de l'échantillon. Lorsque la taille de ce dernier augmente, l'expérimentateur ne peut mémoriser les valeurs de chaque individu aux différentes mesures opérées. Il importe donc de réduire les données. On utilise pour ce faire des indices qui synthétisent les distributions de données : (i) les indices de tendance centrale et (ii) les indices de dispersion.

8.1. Les indices de tendance centrale

Trois indices de tendance centrale se rencontrent généralement en sciences humaines : (i) la moyenne, (ii) le mode et enfin (iii) la médiane.

La **moyenne**, dite aussi la moyenne arithmétique²⁰, est égale à la somme des valeurs observées divisée par le nombre d'observations. Mathématiquement, on peut écrire :

$$\mu_X = \frac{1}{n} \sum_{i=1}^n x_i$$

avec μ_X , la moyenne, x_i la valeur pour l'individu i à la mesure X , et $\sum_{i=1}^n$ la somme sur n individus i .

Notons que la moyenne est généralement symbolisée également par :

1. m pour désigner la moyenne des valeurs de l'échantillon observé ; On peut également lire $\bar{x}$;
2. μ_X pour désigner la moyenne de la population
3. $\hat{\mu}_X$ pour désigner l'estimation de la moyenne de la population au départ de la moyenne de l'échantillon.

²⁰ Pour la différencier de la moyenne géométrique, de la moyenne harmonique et de la moyenne quadratique.

Tableau 8.1. Taille de 10 individus

Individus	Taille	Différences par rapport à la moyenne
1	160	-10
2	162	-8
3	164	-6
4	166	-4
5	168	-2
6	170	0
7	172	2
8	174	4
9	176	6
10	178	8
11	180	10
Somme	1870	0

La taille moyenne de l'échantillon de 11 individus est égale à :

$$\bar{x} = \sum_{i=1}^n x_i = \frac{(160 + 162 + 164 + 166 + 168 + 170 + 172 + 174 + 176 + 178 + 180)}{11} = \frac{1870}{11} = 170$$

La moyenne peut s'assimiler au centre de gravité. En effet, la somme des différences par rapport à la moyenne EST TOUJOURS égale à 0.

Quelques propriétés importantes de la moyenne

1. Si X et Y sont deux variables, alors $\mu_{(X+Y)} = \mu_X + \mu_Y$
2. Si X est une variable et a une constante, alors $\mu_{(a.X)} = a.\mu_X$

La première propriété montre que la moyenne d'une somme est égale à la somme des moyennes. Ainsi, la moyenne d'un score total est égale à la somme des moyennes des scores qui composent le score total. La seconde propriété montre que la moyenne d'une variable multipliée par une constante est égale à la moyenne de cette variable multipliée par cette constante. Si le poids moyen d'un échantillon s'élève à 62,743 kg, la moyenne, exprimée en gramme, s'élève à 62 743 (la constante pour convertir des kilos en grammes étant 1000).

La **médiane** est un indice de tendance centrale calculé de sorte que la moitié des observations lui sont inférieures (ou égales) et la moitié supérieures (ou égales). Pour connaître la médiane, il convient de classer les individus i du plus petit au plus grand en fonction de la mesure envisagée. Si le nombre d'observations est un chiffre impair, la médiane sera égale à :

$$\tilde{x} = x_{(n+1)/2}$$

Dans l'exemple des données reprises dans le tableau 1, comme le nombre d'individus dans l'échantillon est un chiffre impair, la médiane sera égale à :

$$\tilde{x} = x_{(n+1)/2} = x_{(11+1)/2} = x_6 = 170$$

Il y a bien autant d'individus qui obtiennent une valeur inférieure à 170 qu'il y a d'individus qui obtiennent une valeur supérieure à 170.

Lorsque l'échantillon comporte un nombre pair d'individus, la médiane sera égale à :

$$\tilde{x} = \frac{x_{\left[\frac{n}{2}\right]} + x_{\left[\frac{n}{2}+1\right]}}{2}$$

Imaginons un échantillon composé des dix premiers individus repris dans le tableau 1. Comme l'échantillon comporte un nombre pair d'individus, la médiane sera donc égale à

$$\tilde{x} = \frac{x_{\left[\frac{n}{2}\right]} + x_{\left[\frac{n}{2}+1\right]}}{2} = \frac{168 + 170}{2} = 169$$

Si l'échantillon comporte un nombre impair d'individus, la médiane sera égale à une valeur observée. Par contre, lorsque l'échantillon comporte un nombre pair d'individus, la médiane ne sera pas nécessairement une valeur observée.

Enfin, le mode est la valeur la plus souvent observée d'une variable discontinue (variable qui ne comporte qu'un nombre limité de valeurs possibles). Dans le cadre d'une variable continue (variable qui comporte une infinité de valeurs possibles), on ne parle plus de mode, mais bien de classe modale. Ainsi, si l'on mesure la taille d'un grand nombre d'individus, selon que l'on présente les résultats par centimètre, par intervalle de 5 ou de 10 centimètres, la classe modale variera.

8.2. Les indices de dispersion

Il existe différents indices de dispersion. Les plus usités sont :

1. la variance ou sa racine carrée, l'écart type ;
2. le coefficient de variation ;
3. l'amplitude ;
4. l'écart moyen absolu ;
5. l'écart interquartile ou l'écart semi-interquartile.

L'**amplitude** est la distance qui sépare dans une distribution la valeur maximale de la valeur minimale. Dans l'exemple des observations présentées dans le tableau 1, l'amplitude est de $180-160=20$.

L'amplitude n'est que rarement utilisée car sa valeur dans une distribution ne dépend que de deux observations, à savoir le minimum et le maximum. Ainsi, la distribution (2, 3, 4, 5, 6) présente une amplitude de 4 alors que la distribution (2, 3, 4, 5, 10) présente une amplitude de 8. Comme on peut le constater, la valeur de l'amplitude a doublé alors que 4 des 5 observations des deux distributions sont restées inchangées.

En second lieu, au départ d'un échantillon d'une population donnée, la valeur minimale de l'échantillon ne peut qu'être égale ou supérieure à la valeur minimale de la population et la valeur maximale de l'échantillon ne peut qu'être égale ou inférieure à la valeur maximale de la population. En effet, ou bien, à titre d'exemple, l'échantillon comporte l'individu le plus *petit* de la population, auquel cas la valeur minimale de l'échantillon est égale à la valeur minimale de la population, ou bien l'échantillon ne comporte pas l'individu le plus *petit*, et dans ce cas, la valeur minimale de l'échantillon sera toujours supérieure à la valeur minimale de la population. Il en résulte que l'estimation des valeurs minimales et maximales de la population sont biaisées, ce qui rend d'autant moins pertinent le recours à l'amplitude.

L'**écart moyen absolu** est la moyenne des valeurs absolues des écarts par rapport à la moyenne. Mathématiquement, l'écart moyen absolu est égale à :

$$e_m = \frac{1}{n} \sum_{i=1}^n |x_i - \mu_x|$$

Au départ des données du tableau 1, l'écart moyen absolu est égal à :

$$e_m = \frac{1}{n} \sum_{i=1}^n |x_i - \mu_x| = \frac{(10 + 8 + 6 + 4 + 2 + 0 + 2 + 4 + 6 + 8 + 10)}{11} = \frac{60}{11} = 5.45$$

L'**écart interquartile** est égal à la distance qui sépare le premier quartile (ou percentile 25) du troisième quartile (ou percentile 75). Comme le médian, le premier et le troisième quartile séparent la distribution en deux parties : le premier quartile est la valeur en-dessous de laquelle il y a 25 % des individus et au-dessus de laquelle il y a 75 % d'individus. Le troisième quartile est la valeur en-dessous de laquelle il y a 75 % des individus et au-dessus de laquelle il y a 25 % des individus.

La **variance** d'une distribution est égale à la moyenne arithmétique des carrés des différences à la moyenne. Mathématiquement, la variance est égale à :

$$\sigma_x^2 = \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - m_x)^2$$

La variance de la distribution du tableau 1 est égale à :

$$\begin{aligned}
\sigma^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - m_X)^2 \\
&= \frac{1}{11} [(160-170)^2 + (162-170)^2 + \dots + (178-170)^2 + (180-170)^2] \\
&= \frac{100 + 64 + 36 + 16 + 4 + 0 + 4 + 26 + 36 + 64 + 100}{11} = \frac{440}{11} = 40
\end{aligned}$$

L'écart type d'une distribution est égal à la racine carrée de la variance. Mathématiquement, l'écart type correspond à :

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - m_X)^2}$$

L'écart type de la distribution du tableau 1 est égal à :


$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - m_X)^2} = \sqrt{40} = 6.32$$

L'écart type d'une distribution varie de 0 à $+\infty$. Il sera égal à 0 si et seulement si l'ensemble des valeurs sont toutes égales, c'est-à-dire égales à une constante. Dans ce cas, la moyenne sera égale à cette constante et l'écart type sera égal à :

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - m_X)^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (m_X - m_X)^2} = \sqrt{\frac{0}{n}} = 0$$

La valeur maximale d'un écart type est toujours égale ou inférieure à la moitié de l'amplitude de la distribution. Il sera égal à la moitié de l'amplitude de la distribution si la moitié des sujets obtiennent la valeur minimale et l'autre moitié, la valeur maximale. Ainsi, dans une classe de 20 élèves, 10 élèves obtiennent le score de 0/10 et 10 élèves obtiennent le score de 10/10, comme le présente la figure 1.

Figure 8.1. Distribution des scores à un test



La moyenne est égale à :

$$m_x = \frac{1}{n} \sum_{i=1}^n x_i = \frac{(10 \cdot 0) + (10 \cdot 10)}{20} = \frac{100}{20} = 5$$

L'amplitude de la distribution est égale à :

$$\text{Amplitude} = 10 - 0 = 10$$

La variance est égale à :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - m_x)^2 = \frac{[10 \cdot (0 - 5)^2 + 10 \cdot (10 - 5)^2]}{20} = \frac{20 \cdot 25}{20} = \frac{500}{20} = 25$$

L'écart type sera donc égal à :

$$\sigma = \sqrt{\sigma^2} = \sqrt{25} = 5,$$

soit la moitié de l'amplitude.

Quelques propriétés importantes de la variance

1. Si X est une variable et a une constante, alors $\sigma_{(X+a)}^2 = \sigma_{(X)}^2$
2. Si X est une variable et a une constante non nulle, alors $\sigma_{(aX)}^2 = a^2 \sigma_{(X)}^2$
3. Si X et Y sont deux variables, alors $\sigma_{(X+Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 + 2\text{cov}(X, Y)$
4. Si X et Y sont deux variables, alors $\sigma_{(X-Y)}^2 = \sigma_{(X)}^2 + \sigma_{(Y)}^2 - 2\text{cov}(X, Y)$

La première propriété indique que la variance de la taille des individus reste inchangée, même si l'on demande aux individus de monter sur une table et que l'on continue à

mesurer leur taille à partir du sol. Dans cet exemple fictif, la constante a serait égale à la hauteur de la table.

La seconde propriété permet de connaître la variance de la taille des individus exprimée en mètres au départ de la variance de la taille de ces mêmes individus mais exprimée en centimètres.

Enfin, les troisième et quatrième propriétés indiquent que la variance d'une somme (d'une différence) est égale à la somme des variances plus (moins) deux fois la covariance entre les deux variables.

Les deux premières propriétés de la variance peuvent aisément se décliner pour l'écart type comme suit :

1. Si X est une variable et a une constante, alors $\sigma_{(X+a)} = \sigma_{(X)}$
2. Si X est une variable et a une constante non nulle, alors $\sigma_{(aX)} = |a| \sigma_{(X)}$

Ainsi, si l'écart type de la taille exprimée en mètres s'élève à 12.53, l'écart type de la taille exprimée en centimètres sera de 1 253 (la constante pour passer des mètres en centimètres étant 100).

Enfin, le coefficient de variation est obtenu en divisant l'écart type par la moyenne. Mathématiquement, on peut écrire :

$$cv = \frac{\sigma}{\bar{x}}$$

Supposons que l'on veuille comparer la variabilité pondérale des souris par rapport à la variabilité pondérale des éléphants. Le tableau 2 présente le poids, exprimé en kilogramme, de dix souris et dix éléphants.

Tableau 8.2. Poids de 10 souris et 10 éléphants

<i>Souris</i>	<i>Elephants</i>	<i>Poids de l'éléphant exprimé en termes de rapport à la moyenne</i>
0.40	3000.00	0.60
0.42	3800.00	0.76
0.44	4400.00	0.88
0.44	4600.00	0.92
0.45	4800.00	0.96
0.45	5000.00	1.00
0.46	5200.00	1.04
0.46	5400.00	1.08
0.47	5600.00	1.12
0.48	6200.00	1.24
0.50	7000.00	1.40

Moyenne	0.45	5000.00	1.00
Variance	0.00	1000000.00	0.04
Ecart type	0.03	1000.00	0.20
Coefficient de variation	0.06	0.20	0.20

Après ajustement de l'écart type par la moyenne, on peut constater que la variabilité pondérale est proportionnellement plus importante pour l'éléphant que pour la souris. Comme l'indique la dernière colonne du tableau 2, le coefficient de variation est égal à l'écart type de la distribution, après division de chaque valeur par la moyenne.

8.3. Les indices d'association entre deux variables

Dans le cadre des théories psychométriques, deux indices d'association sont particulièrement utilisés : la covariance et la corrélation.

La **covariance** varie de $-\infty$ à $+\infty$ et se définit comme la moyenne du produit des écarts à la moyenne. Mathématiquement la covariance est égale à :

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - m_X) \cdot (y_i - m_Y)$$

Tableau 8.3. Taille et poids de 11 individus

<i>Individus</i>	<i>Taille (cm)</i>	<i>Différence par rapport à la taille moyenne (cm)</i>	<i>Poids (kg)</i>	<i>Différences par rapport au poids moyen (kg)</i>	<i>Produit des différences</i>
1	160	-10	60	-10	100
2	162	-8	62	-8	64
3	164	-6	64	-6	36
4	166	-4	66	-4	16
5	168	-2	68	-2	4
6	170	0	70	0	0
7	172	2	72	2	4
8	174	4	74	4	16
9	176	6	76	6	36
10	178	8	78	8	64
11	180	10	80	10	100
<i>Moyenne</i>	170		70		
<i>Variance</i>	40		40		
<i>Ecart-type</i>	6.32		6.32		

Au départ des données du tableau 3, la covariance entre la taille et le poids des 11 individus est égale à :

$$\begin{aligned}
 \text{cov}(X, Y) &= \frac{1}{n} \sum_{i=1}^n (x_i - m_X) \cdot (y_i - m_Y) \\
 &= \frac{[(-10 \cdot -10) + (-8 \cdot -8) + \dots + (8 \cdot 8) + (10 \cdot 10)]}{11} \\
 &= \frac{[100 + 64 + 36 + 16 + 4 + 0 + 4 + 16 + 36 + 64 + 100]}{11} \\
 &= \frac{440}{11} = 40
 \end{aligned}$$

Une covariance égale à 0 traduit l'absence de lien entre les deux variables. Une covariance positive indique que lorsque le phénomène X augmente, le phénomène Y augmente. Ainsi, on peut constater qu'une augmentation de taille se traduit par une augmentation de poids. Enfin, une covariance négative signifie que lorsque le phénomène X augmente, le phénomène Y diminue et inversement. Ainsi, plus je dépense de l'argent, moins il me reste d'argent sur mon compte.

Cependant, la covariance dépend directement de l'échelle utilisée. Pour s'en convaincre, il suffit d'exprimer les tailles non plus en centimètres mais bien en mètres, comme indiqué dans le tableau 4.

Tableau 8.4. Taille et poids de 11 individus

<i>Individus</i>	<i>Taille (m)</i>	<i>Différence par rapport à la taille moyenne (m)</i>	<i>Poids (kg)</i>	<i>Différences par rapport au poids moyen (kg)</i>	<i>Produit des différences</i>
1	1,60	-0,10	60	-10	1,00
2	1,62	-0,08	62	-8	0,64
3	1,64	-0,06	64	-6	0,36
4	1,66	-0,04	66	-4	0,16
5	1,68	-0,02	68	-2	0,04
6	1,70	0,00	70	0	0,00
7	1,72	0,02	72	2	0,04
8	1,74	0,04	74	4	0,16
9	1,76	0,06	76	6	0,36
10	1,78	0,08	78	8	0,64
11	1,80	0,10	80	10	1,00
<i>Moyenne</i>	1,70		70		
<i>Variance</i>	40		40		
<i>Ecart type</i>	6.32		6.32		

Dans ce cas, la covariance sera égale à

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - m_X) \cdot (y_i - m_Y) = \frac{4,40}{11} = 0,4$$

Cet exemple nous permet par ailleurs d'énoncer une première propriété importante de la covariance, à savoir :

$$\text{cov}(aX, Y) = a \cdot \text{cov}(X, Y)$$

Dans l'exemple des données du tableau 4, $a=0,01$.

Pour faciliter l'interprétation, on recourt plus souvent à la **corrélation**. Mathématiquement, la corrélation peut s'écrire :

$$\rho_{(X,Y)} = \text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_{(X)} \sigma_{(Y)}} = \frac{\text{cov}(X, Y)}{\sqrt{\sigma_{(X)}^2 \sigma_{(Y)}^2}}$$

La corrélation se définit donc comme la covariance, divisée par le produit des écarts types. Il s'agit donc d'une covariance standardisée. Pour s'en convaincre, il suffit de standardiser les variables X et Y dans le tableau 3, c'est-à-dire de diviser chaque valeur par son écart type respectif et de calculer la covariance. Dans ce cas, la covariance sera égale à la corrélation.

La corrélation varie de -1 à +1.


1. Comme la covariance, une corrélation égale à 0 signifie l'absence de lien entre les variables X et Y. Connaissant X, on ne peut rien dire à propos de Y et inversement.
2. Une corrélation de +1 signifie un lien parfait et positif entre la variable X et la variable Y. En d'autres termes, connaissant X, on peut prédire sans risque d'erreur la valeur de Y et inversement.
3. Une corrélation de -1 signifie un lien parfait et négatif entre la variable X et la variable Y. De même, connaissant X, on peut prédire sans risque d'erreur la valeur de Y et inversement.

Dans l'exemple des données du tableau 3, la corrélation est égale à

$$\rho_{(X,Y)} = \text{corr}(X,Y) = \frac{\text{cov}(X,Y)}{\sigma_{(X)}\sigma_{(Y)}} = \frac{\text{cov}(X,Y)}{\sqrt{\sigma_{(X)}^2\sigma_{(Y)}^2}} = \frac{40}{\sqrt{40*40}} = 1$$

La figure 2 représente le lien parfait entre les variables *Taille* et *Poids* du tableau 3.

Figure 8.2. Taille et poids de 11 individus



Lorsque la valeur absolue de la corrélation est égale à 1, tous les points se situent parfaitement sur une droite. Plus la valeur de la corrélation tend vers 0, plus les points s'écartent de la droite, comme l'indiquent les figures suivantes.

Figure 8.3. Représentation graphique d'une corrélation de 0.90




Figure 8.4. Représentation graphique d'une corrélation de 0.45





Figure 8.5. Représentation graphique d'une corrélation de 0.10



8.4. Les niveaux de mesure

Ces différents indices ne peuvent s'appliquer sur tous les types de variables. Guilford (1954, p. 11)²¹ définit 9 axiomes qui permettent de définir le niveau de la mesure :

1. Les éléments sont identiques ou différents ;
2. La relation d'identité est symétrique ;
3. La relation d'identité est transitive ;
4. La relation d'ordre est asymétrique ;
5. La relation d'ordre est transitive ;
6. Les éléments peuvent s'additionner (l'addition d'un zéro laisse l'élément invariant) ;
7. L'addition est commutative ;
8. Des éléments identiques peuvent être substitués l'un à l'autre dans l'addition ;
9. L'addition est associative.

Mathématiquement, on peut écrire ces 9 axiomes comme suit :

1. Soit $a = b$, soit $a \neq b$.
2. Si $a = b$ alors $b = a$.
3. Si $a = b$ et $b = c$ alors $a = c$.
4. Si $a > b$ alors b n'est pas plus grand que a .
5. Si $a > b$ et $b > c$ alors $a > c$.
6. Si $a = p$ et $b > 0$ alors $a + b > p$.
7. $a + b = b + a$.
8. Si $a = p$ et $b = q$ alors $a + b = p + q$.
9. $(a + b) + c = a + (b + c)$.

8.4.1. Les échelles nominales

Les échelles nominales représentent le plus faible degré de la mesure. Lorsqu'on utilise des nombres pour désigner une catégorie de réponses, ils ne portent d'autres sens que celui d'être identiques ou différents. Le nombre utilisé est simplement une étiquette pour désigner une classe ou une catégorie. Au sein d'une classe ou d'une catégorie, les individus sont considérés comme identiques par rapport à la caractéristique mesurée. Inversement, les individus de deux catégories distinctes sont considérés comme différents par rapport à la caractéristique mesurée. En d'autres termes, un individu appartient à une et une seule classe.

Parmi les 9 postulats susmentionnés, seuls les trois premiers, relatifs à l'égalité, sont d'application. On peut aussi différencier les échelles nominales selon que l'on procède à un étiquetage (il n'y a qu'un élément par catégorie) ou à une classification (on peut observer plusieurs éléments par catégorie).

²¹ Guilford, J.P. (1954). *Psychometric methods*. New York: McGraw-Hill.

Les typologies psychologiques de la personnalité, les nomenclatures des professions, le sexe ou le statut matrimonial sont typiquement des échelles nominales.

Les traitements statistiques que l'on peut effectuer sur ce type d'échelles sont :

1. Avec une seule échelle nominale :
 - a. La fréquence absolue ;
 - b. La fréquence relative ;
 - c. La classe modale, c'est-à-dire la classe la plus fréquente.
2. Avec deux échelles nominales (c'est-à-dire que les mêmes individus ont été classés selon deux critères distincts) :
 - a. Le test d'indépendance ;
 - b. Le coefficient d'association (coefficient Phi, coefficient Phi de Cramer, rapports des chances) ;
 - c. L'analyse des correspondances.

Les transformations mathématiques que l'on peut appliquer à ces échelles sont du type $X=f(x)$, pour autant que si $x \neq y$ alors $f(x) \neq f(y)$. Ainsi, si le sexe masculin est représenté par le chiffre 1 et le sexe féminin par le chiffre 2, on peut appliquer une fonction du type $f(x) = x^2$. En effet, cette transformation conduira à étiqueter les garçons par le chiffre 1 et les filles par le chiffre 4. Par contre, on ne peut appliquer la transformation $f(x) = x^0$ car dans ce cas, aussi bien les filles que les garçons seraient étiquetées par le chiffre 1. C'est pour cette raison que l'on parle de condition d'invariance, c'est-à-dire que sont seulement autorisées les transformations qui ne modifient pas les propriétés de l'échelle.

8.4.2. Les échelles ordinales

Les échelles ordinales, comme leur nom l'indique, introduisent une relation d'ordre entre les éléments comme information signifiante. Les échelles ordinales possèdent bien entendu les 3 propriétés ou axiomes des échelles nominales mais aussi les propriétés 4 et 5 relatives à la relation d'ordre. En d'autres termes, les échelles ordinales consistent à classer des sujets dans des catégories (et donc leur assigner une étiquette au même titre que les échelles nominales) avec cependant une nuance importante : ces étiquettes sont ordonnées selon un critère déterminé. Lorsque $a \neq b$, il est possible de déterminer si $a > b$ ou si $b > a$, cette relation d'ordre étant impossible avec les échelles nominales. En effet, on ne peut pas déterminer la supériorité du sexe masculin par rapport au sexe féminin ou inversement.

Les exemples d'échelles ordinales sont nombreux : le prestige social, l'anxiété, les classes d'âges, les niveaux scolaires.

En plus des différents traitements statistiques que l'on peut appliquer aux échelles nominales (on peut toujours ignorer la relation d'ordre entre les différentes catégories et considérer une échelle ordinale comme une échelle nominale), on peut aussi calculer :

1. Avec une seule échelle ordinale :

- a. La fréquence cumulée, absolue ou relative (nombre d'individus ou % d'individus plus petits ou égaux à une catégorie donnée);
 - b. La médiane, les quartiles, déciles, centiles...;
- 2. Avec deux échelles ordinales (c'est-à-dire que les mêmes individus ont été classés selon deux critères distincts) :
 - a. Le coefficient de corrélation de rangs.

Les conditions d'invariance (ou transformations autorisées) se limitent aux transformations qui laissent l'ordre invariant. Mathématiquement, on peut écrire $X' = f(x)$ pour autant que si $x > y$ alors $f(x) > f(y)$. La fonction $f(x) = x^2$ peut donc s'appliquer puisque $1 < 2$ et $1 < 4$. Par contre, la fonction $f(x) = -x^2$ inverse la relation d'ordre puisque $1 < 2$ mais $-4 < -1$.

8.4.3. Les échelles d'intervalles égaux

Les échelles d'intervalles égaux ajoutent à la relation d'ordre la signification des distances. En d'autres termes, la distance qui sépare les catégories étiquetées 1 et 2 est égale à celle qui sépare les catégories étiquetées 2 et 3. On peut également dire que la distance qui sépare A et B « plus (+) » la distance qui sépare B et C est égale à la distance qui sépare A et C. Les échelles d'intervalles égaux possèdent donc les neuf propriétés énoncées par Guilford.

L'échelle des températures est l'exemple le plus célèbre d'échelle d'intervalles égaux. En effet, la distance qui sépare 5°C et 10°C est bien équivalente à la distance qui sépare 10°C et 15°C. De même, la distance qui sépare 5°C et 10°C « plus (+) » la distance qui sépare 10°C et 15°C est bien égale à la distance qui sépare 5°C et 15°C. Le calendrier est également une échelle d'intervalles égaux avec un zéro (ou point de départ) arbitraire. L'altitude est également une échelle d'intervalles égaux puisque le zéro est fixé arbitrairement au niveau de la mer.

Ces échelles se caractérisent par un zéro arbitraire. Pour s'en convaincre, il suffit de comparer l'échelle Celsius à l'échelle Fahrenheit (0°C correspond à 32°F). Bien que l'on puisse additionner les intervalles, on ne peut pas réellement parler de propriétés d'additivité au sens absolu. La somme de quantité sur l'échelle n'a pas beaucoup de sens. Ainsi, si 10 kilos représentent bien deux fois 5 kilos, on ne peut pas dire que 10 degrés Celsius, c'est deux fois plus chaud que 5 degrés Celsius. Pour s'en convaincre, il suffit de convertir ces deux températures exprimées sur l'échelle de Celsius sur l'échelle de Fahrenheit et le rapport n'est plus conservé. La raison en est que le zéro est fixé arbitrairement.

Outre les traitements statistiques applicables aux échelles ordinales, les échelles d'intervalles égaux autorisent :

- 1. Avec une seule échelle d'intervalles égaux :
 - a. La moyenne ;
 - b. Les différents indices de dispersion (variance, écart-type, amplitude...) ;

- c. La classe modale, c'est-à-dire la classe la plus fréquente.
- 2. Avec deux échelles d'intervalles égaux (c'est-à-dire que les mêmes individus ont été classés selon deux critères distincts) :
 - a. Le coefficient de covariance ou tout autre paramètre dérivé, comme la corrélation ou le coefficient de régression.

Les conditions d'invariance limitent les transformations aux fonctions linéaires du type $X' = ax + b$ avec $a > 0$. On peut en effet appliquer à l'échelle de Celsius la transformation linéaire $X' = 32 + 1,8x$ pour exprimer la température sur l'échelle Fahrenheit. Par contre, les transformations quadratiques du type $f(x) = x^2$ ou cubique du type $f(x) = x^3$ annulent la propriété d'égalité des distances et dès lors ne sont pas autorisées.

8.4.4. Les échelles de rapport

Les échelles de rapport sont des échelles d'intervalles égaux avec un zéro absolu, où le zéro représente ni plus ni moins que l'absence de propriété mesurée par l'échelle. Par exemple, sur une échelle de mesure de la longueur, 0 cm représente bel et bien une absence de longueur. Tous les postulats fondamentaux énoncés plus haut sont d'application. On peut même ajouter le postulat suivant : si $\frac{a}{p} = \frac{b}{q}$ alors $a.q = p.b$. A présent, on peut donc établir des rapports. Ainsi, 20 kilos, c'est bien deux fois 10 kilos.


La plupart des échelles physiques qui mesurent la longueur, le temps, la masse, etc. sont des échelles de rapport. Les mesures de dénombrement, obtenues en comptant les objets, relèvent également des échelles de rapport. Les conditions d'invariance limitent les transformations autorisées aux fonctions linéaires du type $X' = ax$, avec $a > 0$. Ainsi, une mesure de masse exprimée en kilo peut être multipliée par 1000 pour l'exprimer en gramme.

Outre les traitements statistiques des échelles d'intervalles égaux, les échelles de rapport autorisent également le calcul du coefficient de variation.

8.5. Les distributions théoriques

La **distribution normale** est certainement la distribution théorique la plus utilisée en statistiques. La figure 6 représente une distribution normale.

Figure 8.6 La distribution normale.



Cette distribution théorique possède deux asymptotes : une asymptote gauche et une asymptote droite. En d'autres termes, cette distribution varie de $-\infty$ à $+\infty$. Entre ces deux asymptotes, toutes les valeurs peuvent être rencontrées. Il s'agit donc d'une variable continue. Dans le monde réel, aucun phénomène ne se distribue à proprement dit normalement puisque la plupart des phénomènes réels ne peuvent pas se distribuer de $-\infty$ à $+\infty$. Par contre, une distribution observée, par exemple la taille humaine, peut s'apparenter à une distribution normale. Le test de *Kolmogorov-Smirnov* permet de tester l'adéquation d'une distribution observée à la distribution théorique normale.

L'importance de la distribution normale en statistiques est imputable à deux raisons :

1. Un certain nombre de phénomènes (qu'ils relèvent du monde animal ou végétal ou du monde inanimé) ont tendance à se distribuer selon une distribution normale. Ainsi, si l'on s'intéresse à la taille humaine, nous pourrions observer qu'un petit nombre d'individus sont de très petite taille, un grand nombre d'individus de taille moyenne et un petit nombre d'individus de très grande taille.
2. Le théorème de *Laplace-Liapounov*, dit aussi théorème de limite centrale, démontre que toute somme de variables aléatoires indépendantes, même de distributions différentes, est, sous des conditions très générales, une variable asymptotiquement normale. Par asymptotiquement, il faut entendre : « *tend vers* (dans le cas présent, la normalité) *lorsque le nombre* (dans ce cas-ci, le nombre de variables aléatoires) *devient de plus en plus grand* ». Par indépendante, il faut entendre que l'espérance mathématique de la corrélation entre deux variables est égale à 0. En d'autres termes, si vous additionnez un


grand nombre de variables, de formes quelconques, mais indépendantes, on obtient une distribution normale. Ce théorème confère donc à la distribution normale un rôle particulièrement important en statistiques.

Par exemple, cinq variables uniformes ont été générées pour un échantillon de 10 000 individus. Une variable uniforme se caractérise par :

1. une borne inférieure : soit 0 ;
2. une borne supérieure : soit 1 ;
3. chaque valeur comprise entre la borne inférieure et la borne supérieure a la même probabilité d'apparition.
- 4.


La figure 7 représente la distribution de la première variable uniforme $[0,1]$ pour les 10 000 individus.

Figure 8. 7. Distribution d'une variable uniforme



La figure 8 présente la distribution de la somme des 5 premières variables uniformes indépendantes. Comme le montre très bien la figure 8, la distribution de cette somme tend vers une distribution normale.

Figure 8.8. : Distribution de la somme de 5 variables uniformes indépendantes



Ce théorème de limite centrale est particulièrement intéressant en psychométrie. En effet, comme indiqué dans le chapitre 1, toute mesure est entachée d'un certain nombre d'erreurs. Si l'on suppose que ces différentes erreurs sont indépendantes, on peut dès lors affirmer que l'erreur de mesure se distribue normalement.

La distribution normale, ainsi que tout autre distribution théorique, peut être décrite selon deux fonctions mathématiques : la fonction de densité et la fonction de répartition.

8.5.1. La fonction de densité

En présence d'une variable discontinue, c'est-à-dire une variable qui ne peut prendre qu'un certain nombre de valeurs, on peut calculer la probabilité d'apparition d'une des valeurs possibles. Ainsi, la probabilité d'obtenir la valeur 1 lors du lancé d'un dé est de $\frac{1}{6}$. La probabilité de tirer l'as de cœur dans un jeu de cartes est de $\frac{1}{52}$. La probabilité de

tirer un as est de $\frac{4}{52} = \frac{1}{13}$. Supposons que l'on puisse mesurer la taille de l'ensemble des

personnes vivant sur le territoire belge. Si l'on rapporte les mesures en unités, on pourra calculer le nombre d'individus qui mesurent 170 cm. Cette proportion pourra ultérieurement être utilisée comme probabilité d'observer dans un échantillon un individu de 170 cm. Le même exercice pourra être réalisé si les mesures sont rapportées avec une décimale, deux décimales, et ainsi de suite. Cependant, dans ce cas, la probabilité d'observer un individu de 170 cm ne sera pas égale à la probabilité d'observer un

individu de 170.0 cm, ou d'observer un individu de 170.00 cm. En présence d'une variable continue, on ne parle plus de probabilité mais bien de densité de probabilité.

La fonction de densité décrit mathématiquement la valeur attendue de cette densité de probabilité en fonction de la valeur de la mesure. La fonction de densité de probabilité d'une distribution normale est égale à :

$$f(x) = \phi(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

Deux éléments définissent cette fonction de densité de la distribution normale : sa moyenne, notée μ et son écart type, noté σ .

8.5.2. La fonction de répartition

La fonction de répartition permet, quant à elle, de calculer le pourcentage d'individus qui se situent en dessous d'une borne, ou entre deux bornes.

Le pourcentage d'individus qui figurent en dessous ou au-dessus d'une valeur donnée dépend des paramètres qui caractérisent la distribution. Comme indiqué ci-dessus, deux paramètres définissent une distribution normale : la moyenne et l'écart type. Ainsi, le pourcentage d'élèves qui obtiennent un score inférieur à 10/20 dépend de la moyenne et de l'écart type des résultats. Comme il existe une infinité de moyennes et d'écarts types, on ne peut proposer des tables de répartitions pour cette infinité de combinaisons « *moyenne écart-type* ».

Pour remédier à cette difficulté, les livres de statistiques présentent une table de répartition pour une distribution normale réduite. Une distribution normale réduite est une distribution normale de moyenne 0 et d'écart type 1. Le passage d'une distribution normale quelconque à une distribution normale réduite s'obtient en appliquant la transformation linéaire à l'ensemble des valeurs x_i de la distribution quelconque :

$$z_i = \frac{(x_i - m_X)}{\sigma}$$

Pour un individu i , sa valeur standardisée s'obtient en calculant la différence entre la valeur initiale et la moyenne de la distribution, le tout divisé par l'écart type. Cette distribution transformée aura une moyenne de 0 et un écart type de 1. En effet,

$$\frac{1}{n} \sum_{i=1}^n (x_i - m_X) = \frac{1}{n} \sum_{i=1}^n x_i - \frac{1}{n} \sum_{i=1}^n m_X = m_X - m_X = 0.$$


De par la propriété 1 de la variance, à savoir $\sigma_{(aX)}^2 = a^2 \sigma_{(X)}^2$, on peut écrire

$\sigma_{(aX)} = a \sigma_{(X)}$. Dès lors, si $a = \frac{1}{\sigma_{(X)}}$, l'écart type sera donc bien égal à 1.

La figure 9 reproduit la table normale réduite.

Figure 8.9. Fonction de répartition de la distribution normale réduite

Fournit la probabilité $P(X \leq x)$
pour $X \sim N(0,1)$



x	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0,0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0,1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0,2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0,3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0,4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0,5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0,6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0,7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0,8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0,9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1,0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1,1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1,2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1,3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1,4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1,5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1,6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1,7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1,8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1,9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2,0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2,1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2,2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2,3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2,4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2,5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2,6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2,7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2,8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2,9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3,0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3,1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3,2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3,3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3,4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Ainsi, 84,38 % de la population figurent en dessous de 1.1. De même, 97,5% de la population figurent en dessous de 1,96. Dès lors, on peut aussi écrire que 100-97,5 soit 2.5% de la population se situent au-dessus de 1,96.

La distribution normale est parfaitement symétrique. Cela signifie que le pourcentage d'individus en dessous de -1 est égal au pourcentage d'individu au dessus de 1. Ainsi, 84,13% de la population se situent en dessous de 1. Dès lors, 15,87 % de la population se situent au-dessus de 1 et par symétrie, 15,87 % de la population se situent en dessous de -1.

Parmi les autres distributions théoriques largement utilisées en statistiques, on peut également citer :

1. la distribution χ^2 , qui se définit non pas par sa moyenne ou son écart type mais par son degré de liberté ;
2. la distribution de *Fisher Snédecor* qui se définit par deux degrés de liberté ;
3. la distribution *t de Student*, qui se définit par un degré de liberté ;
4. la distribution uniforme, qui se définit par une borne inférieure et une borne supérieure;
5. la distribution binomiale.

Pour rappel, ces différentes distributions sont des distributions théoriques. Par contre, ces distributions sont utilisées en statistiques car certains phénomènes ont une distribution qui s'apparente à une de ces distributions théoriques.

Ainsi, la statistique $\chi^2 = \sum \frac{(O - E)^2}{E}$ qui permet de tester l'indépendance entre deux variables nominales, possède une distribution d'échantillonnage χ^2 .

9. Annexes

9.1.Echelles de mesure de la taille et du poids

9.2.Exercices

9.1. Echelles de mesure du poids et de la taille

À quelle fréquence vous arrive-t-il ce qui suit ? (Ne cochez qu'une seule case par ligne.)

		<i>Toujours ou presque toujours</i>	<i>Régulière- ment</i>	<i>Parfois</i>	<i>Jamais ou presque jamais</i>
A1)	Dans les magasins, je dois demander de l'aide pour attraper les articles en hauteur.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A2)	On me demande si je joue au basket.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A3)	Quand je descends dans une cave, je dois courber le dos pour ne pas me cogner la tête.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A4)	Je dois raccourcir les pantalons que j'achète.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A5)	Quand je saute, je parviens à toucher un anneau de panier de basket.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A6)	Au cinéma, une personne assise devant moi réduit mon champ de vision.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A7)	J'éprouve des difficultés à m'asseoir sur la banquette arrière d'une voiture.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A8)	Je dois me mettre sur la pointe des pieds pour embrasser une personne.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A9)	Lorsque je m'assieds dans un canapé, mes pieds ne touchent pas le sol.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A10)	J'ai du mal à trouver ma taille dans les magasins de vêtements « normaux ».	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A11)	On me dit que je ferais bien de manger un peu plus / de me remplumer un peu.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A12)	Pour être polis, les gens me disent que je suis rond(e).	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A13)	Mes parents me disent de cesser de grignoter.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A14)	Je ne peux plus rentrer dans un pantalon.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A15)	En hiver, je cache mes rondeurs sous de longs pulls.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A16)	Quand je reste trop longtemps assis sur une chaise en bois, je finis par avoir mal aux fesses.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A17)	A table, je ne peux m'empêcher de me resservir.	☐ ₁	☐ ₂	☐ ₃	☐ ₄
A18)	Je ne parviens pas à finir mon assiette.	☐ ₁	☐ ₂	☐ ₃	☐ ₄

Répondez par *Oui* ou par *Non* aux affirmations suivantes

(Ne cochez qu'une seule case par ligne.)

		<i>Oui</i>	<i>Non</i>
B1)	Quand j'étais jeune, on me donnait toujours plus que mon âge.	☐ ₁	☐ ₂
B2)	On a déjà dit de moi « <i>tout ce qui est petit est joli</i> ».	☐ ₁	☐ ₂
B3)	Je parviens à voir la scène sans aucune difficulté dans un concert en plein air	☐ ₁	☐ ₂
B4)	Si je ne prends pas une grande taille pour mes chemises, les manches seront trop courtes.	☐ ₁	☐ ₂
B5)	Dans les toilettes publiques, il arrive que les miroirs soient placés trop haut.	☐ ₁	☐ ₂
B6)	Debout dans un bus bondé, je ne vois que des dos et des sacs.	☐ ₁	☐ ₂
B7)	J'ai toujours été dans les plus petits de ma classe.	☐ ₁	☐ ₂
B8)	J'aimerais peser 10 kg de moins.	☐ ₁	☐ ₂
B9)	Je peux manger ce que je veux, je ne prends pas un gramme.	☐ ₁	☐ ₂
B10)	Je trouve difficilement un pantalon qui ne me « flotte » pas aux fesses.	☐ ₁	☐ ₂
B11)	Je me mets sans problème en maillot.	☐ ₁	☐ ₂
B12)	On dit de moi que je suis un oiseau pour le chat.	☐ ₁	☐ ₂
B13)	J'ai déjà essayé un certain nombre de régimes.	☐ ₁	☐ ₂
B14)	Pas question de finir un repas sans un dessert.	☐ ₁	☐ ₂
B15)	Je sais que pour ma santé il vaudrait mieux que je maigrisse.	☐ ₁	☐ ₂

Je pèse kg

Je mesure Cm

Sexe : Masculin / Féminin (entourez la bonne réponse)

Le questionnaire auquel vous venez de répondre comporte quatre sous-échelles :

1. Taille :
 - a. les items A1 à A9 ;
 - b. les items B1 à B7 ;
2. Poids :
 - a. Les items A10 à A18 ;
 - b. Les items B8 à B15 ;

Etapas pour le calcul du score :

1. **Etape 1** : Les items repris ci-dessous dans les points 1a et 1b sont inversés. Veuillez les entourer.
 - a. A2, A3, A5, A7, A10, A12, A13, A14, A15, A17;
 - b. B1, B3, B4, B8, B13, B14, B15
2. **Etape 2**: Echelle Taille 1 (items A1 à A9).
 - a. Additionnez les valeurs (chiffres indiqués dans la partie inférieure droite des petits carrés) des items qui n'ont pas été entourés, à savoir A1, A4, A6, A8, A9. Le total (T1_E1) doit être compris entre 5 et 20. Imaginez que vous obteniez 15.
 - b. Additionnez les valeurs des items entourés (A2, A3, A5, A7). Le total (T1_E2) doit être compris entre 4 et 16. Imaginez que vous obteniez 11.
 - c. Votre score final est égal : $T1 = T1_E1 + (20 - T1_E2)$. Dans l'exemple, le score final sera $T1 = 15 + (20 - 11) = 24$. Veuillez reporter ce score dans le tableau sous l'intitulé Taille 1.
3. **Etape 3** : Echelle Poids 1 (items A10 à A18).
 - a. Additionnez les valeurs des items non entourés (A11, A16, A18). Votre score (P1_E1) doit être compris entre 3 et 12 ;
 - b. Additionnez les valeurs des items entourés (A10, A12, A13, A14, A15, A17). Votre score doit être compris entre 6 et 24. (P1_E2).
 - c. Calculez le score total : $P1 = P1_E1 + (30 - P1_E2)$; Veuillez reporter ce score dans le tableau sous l'intitulé Poids 1.
4. **Etape 4** : Echelle Taille 2 (items B1 à B7).
 - a. Additionnez les valeurs non entourées (B2, B5, B6, B7). Votre score (T2_E1) peut varier entre 4 et 8 ;
 - b. Additionnez les valeurs des items entourés (B1, B3, B4). Votre score (T2_E2) peut varier entre 3 et 6.
 - c. Calculez le score total $T2 = T2_E1 + (9 - T2_E2)$; Veuillez reporter ce score dans le tableau sous l'intitulé Taille 2.
5. **Etape 5** : Echelle Poids 2 (items B8 à B15).
 - a. Additionnez les valeurs non entourées (B9, B10, B11, B12). Votre score (P2_E1) peut varier entre 4 et 8 ;

- b. Additionnez les valeurs des items entourés (B8, B13, B14, B15). Votre score (P2_E2) peut varier entre 4 et 8.
 - c. Calculez le score total $P2 = P2_E1 + (12 - P2_E2)$; Veuillez reporter ce score dans le tableau sous l'intitulé Poids 2.
6. **Etape 6** : Calculez les valeurs Taille globale et Poids global par simple sommation

<i>Taille 1</i>	<i>Taille 2</i>	<i>Taille globale</i>	<i>Poids 1</i>	<i>Poids 2</i>	<i>Poids global</i>

Normes

Ces échelles de mesure ont été normées sur une population de 246 étudiants en psychologie BAC 2 de l'Université de Liège au cours de l'année 2009-2010 et de l'année 2010-2011 dans le cadre du cours *d'Introduction aux problèmes de mesure en psychologie et en sciences de l'éducation* dispensé par C. Monseur.

Le tableau ci-dessous présente les déciles de ces quatre sous-échelles, et des deux échelles combinées. Les moyennes et les écarts-types sont également fournis.

<i>Sexe</i>		P10	P20	P30	P40	P50	P60	P70	P80	P90	Moy	STD
<i>Filles</i> (n=204)	<i>Taille</i>	24	26	29	30	32	34	36	37	39	31,87	5,87
	<i>Poids</i>	26	28	29	29	30	31	32	35	37	30,93	4,18
<i>Garçons</i> (n=46)	<i>Taille</i>	31	33	34	35	37	38	40	42	44	37,70	4,98
	<i>Poids</i>	25	27	28	29	29,5	30	31	33	34	29,57	3,20

Validité et fidélité des échelles

Le tableau ci-dessous reprend les coefficients de consistance interne (α de *Cronbach*) ainsi que les corrélations des différentes échelles avec le poids et la taille réels rapportés par les étudiants interrogés.

	α de <i>Cronbach</i>	Corrélation
<i>Taille 1</i>	0,83	0,85
<i>Taille 2</i>	0,75	0,77
<i>Taille</i>	0,88	0,85
<i>Poids 1</i>	0,51	0,48
<i>Poids 2</i>	0,58	0,38
<i>Poids</i>	0,69	0,49

Analyse de l'échelle taille

Analyse d'items

=====
ConQuest: Generalised Item Response Modelling Software Sun Apr 03 16:31 2011
GENERALISED ITEM ANALYSIS
=====

Item 1

item:1 (1)

Cases for this item 246 Discrimination 0.74

Item Threshold(s): -4.33 -2.41 -0.17 Weighted MNSQ 0.84

Item Delta(s): -4.19 -2.46 -0.27

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	5	2.03	-0.26	-4.23(.000)	-3.50	1.82
2	1.00	26	10.57	-0.46	-7.99(.000)	-1.83	0.88
3	2.00	80	32.52	-0.36	-5.97(.000)	-0.69	1.17
4	3.00	135	54.88	0.69	14.96(.000)	1.17	1.33

Item 2

item:2 (2)

Cases for this item 246 Discrimination 0.45

Item Threshold(s): 2.95 4.18 Weighted MNSQ 0.98

Item Delta(s): 3.29 3.83

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	218	88.62	-0.45	-7.93(.000)	-0.14	1.56
2	1.00	22	8.94	0.37	6.19(.000)	2.23	1.35
3	2.00	6	2.44	0.25	4.04(.000)	3.34	1.01

Item 3

item:3 (3)

Cases for this item 246 Discrimination 0.72

Item Threshold(s): -0.38 2.45 3.86 Weighted MNSQ 1.00

Item Delta(s): -0.33 2.67 3.59

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	99	40.24	-0.66	-13.84(.000)	-1.15	1.29
2	1.00	110	44.72	0.29	4.72(.000)	0.61	1.26
3	2.00	28	11.38	0.38	6.47(.000)	2.04	1.15
4	3.00	9	3.66	0.32	5.27(.000)	3.10	0.84

Item 4

item:4 (4)

Cases for this item 246 Discrimination 0.80

Item Threshold(s): -1.80 -0.63 1.05 Weighted MNSQ 1.07

Item Delta(s): -1.48 -0.79 0.89

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	43	17.48	-0.61	-12.07(.000)	-1.87	1.08
2	1.00	44	17.89	-0.25	-4.05(.000)	-0.80	1.31
3	2.00	76	30.89	0.05	0.79(.431)	0.27	1.13
4	3.00	83	33.74	0.65	13.19(.000)	1.61	1.28

Item 5

item:5 (5)

Cases for this item 246 Discrimination 0.55

Item Threshold(s): 1.00 2.54 3.34 Weighted MNSQ 1.33

Item Delta(s): 1.16 2.88 2.80

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	154	62.60	-0.55	-10.18(.000)	-0.51	1.44
2	1.00	62	25.20	0.29	4.71(.000)	0.95	1.65
3	2.00	17	6.91	0.32	5.29(.000)	1.84	1.10
4	3.00	13	5.28	0.26	4.13(.000)	2.07	1.79

Item 6

item:6 (6)

Cases for this item 246 Discrimination 0.60

Item Threshold(s): -4.70 -2.17 2.02 Weighted MNSQ 1.17

Item Delta(s): -4.61 -2.24 2.00

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	4	1.63	-0.17	-2.62(.009)	-2.09	1.91
2	1.00	37	15.04	-0.48	-8.61(.000)	-1.63	1.42
3	2.00	151	61.38	0.03	0.41(.682)	0.16	1.48
4	3.00	54	21.95	0.44	7.58(.000)	1.53	1.33

Item 7

item:7 (7)

Cases for this item 246 Discrimination 0.52

Item Threshold(s): 1.88 4.03 5.40 Weighted MNSQ 1.01

Item Delta(s): 1.98 4.20 5.13

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	187	76.02	-0.55	-10.28(.000)	-0.35	1.48
2	1.00	51	20.73	0.46	8.12(.000)	1.62	1.43
3	2.00	7	2.85	0.32	5.25(.000)	3.30	0.87
4	3.00	1	0.41	-0.08	-1.29(.199)	-2.11	0.00

Item 8

item:8 (8)

Cases for this item 246 Discrimination 0.73

Item Threshold(s): -5.34 -2.50 0.36 Weighted MNSQ 0.87

Item Delta(s): -5.28 -2.50 0.30

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	2	0.81	-0.18	-2.92(.004)	-3.27	1.77
2	1.00	29	11.79	-0.54	-10.00(.000)	-2.28	1.09
3	2.00	101	41.06	-0.25	-3.96(.000)	-0.33	1.16
4	3.00	114	46.34	0.62	12.48(.000)	1.27	1.36

Item 9

item:9 (9)

Cases for this item 246 Discrimination 0.67

Item Threshold(s): -4.47 -2.69 -0.83 Weighted MNSQ 1.08

Item Delta(s): -4.30 -2.70 -0.98

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	4	1.63	-0.17	-2.62(.009)	-2.81	2.51
2	1.00	20	8.13	-0.41	-6.97(.000)	-2.06	1.01
3	2.00	61	24.80	-0.44	-7.64(.000)	-1.03	1.19
4	3.00	161	65.45	0.68	14.37(.000)	0.96	1.36

Item 10

item:10 (10)

Cases for this item 246 Discrimination 0.41

Item Threshold(s): 0.94 Weighted MNSQ 1.31

Item Delta(s): 0.94

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	153	62.20	-0.41	-7.03(.000)	-0.37	1.63
2	1.00	93	37.80	0.41	7.03(.000)	1.03	1.57

Item 11

item:11 (11)

Cases for this item 246 Discrimination 0.74

Item Threshold(s): -0.46 Weighted MNSQ 0.66

Item Delta(s): -0.46

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	98	39.84	-0.74	-17.06(.000)	-1.33	1.21
2	1.00	148	60.16	0.74	17.06(.000)	1.14	1.28

Item 12

item:12 (12)

Cases for this item 246 Discrimination 0.65

Item Threshold(s): 1.12 Weighted MNSQ 0.91

Item Delta(s): 1.12

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	160	65.04	-0.65	-13.29(.000)	-0.62	1.41
2	1.00	86	34.96	0.65	13.29(.000)	1.60	1.34

Item 13

item:13 (13)

Cases for this item 246 Discrimination 0.54

Item Threshold(s): 2.87 Weighted MNSQ 0.81

Item Delta(s): 2.87

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	213	86.59	-0.54	-9.98(.000)	-0.22	1.52
2	1.00	33	13.41	0.54	9.98(.000)	2.55	1.02

Item 14

item:14 (14)

Cases for this item 246 Discrimination 0.47

Item Threshold(s): -3.28 Weighted MNSQ 0.85

Item Delta(s): -3.28

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	21	8.54	-0.47	-8.38(.000)	-2.38	1.18
2	1.00	225	91.46	0.47	8.38(.000)	0.39	1.59

Item 15

item:15 (15)

Cases for this item 246 Discrimination 0.63

Item Threshold(s): -1.84 Weighted MNSQ 0.88

Item Delta(s): -1.84

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	52	21.14	-0.63	-12.77(.000)	-1.76	1.24
2	1.00	194	78.86	0.63	12.77(.000)	0.67	1.48

Item 16

item:16 (16)

Cases for this item 246 Discrimination 0.67

Item Threshold(s): -1.40 Weighted MNSQ 0.82

Item Delta(s): -1.40

Label	Score	Count	% of tot	Pt Bis	t (p)	PV1Avg:1	PV1 SD:1
1	0.00	65	26.42	-0.67	-14.22(.000)	-1.63	1.21
2	1.00	181	73.58	0.67	14.22(.000)	0.80	1.43

The following traditional statistics are only meaningful for complete designs and when the amount of missing data is minimal.
In this analysis 0.00% of the data are missing.

The following results are scaled to assume that a single response was provided for each item.

```

N                246
Mean             16.77
Standard Deviation 6.05
Variance         36.61
Skewness         -0.12
Kurtosis         -0.63
Standard error of mean 0.39
Standard error of measurement 2.06
Coefficient Alpha 0.88
=====

```

Analyse de Rasch

=====

ConQuest: Generalised Item Response Modelling Software Sun Apr 03 16:31 2011
TABLES OF RESPONSE MODEL PARAMETER ESTIMATES

=====

TERM 1: item

VARIABLES				UNWEIGHTED FIT			WEIGHTED FIT		
item		ESTIMATE	ERROR^	MNSQ	CI	T	MNSQ	CI	T
1	1	-2.303	0.099	0.74 (0.82, 1.18)	-3.1	0.84 (0.80, 1.20)	-1.7		
2	2	3.562	0.129	1.84 (0.82, 1.18)	7.5	0.98 (0.65, 1.35)	-0.0		
3	3	1.976	0.096	1.06 (0.82, 1.18)	0.7	1.00 (0.81, 1.19)	0.0		
4	4	-0.460	0.084	1.10 (0.82, 1.18)	1.1	1.07 (0.82, 1.18)	0.8		
5	5	2.281	0.094	3.24 (0.82, 1.18)	16.0	1.33 (0.78, 1.22)	2.7		
6	6	-1.615	0.104	1.25 (0.82, 1.18)	2.6	1.17 (0.82, 1.18)	1.8		
7	7	3.769	0.115	3.45 (0.82, 1.18)	17.0	1.01 (0.75, 1.25)	0.1		
8	8	-2.495	0.101	0.87 (0.82, 1.18)	-1.5	0.87 (0.82, 1.18)	-1.4		
9	9	-2.661	0.103	1.02 (0.82, 1.18)	0.2	1.08 (0.78, 1.22)	0.7		
10	10	0.936	0.119	1.78 (0.82, 1.18)	7.1	1.31 (0.85, 1.15)	3.8		
11	11	-0.464	0.120	0.52 (0.82, 1.18)	-6.5	0.66 (0.84, 1.16)	-4.9		
12	12	1.121	0.120	0.74 (0.82, 1.18)	-3.1	0.91 (0.85, 1.15)	-1.3		
13	13	2.871	0.137	0.47 (0.82, 1.18)	-7.3	0.81 (0.75, 1.25)	-1.5		
14	14	-3.280	0.146	0.37 (0.82, 1.18)	-9.4	0.85 (0.67, 1.33)	-0.9		
15	15	-1.836	0.129	0.61 (0.82, 1.18)	-5.0	0.88 (0.79, 1.21)	-1.2		
16	16	-1.402*	0.443	0.59 (0.82, 1.18)	-5.3	0.82 (0.81, 1.19)	-2.0		

An asterisk next to a parameter estimate indicates that it is constrained

Separation Reliability = 0.998

Chi-square test of parameter equality = 6236.82, df = 15, Sig Level = 0.000


^ Quick standard errors have been used

=====						
TERM 2: item*step						


VARIABLES		UNWEIGHTED FIT				
item	step	ESTIMATE	ERROR^	MNSQ	CI	T

1 1	0			0.22 (0.82, 1.18)		-13.1
1 1	1	-1.883	0.158	0.60 (0.82, 1.18)		-5.2
1 1	2	-0.153	0.148	0.83 (0.82, 1.18)		-2.0
1 1	3	2.037*		0.64 (0.82, 1.18)		-4.5
2 2	0			1.75 (0.82, 1.18)		6.8
2 2	1	-0.271	0.241	1.73 (0.82, 1.18)		6.7
2 2	2	0.271*		1.22 (0.82, 1.18)		2.3
3 3	0			0.99 (0.82, 1.18)		-0.1
3 3	1	-2.304	0.154	1.03 (0.82, 1.18)		0.4
3 3	2	0.692	0.221	0.78 (0.82, 1.18)		-2.6
3 3	3	1.612*		1.29 (0.82, 1.18)		3.0
4 4	0			0.84 (0.82, 1.18)		-1.9
4 4	1	-1.016	0.142	1.04 (0.82, 1.18)		0.4
4 4	2	-0.330	0.148	0.99 (0.82, 1.18)		-0.1
4 4	3	1.345*		1.14 (0.82, 1.18)		1.6
5 5	0			1.41 (0.82, 1.18)		4.1
5 5	1	-1.119	0.157	1.29 (0.82, 1.18)		3.0
5 5	2	0.602	0.271	0.72 (0.82, 1.18)		-3.4
5 5	3	0.516*		### (0.82, 1.18)		727.8
6 6	0			7.47 (0.82, 1.18)		31.8
6 6	1	-2.994	0.175	0.78 (0.82, 1.18)		-2.6
6 6	2	-0.622	0.143	1.16 (0.82, 1.18)		1.7
6 6	3	3.616*		1.20 (0.82, 1.18)		2.1
7 7	0			1.38 (0.82, 1.18)		3.8
7 7	1	-1.789	0.180	1.16 (0.82, 1.18)		1.7
7 7	2	0.428	0.416	0.14 (0.82, 1.18)		-15.9
7 7	3	1.361*		### (0.82, 1.18)		###
8 8	0			0.04 (0.82, 1.18)		-21.7
8 8	1	-2.790	0.159	0.60 (0.82, 1.18)		-5.2
8 8	2	-0.007	0.142	0.92 (0.82, 1.18)		-0.8
8 8	3	2.796*		0.91 (0.82, 1.18)		-1.0
9 9	0			139.30 (0.82, 1.18)		139.2
9 9	1	-1.642	0.167	0.91 (0.82, 1.18)		-1.0
9 9	2	-0.043	0.161	0.80 (0.82, 1.18)		-2.4
9 9	3	1.684*		0.74 (0.82, 1.18)		-3.2

An asterisk next to a parameter estimate indicates that it is constrained						
^ Quick standard errors have been used						
=====						



Generalised-Item Thresholds



=====

Each 'X' represents 1.5 cases

The labels for thresholds show the levels of

item, and step, respectively

Fonctionnement différentiel des items

ConQuest: Generalised Item Response Modelling Software Sun Apr 03 16:45 2011
TABLES OF RESPONSE MODEL PARAMETER ESTIMATES

TERM 1: item

VARIABLES			UNWEIGHTED FIT			WEIGHTED FIT		
item	ESTIMATE	ERROR^	MNSQ	CI	T	MNSQ	CI	T
1 1	1.961	0.125	1.74 (0.82, 1.18)	6.8	1.32 (0.84, 1.16)	3.6		
2 2	-0.266	0.126	0.73 (0.82, 1.18)	-3.3	0.86 (0.83, 1.17)	-1.7		
3 3	1.245	0.128	0.75 (0.82, 1.18)	-3.1	0.96 (0.82, 1.18)	-0.5		
4 4	3.314	0.144	1.05 (0.82, 1.18)	0.6	0.91 (0.74, 1.26)	-0.6		
5 5	-3.393	0.154	0.47 (0.82, 1.18)	-7.3	0.84 (0.65, 1.35)	-0.9		
6 6	-1.895	0.136	0.66 (0.82, 1.18)	-4.3	0.97 (0.77, 1.23)	-0.2		
7 7	-0.966*	0.333	0.49 (0.82, 1.18)	-7.0	0.76 (0.80, 1.20)	-2.6		

An asterisk next to a parameter estimate indicates that it is constrained

Separation Reliability = 0.997

Chi-square test of parameter equality = 1553.58, df = 6, Sig Level = 0.000

^ Quick standard errors have been used

TERM 2: (-)sexe

VARIABLES			UNWEIGHTED FIT			WEIGHTED FIT		
sexe	ESTIMATE	ERROR^	MNSQ	CI	T	MNSQ	CI	T
1 1	-0.666	0.073	0.89 (0.81, 1.19)	-1.1	0.92 (0.80, 1.20)	-0.8		
2 2	0.666*	0.073	0.84 (0.57, 1.43)	-0.7	0.87 (0.57, 1.43)	-0.5		

An asterisk next to a parameter estimate indicates that it is constrained

Separation Reliability Not Applicable

Chi-square test of parameter equality = 83.27, df = 1

^ Quick standard errors have been used

TERM 3: item*sexe

VARIABLES				UNWEIGHTED FIT			WEIGHTED FIT		
item	sexe	ESTIMATE	ERROR^	MNSQ	CI	T	MNSQ	CI	T
1 1	1 1	-0.941	0.125	1.75 (0.81, 1.19)	6.2	1.31 (0.82, 1.18)	3.1		
2 2	1 1	0.104	0.126	0.73 (0.81, 1.19)	-2.9	0.82 (0.82, 1.18)	-2.0		
3 3	1 1	0.529	0.128	0.73 (0.81, 1.19)	-3.0	0.98 (0.79, 1.21)	-0.2		
4 4	1 1	0.411	0.144	1.15 (0.81, 1.19)	1.4	0.96 (0.66, 1.34)	-0.1		
5 5	1 1	0.061	0.154	0.54 (0.81, 1.19)	-5.5	0.82 (0.65, 1.35)	-1.0		
6 6	1 1	0.213	0.136	0.68 (0.81, 1.19)	-3.6	0.94 (0.77, 1.23)	-0.5		
7 7	1 1	-0.377*	0.333	0.48 (0.81, 1.19)	-6.5	0.72 (0.79, 1.21)	-2.9		
1 1	2 2	0.941*	0.125	1.69 (0.57, 1.43)	2.7	1.37 (0.61, 1.39)	1.7		
2 2	2 2	-0.104*	0.126	0.71 (0.57, 1.43)	-1.4	1.07 (0.51, 1.49)	0.4		
3 3	2 2	-0.529*	0.128	0.83 (0.57, 1.43)	-0.8	0.88 (0.66, 1.34)	-0.7		
4 4	2 2	-0.411*	0.144	0.59 (0.57, 1.43)	-2.2	0.81 (0.61, 1.39)	-1.0		
5 5	2 2	-0.061*	0.154	0.13 (0.57, 1.43)	-6.6	1.21 (0.00, 3.28)	0.6		
6 6	2 2	-0.213*	0.136	0.55 (0.57, 1.43)	-2.4	1.41 (0.00, 2.15)	0.8		
7 7	2 2	0.377*	0.333	0.55 (0.57, 1.43)	-2.4	0.99 (0.46, 1.54)	0.1		


An asterisk next to a parameter estimate indicates that it is constrained



Separation Reliability = 0.933

Chi-square test of parameter equality = 85.11, df = 6, Sig Level = 0.000

^ Quick standard errors have been used

Courbes caractéristiques de l’item





9.2. Exercices

	Q1	Q2	Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Total	Total T1	Total T2	T1-T2	Total pair	Total Impair
Sujet 1	1	0	1	0	0	0	0	0	0	0						
Sujet 2	1	0	0	0	0	0	0	0	0	0						
Sujet 3	1	0	1	1	0	1	0	1	0	1						
Sujet 4	1	0	1	1	0	1	0	1	0	1						
Sujet 5	0	0	1	1	0	1	0	1	0	1						
Sujet 6	0	0	1	0	0	1	0	0	0	1						
Sujet 7	0	1	1	1	0	1	1	1	1	0						
Sujet 8	0	0	1	1	0	1	1	1	1	1						
Sujet 9	0	0	0	1	0	1	1	1	1	0						
Sujet 10	0	0	0	0	0	1	1	0	1	1						
Sujet 11	0	0	0	1	1	1	1	1	1	1						
Sujet 12	0	1	0	1	1	1	1	1	1	0						
Sujet 13	0	0	0	1	1	1	1	1	1	1						
Sujet 14	0	0	0	1	1	1	1	1	1	1						
Sujet 15	1	1	1	0	1	1	1	0	1	1						
Sujet 16	0	0	0	1	1	1	1	1	1	1						
Sujet 17	0	1	0	1	1	0	0	1	0	1						
Sujet 18	0	1	0	0	1	0	1	0	1	1						
Sujet 19	0	1	0	1	1	0	1	1	1	1						
Sujet 20	1	1	1	1	1	1	1	1	1	1						
									Moyenne		5,8	2,3	3,5	-1,2	3,25	2,55
									Variance		4,26	1,21	2,25	2,66	1,79	1,25
									Ecart type		2,06	1,1	1,5	1,631	1,34	1,12
pi																
qi																
pi*qi																
											2,19		Somme pi*qi			

Au départ de la matrice de données présentée ci-dessus, calculer :

- l'indice de fidélité selon la méthode du KR20.
- L'erreur standard de mesure sur base de la fidélité estimée en 1.
- l'indice de fidélité selon la méthode du KR21.
- l'indice de fidélité selon la méthode de Rulon.
→ Test 1 : Q1+Q2+Q3+Q4+Q5.
→ Test 2 : Q6+Q7+Q8+Q9+Q10.
- l'indice de fidélité selon la méthode des Items pairs / Items impairs
- l'indice de fidélité pour un test qui comporterait 100 questions.
→ La fidélité initiale correspond à la fidélité estimée à partir de la méthode du KR20.
- la corrélation bisériale de point pour l'item 1.
- la probabilité de réussite corrigée pour l'item 1.
→ Considérer qu'il y a 5 solutions proposées.
- l'alpha de Cronbach